


# Análisis Multivariante



Máster en Técnicas Estadísticas

# Índice general

|                                                                                                                                  |            |
|----------------------------------------------------------------------------------------------------------------------------------|------------|
| <b>Prefacio</b>                                                                                                                  | <b>4</b>   |
| Autores . . . . .                                                                                                                | 4          |
| Prerrequisitos . . . . .                                                                                                         | 5          |
| <b>1. Introducción al análisis multivariante</b>                                                                                 | <b>6</b>   |
| 1.1. Notación de vectores y matrices . . . . .                                                                                   | 7          |
| 1.2. Vectores aleatorios . . . . .                                                                                               | 8          |
| 1.3. Representación de datos multivariantes . . . . .                                                                            | 10         |
| 1.4. Vector de medias y matrices de covarianzas para subconjuntos de variables . . .                                             | 18         |
| 1.5. Distancias estadísticas . . . . .                                                                                           | 21         |
| <b>2. Inferencia en poblaciones normales</b>                                                                                     | <b>25</b>  |
| 2.1. Estimación en la distribución normal multivariante . . . . .                                                                | 26         |
| 2.2. Contrastes multivariantes versus contrastes univariantes . . . . .                                                          | 31         |
| 2.3. Contrastes sobre el vector de medias . . . . .                                                                              | 31         |
| 2.4. Regiones de confianza y comparaciones simultáneas . . . . .                                                                 | 39         |
| 2.5. Generalización del contraste sobre el vector de medias . . . . .                                                            | 43         |
| 2.6. Inferencia sobre la matriz de covarianzas . . . . .                                                                         | 47         |
| 2.7. Generalización del contraste sobre la matriz de covarianzas . . . . .                                                       | 50         |
| 2.8. Comparación de poblaciones normales multivariantes . . . . .                                                                | 58         |
| 2.9. Contrastes de normalidad . . . . .                                                                                          | 64         |
| <b>3. Análisis Multivariante de la Varianza</b>                                                                                  | <b>76</b>  |
| 3.1. Revisión del modelo de análisis de la varianza univariante ANOVA . . . . .                                                  | 76         |
| 3.2. MANOVA con un factor de variación . . . . .                                                                                 | 79         |
| 3.3. MANOVA con dos factores de variación . . . . .                                                                              | 85         |
| <b>4. Análisis de componentes principales</b>                                                                                    | <b>90</b>  |
| 4.1. Descomposición de un vector aleatorio en sus componentes principales . . . . .                                              | 90         |
| 4.2. Propiedades geométricas de las componentes principales . . . . .                                                            | 98         |
| 4.3. Descomposición de la variabilidad, proporción de varianza explicada y criterios<br>para la reducción de dimensión . . . . . | 100        |
| 4.4. Las componentes principales y los cambios de escala . . . . .                                                               | 102        |
| 4.5. Interpretación de las componentes principales . . . . .                                                                     | 102        |
| <b>5. Análisis de correspondencias</b>                                                                                           | <b>104</b> |
| 5.1. Test ji-cuadrado de independencia y distancia ji-cuadrado entre perfiles . . . . .                                          | 105        |
| 5.2. Representación de los perfiles de fila . . . . .                                                                            | 107        |
| 5.3. Representación de los perfiles de columna . . . . .                                                                         | 111        |
| 5.4. Representación simultánea de los perfiles de fila y columna . . . . .                                                       | 113        |

|                                                                  |            |
|------------------------------------------------------------------|------------|
| <b>6. Análisis discriminante</b>                                 | <b>118</b> |
| 6.1. Dos grupos con distribuciones conocidas . . . . .           | 118        |
| 6.2. Criterios para elegir una regla discriminante . . . . .     | 120        |
| 6.3. Estimación de la regla discriminante . . . . .              | 125        |
| 6.4. Varios grupos con distribuciones conocidas . . . . .        | 129        |
| <b>7. Técnicas de formación de grupos</b>                        | <b>131</b> |
| 7.1. Métodos jerárquicos. . . . .                                | 131        |
| 7.2. Métodos de particionamiento. . . . .                        | 133        |
| <b>A. Distribuciones notables multidimensionales</b>             | <b>135</b> |
| A.1. Distribución normal multivariante . . . . .                 | 135        |
| A.2. Distribución de Wishart . . . . .                           | 137        |
| A.3. Distribución $\Gamma^2$ de Hotelling . . . . .              | 143        |
| A.4. Distribución $\Lambda$ de Wilks . . . . .                   | 145        |
| Propiedades de la distribución de Hotelling y de Wilks . . . . . | 146        |
| <b>B. Conceptos básicos de álgebra matricial</b>                 | <b>148</b> |
| B.1. Autovalores . . . . .                                       | 148        |
| B.2. Matrices semidefinidas positivas . . . . .                  | 148        |
| B.3. Matrices definidas positivas . . . . .                      | 149        |
| <b>Bibliografía</b>                                              | <b>150</b> |

# Prefacio

Este documento es el resultado de unificar el material de Análisis Multivariante, materia del Máster en Técnicas Estadísticas organizado por la Universidad de Santiago de Compostela (coordinadora), Universidad de A Coruña y Universidad de Vigo.

En esta materia se pretende que el alumno aprenda las técnicas más importantes en el análisis de datos multidimensionales. Se abordan tanto los aspectos metodológicos como del uso de software que proporcionan los paquetes estadísticos en el campo del análisis multivariante.

En la Bibliografía se incluye una lista de referencias con libros y artículos consultados para la elaboración de este material.

Agradecemos que nos ayudes a mejorar este documento. Si encuentras erratas, errores, o tienes alguna sugerencia para explicar mejor alguna sección, por favor escribe a [beatriz.pateiro@usc.es](mailto:beatriz.pateiro@usc.es).

Última actualización: 24 septiembre, 2026

## Autores

- Beatriz Pateiro López. Departamento de Estadística, Análisis Matemático y Optimización. Universidad de Santiago de Compostela.
- César Sánchez Sello. Departamento de Estadística, Análisis Matemático y Optimización. Universidad de Santiago de Compostela

Con nuestro agradecimiento a Wenceslao González Manteiga, Catedrático de Estadística de la Universidad de Santiago de Compostela (USC) y profesor de la materia de Análisis Multivariante hasta el curso 2017/18.



Esta obra está bajo una Licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional

## Prerrequisitos

A lo largo del documento se incluyen ejemplos de aplicación de los distintos métodos del análisis multivariante presentados. El software estadístico utilizado es R (R Core Team, 2020). Puedes copiar y ejecutar los fragmentos de código de R para tu práctica. Simplemente debes asegurarte de tener instalados algunos paquetes que necesitaremos y que no están incluidos entre los paquetes que instala R por defecto.

```
> # Paquetes utilizados
> packages <- c("aplpack", "car", "moments", "MVN", "mvtnorm", "rgl", "scatterplot3d")
> install.packages(packages)
>
```

Los conjuntos de datos utilizados en los ejemplos se encuentran disponibles en el siguiente enlace: <https://beatrizpateiro.github.io/materials/AM/data.zip>.

# 1. Introducción al análisis multivariante

Son muchas las situaciones reales en las que necesitamos tener en cuenta varias variables de forma simultánea. Podemos pensar en problemas sencillos en todas las disciplinas en los que necesitemos analizar datos de distintas variables o características medidas sobre los individuos de una muestra. En algunas ocasiones puede resultar adecuado estudiar cada una de las variables de interés de forma individual. Sin embargo, en general las variables están relacionadas entre sí de tal manera que los análisis individuales proporcionan poca información sobre la estructura del conjunto de datos.

≡ **Ejemplo.** Un estudio pretende analizar diferentes medidas corporales del gorrión pantanero carileonado (*Ammodramus caudacutus*), una especie de ave que habita en humedales de Norteamérica. Se seleccionan como variables del estudio el sexo, el tamaño de las alas, la longitud del tarso, el tamaño de la cabeza y el peso.

≡ **Ejemplo.** Para llevar a cabo un estudio sobre lateralidad y aprendizaje se realizó un cuestionario a 237 estudiantes de Estadística de la Universidad de Adelaida. Entre las variables recogidas hay variables cualitativas (como el sexo, mano con la que escribe, etc.) y variables cuantitativas (anchura de la mano con la que escribe, anchura de la mano con la que no escribe, etc.).

≡ **Ejemplo.** El conjunto de datos de iris de Fisher's es un conjunto de datos clásico que recoge la medida en cm. de las variables longitud y anchura de sépalo y longitud y anchura de pétalo para flores de tres especies diferentes de iris (iris setosa, versicolor y virginica).

Se puede definir el **análisis multivariante** como el conjunto de métodos estadísticos que permiten analizar datos que surgen cuando se miden distintas variables en cada uno de los individuos de una o varias muestras. Los avances en informática y en el procesamiento de grandes bancos de datos ha favorecido el desarrollo del análisis multivariante en muchas disciplinas. Si bien tradicionalmente el análisis multivariante se aplicaba fundamentalmente en Biología, en la actualidad son muchos los campos de aplicación. Las técnicas de análisis multivariante incluyen tanto métodos puramente descriptivos que tienen por objetivo extraer información de los datos disponibles, como métodos de inferencia que, a través de la construcción de modelos, pretenden obtener conclusiones sobre la población que ha generado los datos. A continuación describimos algunos de los métodos de análisis multivariante que podemos llevar a cabo cuando disponemos de medidas de un conjunto de variables.

- Contrastar la hipótesis de que las medias de las variables analizadas tienen un valor específico (inferencia sobre la media en poblaciones multivariantes).
- Contrastar la hipótesis de que las variables son incorreladas y tienen varianza común (inferencia sobre la matriz de covarianzas).
- Representar la información mediante un número menor de variables construidas como combinaciones lineales de las originales y que expliquen la mayor parte de la variabilidad original (análisis de componentes principales).

- Encontrar un modelo que nos permita predecir un grupo de variables del conjunto original a partir de otro grupo de variables (modelos de regresión multivariante).
- Comparar las medias de las variables en dos poblaciones (test de Hotelling).
- Comparar las medias de las variables en más de dos poblaciones (MANOVA).
- Si los individuos pertenecen a diferentes grupos, encontrar la combinación lineal de las variables que mejor separe dichos grupos (análisis discriminante).
- Clasificar a un conjunto de observaciones en grupos homogéneos (técnicas de formación de grupos).

## 1.1. Notación de vectores y matrices

Como hemos comentado, la información de partida en análisis multivariante es un conjunto de datos correspondiente a distintas variables medidas en los elementos de una muestra. Las observaciones correspondientes a cada individuo vendrán dadas por un vector y el conjunto de observaciones de la muestra por una matriz. Por lo tanto, la manipulación de datos multivariantes se simplificará mucho utilizando conceptos de matrices y sus propiedades.

Representamos el vector<sup>1</sup>  $\mathbf{x} \in \mathbb{R}^d$  como el vector columna  $d \times 1$ .

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{pmatrix}.$$

El vector  $d \times 1$  con todas sus componentes iguales a uno se denotará como  $\mathbf{1}_d$ . Representamos la matriz  $\mathbf{A} = (a_{ij})$  de tamaño  $m \times n$  como

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}.$$

La traspuesta de  $\mathbf{A}$  se denota  $\mathbf{A}'$ . Si  $\mathbf{A}$  es una matriz cuadrada, su determinante se denota  $|\mathbf{A}|$  y su traza  $\text{tr}(\mathbf{A})$ . Si  $\mathbf{A}$  es no singular ( $|\mathbf{A}| \neq 0$ ), su inversa se denota como  $\mathbf{A}^{-1}$ . La matriz  $n \times n$  con elementos  $d_1, \dots, d_n$  en la diagonal y ceros fuera de ella se denota  $\text{diag}(d_1, \dots, d_n)$ . La matriz identidad  $n \times n$  se denota  $\mathbf{I}_n$ . En el Anexo B encontrarás algunos de los resultados fundamentales de álgebra lineal, que nos servirán de ayuda en los próximos capítulos.

<sup>1</sup>Como es habitual en la literatura de análisis multivariante y para evitar confusión entre escalares, vectores y matrices, denotaremos los vectores con letras minúsculas en negrita y las matrices con letras mayúsculas en negrita. Según esta notación, tanto variables aleatorias como sus valores observados se representarán mediante letras minúsculas.

## 1.2. Vectores aleatorios

Un vector aleatorio  $d$ -dimensional  $\mathbf{x} \in \mathbb{R}^d$  es una colección de variables aleatorias  $\mathbf{x} = (x_1, \dots, x_d)'$  medidas simultáneamente sobre el mismo individuo.

**Ejemplo.** En el estudio del gorrión pantanero carileonado (*Ammodramus caudacutus*), podemos considerar el vector aleatorio 5-dimensional  $\mathbf{x} = (x_1, \dots, x_5)'$ , siendo:

- $x_1$ = Sexo.
- $x_2$ = Tamaño del ala.
- $x_3$ = Longitud del tarso.
- $x_4$ = Tamaño de cabeza.
- $x_5$ = Peso.

Cada una de las componentes de un vector aleatorio es una variable aleatoria y, por lo tanto, se puede calcular su media, su varianza y su distribución. Sin embargo, hay algunas propiedades conjuntas, como son la covarianza o la distribución conjunta que reflejan la relación entre las variables que forman el vector. Las medidas más importantes de las distribuciones de probabilidad de vectores aleatorios son el vector de medias  $\boldsymbol{\mu}$  y la matriz de covarianzas  $\boldsymbol{\Sigma}$ .

Dado un vector aleatorio  $d$ -dimensional  $\mathbf{x} \in \mathbb{R}^d$ , se define el vector de medias como

$$\boldsymbol{\mu} = E(\mathbf{x}) = \begin{pmatrix} E(x_1) \\ \vdots \\ E(x_d) \end{pmatrix}.$$

Es decir, el vector de medias  $\boldsymbol{\mu}$  es el vector cuyas componentes son las esperanzas, o medias, de las componentes del vector aleatorio.

La generalización de la varianza unidimensional al contexto multivariante nos lleva a la definición de matriz de covarianzas. Dado un vector aleatorio  $\mathbf{x} \in \mathbb{R}^d$  con vector de medias  $\boldsymbol{\mu}$ , se define la matriz de covarianzas  $\boldsymbol{\Sigma}$  como

$$\boldsymbol{\Sigma} = E((\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})').$$

Así definida, la matriz de covarianzas  $\boldsymbol{\Sigma}$  es una matriz de dimensión  $d \times d$ , simétrica y semidefinida positiva. Podemos comprobar que además los elementos de la diagonal son las varianzas de cada una de las componentes del vector aleatorio y en cada entrada  $(j, k)$  se tiene la covarianza entre las variables  $x_j$  y  $x_k$ ,

$$\text{Cov}(x_j, x_k) = \sigma_{jk} = E((x_j - E(x_j))(x_k - E(x_k))).$$

Fíjate que

$$\text{Cov}(x_j, x_j) = \sigma_{jj} = E((x_j - E(x_j))^2)$$

representa la varianza de la variable  $x_j$ , que denotaremos también como  $\sigma_j^2$ . En resumen,

$$\Sigma = \begin{pmatrix} \text{Var}(x_1) & \text{Cov}(x_1, x_2) & \dots & \text{Cov}(x_1, x_d) \\ \text{Cov}(x_2, x_1) & \text{Var}(x_2) & \dots & \text{Cov}(x_2, x_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(x_d, x_1) & \text{Cov}(x_d, x_2) & \dots & \text{Var}(x_d) \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1d} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \dots & \sigma_d^2 \end{pmatrix}.$$

Puedes también demostrar como ejercicio que  $\Sigma$  puede ser expresada como

$$\Sigma = E(xx') - \mu\mu'.$$

Es difícil comparar covarianzas entre pares de variables ya que estas dependen de la escala de medida. Para obtener una medida de la relación lineal entre pares de variables que sea invariante ante cambios de escala podemos estandarizar la covarianza dividiendo por el producto de desviaciones típicas de las variables involucradas. Esta covarianza estandarizada es lo que se denomina correlación. Así, la correlación entre las variables  $x_i$  y  $x_j$  se calcula como

$$\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}.$$

La matriz de correlaciones será por lo tanto

$$\rho = \begin{pmatrix} 1 & \rho_{12} & \dots & \rho_{1d} \\ \rho_{21} & 1 & \dots & \rho_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{d1} & \rho_{d2} & \dots & 1 \end{pmatrix}.$$

Se verifica

$$\rho = D_{\Sigma}^{-1} \Sigma D_{\Sigma}^{-1}$$

siendo  $D_{\Sigma}$  la matriz diagonal de orden  $d$  construida colocando en la diagonal principal las desviaciones típicas de las variables, es decir,  $D_{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_d)$ . Equivalentemente,

$$\Sigma = D_{\Sigma} \rho D_{\Sigma}.$$

### 1.3. Representación de datos multivariantes

En el contexto multivariante es conveniente representar las variables aleatorias (o sus valores) en forma matricial. Supongamos que hemos observado  $d$  variables en un conjunto de  $n$  elementos. Cada una de estas  $d$  variables es una variable univariante y el conjunto de las  $d$  variables constituye un vector aleatorio. Los valores del vector aleatorio en cada uno de los  $n$  elementos pueden representarse mediante una matriz de datos  $\mathbf{X}$  de tamaño  $n \times d$  de manera que  $\mathbf{X} = (x_{ij})$ , donde el índice  $i = 1, \dots, n$  representa el individuo y el índice  $j = 1, \dots, d$  representa la variable. Es decir, cada fila de la matriz representa el valor del vector aleatorio (formado por las  $d$  variables) sobre el individuo  $i$ .

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix} = \begin{pmatrix} x'_1 \\ x'_2 \\ \vdots \\ x'_n \end{pmatrix}.$$

**Ejemplo.** Se analizaron las variables del estudio del gorrión pantanero carileonado en una muestra de 979 gorrones de dicha especie.

Los datos se encuentran recogidos en el fichero `gorrion.txt` y se pueden leer en R como se muestra a continuación.

```
> gorrion <- read.table("data/gorrion.txt", header = TRUE)
> gorrion
      Sex Wingcrd Tarsus Head  Wt
1   Male   58.0   21.7 32.7 20.3
2 Female   56.5   21.1 31.4 17.4
3   Male   59.0   21.0 33.3 21.0
4   Male   59.0   21.3 32.5 21.0
...
```

El conjunto de datos se puede representar mediante una matriz de 979 filas (número de individuos en la muestra) y 5 columnas (número de variables).

```
> class(gorrion)
[1] "data.frame"
> dim(gorrion)
[1] 979 5
```

El objeto utilizado en R para almacenar datos de este tipo es un `data.frame`. Podremos editar los datos fácilmente utilizando el comando `fix` o `edit`.

A continuación se muestra parte de uno de los muchos conjuntos de datos multivariantes que puedes encontrar en R. Se trata del conjunto de datos `survey` (librería MASS).

**Ejemplo.** El conjunto de datos `survey` (librería MASS) corresponde a un cuestionario que se realizó a 237 estudiantes de Estadística de la Universidad de Adelaida. Entre las variables

recogidas hay variables cualitativas (como el sexo, mano con la que escribe, etc.) y variables cuantitativas (anchura de la mano con la que escribe, anchura de la mano con la que no escribe, etc.) Puedes consultar más información sobre este conjunto de datos escribiendo `help(survey)` en la consola de comandos.

```
> library(MASS)
> data(survey)
> survey
```

|     | Sex    | Wr.Hnd | NW.Hnd | W.Hnd | Fold    | Pulse | Clap    | Exer | Smoke | Height | M.I      |
|-----|--------|--------|--------|-------|---------|-------|---------|------|-------|--------|----------|
| 1   | Female | 18.5   | 18.0   | Right | R on L  | 92    | Left    | Some | Never | 173.00 | Metric   |
| 2   | Male   | 19.5   | 20.5   | Left  | R on L  | 104   | Left    | None | Regul | 177.80 | Imperial |
| 3   | Male   | 18.0   | 13.3   | Right | L on R  | 87    | Neither | None | Occas | NA     | <NA>     |
| 4   | Male   | 18.8   | 18.9   | Right | R on L  | NA    | Neither | None | Never | 160.00 | Metric   |
| 5   | Male   | 20.0   | 20.0   | Right | Neither | 35    | Right   | Some | Never | 165.00 | Metric   |
| 6   | Female | 18.0   | 17.7   | Right | L on R  | 64    | Right   | Some | Never | 172.72 | Imperial |
| 7   | Male   | 17.7   | 17.7   | Right | L on R  | 83    | Right   | Freq | Never | 182.88 | Imperial |
| 8   | Female | 17.0   | 17.3   | Right | R on L  | 74    | Right   | Freq | Never | 157.00 | Metric   |
| 9   | Male   | 20.0   | 19.5   | Right | R on L  | 72    | Right   | Some | Never | 175.00 | Metric   |
| ... |        |        |        |       |         |       |         |      |       |        |          |

### 1.3.1. Visualización de datos multivariantes

Uno de los problemas con que nos encontramos a la hora de establecer métodos gráficos para describir datos multivariantes es nuestro propio sistema de percepción visual. Los gráficos de dispersión en dos dimensiones son fáciles de entender. Somos también capaces de interpretar gráficos de dispersión en tres dimensiones. Sin embargo, cuando la dimensión es mayor necesitamos otros procedimientos para visualizar los datos.

**Ejemplo.** Diagrama de dispersión para los datos de tamaño del ala (Wingcrd), longitud de tarso (Tarsus) y tamaño de la cabeza (Head) de gorrión. La función `scatterplot3d` de la librería `scatterplot3d` R permite hacer un gráfico como el que se muestra en la Figura 1.1

```
> library(scatterplot3d)
> scatterplot3d(gorrión[, 2:4], color = 4, main = "Diagrama de dispersión 3D.")
```

También se pueden crear diagramas de dispersión en 3D interactivos usando la función `plot3d` de la librería `rgl`, como se indica a continuación:

```
> library(rgl)
> plot3d(gorrión[, 2:4], col = 4)
```

Una forma de representar datos multivariantes es mediante **matrices de diagramas de dispersión**. Se construye una cuadrícula con tantas filas y columnas como variables. En cada casilla se representa el diagrama de dispersión de las variables de la fila y columna correspondientes. Este gráfico informa por lo tanto de cómo son las relaciones entre variables, pero sólo dos a dos. En la Figura 1.2 se muestran matrices de diagramas de dispersión para los datos de gorrión.




Figura 1.1.: Diagrama de dispersión 3D.

**Ejemplo.** Matrices de diagramas de dispersión para los datos de gorrión. La función `pairs` de R permite hacer un gráfico como el que se muestra en la izquierda.

La función `scatterplotMatrix` de la librería `car` permite además añadir en la diagonal los histogramas, boxplots, estimadores de la densidad, etc. de las variables del conjunto de datos. También permite añadir en cada gráfico el ajuste de regresión lineal o no paramétrico para cada par de variables. Consulta la ayuda de la función para obtener más información.

```
> pairs(gorrión[, 2:5])
> library(car)
> scatterplotMatrix(gorrión[, 2:5], diagonal = list(method = "histogram", breaks = "FD"),
+                   smooth = FALSE, regLine = TRUE)
```




Figura 1.2.: Matrices de diagramas de dispersión para los datos de gorrión.

Cuando en un conjunto de datos tenemos diferentes variables categóricas, puede ser interesante visualizar las relaciones entre pares de variables teniendo en cuenta los distintos factores de las

variables categóricas. Podemos en este caso representar **gráficos de dispersión condicionales** como el que se muestra en la Figura 1.3 para los datos survey.

**Ejemplo.** Gráfico de dispersión condicional para los datos survey. La función `coplot` nos permite visualizar la relación entre el ancho de la mano con la que se escribe (variable `Wr.Hnd`) y el ancho de la mano con la que no se escribe (variable `NW.Hnd`), en función del sexo (variable `Sex`) y de la lateralidad (variable `W.Hnd`) del individuo.

```
> coplot(Wr.Hnd ~ NW.Hnd | Sex * W.Hnd, data = na.omit(survey))
```




Figura 1.3.: Gráfico de dispersión condicional para los datos de lateralidad.

Otra herramienta utilizada para representar datos multivariantes son los **gráficos de estrellas**. Cada individuo se representa en una estrella, con tantos rayos o ejes como variables queramos representar. Cada eje representa el valor de la variable re-escalada de manera independiente entre variables. Se muestra en la Figura 1.4 el gráfico de estrellas para los datos de iris. A la vista de los gráficos de estrella podemos identificar perfectamente las diferentes especies de iris, representadas a su vez con distintos colores. Como conclusión, parece que las medidas consideradas (longitud y anchura de pétalo y sépalo) nos servirían para distinguir unas especies de otras.

**Ejemplo.** Gráfico de estrellas para los datos iris obtenido con la función `stars` de R. Cada estrella representa una flor.

```
> data(iris)
> stars(iris[, 1:4], col.stars = iris$Species, key.loc = c(20, 1))
```

También es común representar datos multivariantes mediante **gráficos de caras de Chernoff**. El gráfico de caras de Chernoff es como un gráfico de estrellas, pero cada individuo ahora se representa en una cara y las variables en los rasgos físicos (altura y anchura de la cara, forma de la cara, altura y anchura de la boca, curva de la sonrisa, altura y anchura de ojos, ...). En la




Figura 1.4.: Gráfico de estrellas para los datos de iris.

Figura 1.5 se representa el gráfico de caras de Chernoff para un subconjunto de los datos de iris.

**Ejemplo.** Gráficos de caras de Chernoff para un subconjunto de los datos iris obtenido con la función `faces` de la librería `aplpack` de R. Cada cara representa una flor. Elegimos 4 flores de cada una de las especies (setosa, versicolor, virginica).

```
> library(aplpack)
> faces(iris[c(1:4, 51:54, 101:104), 1:4], face.type = 0)
effect of variables:
modified item      Var
"height of face"   "Sepal.Length"
"width of face"    "Sepal.Width"
"structure of face" "Petal.Length"
"height of mouth"  "Petal.Width"
"width of mouth"   "Sepal.Length"
"smiling"          "Sepal.Width"
"height of eyes"   "Petal.Length"
"width of eyes"    "Petal.Width"
"height of hair"   "Sepal.Length"
"width of hair"    "Sepal.Width"
"style of hair"    "Petal.Length"
"height of nose"   "Petal.Width"
"width of nose"    "Sepal.Length"
"width of ear"     "Sepal.Width"
"height of ear"    "Petal.Length"
```

### 1.3.2. Vector de medias y matriz de covarianzas muestrales

Supongamos que disponemos de una muestra aleatoria  $x_1, \dots, x_n$  de un vector aleatorio en  $\mathbb{R}^d$  con media  $\mu$  y matriz de covarianzas  $\Sigma$ . De forma análoga al caso univariante, calcularemos el




Figura 1.5.: Gráfico de caras de Chernoff para un subconjunto de los datos de iris.

vector de medias muestral como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} X' \mathbf{1}_n.$$

Recuerda que, según la notación establecida,  $x_i = (x_{i1}, \dots, x_{id})'$  y  $X$  es la matriz de datos.

**Ejemplo.** Trabajaremos ahora con variables numéricas del estudio del gorrión pantanero carileonado.

```
> gmed <- gorrión[, 2:5]
> gmed
      Wingcrd Tarsus Head  Wt
1      58.0   21.7 32.7 20.3
2      56.5   21.1 31.4 17.4
3      59.0   21.0 33.3 21.0
4      59.0   21.3 32.5 21.0
...
```

Calculamos el vector de medias muestral a partir de la matriz de observaciones. Podemos hacerlo de varias maneras. A través de la función `summary`.

```
> summary(gmed)
      Wingcrd      Tarsus      Head      Wt
Min.   :52.00  Min.   :18.90  Min.   :29.20  Min.   :15.60
1st Qu.:56.00  1st Qu.:20.90  1st Qu.:31.50  1st Qu.:19.20
Median :58.00  Median :21.40  Median :31.90  Median :20.20
Mean   :57.87  Mean   :21.48  Mean   :32.04  Mean   :20.23
3rd Qu.:59.00  3rd Qu.:21.90  3rd Qu.:32.40  3rd Qu.:21.10
Max.   :68.00  Max.   :25.40  Max.   :35.70  Max.   :26.50
```

A través de la función `apply`.

```
> apply(gmed, 2, mean)
      Wingcrd      Tarsus      Head      Wt
57.86599  21.47620  32.03790  20.22646
```

A través de la matriz de observaciones.

```
> n <- dim(gmed)[1]
> un <- matrix(1, nr = n, nc = 1)
> t(gmed) %*% un/n
      [,1]
Wingcrd 57.86599
Tarsus  21.47620
Head    32.03790
Wt       20.22646
```

La matriz de covarianzas  $\Sigma$  se estimará mediante

$$\mathbf{S} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})'$$

La matriz de covarianzas muestral  $\mathbf{S}$  es una matriz cuadrada y simétrica que contiene en la diagonal las varianzas muestrales y fuera de la diagonal las covarianzas muestrales entre los distintos pares de variables. Es decir

$$\mathbf{S} = \begin{pmatrix} s_1^2 & s_{12} & \dots & s_{1d} \\ s_{21} & s_2^2 & \dots & s_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ s_{d1} & s_{d2} & \dots & s_d^2 \end{pmatrix},$$

siendo

$$s_{jk} = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$

Las varianzas muestrales  $s_{jj}$  se denotan  $s_j^2$ . La matriz de correlaciones muestral  $\mathbf{R}$  se obtendrá dividiendo las covarianzas muestrales por las desviaciones típicas de cada par de variables. Es decir,

$$\mathbf{R} = \begin{pmatrix} 1 & r_{12} & \dots & r_{1d} \\ r_{21} & 1 & \dots & r_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ r_{d1} & r_{d2} & \dots & 1 \end{pmatrix},$$

siendo

$$r_{jk} = \frac{s_{jk}}{s_j s_k}.$$

De forma análoga al caso poblacional,

$$\mathbf{R} = \mathbf{D}_S^{-1} \mathbf{S} \mathbf{D}_S^{-1}$$

siendo ahora  $D_S = \text{diag}(s_1, \dots, s_d)$ , es decir, la matriz diagonal de orden  $d$  construida colocando en la diagonal principal las desviaciones típicas muestrales de las variables. Equivalentemente,

$$S = D_S R D_S.$$

**Ejemplo.** Volvemos al conjunto de datos de iris. Calculamos, para la especie setosa, el vector de medias muestral, la matriz de covarianzas muestral y la matriz de correlaciones muestral. Debemos tener en cuenta que R calcula la matriz de covarianzas muestral corregida

$$\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})'.$$

```
> setosa <- iris[iris$Species == "setosa", 1:4]
> colMeans(setosa)
Sepal.Length Sepal.Width Petal.Length Petal.Width
      5.006      3.428      1.462      0.246
> cov(setosa) # Matriz de covarianzas muestral corregida
      Sepal.Length Sepal.Width Petal.Length Petal.Width
Sepal.Length  0.12424898 0.099216327 0.016355102 0.010330612
Sepal.Width   0.09921633 0.143689796 0.011697959 0.009297959
Petal.Length  0.01635510 0.011697959 0.030159184 0.006069388
Petal.Width   0.01033061 0.009297959 0.006069388 0.011106122
> cor(setosa)
      Sepal.Length Sepal.Width Petal.Length Petal.Width
Sepal.Length  1.0000000  0.7425467  0.2671758  0.2780984
Sepal.Width   0.7425467  1.0000000  0.1777000  0.2327520
Petal.Length  0.2671758  0.1777000  1.0000000  0.3316300
Petal.Width   0.2780984  0.2327520  0.3316300  1.0000000
```

Comprobamos que la matriz de correlaciones muestral también se puede calcular como  $R = D_S^{-1} S D_S^{-1}$ .

```
> desviaciones <- apply(setosa, 2, sd)
> Dinv <- solve(diag(desviaciones))
> Dinv %*% cov(setosa) %*% Dinv
      [,1] [,2] [,3] [,4]
[1,] 1.0000000 0.7425467 0.2671758 0.2780984
[2,] 0.7425467 1.0000000 0.1777000 0.2327520
[3,] 0.2671758 0.1777000 1.0000000 0.3316300
[4,] 0.2780984 0.2327520 0.3316300 1.0000000
```

Algunos de los resultados que veremos irán encaminados a la obtención de la distribución de  $\bar{x}$  y  $S$  en este contexto multidimensional y bajo la hipótesis de normalidad.

## 1.4. Vector de medias y matrices de covarianzas para subconjuntos de variables

En algunas ocasiones podemos estar interesados en dos o más subconjuntos de variables medidas sobre las mismas unidades muestrales.

**Ejemplo.** Un estudio sobre diabetes analiza diferentes variables de interés sobre pacientes que no presentan la enfermedad. Las variables de mayor relevancia para el estudio son:

- $x_1$  = Intolerancia a la glucosa
- $x_2$  = Respuesta de la insulina a la glucosa oral
- $x_3$  = Resistencia de la insulina

Se recogen igualmente otras dos variables de menor relevancia:

- $y_1$  = Peso relativo
- $y_2$  = Glucemia basal

Supongamos, como en el ejemplo anterior, que tenemos dividido el vector aleatorio original en dos subvectores  $\mathbf{y}$  y  $\mathbf{x}$  con  $p$  y  $q$  variables, respectivamente. Tendremos entonces:

$$E \begin{pmatrix} \mathbf{y} \\ \mathbf{x} \end{pmatrix} = \begin{pmatrix} E(\mathbf{y}) \\ E(\mathbf{x}) \end{pmatrix} = \begin{pmatrix} \boldsymbol{\mu}_y \\ \boldsymbol{\mu}_x \end{pmatrix}$$

y

$$\text{Cov} \begin{pmatrix} \mathbf{y} \\ \mathbf{x} \end{pmatrix} = \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{yy} & \boldsymbol{\Sigma}_{yx} \\ \boldsymbol{\Sigma}_{xy} & \boldsymbol{\Sigma}_{xx} \end{pmatrix}.$$

En las expresiones anteriores  $\begin{pmatrix} \mathbf{y} \\ \mathbf{x} \end{pmatrix}$  denota el vector original de  $p + q$  variables. La submatriz  $\boldsymbol{\Sigma}_{yy}$  es la matriz de covarianzas  $p \times p$  del subvector  $\mathbf{y}$ . Del mismo modo, la submatriz  $\boldsymbol{\Sigma}_{xx}$  es la matriz de covarianzas  $q \times q$  del subvector  $\mathbf{x}$ . La submatriz  $\boldsymbol{\Sigma}_{yx}$  es una matriz  $p \times q$  con las covarianzas de cada variable  $y_j$  con  $x_k$ . Nótese que  $\boldsymbol{\Sigma}_{xy} = \boldsymbol{\Sigma}'_{yx}$ .

Estas propiedades a nivel poblacional se trasladan directamente al vector de medias y matriz de covarianzas muestrales. Cada observación en la muestra se podrá particionar de la siguiente manera:

$$\begin{pmatrix} \mathbf{y}_i \\ \mathbf{x}_i \end{pmatrix} = \begin{pmatrix} y_{i1} \\ \vdots \\ y_{ip} \\ x_{i1} \\ \vdots \\ x_{iq} \end{pmatrix}, \quad i = 1, \dots, n.$$

Para la muestra de  $n$  observaciones, el vector de medias muestral y la matriz de covarianzas muestrales tendrán el siguiente aspecto:

$$\begin{pmatrix} \bar{y} \\ \bar{x} \end{pmatrix} = \begin{pmatrix} \bar{y}_1 \\ \vdots \\ \bar{y}_p \\ \bar{x}_1 \\ \vdots \\ \bar{x}_q \end{pmatrix}, \quad S = \begin{pmatrix} S_{yy} & S_{yx} \\ S_{xy} & S_{xx} \end{pmatrix}.$$

Lo visto hasta ahora se puede generalizar de forma natural al caso en que tengamos el vector original dividido en más de dos subvectores.

 **Ejemplo.** Los datos del estudio sobre diabetes se encuentran en el fichero `diabetes.txt`.

```
> diab <- read.table("data/diabetes.txt", header = TRUE)
> head(diab)
  y1 y2 x1 x2 x3
1 0.81 80 356 124 55
2 0.95 97 289 117 76
3 0.94 105 319 143 105
4 1.04 90 356 199 108
5 1.00 90 323 240 143
6 0.76 86 381 157 165
> colMeans(diab)
  y1 y2 x1 x2 x3
0.9178261 90.4130435 340.8260870 171.3695652 97.7826087
> cov(diab)
  y1 y2 x1 x2 x3
y1 0.01618184 0.216029 0.7871691 -0.2138454 2.189072
y2 0.21602899 70.558937 26.2289855 -23.9560386 -20.841546
x1 0.78716908 26.228986 1106.4135266 396.7323671 108.383575
x2 -0.21384541 -23.956039 396.7323671 2381.8826087 1142.637681
x3 2.18907246 -20.841546 108.3835749 1142.6376812 2136.396135
```

### 1.4.1. Combinaciones lineales de variables

Con frecuencia estamos interesados en combinaciones lineales de las variables de estudio  $x_1, \dots, x_d$ . Sean  $a_1, \dots, a_d$  constantes y consideremos la combinación lineal

$$z = a_1x_1 + \dots + a_dx_d = \mathbf{a}'\mathbf{x},$$

donde  $\mathbf{a} = (a_1, \dots, a_d)'$ . Para la combinación lineal  $z = \mathbf{a}'\mathbf{x}$  se tiene que  $E(z) = \mathbf{a}'E(\mathbf{x})$  y  $\text{Var}(z) = \mathbf{a}'\Sigma\mathbf{a}$ .

De forma más general, si consideramos  $k$  combinaciones lineales

$$z = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_k \end{pmatrix} = \begin{pmatrix} a_{11}x_1 + \dots + a_{1d}x_d \\ a_{21}x_1 + \dots + a_{2d}x_d \\ \vdots \\ a_{k1}x_1 + \dots + a_{kd}x_d \end{pmatrix} = \begin{pmatrix} a'_1x \\ a'_2x \\ \vdots \\ a'_kx \end{pmatrix} = Ax,$$

entonces  $E(z) = AE(x)$  y  $\Sigma_z = A\Sigma A'$ . Para la transformación más general  $z = Ax + b$ , se tiene  $E(z) = AE(x) + b$  y  $\Sigma_z = A\Sigma A'$ .

Consideremos ahora el análogo muestral. Si aplicamos la transformación a todos los elementos de la muestra, es decir, si hacemos  $z_i = Ax_i + b$  para  $i = 1, \dots, n$ , entonces  $\bar{z} = A\bar{x} + b$  y  $S_z = ASA'$ .

**Ejemplo.** Para el ejemplo del estudio sobre diabetes consideramos las siguientes transformaciones lineales:

- $z_1 = x_1 + 2x_2 - x_3$
- $z_2 = y_1 + 4y_2$

En primer lugar calculamos  $\bar{z}_1$ ,  $\bar{z}_2$ ,  $s_{z_1}^2$ ,  $s_{z_2}^2$  y  $s_{z_1z_2}$  a partir de los datos transformados

```
> attach(diab)
> z1 <- x1 + 2 * x2 - x3
> z2 <- y1 + 4 * y2
> mean(z1)
[1] 585.7826
> mean(z2)
[1] 362.57
> var(z1)
[1] 9569.952
> var(z2)
[1] 1130.687
> cov(z1, z2)
[1] -5.195778
```

De otro modo, podemos escribir

$$z = \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 1 & 2 & -3 \\ 1 & 4 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix} = A \begin{pmatrix} y_1 \\ y_2 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix}.$$

Teniendo en cuenta las propiedades de las transformaciones lineales discutidas anteriormente, se tiene también:

```

> A <- rbind(c(0, 0, 1, 2, -1), c(1, 4, 0, 0, 0))
> A %*% colMeans(diab)
      [,1]
[1,] 585.7826
[2,] 362.5700
> A %*% cov(diab) %*% t(A)
      [,1]      [,2]
[1,] 9569.951691 -5.195778
[2,] -5.195778 1130.687409

```

## 1.5. Distancias estadísticas

El concepto de distancia entre objetos o individuos observados permite interpretar geométricamente muchas técnicas de análisis multivariante. En el caso unidimensional, la distancia entre dos puntos  $x$  e  $y$  se mide de manera natural mediante la distancia euclídea  $|x - y|$ .

Cuando disponemos de una variable vectorial, cada dato es un punto en  $\mathbb{R}^d$  y podríamos entonces pensar en utilizar de nuevo la distancia euclídea en el contexto multidimensional. A partir de ahora sean  $\mathbf{x}_i = (x_{i1}, \dots, x_{id})'$  y  $\mathbf{x}_k = (x_{k1}, \dots, x_{kd})'$  las observaciones de dos individuos  $i, k$  obtenidas al medir el vector  $d$ -dimensional  $(x_1, \dots, x_d)'$ .

### 1.5.1. Distancia euclídea

Se define la distancia euclídea entre  $\mathbf{x}_i$  y  $\mathbf{x}_k$  como

$$d_E(\mathbf{x}_i, \mathbf{x}_k) = \sqrt{\sum_{j=1}^d (x_{ij} - x_{kj})^2}.$$

La distancia euclídea es la más utilizada pero tiene como inconvenientes que depende de las unidades de medida de las variables (no es invariante ante cambios de escala) y presupone que las variables son incorrelacionadas y de varianza unidad.

**Ejemplo.** Supongamos que disponemos de los datos de peso y estatura de 300 mujeres con edades comprendidas entre 30 y 40 años. Queremos determinar la posición con respecto a la media de tres nuevas mujeres a partir de sus respectivos pesos y estaturas. Supongamos que la mujer  $A$  pesa 63 kg. y mide 180 cm. La mujer  $B$  pesa 60 kg. y mide 177 cm. La mujer  $C$  pesa 70 kg. y mide 177 cm. Los datos se muestran en la Figura 1.6

Si bien parece evidente que la posición de las tres mujeres con respecto a la media es diferente (la mujer  $C$  parece más “cercana” a la media que la  $A$  y la  $B$ ), la distancia euclídea de todos los puntos a la media es la misma.




Figura 1.6.: Peso (en kg.) y estatura (en cm.) de 300 mujeres con edades comprendidas entre 30 y 40 años. En rojo se representa el peso medio y la estatura media. En azul, datos de las mujeres A, B y C.

### 1.5.2. Distancia euclídea estandarizada por columnas

Una manera de evitar el problema de que la distancia dependa de las unidades de medida de las variables, consiste en dividir cada variable por un término que elimine el efecto de la escala.

Se define la distancia euclídea estandarizada por columnas entre  $x_i$  y  $x_k$  como

$$d_{Est}(x_i, x_k) = \sqrt{\sum_{j=1}^d \left( \frac{x_{ij} - x_{kj}}{\sigma_j} \right)^2}.$$

Su utilidad radica en que es una forma de determinar la similitud entre dos variables aleatorias multidimensionales invariante ante cambios de escala. Puede verse como una distancia euclídea donde cada coordenada se pondera inversamente proporcional a la varianza.

Tiene como inconvenientes que presupone que las variables son incorrelacionadas.

**Ejemplo.** En el ejemplo anterior de los datos de peso y estatura de 300 mujeres, la distancia euclídea estandarizada por columnas de la mujer A a la media es mayor que la distancia euclídea estandarizada por columnas de las mujeres B y C a la media. Aun así, la distancia euclídea estandarizada por columnas de las mujeres B y C a la media es la misma.

### 1.5.3. Distancia de Mahalanobis

Se define la distancia de Mahalanobis entre  $x_i$  y  $x_k$  como

$$d_M(x_i, x_k) = \sqrt{(x_i - x_k)' \Sigma^{-1} (x_i - x_k)}.$$

Geométricamente equivale a girar la nube de puntos hasta eliminar las correlaciones y luego calcular la distancia para los datos estandarizados. Es adecuada como medida de discrepancia entre datos, porque es invariante ante cambios de escala y tiene en cuenta las correlaciones entre las variables.

Además,

- $d_M \equiv d_E$  cuando  $\Sigma = I_d$ .
- $d_M \equiv d_{Est}$  cuando  $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_d^2)$ .

En caso de que la matriz de covarianzas sea desconocida se calcula

$$d_M(x_i, x_k) = \sqrt{(x_i - x_k)' S^{-1} (x_i - x_k)}.$$

**Ejemplo.** En el ejemplo anterior de los datos de peso y estatura de 300 mujeres, la distancia de Mahalanobis de la mujer A a la media es mayor que la distancia de Mahalanobis de la mujer B a la media, que a su vez es mayor que la distancia de Mahalanobis de la mujer C a la media.

#### 1.5.4. Estandarización

Una transformación lineal que tiene un interés especial es la **estandarización**. La estandarización (o tipificación) de una variable aleatoria se consigue restando la media y dividiendo por la desviación típica (raíz cuadrada de la varianza). De esta manera se consigue que la nueva variable transformada tenga media cero y varianza uno.

En el caso de un vector aleatorio de dimensión  $d$ , con  $d$  mayor que uno, podemos pensar en estandarizar cada una de sus variables. Como resultado de esta **estandarización univariante** se obtiene un vector cuyas componentes tienen todas media cero y desviación típica uno. Sin embargo, puede haber correlación entre las variables que componen el vector.

**Ejemplo.** En la Figura 1.7 se muestran dos diagramas de dispersión para los datos de peso y estatura de mujeres. El primero de ellos representa los datos tras haber estandarizado de manera univariante las dos variables. Esto hace que se hayan contraído los ejes. Se mantiene la correlación positiva, aunque la orientación de la nube de puntos ahora es más próxima a la diagonal, pues ambas variables tienen la misma dispersión.

El segundo gráfico muestra el diagrama de dispersión de los datos tras haberles aplicado una estandarización bivalente.

La estandarización multivariante se obtiene así:

$$y = \Sigma^{-1/2}(x - \mu)$$

donde  $\mu$  denota el vector de medias,  $\Sigma$  es la matriz de covarianzas y  $\Sigma^{-1/2}$  es una matriz  $d \times d$  que definiremos más adelante. Por las propiedades vistas en la sección anterior, se puede comprobar que:




Figura 1.7.: Estandarización univariante y multivariante

- El vector estandarizado tiene media cero:

$$E(\mathbf{y}) = E(\Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu})) = \Sigma^{-1/2}E(\mathbf{x} - \boldsymbol{\mu}) = \mathbf{0}.$$

- La matriz de covarianzas de  $\mathbf{y}$  es la matriz identidad  $d \times d$ ,  $\mathbf{I}_d$ :

$$\text{Cov}(\mathbf{y}, \mathbf{y}) = \text{Cov}(\Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu}), \Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu})) = \Sigma^{-1/2} \text{Cov}(\mathbf{x}, \mathbf{x}) (\Sigma^{-1/2})' \stackrel{(a)}{=} \mathbf{I}_d.$$

Para obtener la matriz  $\Sigma^{-1/2}$ , de manera que se cumpla la igualdad (a) en el cálculo anterior de la matriz de covarianzas, tendremos presente que toda matriz de covarianzas es una matriz simétrica y semidefinida positiva. Así, se le puede aplicar la descomposición en autovalores y autovectores, que vemos a continuación.

Si  $\mathbf{A}$  es una matriz simétrica, entonces

$$\mathbf{A} = (\mathbf{v}_1, \dots, \mathbf{v}_d) \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_d \end{pmatrix} \begin{pmatrix} \mathbf{v}'_1 \\ \vdots \\ \mathbf{v}'_d \end{pmatrix}$$

siendo  $\mathbf{v}_1, \dots, \mathbf{v}_d$  una base ortonormal de autovectores de  $\mathbf{A}$  y  $\lambda_1, \dots, \lambda_d$  sus autovalores asociados.  $\mathbf{A}$  se dice definida positiva si todos los autovalores de  $\mathbf{A}$  son positivos. En ese caso se puede emplear para definir una norma (y una distancia):  $\|\mathbf{x}\|^2 = \mathbf{x}' \mathbf{A} \mathbf{x}$ .

Entonces, se puede obtener  $\Sigma^{-1/2}$  a partir de los autovalores y autovectores de  $\Sigma$ , de la siguiente manera:

$$\Sigma^{-1/2} = (\mathbf{v}_1, \dots, \mathbf{v}_d) \begin{pmatrix} 1/\sqrt{\lambda_1} & & 0 \\ & \ddots & \\ 0 & & 1/\sqrt{\lambda_d} \end{pmatrix} \begin{pmatrix} \mathbf{v}'_1 \\ \vdots \\ \mathbf{v}'_d \end{pmatrix}.$$

## 2. Inferencia en poblaciones normales

Muchos de los métodos de contrastes de hipótesis y construcción de intervalos de confianza en el contexto unidimensional asumen que la distribución de los datos es normal univariante. De la misma manera, la mayor parte de los procedimientos multivariantes están basados en la distribución normal multivariante. Una de las principales ventajas de la distribución normal multivariante es que puede ser descrita totalmente utilizando únicamente su vector de medias y matriz de covarianzas. Además, las combinaciones lineales de normales siguen siendo normales e, incluso cuando los datos no provienen exactamente de una distribución normal, ésta puede servir como una buena aproximación (especialmente al hacer inferencia que involucre el vector de medias muestrales, que será aproximadamente normal multivariante por el Teorema Central del Límite).

Revisaremos en la primera parte de este capítulo la definición de distribución normal multivariante junto con algunas de sus propiedades. En el resto del tema veremos tareas de inferencia sobre el vector de medias y la matriz de covarianzas de una población normal multivariante, en base a una muestra aleatoria simple extraída de ella. También se tratarán problemas que involucren a varias poblaciones. Muchos procedimientos resultarán ser extensiones naturales de los métodos ya conocidos para poblaciones normales univariantes, mientras que en algún caso surgirán problemas nuevos, por ejemplo, comparación entre componentes del vector de medias o cuestiones de inferencia simultánea; en definitiva, situaciones provocadas por la dimensión múltiple.

Aunque el vector de medias muestral y la matriz de covarianzas muestral son estimadores naturales de sus análogos poblacionales, también vamos a ver que son los estimadores de máxima verosimilitud, y de paso, introducimos la función de verosimilitud y en general la idea de verosimilitud, que será empleada en varias ocasiones a lo largo de este tema.

Por otro lado, al estudiar los procedimientos naturales de inferencia sobre el vector de medias y la matriz de covarianzas, veremos que la suposición de normalidad en la distribución del vector de variables observadas es esencial en muchos de ellos. Por ejemplo, la forma elíptica de las regiones de confianza es consustancial a la forma de la distribución normal multivariante. Si la forma en que se presentaran las observaciones en el espacio no fuera elíptica, tampoco lo debería ser una región de confianza para el vector de medias. La última parte del tema está dedicada a métodos de contraste de normalidad en observaciones multivariantes. Existen varios procedimientos para evaluar si un conjunto de datos proviene de una población normal multivariante. Una primera posibilidad sería evaluar si cada una de las variables es normal univariante. Como hemos comentado, la normalidad multivariante implica la normalidad de distribuciones marginales unidimensionales. Por lo tanto, si alguna de las variables no es normal univariante, el vector no será normal multivariante. Tiene sentido entonces hacer un estudio inicial sobre las variables de forma individual. En la Sección 2.9 repasaremos en primer lugar los métodos de contraste de la normalidad en el caso univariante, prestando especial atención a los métodos susceptibles de ser extendidos al caso multivariante. De todos modos,

los contrastes de normalidad univariante no serán en general suficientes, ya que la existencia de normalidad univariante de todas las variables no garantiza la normalidad multivariante de los datos. A continuación se abordan algunos métodos (los más representativos) para el contraste de normalidad multivariante. Están basados en la extensión de las medidas de asimetría, kurtosis, así como del test de Shapiro-Wilk al caso multivariante.

## 2.1. Estimación en la distribución normal multivariante

### 2.1.1. La distribución normal multivariante

Recordamos que si una variable aleatoria  $x$  unidimensional, con media  $\mu$  y varianza  $\sigma^2$  tiene distribución normal, entonces su función de densidad viene dada por

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty.$$

Decimos en este caso que  $x$  tiene distribución  $N(\mu, \sigma^2)$ . Puedes ver la representación de la función de densidad de distintas variables normales en la Figura 2.1.




Figura 2.1.: Representación de la densidad de variables normales.

Si el vector aleatorio  $d$ -dimensional  $\mathbf{x}$  tiene distribución normal multivariante con vector de medias  $\boldsymbol{\mu}$  y matriz de covarianzas  $\boldsymbol{\Sigma}$ , entonces su función de densidad viene dada por

$$f(\mathbf{x}) = \frac{1}{(\sqrt{2\pi})^d |\boldsymbol{\Sigma}|^{1/2}} e^{-\frac{(\mathbf{x}-\boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}{2}}.$$

Decimos en este caso que  $\mathbf{x}$  tiene distribución  $N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ . En la Figura 2.2 se representan las funciones de densidad de distintas variables normales bivariantes. En el Anexo A encontrarás propiedades importantes de esta distribución.




Figura 2.2.: Densidad de vectores aleatorios con distribución normal bivalente. A la izquierda  $N(\mathbf{0}, \mathbf{I}_2)$ . A la derecha  $N(\mathbf{0}, \Sigma)$  con  $\sigma_1^2 = 1$ ,  $\sigma_2^2 = 3$  y  $\sigma_{12} = 1,5$ .

Fíjate que en la densidad multivariante,  $|\Sigma|^{1/2}$  juega el papel de  $\sqrt{\sigma^2}$  en el caso unidimensional. Decimos que  $|\Sigma|$  es la *varianza poblacional generalizada*. En efecto, el determinante  $|\Sigma|$  nos sirve como una medida de variabilidad total. Dado un vector aleatorio  $\mathbf{x}$  con media  $\mu$  y matriz de covarianzas  $\Sigma$ , un valor pequeño de  $|\Sigma|$  indica que  $\mathbf{x}$  está concentrado cerca de  $\mu$  o que existe multicolinealidad entre las variables. Si recordamos que el determinante de una matriz es el producto de sus autovalores, podemos concebir el determinante como una medida de si una matriz de covarianzas es grande o pequeña. Por ejemplo, si existe multicolinealidad, uno o más autovalores de  $\Sigma$  será próximo a cero y en consecuencia,  $|\Sigma|$  será pequeño.

Podemos representar una matriz de covarianzas  $2 \times 2$  mediante una elipse cuyos ejes principales siguen la dirección de sus autovectores. Cada radio de la elipse es la raíz cuadrada de un autovalor de la matriz de covarianzas, ver Figura 2.3 (izquierda). Entonces, si denotamos por  $\lambda_1$  y  $\lambda_2$  a los autovalores de  $\Sigma$ ,

$$\text{Area del rectángulo circunscrito en la elipse} = 4 \cdot \sqrt{\lambda_1} \sqrt{\lambda_2} = 4\sqrt{|\Sigma|}.$$

En la última igualdad hemos usado que el determinante es el producto de los autovalores. En la Figura 2.3 (derecha) se representan las elipses correspondientes a distintas matrices de covarianzas. Para esta representación hemos utilizado la función `ellipse` de la librería `car`. En general, si la dimensión del espacio es  $d$ , se tendrá que

$$\text{Volumen del rectángulo circunscrito en el elipsoide} = 2^d \sqrt{|\Sigma|}.$$

Empleamos los términos volumen y elipsoide, pues son los que corresponden en el espacio de dimensión tres. En espacios de dimensión superior, que no son representables, se suele emplear igualmente esos términos. Por tanto, el determinante es una forma de medir el volumen o capacidad de un rectángulo ( $d = 2$ ), caja ( $d = 3$ ), ortoedro en general, que contenga al grueso del vector.




Figura 2.3.: Izquierda, representación de la elipse correspondiente a una matriz de covarianzas  $2 \times 2$  con autovectores  $v_1, v_2$  y autovalores  $\lambda_1, \lambda_2$ . Cada radio de la elipse es la raíz cuadrada de un autovalor de la matriz de covarianzas. Derecha, representación de las elipses correspondientes a matrices de covarianzas  $\Sigma_1 = I_2$  (rojo),  $\Sigma_2 = \text{diag}(3, 1)$  (verde) y  $\Sigma_3 = (\sigma_{ij})$  con  $\sigma_{11} = 3, \sigma_{22} = 1, \sigma_{12} = 1,4$  (azul).

### 2.1.2. Estimadores de máxima verosimilitud

Consideremos disponible una muestra aleatoria simple  $x_1, \dots, x_n \in N_d(\mu, \Sigma)$  de vectores aleatorios independientes y con la misma distribución normal multivariante. Vamos a obtener los estimadores de máxima verosimilitud para el vector de medias  $\mu$  y para la matriz de covarianzas  $\Sigma$ . La función de verosimilitud sería:

$$L(x, \mu, \Sigma) = (2\pi)^{-nd/2} |\Sigma|^{-n/2} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (x_i - \mu)' \Sigma^{-1} (x_i - \mu) \right\}.$$

Observamos que

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu)' \Sigma^{-1} (x_i - \mu) &= \sum_{i=1}^n \left[ (x_i - \bar{x})' \Sigma^{-1} (x_i - \bar{x}) \right. \\ &\quad \left. + (\bar{x} - \mu)' \Sigma^{-1} (\bar{x} - \mu) + 2(\bar{x} - \mu)' \Sigma^{-1} (x_i - \bar{x}) \right], \\ &= \sum_{i=1}^n (x_i - \bar{x})' \Sigma^{-1} (x_i - \bar{x}) + n(\bar{x} - \mu)' \Sigma^{-1} (\bar{x} - \mu) \end{aligned}$$

ya que la suma de los dobles productos vale cero. Entonces la log-verosimilitud se puede expresar así:

$$\begin{aligned}
\log L(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \\
&= c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) \\
&\quad - \frac{n}{2} (\bar{\mathbf{x}} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu})
\end{aligned}$$

siendo  $c = -\frac{nd}{2} \log(2\pi)$ .

Observamos que, por ser  $\boldsymbol{\Sigma}$  definida positiva, (y en consecuencia, también lo será su inversa  $\boldsymbol{\Sigma}^{-1}$ ), se tiene  $(\bar{\mathbf{x}} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}) > 0$ , salvo que  $\boldsymbol{\mu} = \bar{\mathbf{x}}$ , en cuyo caso vale cero. Por tanto, la función de log-verosimilitud alcanza su máximo en  $\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}$ , que de este modo se convierte en el estimador de máxima verosimilitud del vector de medias. Además,

$$\sup_{\boldsymbol{\mu}} \log L(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) \quad (2.1)$$

para cualquier matriz de covarianzas  $\boldsymbol{\Sigma}$ .

A continuación calcularemos el máximo de aquella función respecto de  $\boldsymbol{\Sigma}$ . Podemos expresar

$$\begin{aligned}
\sup_{\boldsymbol{\mu}} \log L(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \text{traza} \left[ \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) \right] \\
&= c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n \text{traza} \left[ (\mathbf{x}_i - \bar{\mathbf{x}})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) \right] \\
&= c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n \text{traza} \left[ \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})' \right] \\
&= c - \frac{n}{2} \left( \log |\boldsymbol{\Sigma}| + \text{traza} \left( \boldsymbol{\Sigma}^{-1} \mathbf{S} \right) \right)
\end{aligned}$$

donde hemos aplicado que  $\text{traza}(\mathbf{A} + \mathbf{B}) = \text{traza}(\mathbf{A}) + \text{traza}(\mathbf{B})$  y que  $\text{traza}(\mathbf{AB}) = \text{traza}(\mathbf{BA})$ . Ahora debemos obtener el máximo de esta función respecto del argumento  $\boldsymbol{\Sigma}$ . Para ello, apelamos al resultado siguiente, del cual omitimos su demostración.

**Lema 2.1.** *Supongamos una matriz  $\mathbf{A}$  definida positiva. La función*

$$f(\boldsymbol{\Sigma}) = \log |\boldsymbol{\Sigma}| + \text{traza} \left( \boldsymbol{\Sigma}^{-1} \mathbf{A} \right),$$

*restringida a las matrices  $\boldsymbol{\Sigma}$  definidas positivas, alcanza su mínimo en  $\boldsymbol{\Sigma} = \mathbf{A}$ .*

Entonces, aplicando este lema llegamos a la conclusión de que los estimadores de máxima verosimilitud del vector de medias y la matriz de covarianzas (sin restricciones) son  $\bar{\mathbf{x}}$  y  $\mathbf{S}$ , respectivamente. Asimismo, la función de verosimilitud tiene como máximo:

$$\begin{aligned}\sup_{\Sigma} \sup_{\mu} \log L(\mathbf{x}, \mu, \Sigma) &= c - \frac{n}{2} \left( \log |\mathbf{S}| + \text{traza} \left( \mathbf{S}^{-1} \mathbf{S} \right) \right) \\ &= c - \frac{n}{2} (\log |\mathbf{S}| + d).\end{aligned}$$

### 2.1.3. Distribución de $\bar{\mathbf{x}}$ y $\mathbf{S}$

Sea entonces  $\mathbf{x}_1, \dots, \mathbf{x}_n$  una muestra aleatoria simple de  $N_d(\mu, \Sigma)$ . En el apartado anterior hemos visto que los estimadores de máxima verosimilitud de  $\mu$  y  $\Sigma$  son  $\bar{\mathbf{x}}$  y  $\mathbf{S}$ , respectivamente. Se verifica que:

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \in N_d \left( \mu, \frac{1}{n} \Sigma \right).$$

Se puede ver este resultado como una generalización del caso unidimensional. Recuerda que si  $x_1, \dots, x_n$  es una muestra aleatoria simple de  $N(\mu, \sigma^2)$ , entonces  $\bar{x} \in N(\mu, \sigma^2/n)$ . Además en el caso unidimensional se demostraba también que  $ns^2/\sigma^2 = \sum_{i=1}^n (x_i - \bar{x})^2/\sigma^2 \in \chi_{n-1}^2$ , es decir, tiene distribución ji-cuadrado con  $n-1$  grados de libertad<sup>1</sup>. Una forma de generalizar la suma de cuadrados anterior al caso multivariante sería considerar

$$n\mathbf{S} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'$$

Fíjate que  $n\mathbf{S}$  es una matriz aleatoria  $d \times d$  y por tanto su distribución ya no podrá ser ji-cuadrado como en el caso unidimensional. Decimos que  $n\mathbf{S}$  sigue una distribución de Wishart<sup>2</sup> con parámetros  $\Sigma$  y  $n-1$  y denotamos:

$$n\mathbf{S} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})' \in W_d(\Sigma, n-1).$$

En el Anexo A puedes encontrar un resumen de las principales propiedades de la distribución de Wishart.

<sup>1</sup>La distribución ji-cuadrado se define formalmente como la suma de los cuadrados de variables normales estándar, es decir si  $x_1, \dots, x_n$  son  $N(\mu, \sigma^2)$  independientes, entonces  $\sum_{i=1}^n (x_i - \mu)^2/\sigma^2 \in \chi_n^2$ .

<sup>2</sup>La distribución de Wishart es el análogo multivariante de la distribución ji-cuadrado y se define formalmente a partir de normales multivariantes estándar. Si  $\mathbf{x}_1, \dots, \mathbf{x}_n$  son  $N_d(\mu, \Sigma)$  independientes, entonces

$$\sum_{i=1}^n (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)' \in W_d(\Sigma, n).$$

Cuando sustituimos  $\mu$  por  $\bar{\mathbf{x}}$ , la distribución de Wishart pierde un grado de libertad.

## 2.2. Contrastes multivariantes versus contrastes univariantes

Antes de presentar resultados sobre contrastes multivariantes deberíamos discutir brevemente cual es la motivación para plantear contrastes multivariantes en lugar de (o junto con) contrastes univariantes. Consideremos como ejemplo un contraste acerca del vector de medias  $\mu = (\mu_1, \dots, \mu_d)'$ .

**Ejemplo.** Un estudio sobre Psicología educativa pretende analizar si las notas medias obtenidas por estudiantes universitarios en dos tests de inteligencia diferentes fueron iguales a 100. El primer test está orientado fundamentalmente a la valoración de habilidades aritméticas y el segundo a la valoración de habilidades de memoria.

Denotaremos por  $x = (x_1, x_2)'$  el vector aleatorio bidimensional correspondiente a las notas de los dos tests. Parece claro que las medidas de habilidad analizadas estarán interrelacionadas y, por lo tanto, es más natural contrastar si la media  $\mu = (\mu_1, \mu_2)'$  del vector  $x$  es igual a  $\mu_0 = (100, 100)'$  que contrastar de forma individual si la nota media de cada uno de los tests  $\mu_i$  es igual a 100. Es decir, nos gustaría contrastar la hipótesis nula  $H_0 : \mu = \mu_0$ , siendo  $\mu_0 = (100, 100)'$ .

Además de que los contrastes univariantes ignoran la correlación entre variables, lo cual en muchas ocasiones no es deseable (como se comenta en el ejemplo anterior), existen otros motivos por los que puede ser más conveniente plantear contrastes multivariantes. El uso de contrastes univariantes tiende a *inflar* el error de tipo I, que denotamos por  $\alpha$ . Volvemos al ejemplo sobre los tests de inteligencia. Si para contrastar la hipótesis nula  $H_0 : \mu = \mu_0$  planteamos dos contrastes individuales de nivel  $\alpha = 0,05$ , entonces está claro que rechazaremos  $H_0$  si rechazamos al menos uno de los dos contrastes individuales. Pero bajo  $H_0$  (suponiendo que las variables fuesen independientes),

$$\begin{aligned} P(\text{al menos un rechazo individual}) &= 1 - P(\text{ningún rechazo individual}) \\ &= 1 - (1 - 0,05)^2 \\ &= 0,0975. \end{aligned}$$

Es decir, al plantear el problema a través de contrastes individuales aumentamos la probabilidad del error de tipo I. Este inconveniente se hace más patente al aumentar la dimensión  $d$ . Además los test multivariantes resultan en muchos casos más potentes (capaces de rechazar  $H_0$  cuando es falsa).

## 2.3. Contrastes sobre el vector de medias

A continuación veremos cómo se puede usar el test de razón de verosimilitudes para hacer inferencia en poblaciones normales multivariantes. En esta sección ilustraremos el caso del problema de inferencia sobre el vector de medias cuando la matriz de covarianzas es conocida, y también cuando es desconocida.

### 2.3.1. Contraste sobre el vector de medias con matriz de covarianzas conocida

En este apartado veremos como llevar a cabo un contraste sobre el vector de medias de una población normal asumiendo que la matriz de covarianzas  $\Sigma$  es conocida. Antes, repasaremos la teoría en el caso unidimensional.

#### 2.3.1.1. Revisión del caso unidimensional $H_0 : \mu = \mu_0$ con $\sigma^2$ conocida

La hipótesis de interés es que la media  $\mu$  de una variable aleatoria  $x$  es igual a un valor dado  $\mu_0$  frente a la alternativa de que no es igual a  $\mu_0$ , es decir

$$H_0 : \mu = \mu_0 \text{ frente a } H_1 : \mu \neq \mu_0.$$

Dada una muestra  $x_1, \dots, x_n$  de normales  $N(\mu, \sigma^2)$  con  $\sigma^2$  conocida, se calcula la media muestral  $\bar{x}$  y se compara con  $\mu_0$  a través del estadístico

$$z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$$

que, bajo la hipótesis nula, se distribuye como una normal estándar. Por lo tanto, para un nivel de significación  $\alpha = 0,05$  rechazamos la hipótesis nula si  $|z| \geq 1,96$ . Equivalentemente

$$z^2 = n(\bar{x} - \mu_0)^2 \frac{1}{\sigma^2}$$

y podríamos utilizar que  $z^2$  se distribuye, bajo la hipótesis nula, como una ji-cuadrado con un grado de libertad. Entonces rechazaríamos  $H_0$  si  $z^2 \geq 3,84$ .

#### 2.3.1.2. Contraste multivariante $H_0 : \mu = \mu_0$ con $\Sigma$ conocida

Partimos ahora de una muestra aleatoria simple  $x_1, \dots, x_n \in N_d(\mu, \Sigma)$  de vectores aleatorios independientes y con la misma distribución normal multivariante.

Suponiendo que la matriz de covarianzas  $\Sigma$  es conocida, deseamos llevar a cabo tareas de inferencia relativas al vector de medias  $\mu$ . En concreto, podemos estar interesados en una región de confianza para  $\mu$ , o podemos querer contrastar una hipótesis nula del tipo  $H_0 : \mu = \mu_0$ .

Centrándonos en el contraste de la hipótesis nula  $H_0 : \mu = \mu_0$ , vamos a abordar este problema mediante el procedimiento de razón de verosimilitudes. En esta situación, el estadístico de contraste sería:

$$-2 \log \lambda(x) = -2 \log \frac{L(x, \mu_0, \Sigma)}{\sup_{\mu} L(x, \mu, \Sigma)}$$

donde la función de verosimilitud es la que se ha tratado en la sección anterior.

De lo allí expuesto extraemos que, bajo la hipótesis nula,  $H_0 : \mu = \mu_0$ , la función de log-verosimilitud adopta la forma:

$$\log L(\mathbf{x}, \boldsymbol{\mu}_0, \boldsymbol{\Sigma}) = c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) - \frac{n}{2} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$$

mientras que bajo la alternativa, aplicando la expresión (2.1), se tiene

$$\sup_{\boldsymbol{\mu}} \log L(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = c - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}).$$

En definitiva, el estadístico de contraste resulta:

$$-2 \log \lambda(\mathbf{x}) = -2 \log \frac{L(\mathbf{x}, \boldsymbol{\mu}_0, \boldsymbol{\Sigma})}{\sup_{\boldsymbol{\mu}} L(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma})} = n (\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0).$$

Observamos que si  $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$  es cierta,

$$\bar{\mathbf{x}} \in N_d(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}/n)$$

y, en consecuencia,

$$n (\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) \in \chi_d^2.$$

Así, rechazaremos la hipótesis nula  $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$  cuando

$$n (\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) > \chi_{d,\alpha}^2$$

siendo  $\chi_{d,\alpha}^2$  el cuantil  $1 - \alpha$  de la distribución  $\chi_d^2$ . La región de rechazo se corresponde con el exterior de un elipsoide en  $\mathbb{R}^d$ .

**Ejemplo.** Volvemos al estudio sobre Psicología educativa. Se le han realizado los dos tests de inteligencia a 20 alumnos de un centro universitario. La nota media obtenida por los 20 alumnos en el test de valoración de habilidades aritméticas fue de 102 puntos. La nota media en el test de habilidades de memoria fue de 98 puntos. Asumamos además que las notas obtenidas provienen de una distribución normal bivalente  $N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  siendo

$$\boldsymbol{\Sigma} = \begin{pmatrix} 49 & 35 \\ 35 & 52 \end{pmatrix}.$$

Queremos contrastar si las notas medias de estudiantes universitarios en los dos tests de inteligencia son iguales a 100. Es decir, queremos contrastar la hipótesis nula  $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ , siendo  $\boldsymbol{\mu}_0 = (100, 100)'$ .

A partir de la muestra obtenemos que  $\bar{\mathbf{x}} = (\bar{x}_1, \bar{x}_2)' = (102, 98)'$ . Calculamos el valor del estadístico para el contraste multivariante.

$$n (\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) = 20 (2, -2) \begin{pmatrix} 49 & 35 \\ 35 & 52 \end{pmatrix}^{-1} \begin{pmatrix} 2 \\ -2 \end{pmatrix} = 10,34014.$$

```
> Sigma <- matrix(c(49, 35, 35, 52), nrow = 2)
> xbar <- c(102, 98)
> mu0 <- c(100, 100)
> estad <- 20 * (xbar - mu0) %*% solve(Sigma) %*% (xbar - mu0)
> estad
      [,1]
[1,] 10.34014
```

Rechazamos la hipótesis nula (para un nivel de significación  $\alpha = 0,05$ ) ya que el valor del estadístico es mayor que  $\chi^2_{d,\alpha} = 5,991465$ . También podemos calcular el  $p$ -valor del estadístico y razonar a partir de él (como el  $p$ -valor es menor que  $\alpha = 0,05$  se rechaza  $H_0$  para dicho nivel de significación).

```
> alpha <- 0.05
> qchisq(1 - alpha, 2)
[1] 5.991465
> pvalue <- 1 - pchisq(estad, 2)
> pvalue
      [,1]
[1,] 0.005684182
```

Sin embargo, si planteamos los contrastes individuales  $H_0 : \mu_1 = 100$  y  $H_0 : \mu_2 = 100$  se tiene que

$$\frac{\bar{x}_1 - \mu_0}{\sigma_1 / \sqrt{n}} = \frac{102 - 100}{\sqrt{49/20}} = 1,2777$$

y

$$\frac{\bar{x}_2 - \mu_0}{\sigma_2 / \sqrt{n}} = \frac{98 - 100}{\sqrt{52/20}} = -1,24034.$$

En ambos casos, el valor absoluto del estadístico es menor que 1.96 y por lo tanto no se rechazaría la hipótesis nula para ninguno de los dos contrastes individuales. En la Figura 2.4 se representan las zonas de rechazo y no rechazo para los contrastes univariantes y para el contraste bivalente correspondiente a los datos de este ejemplo ( $n = 20$ ). Si  $\bar{x}$  pertenece a la zona verde, no se rechaza la hipótesis nula  $H_0 : \mu = \mu_0$  siendo  $\mu_0 = (100, 100)'$ . Si  $\bar{x}$  pertenece a la zona azul, no se rechaza ni  $H_0 : \mu_1 = 100$  ni  $H_0 : \mu_2 = 100$ . Fíjate que el punto  $\bar{x} = (\bar{x}_1, \bar{x}_2)' = (102, 98)'$  está fuera de la elipse que representa la zona de no rechazo del test multivariante y sin embargo, cae en la zona de no rechazo de los dos contrastes univariantes.

### 2.3.2. Contraste sobre el vector de medias con matriz de covarianzas desconocida

Veremos ahora como llevar a cabo un contraste sobre el vector de medias de una población normal asumiendo que la matriz de covarianzas  $\Sigma$  es desconocida. Repasaremos de nuevo en primer lugar la teoría en el caso unidimensional.




Figura 2.4.: Zonas de rechazo y no rechazo para los contrastes univariantes y para el contraste bivalente correspondiente a los datos de tests de inteligencia ( $n = 20$ ). Si  $\bar{x}$  pertenece a la zona verde, no se rechaza la hipótesis nula  $H_0 : \mu = \mu_0$  siendo  $\mu_0 = (100, 100)'$ . Si  $\bar{x}$  pertenece a la zona azul, no se rechaza ni  $H_0 : \mu_1 = 100$  ni  $H_0 : \mu_2 = 100$ .

### 2.3.2.1. Revisión del caso unidimensional $H_0 : \mu = \mu_0$ con $\sigma^2$ desconocida

La hipótesis de interés es que la media  $\mu$  de una variable aleatoria  $x$  es igual a un valor dado  $\mu_0$  frente a la alternativa de que no es igual a  $\mu_0$ , es decir

$$H_0 : \mu = \mu_0 \text{ frente a } H_1 : \mu \neq \mu_0.$$

Dada una muestra  $x_1, \dots, x_n$  de normales  $N(\mu, \sigma^2)$  con  $\sigma^2$  desconocida, se calcula la media muestral  $\bar{x}$  y se compara con  $\mu_0$  a través del estadístico

$$t = \frac{\bar{x} - \mu_0}{s_c / \sqrt{n}}$$

siendo  $s_c = \sum_{i=1}^n (x_i - \bar{x})^2 / (n - 1)$  la cuasivarianza muestral. Bajo la hipótesis nula, el estadístico se distribuye como una  $t$  de Student con  $n - 1$  grados de libertad. Por lo tanto, para un nivel de significación  $\alpha$  rechazamos la hipótesis nula si  $|t| \geq t_{\alpha/2}$ , siendo  $t_{\alpha/2}$  el cuantil  $1 - \alpha/2$  de la distribución  $t$  de Student con  $n - 1$  grados de libertad. Equivalentemente

$$t^2 = n(\bar{x} - \mu_0) \frac{1}{s_c^2} (\bar{x} - \mu_0). \quad (2.2)$$

Veremos que esta forma de escribir el estadístico estará relacionada con la versión multivariante del contraste.

### 2.3.2.2. Contraste multivariante $H_0 : \mu = \mu_0$ con $\Sigma$ desconocida

Disponemos ahora de una muestra aleatoria simple  $x_1, \dots, x_n \in N_d(\mu, \Sigma)$  y deseamos realizar tareas de inferencia relativas al vector de medias  $\mu$ . Suponemos que la matriz de covarianzas  $\Sigma$  es desconocida.

El estadístico de razón de verosimilitudes para el contraste de la hipótesis nula  $H_0 : \mu = \mu_0$  sería:

$$-2 \log \lambda(x) = -2 \log \frac{\sup_{\Sigma} L(x, \mu_0, \Sigma)}{\sup_{\mu, \Sigma} L(x, \mu, \Sigma)}.$$

Nótese que ahora, al ser  $\Sigma$  desconocida, se convierte en un parámetro tanto bajo la hipótesis nula como bajo la alternativa, parámetro que será estimado por máxima verosimilitud.

Bajo la alternativa, hemos visto en la sección anterior que los estimadores de máxima verosimilitud del vector de medias y la matriz de covarianzas (sin restricciones) son  $\bar{x}$  y  $S$ , respectivamente. Asimismo, la función de verosimilitud tiene como máximo:

$$\sup_{\Sigma} \sup_{\mu} \log L(x, \mu, \Sigma) = c - \frac{n}{2} \left( \log |S| + \text{traza} \left( S^{-1} S \right) \right) = c - \frac{n}{2} (\log |S| + d).$$

A continuación maximizamos la verosimilitud bajo la hipótesis nula. Para ello basta con expresar la verosimilitud en una forma similar a la anterior:

$$\begin{aligned} \log L(x, \mu_0, \Sigma) &= c - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{traza} \left[ \sum_{i=1}^n (x_i - \mu_0)' \Sigma^{-1} (x_i - \mu_0) \right] \\ &= c - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^n \text{traza} \left[ \Sigma^{-1} (x_i - \mu_0) (x_i - \mu_0)' \right] \\ &= c - \frac{n}{2} \left( \log |\Sigma| + \text{traza} \left( \Sigma^{-1} \hat{\Sigma}_{\mu_0} \right) \right) \end{aligned}$$

siendo  $\hat{\Sigma}_{\mu_0} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0) (x_i - \mu_0)'$ , el cual resulta ser un estimador razonable de la matriz de covarianzas bajo la hipótesis de que la media vale  $\mu_0$ . Por lo demás los pasos son idénticos al caso anterior, salvo que se ha puesto  $\mu_0$  allí donde se hallaba  $\bar{x}$ . Aplicando de nuevo el lema, concluimos que  $\hat{\Sigma}_{\mu_0}$  es el estimador de máxima verosimilitud de la matriz de covarianzas bajo la hipótesis nula, y que la función de verosimilitud bajo dicha hipótesis alcanza el valor máximo:

$$\sup_{\Sigma} \log L(x, \mu_0, \Sigma) = c - \frac{n}{2} (\log |\hat{\Sigma}_{\mu_0}| + d).$$

Entonces el estadístico de contraste mediante la razón de verosimilitudes resulta:

$$-2 \log \lambda(x) = -2 \log \frac{\sup_{\Sigma} L(x, \mu_0, \Sigma)}{\sup_{\mu, \Sigma} L(x, \mu, \Sigma)} = n (\log |\hat{\Sigma}_{\mu_0}| - \log |S|).$$

Descomponemos

$$\begin{aligned}\hat{\Sigma}_{\mu_0} &= \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0) (x_i - \mu_0)' \\ &= \frac{1}{n} \sum_{i=1}^n [(x_i - \bar{x}) (x_i - \bar{x})' + (\bar{x} - \mu_0) (\bar{x} - \mu_0)' + 2 (\bar{x} - \mu_0) (x_i - \bar{x})'] \\ &= S + r r'\end{aligned}$$

siendo  $r = \bar{x} - \mu_0$ . Sustituyendo en el estadístico de contraste obtenemos

$$\begin{aligned}-2 \log \lambda(x) &= n (\log |S + r r'| - \log |S|) \\ &= n \left( \log \left( |S| \cdot |I_d + S^{-1} r r'| \right) - \log |S| \right) \\ &= n \log |I_d + S^{-1} r r'|.\end{aligned}$$

Estudiemos, pues, el determinante que aparece en el último término. En (a) denotamos mediante  $\lambda_1, \dots, \lambda_d$  a los autovalores de  $S^{-1} r r'$ , y observamos que  $1 + \lambda_1, \dots, 1 + \lambda_d$  son los autovalores de  $I_d + S^{-1} r r'$ . En (b) y (c) usamos que la matriz  $S^{-1} r r'$  es de rango uno.

$$\begin{aligned}|I_d + S^{-1} r r'| &\stackrel{(a)}{=} \prod_{j=1}^d (1 + \lambda_j) \\ &\stackrel{(b)}{=} 1 + \lambda_1 \\ &\stackrel{(c)}{=} 1 + \text{traza} (S^{-1} r r') \\ &= 1 + \text{traza} (r' S^{-1} r) \\ &= 1 + r' S^{-1} r.\end{aligned}$$

Finalmente,

$$-2 \log \lambda(x) = n \log (1 + r' S^{-1} r)$$

será el estadístico de contraste y rechazaremos la hipótesis nula si este estadístico toma un valor demasiado grande.

Será equivalente si consideramos el estadístico

$$r' S^{-1} r = (\bar{x} - \mu_0)' S^{-1} (\bar{x} - \mu_0)$$

y rechazamos la hipótesis nula cuando este nuevo estadístico toma un valor demasiado grande. Nótese que el estadístico anterior se obtiene tras aplicar una transformación creciente a este último.

El estadístico recuerda al comentado en (2.2) para el caso univariante si tenemos en cuenta que:

$$T^2 = (n-1)(\bar{x} - \mu_0)' S^{-1} (\bar{x} - \mu_0) = n(\bar{x} - \mu_0)' S_c^{-1} (\bar{x} - \mu_0)$$

donde  $S_c = n/(n-1)S$  denota la matriz de covarianzas corregida. La distribución de  $T^2$  bajo la hipótesis nula fue obtenida por Hotelling (1936). Se tiene que, si  $H_0$  es cierta, el estadístico  $T^2$  sigue una distribución  $\Gamma^2$  de Hotelling<sup>3</sup> de parámetros  $d$  y  $n-1$ . La distribución  $\Gamma^2$  de Hotelling juega un papel semejante a la distribución  $t$  de Student en el caso multivariante. Puedes encontrar propiedades y resultados sobre esta distribución en el Anexo A. Los valores críticos de la distribución  $\Gamma^2$  de Hotelling están tabulados. Aun así, se puede convertir una variable con distribución  $\Gamma^2$  de Hotelling en otra con distribución  $F$  de Snédecor. De este modo se evita la necesidad de considerar nuevas tablas de cuantiles. Simplemente se efectuaría la transformación y se apelaría a las tablas y operaciones conocidas para la  $F$  de Snédecor. En nuestro caso se tiene que, bajo  $H_0$ ,

$$\frac{n-d}{d} (\bar{x} - \mu_0)' S^{-1} (\bar{x} - \mu_0) \in F_{d, n-d}.$$

En definitiva, rechazaremos la hipótesis nula  $H_0 : \mu = \mu_0$  si

$$\frac{n-d}{d} (\bar{x} - \mu_0)' S^{-1} (\bar{x} - \mu_0) > f_{d, n-d, \alpha}$$

siendo  $f_{d, n-d, \alpha}$  el cuantil  $1 - \alpha$  de la distribución  $F_{d, n-d}$ .

**Ejemplo.** El fichero `notas.txt` contiene las puntuaciones obtenidas por los 20 alumnos que han realizado los tests de inteligencia citados en los ejemplos previos. Asumamos ahora que las notas obtenidas provienen de una distribución normal bivalente  $N_2(\mu, \Sigma)$  pero que  $\Sigma$  es desconocida. Queremos contrastar la hipótesis nula  $H_0 : \mu = \mu_0$ , siendo  $\mu_0 = (100, 100)'$ .

```
> tests <- read.table("data/notas.txt", header = TRUE)
> n <- dim(tests)[1]
> d <- dim(tests)[2]
> xbar <- colMeans(tests)
> xbar
Test1 Test2
  102    98
> S <- (n - 1)/n * cov(tests)
> S
      Test1 Test2
Test1  84.1  38.3
Test2  38.3  32.6
> mu0 <- c(100, 100)
> estad <- (n - d)/d * (xbar - mu0) %*% solve(S) %*% (xbar - mu0)
> estad
      [,1]
[1,] 5.458867
```

<sup>3</sup>Formalmente, dadas  $Z \in N_d(0, I_d)$  y  $R \in W_d(I_d, m)$  independientes, con  $m \geq d$  se dice que la variable aleatoria unidimensional  $mZ'R^{-1}Z \in \Gamma^2(d, m)$  tiene una distribución  $\Gamma^2$  de Hotelling de parámetros  $d$  y  $m$ .

Rechazamos la hipótesis nula (para un nivel de significación  $\alpha = 0,05$ ) ya que el valor del estadístico es mayor que  $f_{d,n-d,\alpha} = 3,554557$ . También podemos calcular el  $p$ -valor del estadístico y razonar a partir de él (como el  $p$ -valor es menor que  $\alpha = 0,05$  se rechaza  $H_0$  para dicho nivel de significación).

```
> alpha <- 0.05
> qf(1 - alpha, d, n - d)
[1] 3.554557
> pvalue <- 1 - pf(estad, d, n - d)
> pvalue
      [,1]
[1,] 0.0140273
```

En la Figura 2.5 se representa en rojo la zona de no rechazo del contraste bivalente correspondiente a los datos de este ejemplo ( $n = 20$ ) en comparación con la zona de no rechazo cuando se suponía que la matriz de covarianzas era conocida (elipse en verde).




Figura 2.5.: Zonas de rechazo y no rechazo para el contraste bivalente correspondiente a los datos de tests de inteligencia ( $n = 20$ ). Para el caso en que se conoce la matriz de covarianzas, rechazamos la hipótesis nula si  $\bar{x}$  no pertenece a la elipse en verde. Para el caso en que se desconoce la matriz de covarianzas, rechazamos la hipótesis nula si  $\bar{x}$  no pertenece a la elipse en rojo.

## 2.4. Regiones de confianza y comparaciones simultáneas

### 2.4.1. Regiones de confianza

A partir del estadístico  $\Gamma^2$  de Hotelling, podemos obtener una región de confianza para el vector de medias, de la forma:

$$\left\{ \mu \in \mathbb{R}^d : \frac{n-d}{d} (\bar{x} - \mu)' S^{-1} (\bar{x} - \mu) < f_{d,n-d,\alpha} \right\}.$$

Esta región constituye un elipsoide en  $\mathbb{R}^d$ , centrado en  $\bar{x}$ , cuyos ejes van en la dirección de los autovectores de  $S$  y la longitud de los radios (semilongitud de los ejes) viene dada por

$$\sqrt{\lambda_j} \sqrt{\frac{d}{n-d} f_{d,n-d,\alpha}} \quad j \in \{1, \dots, d\}$$

siendo  $\lambda_1, \dots, \lambda_d$  los autovalores de  $S$ . En la Figura 2.6 se muestra la región de confianza ( $\alpha = 0,05$ ) para el vector de notas medias en el ejemplo de tests de inteligencia. El elipsoide se calcula en base al estadístico  $\Gamma^2$  de Hotelling.




Figura 2.6.: Región de confianza ( $\alpha = 0,05$ ) para el vector de notas medias en el ejemplo de tests de inteligencia.

### 2.4.2. Intervalos de confianza individuales

A continuación planteamos el problema de conseguir intervalos de confianza para las componentes del vector de medias, o más en general, para combinaciones lineales del tipo

$$\mathbf{a}'\boldsymbol{\mu} = a_1\mu_1 + \dots + a_d\mu_d.$$

Observando que  $\mathbf{a}'x_1, \dots, \mathbf{a}'x_n \in N(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\Sigma\mathbf{a})$  y además son independientes, podemos abordar este problema, que ya es univariante, mediante el procedimiento de la  $t$  de Student. Así, como la media y la cuasivarianza muestrales calculadas sobre las observaciones  $\mathbf{a}'x_1, \dots, \mathbf{a}'x_n$  resultan ser  $\mathbf{a}'\bar{x}$  y  $\mathbf{a}'S_c\mathbf{a}$ , respectivamente, el intervalo de confianza adopta la forma

$$\left( \mathbf{a}'\bar{x} - t_{n-1,\alpha/2} \frac{\sqrt{\mathbf{a}'S_c\mathbf{a}}}{\sqrt{n}}, \mathbf{a}'\bar{x} + t_{n-1,\alpha/2} \frac{\sqrt{\mathbf{a}'S_c\mathbf{a}}}{\sqrt{n}} \right)$$

siendo  $t_{n-1,\alpha/2}$  el cuantil  $1 - \alpha/2$  de la distribución  $t$  de Student con  $n - 1$  grados de libertad. De este modo, para un  $\mathbf{a}$  fijo, el intervalo anterior contiene a  $\mathbf{a}'\boldsymbol{\mu}$  con una probabilidad  $1 - \alpha$ . En particular, podemos pensar en un vector de la forma  $\mathbf{a} = (1, 0, \dots, 0)'$  que serviría para extraer la primera componente del vector aleatorio. Igual se haría con las demás componentes mediante los vectores canónicos correspondientes. Así obtendríamos  $p$  intervalos de confianza,

uno para cada componente del vector de medias. Sin embargo, el nivel de confianza se refiere a la probabilidad individual de cada intervalo, de modo que la probabilidad de que todos los intervalos simultáneamente contengan a la componente correspondiente del vector de medias será en general inferior al nivel de confianza fijado.

### 2.4.3. Intervalos de confianza simultáneos por el método de Scheffé

Para satisfacer un nivel de confianza simultáneo, debemos modificar la construcción de los intervalos haciéndolos más amplios. Vamos a plantear este objetivo de manera simultánea en todos los vectores  $\mathbf{a}$ . Si seguimos partiendo como pivote de la media estudentizada, la idea podría ser cambiar el valor  $t_{n-1, \alpha/2}$  por otra constante adecuada, previsiblemente más grande. Así, si

$$P \left\{ \left| \frac{\sqrt{n} (\mathbf{a}'\bar{\mathbf{x}} - \mathbf{a}'\boldsymbol{\mu})}{\sqrt{\mathbf{a}'\mathbf{S}_c\mathbf{a}}} \right| < c \quad \forall \mathbf{a} \in \mathbb{R}^p \right\} = 1 - \alpha$$

los intervalos de confianza obtenidos al sustituir  $t_{n-1, \alpha/2}$  por  $c$  cumplirán el nivel de confianza de manera simultánea. Enunciamos el lema siguiente.

**Lema 2.2.** Sea  $\mathbf{B}$  una matriz  $d \times d$ , simétrica y definida positiva, y  $\mathbf{r} \in \mathbb{R}^d$ . Entonces

$$\max_{\mathbf{x} \in \mathbb{R}^d \setminus \{0\}} \frac{(\mathbf{x}'\mathbf{r})^2}{\mathbf{x}'\mathbf{B}\mathbf{x}} = \mathbf{r}'\mathbf{B}^{-1}\mathbf{r}$$

y este máximo se alcanza cuando  $\mathbf{x} = c\mathbf{B}^{-1}\mathbf{r}$  para cualquier  $c \in \mathbb{R} \setminus \{0\}$ .

Aplicando este lema obtenemos

$$\max_{\mathbf{a} \in \mathbb{R}^d} \frac{n (\mathbf{a}'(\bar{\mathbf{x}} - \boldsymbol{\mu}))^2}{\mathbf{a}'\mathbf{S}_c\mathbf{a}} = n (\bar{\mathbf{x}} - \boldsymbol{\mu})' \mathbf{S}_c^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}) \in \Gamma^2(d, n-1).$$

De este resultado se puede extraer el valor de  $c$  y finalmente se obtienen los que se conocen como intervalos de confianza simultáneos por el método de Scheffé:

$$\left( \mathbf{a}'\bar{\mathbf{x}} - \sqrt{\frac{d(n-1)}{n-d}} f_{d, n-d, \alpha} \frac{\sqrt{\mathbf{a}'\mathbf{S}_c\mathbf{a}}}{\sqrt{n}}, \mathbf{a}'\bar{\mathbf{x}} + \sqrt{\frac{d(n-1)}{n-d}} f_{d, n-d, \alpha} \frac{\sqrt{\mathbf{a}'\mathbf{S}_c\mathbf{a}}}{\sqrt{n}} \right)$$

o equivalentemente

$$\left( \mathbf{a}'\bar{\mathbf{x}} - \sqrt{\frac{d}{n-d}} f_{d, n-d, \alpha} \mathbf{a}'\mathbf{S}\mathbf{a}, \mathbf{a}'\bar{\mathbf{x}} + \sqrt{\frac{d}{n-d}} f_{d, n-d, \alpha} \mathbf{a}'\mathbf{S}\mathbf{a} \right)$$

**Observación.** Se puede demostrar que los intervalos de confianza simultáneos por el método de Scheffé coinciden con la proyección de la elipse de confianza sobre cada una de las direcciones

determinadas por los vectores  $\mathbf{a}$ . En concreto, si en  $\mathbf{a}$  se consideran las direcciones de los ejes, se obtendrían intervalos de confianza para cada componente.

La tabla siguiente permite comparar los valores de  $c$  para el cálculo de los intervalos de confianza, extraídos de la  $t$  de Student frente a los que se obtienen mediante el método de Scheffé.

| $n$      | $t_{n-1,0,025}$ | $\sqrt{\frac{d(n-1)}{n-d}} f_{d,n-d,0,05}$ |          |
|----------|-----------------|--------------------------------------------|----------|
|          |                 | $d = 4$                                    | $d = 10$ |
| 15       | 2.145           | 4.14                                       | 11.52    |
| 25       | 2.064           | 3.60                                       | 6.39     |
| 50       | 2.010           | 3.31                                       | 5.05     |
| 100      | 1.970           | 3.19                                       | 4.61     |
| $\infty$ | 1.960           | 3.08                                       | 4.28     |

#### 2.4.4. Intervalos de confianza simultáneos por el método de Bonferroni

Otro método para obtener intervalos de confianza simultáneos es el método de Bonferroni. Es una alternativa válida en cualquier contexto en el que se requiera una cantidad finita de intervalos simultáneos, ya que no se basa en la naturaleza probabilística del problema en cuestión (como sí lo hace el método de Scheffé), sino que su fundamento radica simplemente en la subaditividad de la probabilidad.

Si  $C_1, \dots, C_m$  consisten en los sucesos respectivos de que cada intervalo de confianza contenga al parámetro correspondiente,

$$\begin{aligned} P(C_i \text{ cierto } \forall i) &= 1 - P(C_i \text{ falso para algún } i) \\ &\geq 1 - \sum_{i=1}^m P(C_i \text{ falso}) = 1 - (\alpha_1 + \dots + \alpha_m) \end{aligned}$$

siendo  $1 - \alpha_1, \dots, 1 - \alpha_m$  los niveles de confianza individuales de cada intervalo. Así, para alcanzar un nivel de confianza simultáneo  $1 - \alpha$  basta con tomar  $\alpha_1, \dots, \alpha_m$  de modo que  $\alpha_1 + \dots + \alpha_m = \alpha$ , por ejemplo mediante  $\alpha_1 = \dots = \alpha_m = \alpha/m$ .

La tabla siguiente muestra el cociente de longitudes (para  $1 - \alpha = 0,95$ ), cuando se construyen intervalos para cada componente:

$$\frac{\text{Longitud del intervalo de Bonferroni}}{\text{Longitud del intervalo de Scheffé}} = \frac{t_{n-1,\alpha/(2m)}}{\sqrt{\frac{d(n-1)}{n-d}} f_{d,n-d,\alpha}}$$

| $n$ | $m = d$ |      |      |
|-----|---------|------|------|
|     | 2       | 4    | 10   |
| 15  | 0.88    | 0.69 | 0.29 |
| 25  | 0.90    | 0.75 | 0.48 |
| 50  | 0.91    | 0.78 | 0.58 |

|          |      |      |      |
|----------|------|------|------|
| 100      | 0.91 | 0.80 | 0.62 |
| $\infty$ | 0.91 | 0.81 | 0.66 |

**Ejemplo.** Sobre el ejemplo de las puntuaciones de tests de inteligencia, vamos a calcular los intervalos de confianza para la calificación media del test 1 y del test 2, al nivel de confianza del 95 %, obtenidos de manera individual, y simultáneos por el método de Scheffé y por el método de Bonferroni. Así, en la Figura 2.7 se representan mediante una elipse en color rojo la región de confianza para el vector de medias  $\mu = (\mu_1, \mu_2)'$ . En el centro de la elipse se sitúa el vector con las medias muestrales  $\bar{x} = (102, 98)'$ .

Al proyectar la elipse sobre los ejes horizontal y vertical se obtienen los intervalos representados en color verde, que serían intervalos de confianza simultáneos por el método de Scheffé. Los intervalos de confianza simultáneos por el método de Bonferroni vienen representados en color negro. Como cabía esperar, son más pequeños que los intervalos simultáneos por el método de Scheffé. Por último, los intervalos de confianza individuales han sido representados con trazo azul. Son los más pequeños, también conforme a lo previsible.




Figura 2.7.: Región de confianza para el vector de medias (elipse), junto con intervalos de confianza individuales (trazo azul), simultáneos por el método de Bonferroni (trazo negro) y simultáneos por el método de Scheffé (trazo verde).

## 2.5. Generalización del contraste sobre el vector de medias

En esta sección veremos cómo se puede generalizar el contraste sobre el vector de medias, al caso de restricciones más genéricas sobre  $\mu$ , más generales que la hipótesis nula,  $H_0 : \mu = \mu_0$ . El resultado básico lo enunciamos como un teorema. Después, como aplicación más común de este resultado, veremos el contraste de restricciones lineales sobre  $\mu$ , entre las cuales tiene un interés especial el contraste de igualdad de las componentes del vector de medias.

### 2.5.1. Resultado general

**Teorema 2.1.** Sea  $x_1, \dots, x_n$  una muestra aleatoria simple de  $N_d(\mu, \Sigma)$ . Si las hipótesis  $H_0$  y  $H_a$  conducen a los estimadores de máxima verosimilitud  $\hat{\mu}$  y  $\bar{x}$ , respectivamente, y bajo ninguna de las dos hipótesis hay restricciones para  $\Sigma$ , entonces los estimadores de máxima verosimilitud de  $\Sigma$  son  $S + rr'$  y  $S$ , bajo  $H_0$  y  $H_a$  respectivamente, siendo  $r = \bar{x} - \hat{\mu}$ .

Además, el test de razón de verosimilitudes para contrastar  $H_0$  frente a  $H_a$  viene dado por

$$-2 \log \lambda(x) = nr' \Sigma^{-1} r \quad \text{si } \Sigma \text{ es conocida} \quad (2.3)$$

y

$$-2 \log \lambda(x) = n \log \left( 1 + r' S^{-1} r \right) \quad \text{si } \Sigma \text{ es desconocida.} \quad (2.4)$$

*Demostración.* La demostración seguiría los mismos pasos que en los casos anteriores, donde contrastábamos una hipótesis nula simple sobre el vector de medias con matriz de covarianzas conocida o desconocida.  $\square$

### 2.5.2. Contraste de restricciones lineales

Supongamos que  $\Sigma$  es conocida y deseamos contrastar la hipótesis nula

$$H_0 : A\mu = b$$

siendo  $A$  una matriz conocida de orden  $q \times d$  y rango máximo  $q$ , y  $b$  un vector conocido.

A este problema de contraste le podemos aplicar el teorema anterior. Para ello, tenemos que obtener el estimador de máxima verosimilitud bajo  $H_0$ , que denotaremos mediante  $\hat{\mu}$ . La función de log-verosimilitud se puede escribir así:

$$\begin{aligned} l(x, \mu, \Sigma) &= \log L(x, \mu, \Sigma) \\ &= c - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})' \Sigma^{-1} (x_i - \bar{x}) \\ &\quad - \frac{n}{2} (\bar{x} - \mu)' \Sigma^{-1} (\bar{x} - \mu). \end{aligned}$$

En tal caso, el problema consiste en:

$$\begin{aligned} &\text{Maximizar } l(x, \mu, \Sigma) \\ &\text{sujeto a } A\mu = b \end{aligned}$$

Consideramos la función

$$a^+ = a - n\lambda'(A\mu - b)$$

siendo  $\lambda$  un vector de multiplicadores de Lagrange. Derivando

$$\frac{\partial \alpha^+}{\partial \mu} = n (\bar{x} - \mu)' \Sigma^{-1} - n \lambda' A = 0.$$

De donde

$$\bar{x} - \mu = \Sigma A' \lambda \quad (2.5)$$

ecuación que debemos añadir a la restricción  $A\mu = b$ , para obtener las soluciones para  $\lambda$  y  $\mu$ . Multiplicando por  $A$ ,

$$A\bar{x} - A\mu = A\bar{x} - b = (A\Sigma A') \lambda$$

lo cual nos permite despejar  $\lambda = (A\Sigma A')^{-1} (A\bar{x} - b)$  que, sustituido en la ecuación (2.5), da lugar al estimador de máxima verosimilitud

$$\hat{\mu} = \bar{x} - \Sigma A' (A\Sigma A')^{-1} (A\bar{x} - b).$$

El test de razón de verosimilitudes viene dado por (2.3), donde

$$r = \bar{x} - \hat{\mu} = \Sigma A' (A\Sigma A')^{-1} (A\bar{x} - b)$$

de modo que finalmente adopta la forma

$$-2 \log \lambda(x) = n (A\bar{x} - b)' (A\Sigma A')^{-1} (A\bar{x} - b).$$

Bajo la hipótesis nula,  $H_0$ ,  $Ax_1, \dots, Ax_n \in N_q(b, A\Sigma A')$  y son independientes, siendo  $q$  la dimensión de  $b$ , y por tanto la distribución del estadístico de contraste es  $\chi_q^2$ . En resumen, rechazaremos la hipótesis nula  $H_0 : A\mu = b$  si

$$n (A\bar{x} - b)' (A\Sigma A')^{-1} (A\bar{x} - b) > \chi_{q,\alpha}^2$$

siendo  $\chi_{q,\alpha}^2$  el cuantil  $1 - \alpha$  de la distribución  $\chi_q^2$ .

Si la matriz de covarianzas es desconocida, los desarrollos que conducen al estimador de máxima verosimilitud de  $\mu$  bajo  $H_0$  son algo más complejos. Por ello, omitimos los detalles. El resultado es el siguiente:

$$\hat{\mu} = \bar{x} - SA' (ASA')^{-1} (A\bar{x} - b).$$

El test de razón de verosimilitudes viene dado por (2.4), donde

$$r = \bar{x} - \hat{\mu} = SA' (ASA')^{-1} (A\bar{x} - b)$$

de modo que finalmente tomamos como estadístico de contraste

$$(n-1)\mathbf{r}'\mathbf{S}^{-1}\mathbf{r} = (n-1)(\mathbf{A}\bar{\mathbf{x}} - \mathbf{b})'(\mathbf{A}\mathbf{S}\mathbf{A}')^{-1}(\mathbf{A}\bar{\mathbf{x}} - \mathbf{b})$$

cuya distribución es  $\Gamma^2(q, n-1)$ . Empleando que la distribución  $\Gamma^2$  de Hotelling se puede expresar como una  $F$  de Snédecor, salvo constantes, se llega a

$$\frac{n-q}{q}(\mathbf{A}\bar{\mathbf{x}} - \mathbf{b})'(\mathbf{A}\mathbf{S}\mathbf{A}')^{-1}(\mathbf{A}\bar{\mathbf{x}} - \mathbf{b}) \in F_{q, n-q}.$$

Por lo tanto, si  $\Sigma$  es desconocida, rechazaremos la hipótesis nula  $H_0: \mathbf{A}\mu = \mathbf{b}$  si

$$\frac{n-q}{q}(\mathbf{A}\bar{\mathbf{x}} - \mathbf{b})'(\mathbf{A}\mathbf{S}\mathbf{A}')^{-1}(\mathbf{A}\bar{\mathbf{x}} - \mathbf{b}) > f_{q, n-q, \alpha}$$

siendo  $f_{q, n-q, \alpha}$  el cuantil  $1 - \alpha$  de la distribución  $F_{q, n-q}$ .

### 2.5.2.1. Caso particular. Contraste de igualdad de las componentes del vector de medias

El contraste de la hipótesis nula de que las  $d$  componentes del vector de medias,  $\mu = (\mu_1, \dots, \mu_d)'$ , son iguales, se puede ver como un caso particular del contraste de restricciones lineales. Para ello, basta considerar la siguiente matriz

$$\mathbf{A} = \begin{pmatrix} 1 & -1 & 0 & \dots & 0 \\ 1 & 0 & -1 & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & 0 \\ 1 & 0 & \dots & 0 & -1 \end{pmatrix}$$

de modo que  $H_0: \mathbf{A}\mu = \mathbf{0}$  equivale a la igualdad de las  $d$  medias. Nótese que hay otras matrices que también servirían para efectuar este contraste. En concreto, la matriz  $\mathbf{A}$  que acabamos de proponer, efectúa las diferencias entre la media de la primera componente y cada una de las demás medias. En este sentido, además de servir para el contraste, permite estimar la discrepancia entre las medias por comparación con la primera de ellas. Si se emplea otro tipo de matriz, se obtendrían las posibles discrepancias entre las medias en una presentación diferente.

**Ejemplo.** En Mardia et al. (1979), página 12, se pueden encontrar los datos de depósitos de corcho obtenidos en 28 árboles y extraídos en las cuatro direcciones: Norte, Sur, Este y Oeste. Se está estudiando si la cantidad media de corcho que se llega a recoger, es similar en las cuatro direcciones. Vamos a efectuar el contraste de esta hipótesis usando el test propuesto en esta sección.

```
> corcho <- read.table("data/corcho.txt", header = TRUE)
> n <- dim(corcho)[1]
> d <- dim(corcho)[2]
> xbar <- colMeans(corcho)
> xbar
      N      E      S      W
50.53571 46.17857 49.67857 45.17857
```

```
> Sc <- cov(corcho)
> S <- (n - 1)/n * Sc
> S
      N      E      S      W
N 280.0344 215.7615 278.1365 218.1901
E 215.7615 212.0753 220.8788 165.2538
S 278.1365 220.8788 337.5038 250.2717
W 218.1901 165.2538 250.2717 217.9324
```

Se consideró una matriz  $A$  que calcula las diferencias respecto de la dirección norte. A continuación se muestran los valores de esta matriz.

```
> A <- rbind(c(1, -1, 0, 0), c(1, 0, -1, 0), c(1, 0, 0, -1))
> A
      [,1] [,2] [,3] [,4]
[1,]    1   -1    0    0
[2,]    1    0   -1    0
[3,]    1    0    0   -1
```

El estadístico  $F$  y su nivel crítico se muestran a continuación. Como el nivel crítico es pequeño se rechaza la igualdad de las cuatro direcciones en cuanto al depósito medio de corcho.

```
> q <- nrow(A)
> difmed <- A %*% xbar
> covdif <- A %*% S %*% t(A)
> estadF <- ((n - q)/q) * t(difmed) %*% solve(covdif) %*% difmed
> estadF
      [,1]
[1,] 6.401857
> alpha <- 0.05
> qf(1 - alpha, q, n - q)
[1] 2.991241
> pvalor <- 1 - pf(estadF, q, n - q)
> pvalor
      [,1]
[1,] 0.002280399
```

Como ejercicio adicional, se podría modificar la matriz  $A$ , por ejemplo de modo que se calculen las diferencias respecto de otra dirección, y efectuar todo el procedimiento del mismo modo con la nueva matriz  $A$ . El vector  $\text{difmed}$  y la matriz  $\text{covdif}$  tomarán valores diferentes. Sin embargo, el estadístico  $F$  ( $\text{estadF}$ ) y su nivel crítico ( $\text{pvalor}$ ) tendrán los mismos valores que hemos mostrado, pues, como hemos dicho, el test no depende de la matriz  $A$  escogida, siempre que se mantenga la naturaleza de la hipótesis que se va a contrastar. En este caso, la hipótesis es la igualdad de las cuatro medias, independientemente de cómo se exprese.

## 2.6. Inferencia sobre la matriz de covarianzas

Consideramos ahora contrastes de hipótesis que involucran la estructura de covarianzas de una población normal. En general, este tipo de contrastes se llevan a cabo para comprobar

hipótesis de otros modelos. Los procedimientos que estudiaremos nos permitirán contrastar por ejemplo si la matriz de covarianzas tiene una estructura determinada o si algunos elementos de la matriz de covarianzas son cero (implicando así la independencia de los subvectores correspondientes).

### 2.6.1. Contraste $H_0 : \Sigma = \Sigma_0$

Disponemos de una muestra aleatoria simple  $x_1, \dots, x_n \in N_d(\mu, \Sigma)$  de vectores aleatorios independientes y con la misma distribución normal multivariante. Suponemos que el vector de medias  $\mu$  es desconocido. Deseamos llevar a cabo tareas de inferencia relativas a la matriz de covarianzas. En particular, deseamos contrastar

$$H_0 : \Sigma = \Sigma_0 \text{ frente a } H_1 : \Sigma \neq \Sigma_0.$$

En este contraste la matriz de covarianzas en la hipótesis alternativa no está sujeta a restricciones. Aplicando el procedimiento de razón de verosimilitudes, resulta el estadístico de contraste:

$$-2 \log \lambda(x) = -2 \log \frac{\sup_{\mu} L(x, \mu, \Sigma_0)}{\sup_{\mu, \Sigma} L(x, \mu, \Sigma)}.$$

Recordamos que la función de verosimilitud alcanza su máximo en  $\mu = \bar{x}$  para cualquier matriz de covarianzas  $\Sigma$ . Se tiene por lo tanto,

$$\sup_{\mu} \log L(x, \mu, \Sigma_0) = c - \frac{n}{2} \left( \log |\Sigma_0| + \text{traza} \left( \Sigma_0^{-1} S \right) \right).$$

También habíamos visto que,

$$\sup_{\Sigma} \sup_{\mu} \log L(x, \mu, \Sigma) = c - \frac{n}{2} (\log |S| + d)$$

de modo que el estadístico de contraste adopta la forma:

$$\begin{aligned} -2 \log \lambda(x) &= n \left( \log |\Sigma_0| + \text{traza} \left( \Sigma_0^{-1} S \right) - \log |S| - d \right) \\ &= n \left( \text{traza} \left( \Sigma_0^{-1} S \right) - \log |S| - d \right) \\ &= n \left( \sum_{j=1}^d \lambda_j - \log \left( \prod_{j=1}^d \lambda_j \right) - d \right) \\ &= n \left( da - \log (g^d) - d \right) \\ &= nd (a - \log g - 1) \end{aligned}$$

siendo  $\lambda_1, \dots, \lambda_d$  los autovalores de la matriz  $\Sigma_0^{-1} S$ ,  $a$  la media aritmética de tales autovalores y  $g$  su media geométrica. La distribución exacta de este estadístico bajo la hipótesis nula no se

encuentra disponible. En su lugar, usaremos la distribución asintótica que presenta por ser un estadístico de razón de verosimilitudes:

$$-2 \log \lambda(\mathbf{x}) = nd(a - \log g - 1) \sim \chi_m^2$$

siendo el número de grados de libertad, la diferencia entre el número de parámetros independientes bajo la hipótesis alternativa y bajo la hipótesis nula, que en este caso resulta,  $m = \frac{1}{2}d(d+1)$ , pues es el número de parámetros independientes en una matriz de covarianzas.

Por haberse construido como cociente de verosimilitudes bajo la hipótesis nula y bajo la alternativa, rechazaremos la hipótesis nula cuando este estadístico sea grande o, mejor dicho, cuando supere el cuantil  $(1 - \alpha)$  de la distribución  $\chi_m^2$ , denotado por  $\chi_{m,\alpha}^2$ , siendo  $\alpha$  el nivel de significación fijado de antemano.

**Ejemplo.** Recordemos el ejemplo sobre Psicología educativa en el que se analizaba si las notas medias obtenidas por estudiantes universitarios en dos tests de inteligencia fueron iguales a 100. Cuando planteamos por primera vez el contraste sobre el vector de medias, suponíamos que la matriz de covarianzas era conocida e igual a

$$\Sigma = \begin{pmatrix} 49 & 35 \\ 35 & 52 \end{pmatrix}.$$

Utilizando los datos del fichero `notas.txt` vamos a contrastar si esa es efectivamente la estructura de la matriz de covarianzas del vector  $\mathbf{x} = (x_1, x_2)'$  correspondiente a las notas de los dos tests. En primer lugar leemos los datos, calculamos la matriz de covarianzas muestral  $S$  y definimos la matriz de covarianzas bajo la hipótesis nula  $\Sigma_0$ .

```
> tests <- read.table("data/notas.txt", header = TRUE)
> n <- dim(tests)[1]
> d <- dim(tests)[2]
> S <- (n - 1)/n * cov(tests)
> Sigma_0 <- matrix(c(49, 35, 35, 52), nrow = 2)
```

Calculamos ahora los autovalores de la matriz  $\Sigma_0^{-1}S$ . El estadístico de contraste se define a partir de la media aritmética  $a$  y la media geométrica  $g$  de los autovalores.

```
> lambda <- eigen(solve(Sigma_0) %*% S)$values
> a <- mean(lambda)
> g <- prod(lambda)^(1/d)
> estad <- n * d * (a - log(g) - 1)
> estad
[1] 10.47213
```

Bajo  $H_0$ , la distribución asintótica del estadístico es  $\chi_m^2$ , siendo  $m = d(d+1)/2$ .

```
> m <- 0.5 * d * (d + 1)
> pval <- 1 - pchisq(estad, m)
> pval
[1] 0.01495119
```

Para un nivel de significación inferior al del nivel crítico (0,0149) podremos aceptar que la matriz de covarianzas sea la que se planteó como hipótesis.

**Nota.** Debemos observar que si se hubiera supuesto que el vector de medias es conocido, siguiendo los mismos pasos habríamos llegado al estadístico de contraste

$$-2 \log \lambda(\mathbf{x}) = nd(a - \log g - 1)$$

siendo  $a$  y  $g$  las medias aritmética y geométrica, respectivamente, de los autovalores de la matriz  $\Sigma_0^{-1} \hat{\Sigma}_\mu$ . La única diferencia radica en la sustitución de  $S$  por el estimador

$$\hat{\Sigma}_\mu = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)'$$

Nuevamente tenemos los mismos problemas con la distribución del estadístico de contraste y apelamos a la distribución asintótica, que es  $\chi_m^2$  con el mismo número de grados de libertad,  $m = \frac{1}{2}d(d+1)$ .

## 2.7. Generalización del contraste sobre la matriz de covarianzas

En esta sección se va a generalizar el test obtenido para el contraste de la matriz de covarianzas. En primer lugar ofrecemos el enunciado de un teorema de generalización, cuya demostración es innecesaria, pues consiste en la constatación de los mismos argumentos de máxima verosimilitud ya empleados, y de los desarrollos subsiguientes.

**Teorema 2.2.** Sea  $\mathbf{x}_1, \dots, \mathbf{x}_n$  una muestra aleatoria simple de  $N_d(\mu, \Sigma)$ . Si las hipótesis  $H_0$  y  $H_a$  conducen a los estimadores de máxima verosimilitud  $\hat{\Sigma}$  y  $S$ , respectivamente, y si  $\bar{\mathbf{x}}$  es el estimador de máxima verosimilitud para  $\mu$  bajo cualquiera de las dos hipótesis, entonces el estadístico de razón de verosimilitudes para contrastar  $H_0$  frente a  $H_a$  viene dado por

$$-2 \log \lambda(\mathbf{x}) = nd(a - \log g - 1)$$

siendo  $a$  y  $g$  las medias aritmética y geométrica, respectivamente, de los autovalores de  $\hat{\Sigma}^{-1}S$ .

Una vez establecido este resultado general, trataremos diversas situaciones en las cuales se puede aplicar este teorema. En todos los casos supondremos que disponemos de una muestra aleatoria simple  $\mathbf{x}_1, \dots, \mathbf{x}_n \in N_d(\mu, \Sigma)$  y que el vector de medias  $\mu$  es desconocido.

### 2.7.1. Contraste de la hipótesis nula $H_0 : \Sigma = k\Sigma_0, \quad k \in (0, +\infty)$

Supongamos que queremos contrastar una hipótesis nula compuesta sobre la matriz de covarianzas

$$H_0 : \Sigma = k\Sigma_0 \quad k \in (0, +\infty)$$

siendo  $\Sigma_0$  una matriz de covarianzas fijada, frente a una alternativa en la que la matriz de covarianzas no está sujeta a restricciones. El vector de medias carece de restricciones tanto bajo la hipótesis nula como bajo la alternativa. Estamos en las condiciones del teorema anterior, por lo que sólo nos falta calcular el estimador de la matriz de covarianzas bajo la hipótesis nula,  $\hat{\Sigma} = \hat{k}\Sigma_0$ . Se puede comprobar que  $\hat{k} = a_0$  es el estimador de máxima verosimilitud de  $k$ , siendo  $a_0$  la media aritmética de los autovalores de  $\Sigma_0^{-1}S$ .

Entonces, aplicando la expresión que figura en el teorema anterior, el estadístico de razón de verosimilitudes adopta la forma:

$$-2 \log \lambda(x) = nd(a - \log g - 1)$$

siendo  $a$  y  $g$  las medias aritmética y geométrica, respectivamente, de los autovalores de la matriz  $\hat{\Sigma}^{-1}S = \frac{1}{a_0}\Sigma_0^{-1}S$ . En consecuencia,  $a = 1$  y  $g = \frac{1}{a_0}g_0$ , siendo  $g_0$  la media geométrica de los autovalores de  $\Sigma_0^{-1}S$ . Sustituyendo los valores de  $a$  y  $g$  obtenemos

$$-2 \log \lambda(x) = nd \left( 1 - \log \left( \frac{1}{a_0}g_0 \right) - 1 \right) = nd \log \frac{a_0}{g_0}.$$

Por último, no estando disponible la distribución exacta de este estadístico, la aproximamos por una  $\chi_m^2$ , siendo el número de grados de libertad  $m = \frac{1}{2}d(d+1) - 1 = \frac{1}{2}(d-1)(d+2)$ .

#### 2.7.1.1. Test de esfericidad $H_0 : \Sigma = \sigma^2 I_d$

Hay un caso particular de este tipo de contraste que tiene un interés especial. Es el test de esfericidad, que consiste en contrastar la hipótesis nula de que las variables son incorreladas y tienen la misma varianza. La hipótesis nula es de la forma

$$H_0 : \Sigma = \sigma^2 I_d,$$

siendo  $\sigma^2$  la varianza común desconocida. Nótese que la incorrelación equivale a independencia cuando se trata de variables normales. Es inmediato que estamos ante un caso particular del test anterior. Para verlo basta con tomar  $\Sigma_0 = I_d$ . Por tanto, el estadístico de contraste sería:

$$-2 \log \lambda(x) = nd \log \frac{a_0}{g_0} \sim \chi_m^2$$

siendo  $a_0$  y  $g_0$  las medias aritmética y geométrica, respectivamente, de los autovalores de la matriz  $\Sigma_0^{-1}S = S$ , y  $m = \frac{1}{2}(d-1)(d+2)$ .

**Ejemplo.** Vamos a contrastar la esfericidad de datos generados de distintas normales multivariantes. Para ello utilizaremos la función `rmvnorm` de la librería `mvtnorm`. En primer lugar generamos una muestra de tamaño  $n = 100$  de una normal  $N_3(\mathbf{0}, \mathbf{I}_3)$ .

```
> set.seed(123456)
> library(mvtnorm)
> d <- 3
> mu <- c(0, 0, 0)
> n <- 100
> Sigma <- diag(d)
> x <- rmvnorm(n, mu, Sigma)
```

Una vez generados los datos, vamos a realizar el contraste de esfericidad. Para ello calculamos  $a_0$  y  $g_0$  las medias aritmética y geométrica, respectivamente, de los autovalores de la matriz  $S$ .

```
> S <- cov(x) * (n - 1)/n
> lambda <- eigen(S)$values
> a0 <- mean(lambda)
> g0 <- prod(lambda)^(1/d)
> estad <- n * d * log(a0/g0)
> estad
[1] 4.483253
```

Bajo  $H_0$ , la distribución asintótica del estadístico es  $\chi^2_m$ , siendo  $m = (d - 1)(d + 2)/2$ . En este caso, para un nivel de significación  $\alpha = 0,05$ , no rechazamos la hipótesis nula de esfericidad, ya que el valor del estadístico es menor que  $\chi^2_{m,\alpha}$ . De hecho el valor crítico del estadístico es considerablemente grande.

```
> m <- 0.5 * (d - 1) * (d + 2)
> qchisq(0.95, m)
[1] 11.0705
> pval <- 1 - pchisq(estad, m)
> pval
[1] 0.4821273
```

Trabajaremos ahora con datos generados de una normal multivariante  $N_3(\mathbf{0}, 4\mathbf{I}_3)$ .

```
> Sigma <- 4 * diag(d)
> x <- rmvnorm(n, mu, Sigma)
```

Planteamos el contraste de esfericidad y, de nuevo, no rechazamos la hipótesis nula.

```

> S <- cov(x) * (n - 1)/n
> lambda <- eigen(S)$values
> a0 <- mean(lambda)
> g0 <- prod(lambda)^(1/d)
> estad <- n * d * log(a0/g0)
> estad
[1] 3.251188
> qchisq(0.95, m)
[1] 11.0705
> pval <- 1 - pchisq(estad, m)
> pval
[1] 0.6613227

```

Como último ejemplo, vamos a generar datos de un vector normal que no verifique la hipótesis nula de esfericidad. Para ello elegiremos una matriz de covarianzas diagonal pero en la que no todas las variables tengan la misma varianza.

```

> Sigma <- diag(c(3, 5, 1))
> x <- rmvnorm(n, mu, Sigma)

```

Calculamos el estadístico de contraste y obtenemos los siguientes resultados.

```

> S <- cov(x) * (n - 1)/n
> lambda <- eigen(S)$values
> a0 <- mean(lambda)
> g0 <- prod(lambda)^(1/d)
> estad <- n * d * log(a0/g0)
> estad
[1] 69.92047
> qchisq(0.95, m)
[1] 11.0705
> pval <- 1 - pchisq(estad, m)
> pval
[1] 1.064704e-13

```

La esfericidad permite una mayor o menor varianza, pero esta varianza tendría que ser la misma en las tres variables y no debe existir correlación. Esto se pone en evidencia mediante los autovalores de la matriz de covarianzas, que deben ser iguales. Como se puede comprobar, los autovalores para este último ejemplo muestran una gran desigualdad. Esto hace que las medias aritmética y geométrica sean muy diferentes. El nivel crítico es muy pequeño, por lo que hay pruebas muy significativas de ausencia de esfericidad.

### 2.7.2. Contraste de independencia de dos subvectores $H_0 : \Sigma_{12} = 0$

Supongamos que el vector de interés  $x$  se divide en dos subvectores con  $d_1$  y  $d_2$  variables ( $d_1 + d_2 = d$ ). Por ejemplo, si  $x_1$  denota el subvector de las primeras  $d_1$  componentes de  $x$  y  $x_2$  denota el subvector con las restantes  $d_2$  componentes, entonces podemos escribir:

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}.$$

Queremos contrastar la hipótesis de que los dos conjuntos de variables son independientes entre sí, lo cual, en esta situación donde se supone normalidad, equivale a incorrelación, esto es, a que  $\Sigma_{12} = 0$ . Bajo la hipótesis nula  $H_0 : \Sigma_{12} = 0$ , la verosimilitud se descompone en el producto de dos factores correspondientes a las verosimilitudes que provienen de cada conjunto de variables. De este modo, bajo la hipótesis nula, los estimadores de  $\mu_1$  y  $\Sigma_{11}$  por un lado, y de  $\mu_2$  y  $\Sigma_{22}$  por otro, se obtienen maximizando la verosimilitud de cada conjunto de variables por separado. Así, suponiendo que el vector de medias  $\mu = (\mu_1, \mu_2)'$  es desconocido, su estimador de máxima verosimilitud será  $\hat{\mu} = (\bar{x}_1, \bar{x}_2)' = \bar{x}$ , mientras que

$$\hat{\Sigma} = \begin{pmatrix} S_{11} & 0 \\ 0 & S_{22} \end{pmatrix}.$$

Bajo la alternativa, no hay restricciones ni para el vector de medias ni para la matriz de covarianzas, de modo que los estimadores de máxima verosimilitud serán  $\bar{x}$  y  $S$ , respectivamente.

Entonces el estadístico de razón de verosimilitudes adopta la forma que figura en la expresión del teorema anterior, donde

$$\hat{\Sigma}^{-1} S = \begin{pmatrix} S_{11} & 0 \\ 0 & S_{22} \end{pmatrix}^{-1} \begin{pmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{pmatrix} = \begin{pmatrix} I_{d_1} & S_{11}^{-1} S_{12} \\ S_{22}^{-1} S_{21} & I_{d_2} \end{pmatrix}.$$

En tal caso,  $a = \frac{1}{d} \text{traza}(\hat{\Sigma}^{-1} S) = \frac{1}{d} d = 1$ . Por otro lado,

$$\begin{aligned} g^d &= |\hat{\Sigma}^{-1} S| \\ &= \frac{|S|}{|S_{11}| \cdot |S_{22}|} \\ &= \frac{|S_{22} - S_{21} S_{11}^{-1} S_{12}|}{|S_{22}|} \\ &= |I_{d_2} - S_{22}^{-1} S_{21} S_{11}^{-1} S_{12}| \\ &= |I_{d_2} - R_{22}^{-1} R_{21} R_{11}^{-1} R_{12}|. \end{aligned}$$

En el último paso hemos sustituido las matrices de covarianzas por matrices de correlaciones, que se construyen a partir de las anteriores así:  $R = D^{-1/2} S D^{-1/2}$ , siendo  $D$  una matriz diagonal que contiene las varianzas. Entonces, el estadístico de contraste será:

$$-2 \log \lambda(x) = -n d \log g = -n \log |I_{d_2} - S_{22}^{-1} S_{21} S_{11}^{-1} S_{12}|.$$

Ahora podríamos apelar a la distribución asintótica del estadístico  $-2 \log \lambda(x)$ , como hemos hecho en el resto de contrastes. Sin embargo, se puede obtener la distribución exacta  $\lambda(x)^{2/n}$

bajo  $H_0$ . Se tiene que, si  $H_0 : \Sigma_{12} = \mathbf{0}$  es cierta,  $\lambda(x)^{2/n}$  sigue una distribución  $\Lambda$  de Wilks<sup>4</sup> de parámetros  $d_2, d_1, n - 1 - d_1$ . Es decir,

$$\lambda(x)^{2/n} = \frac{|S|}{|S_{11}| \cdot |S_{22}|} = \left| I_{d_2} - S_{22}^{-1} S_{21} S_{11}^{-1} S_{12} \right| \in \Lambda(d_2, d_1, n - 1 - d_1).$$

Como corresponde a un test de razón de verosimilitudes, se rechazará la hipótesis nula  $H_0 : \Sigma_{12} = \mathbf{0}$  cuando  $\lambda(x)$  sea pequeño, o equivalentemente, cuando  $|I_{d_2} - S_{22}^{-1} S_{21} S_{11}^{-1} S_{12}|$  sea pequeño. La distribución  $\Lambda$  de Wilks se puede transformar (ver Anexo A) en una  $F$  de Snédecor<sup>5</sup>. Puesto que las funciones para transformar una  $\Lambda$  de Wilks en una  $F$  de Snédecor son decrecientes, se rechazará la hipótesis nula  $H_0 : \Sigma_{12} = \mathbf{0}$  cuando su transformación en una  $F$  de Snédecor sea grande.

**Ejemplo.** En el primer capítulo habíamos presentado un estudio sobre diabetes en el que se analizaban diferentes variables de interés sobre pacientes que no presentan la enfermedad. Las variables de mayor relevancia para el estudio eran:

- $x_1$ = Intolerancia a la glucosa
- $x_2$ = Respuesta de la insulina a la glucosa oral
- $x_3$ = Resistencia de la insulina

Se recogían igualmente otras dos variables de menor relevancia:

- $y_1$ = Peso relativo
- $y_2$ = Glucemia basal

Suponiendo que el vector  $v = (y_1, y_2, x_1, x_2, x_3)'$  sigue una distribución normal multivariante, nos interesa contrastar la independencia de los subvectores  $y = (y_1, y_2)'$  y  $x = (x_1, x_2, x_3)'$ . Es decir, planteamos la hipótesis nula  $H_0 : \Sigma_{yx} = \mathbf{0}$ . Como habíamos visto al comentar los datos, podemos particionar la matriz de covarianzas muestral  $S$  y definir a partir de ella las submatrices  $S_{11}$ ,  $S_{22}$ ,  $S_{12}$  y  $S_{21}$ .

```
> diab <- read.table("data/diabetes.txt", header = TRUE)
> n <- dim(diab)[1]
> S <- cov(diab) * (n - 1)/n
> S
```

|    | y1         | y2         | x1           | x2          | x3         |
|----|------------|------------|--------------|-------------|------------|
| y1 | 0.01583006 | 0.2113327  | 0.7700567    | -0.2091966  | 2.141484   |
| y2 | 0.21133270 | 69.0250473 | 25.6587902   | -23.4352552 | -20.388469 |
| x1 | 0.77005671 | 25.6587902 | 1082.3610586 | 388.1077505 | 106.027410 |

<sup>4</sup>La distribución  $\Lambda$  de Wilks sirve para extender al caso multivariante la distribución  $F$  de Snédecor. Así, si la  $F$  de Snédecor se obtiene mediante el cociente de dos variables de tipo ji-cuadrado, la  $\Lambda$  de Wilks surge como el cociente de los determinantes de dos matrices de covarianzas.

<sup>5</sup>En una  $\Lambda(d, m_H, m_E)$ , si  $m_H = 2$  ( $d \geq 2$ ),

$$\frac{1 - \sqrt{\Lambda(d, 2, m_E)}}{\sqrt{\Lambda(d, 2, m_E)}} \stackrel{d}{=} \frac{d}{m_E - d + 1} F_{2d, 2(m_E - d + 1)}.$$

```

x2 -0.20919660 -23.4352552 388.1077505 2330.1025520 1117.797732
x3 2.14148393 -20.3884688 106.0274102 1117.7977316 2089.952741
> S11 <- S[1:2, 1:2]
> S12 <- S[1:2, 3:5]
> S21 <- S[3:5, 1:2]
> S22 <- S[3:5, 3:5]

```

Calculamos el estadístico del contraste  $\lambda(v)^{2/n}$ . Lo podemos hacer de dos formas:

```

> estad <- det(S)/(det(S11) * det(S22))
> estad
[1] 0.7240096
> estad <- det(diag(3) - solve(S22) %*% S21 %*% solve(S11) %*% S12)
> estad
[1] 0.7240096

```

Recordamos que si  $H_0$  es cierta,  $\lambda(v)^{2/n}$  sigue una distribución  $\Lambda$  de Wilks de parámetros  $d_2$ ,  $d_1$ ,  $n - 1 - d_1$ . En nuestro ejemplo,  $d_2 = 3$ ,  $d_1 = 2$  y  $n = 46$ , por lo tanto,  $\lambda(v)^{2/n}$  sigue una distribución  $\Lambda(3, 2, 43)$ . Se verifica además (ver Anexo A) que

$$\frac{41(1 - \sqrt{\Lambda(3, 2, 43)})}{3\sqrt{\Lambda(3, 2, 43)}} \stackrel{d}{=} F_{6,82}$$

Teniendo en cuenta que rechazamos  $H_0$  cuando  $\lambda(x)$  es pequeño y que la transformación anterior es una función decreciente, rechazarémos la hipótesis de independencia (para una significación  $\alpha$ ) si

$$\frac{41(1 - \sqrt{\Lambda(3, 2, 43)})}{3\sqrt{\Lambda(3, 2, 43)}} > f_{6,82,\alpha}$$

siendo  $f_{6,82,\alpha}$  el cuantil  $1 - \alpha$  de la distribución  $F_{6,82}$ .

```

> d1 <- 2
> d2 <- 3
> # Parámetros de la distribución Lambda de Wilks (d,mH,mE)
> d <- d2
> mH <- d1
> mE <- n - 1 - d1
> # Transformación del estadístico a F de Snedecor
> estadF <- (mE - d + 1)/d * (1 - sqrt(estad))/sqrt(estad)
> estadF
[1] 2.394993
> # Grados de libertad F de Snedecor
> glF1 <- 2 * d
> glF2 <- 2 * (mE - d + 1)
> qf(0.95, glF1, glF2)
[1] 2.211303
> pval <- 1 - pf(estadF, glF1, glF2)
> pval
[1] 0.03499556

```

Es decir, rechazamos la hipótesis nula de independencia.

### 2.7.2.1. Caso particular. Coeficiente de correlación múltiple

Consideremos que uno de los conjuntos de variables tenga un único elemento, por ejemplo,  $d_1 = 1$  y  $d_2 = d - 1$ . En esta situación,  $R_{11} = 1$ , y si denotamos  $\alpha = R_{21}$ , éste será un vector  $(d - 1)$ -dimensional. De este modo, el estadístico de contraste resulta:

$$\lambda(x)^{2/n} = \left| I_{d_2} - R_{22}^{-1} \alpha \alpha' \right| \stackrel{(a)}{=} 1 - \alpha' R_{22}^{-1} \alpha = 1 - R_{12} R_{22}^{-1} R_{21} = 1 - R^2 \in \Lambda(d_2, 1, n - 2)$$

siendo  $R$  el coeficiente de correlación múltiple entre la primera variable y las restantes. Usando que en general

$$\frac{1 - \Lambda(d, 1, m)}{\Lambda(d, 1, m)} = \frac{d}{m - d + 1} F_{d, m-d+1},$$

tenemos que

$$\frac{R^2}{1 - R^2} \in \frac{d - 1}{n - d} F_{d-1, n-d}$$

Finalmente, el coeficiente de correlación múltiple se considerará significativo cuando el estadístico anterior  $R^2/(1 - R^2)$  sea grande, comparado con la distribución  $F$  de Snédecor.

### 2.7.3. Contraste de independencia de todas las variables $H_0 : \Sigma$ es diagonal

La hipótesis nula consiste en suponer que las variables son incorrelacionadas, pero, a diferencia del test de esfericidad, no exigimos que tengan la misma varianza. De nuevo, la incorrelación equivale a independencia en un contexto de normalidad. Así, bajo la hipótesis nula, se maximiza la verosimilitud separadamente para cada variable, dando lugar a los estimadores de la media y la varianza de dichas variables y en consecuencia a los estimadores del vector de medias y matriz de covarianzas:

$$\bar{x} \quad \text{y} \quad \hat{\Sigma} = \text{diag}(s_1^2, \dots, s_d^2)$$

Bajo la alternativa, no hay ninguna clase de restricciones sobre los parámetros  $\mu$  y  $\Sigma$  que, por tanto, admiten como estimadores de máxima verosimilitud  $\bar{x}$  y  $S$ .

Entonces, aplicando el teorema general, el estadístico de contraste será:

$$-2 \log \lambda(x) = nd(a - \log g - 1) = -n \log |R|$$

siendo  $a$  y  $g$  las medias aritmética y geométrica, respectivamente, de los autovalores de la matriz  $\hat{\Sigma}^{-1}S$ , y  $R$  la matriz de correlaciones.

El último paso de la expresión anterior se debe a que  $\mathbf{R} = \hat{\Sigma}^{-1/2} \mathbf{S} \hat{\Sigma}^{-1/2}$  y esta matriz, aún siendo distinta de  $\hat{\Sigma}^{-1} \mathbf{S}$ , tiene los mismos autovalores que ella. Además, como la diagonal de una matriz de correlaciones está formada por unos, la traza vale  $d$  y, en consecuencia, la media de los autovalores vale uno,  $a = 1$ .

Por último, aproximamos la distribución del estadístico así:

$$-n \log |\mathbf{R}| \sim \chi^2_{\frac{1}{2}d(d-1)}$$

donde el número de grados de libertad resulta de la diferencia del número de parámetros independientes bajo la hipótesis nula y bajo la alternativa:  $d + \frac{1}{2}d(d+1) - (d+d) = \frac{1}{2}d(d-1)$ .

**Ejemplo.** Para ilustrar los contrastes de esfericidad habíamos generado, entre otros, datos de un vector normal multivariante con matriz de covarianzas diagonal y tal que no todas las variables tenían la misma varianza. En concreto, habíamos ejecutado el siguiente código para generar la muestra.

```
> library(mvtnorm)
> d <- 3
> mu <- c(0, 0, 0)
> Sigma <- diag(c(3, 5, 1))
> n <- 100
> x <- rmvnorm(n, mu, Sigma)
```

Si queremos contrastar  $H_0 : \Sigma$  es diagonal, debemos calcular la matriz de correlaciones muestral y su determinante. Como hemos visto, bajo  $H_0$  la distribución asintótica del estadístico es  $\chi^2_m$ , siendo  $m = d(d-1)/2$ . En este caso, para un nivel de significación  $\alpha = 0,05$ , no rechazamos la hipótesis nula, ya que el valor del estadístico es menor que  $\chi^2_{m,\alpha}$ . El valor crítico del estadístico nos lleva a aceptar sin lugar a dudas la hipótesis nula.

```
> R <- cor(x)
> estad <- -n * log(det(R))
> estad
[1] 0.6970712
> m <- 0.5 * d * (d - 1)
> qchisq(0.95, m)
[1] 7.814728
> pval <- 1 - pchisq(estad, m)
> pval
[1] 0.8738926
```

## 2.8. Comparación de poblaciones normales multivariantes

Vamos a considerar ahora varias poblaciones normales multivariantes, de las cuales extraemos muestras de manera independiente. En base a estas muestras contrastaremos hipótesis de igualdad o comparación entre los parámetros de las diferentes poblaciones. Sean entonces

$$\begin{aligned} x_{11}, \dots, x_{1n_1} &\in N_d(\mu_1, \Sigma_1) && \text{independientes,} \\ &\dots && \dots \\ x_{k1}, \dots, x_{kn_k} &\in N_d(\mu_k, \Sigma_k) && \text{independientes,} \end{aligned}$$

donde a su vez las  $k$  muestras independientes entre sí. El abanico de posibles problemas de comparación de estas  $k$  poblaciones es muy amplio. En lo que sigue hemos seleccionado algunos casos que nos parecen más interesantes.

### 2.8.1. Contraste de igualdad de medias de dos poblaciones normales multivariantes con matrices de covarianzas iguales

En primer lugar trataremos el contraste de igualdad de medias de dos poblaciones normales multivariantes, suponiendo que la matrices de covarianzas son desconocidas, pero asumiendo que son iguales. El caso de más de dos muestras será tratado en el capítulo dedicado al análisis multivariante de la varianza (MANOVA). Respecto de cómo realizar el contraste si las dos matrices de covarianzas son distintas, es un problema que ya estaba presente en observaciones univariantes. Se conoce como problema de Behrens-Fisher. La complejidad de este problema así como de sus soluciones, no es esencialmente mayor en el caso multivariante. No nos adentraremos en más detalles en este momento y nos ceñiremos al caso de matrices de covarianzas iguales. Repasemos en primer lugar el contraste de igualdad de medias de dos poblaciones normales univariantes suponiendo que las varianzas son desconocidas pero iguales.

#### 2.8.1.1. Revisión del caso unidimensional $H_0 : \mu_1 = \mu_2$ con $\sigma_1^2 = \sigma_2^2$ desconocidas

Disponemos de una muestra formada por  $n_1$  variables independientes y con la misma distribución  $N(\mu_1, \sigma_1^2)$  y una muestra formada por  $n_2$  variables independientes y con la misma distribución  $N(\mu_2, \sigma_2^2)$ . Es decir

$$\begin{aligned} x_{11}, \dots, x_{1n_1} &\in N(\mu_1, \sigma_1^2) && \text{independientes,} \\ x_{21}, \dots, x_{2n_2} &\in N(\mu_2, \sigma_2^2) && \text{independientes.} \end{aligned}$$

Suponemos que las varianzas  $\sigma_1^2$  y  $\sigma_2^2$  son desconocidas pero iguales. Si suponemos que las varianzas de las dos poblaciones son iguales, el mejor estimador de la varianza es:

$$s_p^2 = \frac{(n_1 - 1)s_{c1}^2 + (n_2 - 1)s_{c2}^2}{n_1 + n_2 - 2}.$$

En la ecuación anterior,  $s_{c1}^2$  y  $s_{c2}^2$  denotan la cuasivarianza muestral de la primera y segunda población, respectivamente. Si la hipótesis nula  $H_0 : \mu_1 = \mu_2$  es cierta, entonces

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_p^2}{n_1} + \frac{s_p^2}{n_2}}} \in t_{n_1 + n_2 - 2}.$$

Fijado un nivel de significación  $\alpha$ , rechazamos la hipótesis nula  $H_0 : \mu_1 = \mu_2$  frente a  $H_1 : \mu_1 \neq \mu_2$  si  $|t| \geq t_{\alpha/2}$  siendo  $t_{\alpha/2}$  el cuantil  $1 - \alpha/2$  de la distribución  $t$  de Student con  $n_1 + n_2 - 2$  grados de libertad. Equivalentemente

$$t^2 = \frac{n_1 n_2}{n_1 + n_2} (\bar{x}_1 - \bar{x}_2) \frac{1}{s_p^2} (\bar{x}_1 - \bar{x}_2). \quad (2.6)$$

### 2.8.1.2. Caso multidimensional $H_0 : \mu_1 = \mu_2$ con $\Sigma_1 = \Sigma_2$ desconocidas

En el caso multivariante disponemos de

$$\begin{aligned} x_{11}, \dots, x_{1n_1} &\in N_d(\mu_1, \Sigma_1) && \text{independientes} \\ x_{21}, \dots, x_{2n_2} &\in N_d(\mu_2, \Sigma_2) && \text{independientes} \end{aligned}$$

siendo a su vez las dos muestras independientes entre sí. Además supondremos que las dos matrices de covarianzas son iguales,  $\Sigma_1 = \Sigma_2$ . En estas condiciones pretendemos contrastar la hipótesis nula

$$H_0 : \mu_1 = \mu_2$$

Parece razonable basar el procedimiento de contraste en una medida de discrepancia o distancia entre estimadores de  $\mu_1$  y de  $\mu_2$ . De cada una de las dos poblaciones se pueden obtener estimadores de los parámetros correspondientes a cada población,

$$\begin{aligned} \bar{x}_1 &= \frac{1}{n_1} \sum_{j=1}^{n_1} x_{1j} & S_{c1} &= \frac{1}{n_1 - 1} \sum_{j=1}^{n_1} (x_{1j} - \bar{x}_1) (x_{1j} - \bar{x}_1)' \\ \bar{x}_2 &= \frac{1}{n_2} \sum_{j=1}^{n_2} x_{2j} & S_{c2} &= \frac{1}{n_2 - 1} \sum_{j=1}^{n_2} (x_{2j} - \bar{x}_2) (x_{2j} - \bar{x}_2)' \end{aligned}$$

Por ser las dos muestras independientes entre sí, también lo son los estadísticos procedentes de cada una de ellas. Además, la extensión del teorema de Fisher al caso multivariante garantiza que

$$\bar{x}_1 \in N_d(\mu_1, \Sigma/n_1), (n_1 - 1) S_{c1} \in \text{Wishart}_d(\Sigma, n_1 - 1) \text{ y son independientes}$$

$$\bar{x}_2 \in N_d(\mu_2, \Sigma/n_2), (n_2 - 1) S_{c2} \in \text{Wishart}_d(\Sigma, n_2 - 1) \text{ y son independientes.}$$

Además, como las dos muestras son independientes entre sí, también lo son los estadísticos obtenidos en base a cada una de ellas. Por tanto,

$$\bar{x}_1 - \bar{x}_2 \in N_d\left(\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2}\right) \Sigma\right),$$

$$(n_1 - 1) S_{c1} + (n_2 - 1) S_{c2} \in \text{Wishart}_d(\Sigma, n_1 + n_2 - 2)$$

y además son independientes. Denotemos mediante

$$S_P = \frac{(n_1 - 1) S_{c1} + (n_2 - 1) S_{c2}}{n_1 + n_2 - 2}$$

una media ponderada de  $S_{c1}$  y  $S_{c2}$ , que sirve como estimador de la matriz de covarianzas común  $\Sigma$ .

Entonces, bajo la hipótesis nula  $H_0 : \mu_1 = \mu_2$ ,

$$T^2 = \frac{n_1 n_2}{n_1 + n_2} (\bar{x}_1 - \bar{x}_2)' S_P^{-1} (\bar{x}_1 - \bar{x}_2) \in \Gamma^2(d, n_1 + n_2 - 2)$$

lo cual lo convierte en un estadístico adecuado para el contraste de dicha hipótesis. Además, el estadístico  $T^2$  se puede transformar fácilmente a una  $F$  de Snédecor utilizando que

$$\frac{n_1 + n_2 - d - 1}{(n_1 + n_2 - 2)d} T^2 = F_{d, n_1 + n_2 - d - 1}$$

**Ejemplo.** Se ha medido la longitud, la anchura y la altura del caparazón de 48 tortugas, 24 hembras y 24 machos. Los vectores de medias y matrices de covarianzas respectivos son:

$$\bar{x}_1 = \begin{pmatrix} 136,00 \\ 102,58 \\ 51,96 \end{pmatrix} \quad S_1 = \begin{pmatrix} 432,58 & 259,87 & 161,67 \\ & 164,57 & 98,99 \\ & & 63,87 \end{pmatrix}$$

$$\bar{x}_2 = \begin{pmatrix} 113,38 \\ 88,29 \\ 40,71 \end{pmatrix} \quad S_2 = \begin{pmatrix} 132,99 & 75,85 & 35,82 \\ & 47,96 & 20,75 \\ & & 10,79 \end{pmatrix}$$

Vamos a contrastar que los vectores de medias son iguales en ambos sexos, suponiendo que en cada sexo las observaciones son normales y que presentan la misma matriz de covarianzas. En primer lugar introducimos los datos en R:

```
> n1 <- 24
> n2 <- 24
> d <- 3
> bx1 <- c(136, 102.58, 51.96)
> bx2 <- c(113.38, 88.29, 40.71)
> S1 <- matrix(c(432.58, 259.87, 161.67, 259.87, 164.57, 98.99, 161.67, 98.99, 63.87),
+   nrow = 3, ncol = 3)
> S2 <- matrix(c(132.99, 75.85, 35.82, 75.85, 47.96, 20.75, 35.82, 20.75, 10.79), nrow = 3,
+   ncol = 3)
```

Calculamos ahora el estimador de la matriz de covarianzas común  $S_P$ .

```
> Sp <- (n1 * S1 + n2 * S2)/(n1 + n2 - 2)
```

Por último calculamos el valor del estadístico y su transformación a una  $F$  de Snédecor:

```
> estad <- n1 * n2/(n1 + n2) * t(bx1 - bx2) %*% solve(Sp) %*% (bx1 - bx2)
> estad
      [,1]
[1,] 66.85048
> f <- (n1 + n2 - d - 1)/((n1 + n2 - 2) * d) * estad
> f
      [,1]
[1,] 21.31464
> pval <- 1 - pf(f, d, n1 + n2 - d - 1)
> pval
      [,1]
[1,] 1.119998e-08
```

El nivel crítico obtenido es muy pequeño,  $1,1199977 \times 10^{-8}$ , por lo que se rechaza la igualdad de vectores de medias. Realmente ya podíamos observar que las medias muestrales eran diferentes, y que las varianzas no parecían suficientes para ocultar esas diferencias, pero aún así es conveniente efectuar un contraste como éste, que aporta un criterio objetivo.

### 2.8.2. Contraste de igualdad de matrices de covarianzas de normales multivariantes

Recordemos el modelo inicial de esta sección

$$\begin{aligned} x_{11}, \dots, x_{1n_1} &\in N_d(\mu_1, \Sigma_1) && \text{independientes} \\ &\dots\dots\dots \\ x_{k1}, \dots, x_{kn_k} &\in N_d(\mu_k, \Sigma_k) && \text{independientes} \end{aligned}$$

siendo a su vez las  $k$  muestras independientes entre sí. Nos planteamos el contraste de la hipótesis nula  $H_0 : \Sigma_1 = \dots = \Sigma_k$ . Los vectores de medias están exentos de restricciones tanto bajo la hipótesis nula como bajo la alternativa.

Vamos a obtener el test de razón de verosimilitudes. Lo primero que observamos es que, como las muestras son independientes entre sí, la función de verosimilitud se puede expresar como producto de las funciones de verosimilitud de cada una de las  $k$  poblaciones. Bajo la alternativa,

$$\begin{aligned}
\sup_{\mu_1, \Sigma_1, \dots, \mu_k, \Sigma_k} \log \prod_{i=1}^k L(\mu_i, \Sigma_i) &= \sum_{i=1}^k \sup_{\mu_i, \Sigma_i} \log L(\mu_i, \Sigma_i) \\
&= \sum_{i=1}^k \log L(\bar{x}_i, S_i) \\
&= \sum_{i=1}^k \left[ -\frac{n_i d}{2} \log(2\pi) - \frac{1}{2} n_i \log |S_i| - \frac{n_i d}{2} \right] \\
&= -\frac{nd}{2} \log(2\pi) - \frac{1}{2} \sum_{i=1}^k n_i \log |S_i| - \frac{nd}{2}
\end{aligned}$$

Bajo la hipótesis nula, denotemos  $\Sigma = \Sigma_1 = \dots = \Sigma_k$  a la matriz de covarianzas común,

$$\begin{aligned}
\sup_{\mu_1, \dots, \mu_k, \Sigma} \log \prod_{i=1}^k L(\mu_i, \Sigma) &= \sup_{\Sigma} \sum_{i=1}^k \sup_{\mu_i} \log L(\mu_i, \Sigma) \\
&= \sup_{\Sigma} \sum_{i=1}^k \log L(\bar{x}_i, \Sigma) \\
&= \sup_{\Sigma} \sum_{i=1}^k \left[ -\frac{n_i d}{2} \log(2\pi) - \frac{n_i}{2} \left( \log |\Sigma| + \text{traza} \left( \Sigma^{-1} S_i \right) \right) \right] \\
&= \sup_{\Sigma} \left[ -\frac{nd}{2} \log(2\pi) - \frac{n}{2} \left( \log |\Sigma| + \text{traza} \left( \Sigma^{-1} \frac{Q}{n} \right) \right) \right] \\
&= -\frac{nd}{2} \log(2\pi) - \frac{n}{2} \log \left| \frac{Q}{n} \right| - \frac{nd}{2}
\end{aligned}$$

siendo  $Q = \sum_{i=1}^k n_i S_i$ . Nótese que  $Q/n$  es el estimador de máxima verosimilitud de la matriz de covarianzas común,  $\Sigma$ , y resulta ser una media ponderada de las matrices de covarianzas muestrales provenientes de cada población.

Finalmente, el estadístico de razón de verosimilitudes adopta la forma:

$$\begin{aligned}
-2 \log \frac{\sup_{\mu_1, \dots, \mu_k, \Sigma} \prod_{i=1}^k L(\mu_i, \Sigma)}{\sup_{\mu_1, \Sigma_1, \dots, \mu_k, \Sigma_k} \prod_{i=1}^k L(\mu_i, \Sigma_i)} &= n \log \left| \frac{Q}{n} \right| - \sum_{i=1}^k n_i \log |S_i| \\
&= \sum_{i=1}^k n_i \log \left| \frac{Q}{n} S_i^{-1} \right| \sim \chi_{\frac{1}{2}d(d+1)(k-1)}^2
\end{aligned}$$

cuya distribución hemos aproximado por una ji-cuadrado cuyos grados de libertad resultan de la diferencia de parámetros independientes entre la hipótesis nula y la alternativa.

**Ejemplo.** Para el ejemplo anterior de las tortugas, vamos a contrastar que las matrices de covarianzas son iguales en ambos sexos, suponiendo que en cada sexo las observaciones son normales.

Calculamos el estimador de la matriz de covarianzas común bajo  $H_0$

```
> Q <- n1 * S1 + n2 * S2
> n <- n1 + n2
> Qn <- Q/n
```

Calculamos ahora el valor del estadístico y el  $p$ -valor correspondiente.

```
> estad <- n1 * log(det(Qn %*% solve(S1))) + n2 * log(det(Qn %*% solve(S2)))
> estad
[1] 26.98611
> k <- 2
> gl <- 0.5 * d * (d + 1) * (k - 1)
> pval <- 1 - pchisq(estad, gl)
> pval
[1] 0.0001456775
```

El nivel crítico obtenido es bastante pequeño,  $1,4567753 \times 10^{-4}$ , por lo que se rechaza la igualdad de matrices de covarianzas. A la vista de este resultado, y como en el ejemplo anterior se supuso igualdad de matrices de covarianzas para el contraste de igualdad de los vectores de medias, tendría sentido reconsiderar el procedimiento aplicado en aquella ocasión. Para ello, en lugar de emplear la estimación de una matriz de covarianzas común, habría que considerar las dos matrices de manera más separada. No entraremos en más detalle en este momento.

## 2.9. Contrastes de normalidad

### 2.9.1. Revisión del caso univariante

Se han desarrollado muchos procedimientos para el contraste de la normalidad en el caso univariante. Un procedimiento gráfico sencillo para evaluar la normalidad de un conjunto de observaciones de una variable es el Q-Q plot, que compara los cuantiles de la muestra con los cuantiles de la distribución normal univariante. En la Figura 2.8 se muestran los Q-Q plots correspondientes a muestras generadas a partir de distintas distribuciones. Cuando los puntos se acercan a la línea recta representada (como en la primera gráfica), no hay evidencia de falta de normalidad. La desviación de los puntos con respecto a la recta indica falta de normalidad. Por ejemplo, un Q-Q plot como el de los datos generados a partir de la  $t$  de Student, es típico en datos que provienen de distribuciones con colas más pesadas que la Normal. Para datos que provienen de distribuciones con colas menos pesadas que la Normal se suelen obtener Q-Q plots como el de los datos uniformes en la Figura 2.8. Un Q-Q plot como el de los datos generados a partir de la  $\chi^2$  es típico en datos que provienen de distribuciones asimétricas. Si bien el Q-Q plot nos puede servir para valorar de forma visual la normalidad de una muestra, es adecuado hacer uso de procedimientos objetivos. Veremos a continuación algunos de dichos procedimientos, aquellos que se extienden de manera más natural al caso multivariante. Serán los métodos basados en la asimetría, la kurtosis, y el test de Shapiro-Wilk.




Figura 2.8.: Funciones de densidad correspondientes a una distribución normal de media cero y varianza  $5/3$  (rojo),  $t$  de Student con 5 grados de libertad (azul), uniforme en  $[-\sqrt{5}, \sqrt{5}]$  (verde) y  $\chi^2$  con 5 grados de libertad (rosa) y Q-Q plots correspondientes a muestras generadas a partir de dichas distribuciones.

### 2.9.1.1. Test basado en la asimetría

Es bien conocido que la distribución normal es simétrica en torno a su media. Como además, la forma más común de desviarse respecto de la normalidad es por falta de simetría, por ejemplo en variables positivas, parece lógico construir un método de contraste en base a cierta medida de asimetría.

Si  $x_1, \dots, x_n$  es una muestra aleatoria simple (observaciones independientes e idénticamente distribuidas), el coeficiente de asimetría muestral se define como

$$A = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3} = \frac{1}{n} \sum_{i=1}^n \left( \frac{x_i - \bar{x}}{s} \right)^3$$

siendo  $\bar{x}$  la media muestral y  $s^2$  la varianza muestral. El coeficiente de asimetría es la media de las potencias cúbicas (también llamado momento de orden tres) de los valores estandarizados. Al estar estandarizados, habrá observaciones a ambos lados de la media, manteniendo un equilibrio (en orden uno). Sin embargo, la potencia tres que se emplea en el coeficiente de asimetría, rompe el equilibrio en caso de distribución asimétrica. En la Figura 2.9 se muestran los coeficiente de asimetría (para calcularlos puedes utilizar la función `skewness` de la librería `moments`) de datos generados de distintas distribuciones.

Si la distribución de los datos muestrales es normal, entonces el coeficiente de asimetría tiene distribución asintótica normal de media cero y varianza  $6/n$ , por lo que se puede emplear como estadístico de contraste el siguiente:

$$\sqrt{\frac{n}{6}} A \approx N(0, 1)$$




Figura 2.9.: Histogramas y coeficiente de asimetría correspondientes a datos generados de una distribución normal (izquierda), de una exponencial (centro) y de los mismos datos exponenciales tras cambiarles el signo (derecha). Los datos se representan en azul. En rojo, media muestral.

Se rechazará la normalidad, en base al coeficiente de asimetría, cuando el estadístico anterior sea muy grande (en positivo o negativo), en comparación con los cuantiles de la  $N(0, 1)$ .

**Ejemplo.** Vamos a presentar los resultados del contraste de normalidad basado en asimetría aplicado a datos simulados de distintas distribuciones. Mostramos en primer lugar los valores del coeficiente de asimetría, el estadístico de contraste y nivel crítico para datos simulados de la distribución normal.

```
> library(moments)
> n <- 30
> x <- rnorm(n)
> A <- skewness(x)
> A
[1] -0.09408815
> estad <- sqrt(n/6) * A
> estad
[1] -0.2103875
> pval <- 2 * (1 - pnorm(abs(estad)))
> pval
[1] 0.8333653
```

Como cabía esperar, la pequeña asimetría muestral de los datos normales no resulta significativa. Veamos ahora lo que ocurre cuando generamos datos de una distribución asimétrica como la exponencial.

```
> x <- rexp(n)
> A <- skewness(x)
> A
[1] 1.754585
> estad <- sqrt(n/6) * A
> estad
[1] 3.923371
> pval <- 2 * (1 - pnorm(abs(estad)))
> pval
[1] 8.73186e-05
```

### 2.9.1.2. Test basado en la kurtosis

Partimos de la muestra  $x_1, \dots, x_n$ . El momento de orden cuatro de los valores estandarizados se calcula como:

$$\frac{1}{n} \sum_{i=1}^n \left( \frac{x_i - \bar{x}}{s} \right)^4,$$

siendo  $\bar{x}$  la media muestral y  $s^2$  la varianza muestral. Recordemos que las características de posición se calculan mediante un momento de orden uno (la media), las de dispersión a través de un momento de orden dos (la varianza) y la asimetría con un momento de orden tres (el coeficiente de asimetría). El momento de orden cuatro permite medir características de forma, que son un refinamiento todavía más detallado en el análisis de la distribución. Si bien en algunos textos la kurtosis se define como el momento de orden 4, es más habitual definir la kurtosis como:

$$K = \frac{1}{n} \sum_{i=1}^n \left( \frac{x_i - \bar{x}}{s} \right)^4 - 3.$$

En esta definición se resta tres para que el coeficiente valga cero en la distribución normal. Así definida,  $K$  también se conoce como *exceso de kurtosis*.

En la Figura 2.8 se representaban tres distribuciones con la misma media, desviación típica y asimetría (asimetría cero, pues son simétricas). Son la  $t$  de Student con 5 grados de libertad, la normal y la uniforme, ambas con la misma media y desviación típica que la  $t_5$ . Para ello, se toma la normal con media cero y desviación típica  $\sqrt{5/3}$ , y la uniforme entre  $-\sqrt{5}$  y  $\sqrt{5}$ . Vemos que la distribución  $t$  de Student es la que presenta una mayor concentración de probabilidad en las proximidades de la media, así como en las colas (lejanías extremas)<sup>6</sup>. Esto hace que tenga un coeficiente de apuntamiento más grande. Por el contrario, la distribución uniforme es la que presenta menor densidad en las proximidades de la media, y carece de colas. En este caso, la densidad es más grande en los valores con desviaciones intermedias ( $\mu - \sigma$ ) y ( $\mu + \sigma$ ). Como resultado, el coeficiente de apuntamiento será más pequeño para la distribución uniforme. La distribución normal presenta un comportamiento intermedio entre la  $t_5$  y la uniforme.

Si una distribución tiene un apuntamiento similar al de la normal decimos que es **mesocúrtica**, si el apuntamiento es mayor se dice **leptocúrtica**, y si es menor se dice **platicúrtica**. La  $t$  de Student es una distribución leptocúrtica y la uniforme platicúrtica.

Volviendo al propósito de contraste de la normalidad, si estamos ante una distribución simétrica, podemos valorar una posible desviación del modelo normal en función de su apuntamiento o kurtosis. Rechazaremos la normalidad si la kurtosis muestral es mucho mayor o mucho menor que cero, que es lo que corresponde a la distribución normal.

<sup>6</sup>El fenómeno de la cola es difícilmente perceptible en la Figura 2.8. Aún así, se puede observar que el trazo rojo, correspondiente a la  $t_5$ , se encuentra ligeramente más elevado que el azul, correspondiente a la normal, en las colas. Es una pequeña diferencia a la vista, porque ambas densidades convergen a cero en las colas. Sin embargo, la consecuencia es que la  $t_5$  presenta una frecuencia no despreciable de observaciones muy grandes, cosa que no ocurre con la normal. Estas observaciones grandes (o extremas), al elevarlas a la potencia cuarta, aportan una contribución considerable a la kurtosis.

Se puede demostrar que si la distribución de los datos muestrales es normal, entonces la kurtosis tiene distribución asintótica normal de media cero y varianza  $24/n$ , por lo que se puede emplear como estadístico de contraste el siguiente:

$$\sqrt{\frac{n}{24}} K \approx N(0, 1).$$

Se rechazará la normalidad, en base a la kurtosis, cuando el estadístico anterior sea muy grande (en positivo o negativo), en comparación con los cuantiles de la  $N(0, 1)$ .

**Ejemplo.** Vamos a extraer muestras simuladas de tamaño 100 de cada una de las tres distribuciones que se han comentado en esta sección, y cuyas densidades se representan en la Figura 2:  $t_5$  de Student, normal y uniforme. Aplicamos a continuación el contraste de normalidad basado en la kurtosis. En primer lugar, generamos datos de una normal con varianza  $5/3$ :

```
> library(moments)
> n <- 100
> x <- rnorm(n, sd = sqrt(5/3))
> K <- kurtosis(x) - 3
> K
[1] 0.6656975
> estad <- sqrt(n/24) * K
> estad
[1] 1.358849
> pval <- 2 * (1 - pnorm(abs(estad)))
> pval
[1] 0.1741943
```

Aplicamos ahora el contraste a una muestra generada a partir de una  $t_5$ :

```
> x <- rt(n, 5)
> K <- kurtosis(x) - 3
> K
[1] 1.095394
> estad <- sqrt(n/24) * K
> estad
[1] 2.235964
> pval <- 2 * (1 - pnorm(abs(estad)))
> pval
[1] 0.02535411
```

Por último, aplicamos el contraste a una muestra generada a partir de la distribución uniforme en el intervalo  $[-\sqrt{5}, \sqrt{5}]$ .

```

> x <- runif(n, -sqrt(5), sqrt(5))
> K <- kurtosis(x) - 3
> K
[1] -1.031331
> estad <- sqrt(n/24) * K
> estad
[1] -2.105195
> pval <- 2 * (1 - pnorm(abs(estad)))
> pval
[1] 0.03527432

```

Los resultados son los que cabía esperar. Así, el coeficiente de apuntamiento muestral es próximo a cero para la normal, negativo para la uniforme y positivo para la  $t_5$ . Al estandarizarlos, se obtienen cantidades comparables con la  $N(0, 1)$ , que arrojan los niveles críticos que se muestran en las salidas. Las discrepancias más significativas se obtienen con la  $t_5$  de Student.

### 2.9.1.3. Test de Shapiro-Wilk

Veamos ahora uno de los contrastes más utilizados para contrastar normalidad. Se trata del test de Shapiro-Wilk, que plantea como hipótesis nula que la muestra  $x_1, \dots, x_n$  proviene de una población normal. Este procedimiento es más general, pues permite detectar tanto defectos de simetría como de kurtosis, o incluso de otro tipo no considerado por los tests anteriores. Consideremos los datos estandarizados

$$z_i = \frac{x_i - \bar{x}}{s} \quad i \in \{1, \dots, n\}.$$

El estadístico de Shapiro-Wilk se construye de la siguiente manera:

$$W = \sum_{i=1}^{\lfloor n/2 \rfloor} a_{i,n} \left( z_{(n-i+1):n} - z_{i:n} \right)$$

siendo  $z_{1:n} < \dots < z_{n:n}$  la muestra ordenada de los datos estandarizados y  $a_{i,n}$  ciertas constantes. Consiste en calcular las distancias entre los datos de la muestra ordenada, simétricos respecto de la mediana, esto es, la distancia entre el primero y el último, el segundo y el penúltimo, y así sucesivamente; en general el  $z_{i:n}$  y el  $z_{(n-i+1):n}$ . El propósito es comparar estas distancias con las que habría en una muestra de observaciones normales. Podremos llevar a cabo el test de Shapiro-Wilk en R mediante la función `shapiro.test`, como se muestra en el siguiente ejemplo.

**Ejemplo.** Vamos a extraer muestras simuladas de tamaño 100 de cada una de las distribuciones vistas en las secciones anteriores: normal,  $\chi^2$ , uniforme y  $t$  de Student, ver Figura 2.8. Los resultados del test de Shapiro-Wilk se muestran a continuación:

```

> n <- 30
> x1 <- rnorm(n, sd = sqrt(5/3))
> x2 <- rt(n, 5)
> x3 <- runif(n, -sqrt(5), sqrt(5))
> x4 <- rchisq(n, 5)
> shapiro.test(x1)

      Shapiro-Wilk normality test

data:  x1
W = 0.9515, p-value = 0.1854
> shapiro.test(x2)

      Shapiro-Wilk normality test

data:  x2
W = 0.88543, p-value = 0.003765
> shapiro.test(x3)

      Shapiro-Wilk normality test

data:  x3
W = 0.90155, p-value = 0.009167
> shapiro.test(x4)

      Shapiro-Wilk normality test

data:  x4
W = 0.89688, p-value = 0.007053

```

En los tres casos donde los datos no proceden de una distribución normal los niveles críticos conducen al rechazo de la normalidad.

## 2.9.2. Contraste de la normalidad multivariante

En esta sección veremos cómo se pueden extender los conceptos de asimetría y kurtosis al caso multivariante. Asimismo, también se verá la manera de extender el test de Shapiro-Wilk con datos multivariantes. Empezamos estudiando ciertos conceptos previos en relación con este tipo de contrastes.

### 2.9.2.1. Invariancia, estandarización, y distancias y ángulos de Mahalanobis

Sabemos que la normalidad se conserva frente a traslaciones y transformaciones lineales, esto es:

Para cualesquiera  $\mathbf{b}$  vector de dimensión  $d$  y  $\mathbf{A}$  matriz  $d \times d$  no singular,

$$\mathbf{x} \text{ tiene distribución normal} \Leftrightarrow \mathbf{Ax} + \mathbf{b} \text{ tiene distribución normal}$$

Por tanto, si estamos contrastando que el vector  $x$  tenga distribución normal, tanta evidencia habrá a favor o en contra de esta hipótesis, si empleamos los datos de  $x$  como si empleamos los datos transformados  $Ax + b$ .

Diremos que un test de normalidad multivariante es **invariante** si proporciona los mismos resultados con los datos originales que con datos transformados por traslaciones o transformaciones lineales.

Nos parece que la invariancia es una propiedad deseable para un test de normalidad. Ahora, si somos libres de transformar los datos, se nos ocurre aplicar la estandarización multivariante, pues es una transformación que los simplifica al suprimirles la media y la matriz de covarianzas. Pasamos entonces de los datos originales  $x_1, \dots, x_n$  a los datos estandarizados:

$$z_i = S^{-1/2} (x_i - \bar{x})$$

siendo  $\bar{x}$  la media muestral y  $S$  la matriz de covarianzas muestral. La idea es que si los datos originales  $x_1, \dots, x_n$  provienen de una distribución normal, los datos estandarizados  $z_1, \dots, z_n$  deberían presentar una distribución normal estándar, esto es, deberían mostrar un aspecto esférico, sin especial predilección por unas direcciones frente a otras, y con mayor concentración en la zona central.

Las distancias de Mahalanobis de las observaciones al vector de medias se pueden expresar así:

$$r_{ii} = (x_i - \bar{x})' S^{-1} (x_i - \bar{x}) = z_i' z_i = \|z_i\|^2.$$

Consideramos ahora los valores

$$r_{ij} = (x_i - \bar{x})' S^{-1} (x_j - \bar{x}) = z_i' z_j.$$

Además, como  $z_i' z_j$  representa un producto escalar de vectores, se tiene también

$$r_{ij} = z_i' z_j = \|z_i\| \cdot \|z_j\| \cdot \cos(\theta_{ij})$$

siendo  $\theta_{ij}$  el ángulo que forman las observaciones estandarizadas  $z_i$  y  $z_j$  en el espacio usual. El ángulo  $\theta_{ij}$  se conoce como **ángulo de Mahalanobis** que forman las observaciones  $x_i$  y  $x_j$  en el espacio original. En la Figura 2.10 se representa una muestra de observaciones, que han sido estandarizadas. Por tanto, las distancias y los ángulos de Mahalanobis coinciden con las distancias y ángulos ordinarios en esta representación. El punto central, representado en color azul, es la posición del vector de medias. En el gráfico se han destacado también dos puntos, denotados por (a) y (b), respectivamente.

Las longitudes de las flechas, que son sus distancias al vector de medias, serían las raíces cuadradas de sus valores  $r_{ii}$  y  $r_{jj}$ . El valor  $r_{ij}$  para este par de puntos sería el producto de las longitudes, multiplicado por el coseno del ángulo que forman las dos flechas. Así, si el ángulo es de 90 grados,  $r_{ij}$  vale cero, si es menor de 90 grados  $r_{ij}$  es positivo, y si es mayor de 90 grados es negativo. De este modo,  $r_{ij}$  refleja si los dos puntos (a) y (b) están del mismo lado o si se encuentran en lados opuestos. Esto será utilizado en la sección siguiente para definir una medida de asimetría.




Figura 2.10.: Representación de los valores  $r_{ij}$ .

### 2.9.2.2. Tests basados en medidas de asimetría y kurtosis

Existen diversas formas de definir medidas de asimetría y kurtosis con datos multivariantes. Consideraremos aquí las introducidas por Mardia (1970).

**2.9.2.2.1. Coeficiente de asimetría multivariante** Así, calcularemos la asimetría de la siguiente manera:

$$A_m = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n r_{ij}^3$$

En la Figura 2.10 se ofrece una representación que resulta muy útil para interpretar los valores  $r_{ij}$ . Como vimos en la sección anterior,  $r_{ij}$  es positivo si los dos puntos en cuestión, (a) y (b) en el gráfico, forman un ángulo inferior a 90 grados. Por el contrario,  $r_{ij}$  será negativo si el ángulo es superior a 90 grados. Siempre se cumple que

$$\sum_{i=1}^n r_{ij} = 0 = \sum_{j=1}^n r_{ij}$$

esto es, se cancelan los valores positivos con los negativos, lo cual es muy comprensible, pues el vector de media ocupa la posición central. Esto también se cumplía en el caso univariante.

Sin embargo, al elevar al cubo los  $r_{ij}$ , se desequilibra este balance. Para mantener el equilibrio, por cada punto, como el (b), tendría que haber otro punto, que se representa como -(b) en el gráfico, situado en la posición contraria a (b) respecto del vector de medias. Los puntos (b) y -(b) tendrían los mismos valores  $r_{ij}$  con el resto de la muestra, pero con signos cambiados. Al efectuar cualquier potencia impar, como el cubo, se cancelarían. Así, si cada punto de la muestra tuviera otro punto simétrico en la propia muestra, el coeficiente de asimetría valdría cero. En otro caso, si la simetría se cumple aceptablemente, el coeficiente sería sólo algo mayor que cero, mientras que si hay un comportamiento claramente distinto en lados opuestos, el coeficiente de asimetría sería más grande.

En la Figura 2.11 se presentan ejemplos de muestras bivalentes generadas a partir de diferentes distribuciones. Los puntos en negro representan los datos muestrales y en rojo se representa el vector de medias muestral y la elipse asociada a la matriz de covarianzas muestral.

Los dos primeros gráficos representan datos simulados de distintas distribuciones normales. Como se esperaba, en ambos casos el valor del coeficiente de asimetría muestral  $A_m$  se aproxima a cero ya que, a nivel teórico, la distribución normal multivariante es simétrica.

A continuación se representan datos bivalentes con marginales exponenciales e independientes. La asimetría del modelo se refleja en el valor del coeficiente de asimetría muestral. En el cuarto gráfico se han simulados tres grupos de datos normales multivariantes. Esto hace que la distribución de la muestra completa no sea normal. De hecho, la presencia de varios grupos es una causa muy común de falta de normalidad. También es común que produzca un efecto de asimetría, que permite detectar esa falta de normalidad. Por último, se han simulado observaciones uniformes en el cuadrado unidad. El modelo teórico es simétrico y de hecho el valor muestral de  $A_m$  es próximo a cero.

Como test de normalidad, y dado que la distribución normal es simétrica, rechazaremos la normalidad, por falta de simetría, si el coeficiente  $A_m$  es demasiado grande, comparado con ciertos valores tabulados correspondientes a muestras normales. Aproximaremos estos valores por simulación.




Figura 2.11.: Ejemplos de muestras bivalentes para su contraste de normalidad.

**2.9.2.2.2. Coeficiente de kurtosis multivariante** El coeficiente de kurtosis propuesto por Mardia (1970) adopta la forma siguiente:

$$K_m = \frac{1}{n} \sum_{i=1}^n r_{ii}^2.$$

A la vista de esta definición, el coeficiente de kurtosis está basado únicamente en los valores  $r_{ii}$ . Como  $r_{ii}$  es el cuadrado de la distancia del dato  $i$ -ésimo al vector de medias, los valores  $r_{ii}^2$  que figuran en la definición de  $K_m$  son las potencias cuartas de estas distancias.

Por tanto, el coeficiente  $K_m$  generaliza la medida de kurtosis al caso multivariante como estas potencias cuartas de la distancia a la media. De esta manera, para la kurtosis no importará la dirección o sentido de la desviación respecto de la media, sino únicamente la magnitud de dicha desviación. Se trata, pues, de detectar si los datos se agrupan en torno a la Media  $\pm$  Desviación típica, que en el caso multivariante sería la elipse en rojo de la Figura 11, o si por el contrario se agrupan o muy cerca de la media o muy lejos de ésta. Si están cerca de la elipse la kurtosis será pequeña (distribución platicúrtica), y si están o muy cerca de la media o muy lejos de ella, la kurtosis será grande y diremos que la distribución es leptocúrtica.

Igual que en el caso univariante, la distribución normal multivariante presenta un valor intermedio de kurtosis (diríamos que es mesocúrtica). Se puede demostrar que un vector normal  $d$ -dimensional tiene kurtosis multivariante igual a  $d(d+2)$ . En la Figura 2.11 se observa que el valor del coeficiente de kurtosis  $K_m$  es próximo a  $d(d+2) = 8$  para las muestras normales. Los datos generados de la mixtura de normales y de la uniforme presentan valores menores, y serían platicúrticos. Los datos generados de la exponencial son leptocúrticos.

Respecto del contraste de normalidad, el test basado en la kurtosis rechazará la normalidad tanto para valores demasiado grandes como para valores demasiado pequeños de  $K_m$ . De nuevo, los valores críticos están tabulados y los aproximaremos por simulación.

### 2.9.2.3. Extensión multivariantes del test de Shapiro-Wilk

Existen diversas maneras de extender el test de Shapiro-Wilk. Nos centraremos en una idea muy sencilla, que surge del concepto de invariancia. Así, el vector aleatorio es normal multivariante si y sólo si su estandarización lo es, esto es:

$$\mathbf{x} \in N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \iff \mathbf{z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{x} - \boldsymbol{\mu}) \in N_d(\mathbf{0}, \mathbf{I}_d)$$

Lo interesante es que  $\mathbf{z}$  tiene sus  $d$  componentes (las  $d$  variables) incorrelacionadas, y entonces  $\mathbf{z}$  es normal si y sólo si sus componentes son normales. Ante tal resultado, basta con comprobar si las  $d$  variables resultantes de la estandarización multivariante son normales. Volvemos entonces a los datos estandarizados:

$$\mathbf{z}_i = \mathbf{S}^{-1/2}(\mathbf{x}_i - \bar{\mathbf{x}})$$

siendo  $\bar{\mathbf{x}}$  la media muestral y  $\mathbf{S}$  la matriz de covarianzas muestral.

Si  $W_1, \dots, W_d$  son los estadísticos de Shapiro-Wilk de cada componente de  $\mathbf{z}_1, \dots, \mathbf{z}_n$ , entonces podemos considerar el estadístico de Shapiro-Wilk multivariante:

$$W_{VG} = \frac{1}{d} \sum_{j=1}^d W_j$$

Este estadístico ha sido propuesto por Villasenor Alva y González Estrada (2009). Se rechazará la normalidad cuando  $W_{VG}$  sea pequeño, en comparación con ciertos valores tabulados, que de nuevo podemos aproximar por simulación.

### 3. Análisis Multivariante de la Varianza

En este capítulo vemos la extensión del análisis de la varianza univariante (ANOVA) al caso de que la variable respuesta es multivariante (MANOVA). En primer lugar repasaremos los aspectos fundamentales del caso unidimensional. Para el caso multidimensional veremos que, en lugar del test  $F$ , surgen los test de la  $\Lambda$  de Wilks y sus alternativas.

#### 3.1. Revisión del modelo de análisis de la varianza univariante ANOVA

En el modelo de análisis de la varianza univariante, disponemos de  $k$  muestras independientes que provienen de poblaciones normales con la misma varianza (modelo homocedástico). Es decir,

$$\begin{array}{llll} y_{11} & y_{12} & \cdots & y_{1n_1} \text{ de una población } N(\mu_1, \sigma^2), \\ y_{21} & y_{22} & \cdots & y_{2n_2} \text{ de una población } N(\mu_2, \sigma^2), \\ \cdots & \cdots & \cdots & \cdots \\ y_{k1} & y_{k2} & \cdots & y_{kn_k} \text{ de una población } N(\mu_k, \sigma^2). \end{array}$$

Cada una de las  $k$  muestras (también denominadas grupos) está formada por variables independientes y con la misma distribución. Se supone además que las  $k$  muestras son independientes entre sí. Los grupos pueden corresponder, por ejemplo, a diferentes tratamientos aplicados por el investigador en un experimento. El primer objetivo de un modelo de análisis de la varianza es contrastar la hipótesis nula de que todas las medias son iguales. Planteamos así el contraste:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k.$$

**Ejemplo.** En el trabajo clásico de Andrews and Herzberg (1985), se comparan manzanos sobre seis tipos de portainjertos. En concreto, se analizan ocho manzanos sobre cada tipo de portainjerto. Para cada manzano se determina la circunferencia del tronco (mm  $\times$  100) a los 4 años. Los datos se encuentran en el fichero `tronco.txt`.

```
> tronco <- read.table("data/tronco.txt", header = TRUE)
> head(tronco)
  portainjerto cir4
1           1 1.11
2           1 1.19
3           1 1.09
```

```

4          1 1.25
5          1 1.11
6          1 1.08
> table(tronco[, 1])

1 2 3 4 5 6
8 8 8 8 8 8

```

En este caso  $k = 6$  (tipos de portainjertos) y  $n_i = 8$  para  $i = 1, \dots, 6$  (número de árboles para cada tipo de portainjerto). El objetivo es determinar si existen diferencias significativas en el crecimiento de los manzanos debidas al tipo de portainjerto, ver Figura 3.1




Figura 3.1.: Boxplot para la circunferencia de tronco a los 4 años en cada tipo de portainjerto.

Denotamos mediante  $\bar{y}_{i\bullet}$  a la media muestral procedente de la población  $i$ -ésima, es decir,

$$\bar{y}_{i\bullet} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij}$$

para  $i = 1, \dots, k$ . Sea  $n = n_1 + \dots + n_k$  el número total de datos. Entonces, la media global de la muestra se calcula como:

$$\bar{y}_{\bullet\bullet} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} y_{ij}.$$

Se puede expresar el modelo de análisis multivariante de la varianza como un caso particular del modelo de regresión lineal. El modelo para cada observación es:

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij} = \mu_i + \epsilon_{ij}$$

con  $i = 1, \dots, k$  y  $j = 1, \dots, n_i$ . En el modelo,  $\mu_i = \mu + \alpha_i$  es la media de la población  $i$ -ésima.

Queremos comparar las medias muestrales  $\bar{y}_{i\bullet}$  para ver si son suficientemente distintas como para llevarnos a pensar que las medias de cada población difieren. Para determinar si hay

diferencias significativas entre las respuestas medias a distintos niveles del factor, el ANOVA descompone la variabilidad total. La variabilidad total, medida a través de la desviación cuadrática de los datos a la media global, admite la siguiente descomposición:

$$\sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 + \sum_{i=1}^k \sum_{j=1}^{n_i} (\bar{y}_{i.} - \bar{y}_{..})^2.$$

Al igual que en regresión, lo representamos mediante la **tabla de análisis de la varianza**.

| Fuente de variación    | Suma de cuadrados                                         | Grados de libertad |
|------------------------|-----------------------------------------------------------|--------------------|
| Entre poblaciones (VE) | $\sum_{i=1}^k n_i (\bar{y}_{i.} - \bar{y}_{..})^2$        | $k - 1$            |
| Error (VNE)            | $\sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2$ | $n - k$            |
| Total (VT)             | $\sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{..})^2$ | $n - 1$            |

Nos fijamos en que VE representa las desviaciones de las medias muestrales de cada población respecto a la media global. Sirve por lo tanto como medición de la variabilidad entre poblaciones (inter-grupos). Además, VNE representa las desviaciones de cada dato respecto a la media muestral de la población de la que procede. Es útil como medida de la variabilidad interna (intra-grupos), presente entre los individuos de la misma población. Para efectuar el contraste de igualdad de las medias debemos considerar un estadístico que mida la discrepancia respecto a la hipótesis nula de igualdad. Si las medias fueran iguales, las desviaciones entre poblaciones no deberían ser muy grandes, comparadas con las desviaciones dentro de cada población. Un estadístico razonable para el contraste es

$$F = \frac{VE/(k-1)}{VNE/(n-k)} = \frac{\sum_{i=1}^k \sum_{j=1}^{n_i} (\bar{y}_{i.} - \bar{y}_{..})^2 / (k-1)}{\sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 / (n-k)}.$$

Si la hipótesis nula  $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$  es cierta,  $F$  presenta una distribución  $F$  de Snédecor  $F \in F_{(k-1), (n-k)}$ . Rechazaremos  $H_0$  cuando para valores grandes de  $F$ .

**Ejemplo.** Volvemos sobre el ejemplo de manzanos sobre diferentes tipos de portainjertos. Existen distintas formas de realizar un ANOVA en R. Esta es una de ellas:

```
> x <- factor(tronco[, 1])
> y <- tronco[, 2]
> z <- lm(y ~ x)
> anova(z)
Analysis of Variance Table

Response: y
      Df Sum Sq Mean Sq F value Pr(>F)
x       5  0.07356  0.0147121    1.931  0.1094
Residuals 42  0.31999  0.0076187
```

Vemos que el  $p$ -valor indica que no hay evidencias significativas para rechazar la hipótesis nula de igualdad de medias.

### 3.2. MANOVA con un factor de variación

En general, cuando disponemos de una muestra, no medimos una única variable. Lo más habitual es realizar mediciones de diversas variables dependientes sobre cada unidad muestral.

**Ejemplo.** En el trabajo clásico de Andrews and Herzberg (1985), se comparan manzanos sobre seis tipos de portainjertos. En concreto, se analizan ocho manzanos sobre cada tipo de portainjerto. Para cada manzano se determina  $\mathbf{y} = (y_1, \dots, y_4)'$ , siendo  $y_1$  la circunferencia del tronco (mm  $\times$  100) a los 4 años,  $y_2$  el crecimiento (m) a los 4 años,  $y_3$  la circunferencia del tronco (mm  $\times$  100) a los 15 años e  $y_4$  el peso del árbol (lb  $\times$  1000) a los 15 años. Los datos se encuentran en el fichero `manzanos.txt`.

```
> manzanos <- read.table("data/manzanos.txt", header = TRUE)
> head(manzanos)
  portainjerto cir4  crec4 cir15 peso15
1           1 1.11 2.569  3.58  0.760
2           1 1.19 2.928  3.75  0.821
3           1 1.09 2.865  3.93  0.928
4           1 1.25 3.844  3.94  1.009
5           1 1.11 3.027  3.60  0.766
6           1 1.08 2.336  3.51  0.726
```

Se trata de comparar las medias de  $k$  poblaciones normales multivariantes independientes y con matriz de dispersión común. Consideremos entonces  $k$  muestras independientes

$$\begin{array}{ccccccc} y_{11} & y_{12} & \cdots & y_{1n_1} & \text{de una población} & N_d(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}), \\ y_{21} & y_{22} & \cdots & y_{2n_2} & \text{de una población} & N_d(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}), \\ \dots & \dots & \dots & \dots & \dots & \dots \\ y_{k1} & y_{k2} & \cdots & y_{kn_k} & \text{de una población} & N_d(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}). \end{array}$$

Cada una de las  $k$  muestras está formada por vectores independientes y con la misma distribución. Se trata, por tanto, de  $k$  muestras aleatorias simples. Además se supone que las  $k$  muestras son, entre sí, independientes. La hipótesis de homocedasticidad consiste ahora en que la matriz de covarianzas se supone que es la misma en todas las poblaciones. Recuerda que la homocedasticidad se puede contrastar mediante un test de igualdad de las matrices de covarianzas.

#### 3.2.1. Descomposición de la variabilidad. Contraste de igualdad de medias

Igual que ocurría en el caso univariante, se puede expresar el modelo de análisis multivariante de la varianza como un caso particular del modelo lineal múltiple (la variable respuesta es un vector  $d$ -dimensional). Para cada observación se tiene,

$$y_{ij} = \boldsymbol{\mu} + \boldsymbol{\alpha}_i + \boldsymbol{\epsilon}_{ij} = \boldsymbol{\mu}_i + \boldsymbol{\epsilon}_{ij}$$

con  $i = 1, \dots, k$  y  $j = 1, \dots, n_i$ . En el modelo,  $\boldsymbol{\mu}_i = \boldsymbol{\mu} + \boldsymbol{\alpha}_i$  es el vector de medias de la población  $i$ -ésima.

El objetivo del modelo de análisis de la varianza multivariante es contrastar la hipótesis nula de que los vectores de medias son iguales. Planteamos así el contraste:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k.$$

Es decir,

$$H_0 : \begin{pmatrix} \mu_{11} \\ \mu_{12} \\ \vdots \\ \mu_{1d} \end{pmatrix} = \begin{pmatrix} \mu_{21} \\ \mu_{22} \\ \vdots \\ \mu_{2d} \end{pmatrix} = \cdots = \begin{pmatrix} \mu_{k1} \\ \mu_{k2} \\ \vdots \\ \mu_{kd} \end{pmatrix}.$$

Al igual que en el caso univariante, podremos calcular la media global de la muestra y las medias muestrales por grupo. Así denotamos mediante  $\bar{y}_{i\bullet}$  a la media muestral procedente de la población  $i$ -ésima, es decir,

$$\bar{y}_{i\bullet} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij}$$

para  $i = 1, \dots, k$ . Sea  $n = n_1 + \dots + n_k$  el número total de datos. Entonces, la media global de la muestra se calcula como:

$$\bar{y}_{\bullet\bullet} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} y_{ij}$$

Para determinar si hay diferencias significativas entre las respuestas medias a distintos niveles del factor, el MANOVA descompone la variabilidad total de forma similar a como se hacía en el ANOVA. La diferencia está en que ahora la variabilidad total se medirá mediante la siguiente matriz  $d \times d$ :

$$\sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{\bullet\bullet}) (y_{ij} - \bar{y}_{\bullet\bullet})'.$$

Por analogía con el caso univariante, en el que se comparaban la variabilidad inter-grupos con la variabilidad intra-grupos, se calculan ahora las matrices

$$H = \sum_{i=1}^k n_i (\bar{y}_{i\bullet} - \bar{y}_{\bullet\bullet}) (\bar{y}_{i\bullet} - \bar{y}_{\bullet\bullet})'$$

y

$$E = \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i\bullet}) (y_{ij} - \bar{y}_{i\bullet})'.$$

Se muestra a continuación la **tabla del análisis multivariante de la varianza** o tabla MANOVA:

| Fuente de variación | Matriz de covarianzas                                                                                                                                                | Grados de libertad       |
|---------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------|
| Entre poblaciones   | $\mathbf{H} = \sum_{i=1}^k n_i (\bar{\mathbf{y}}_{i\bullet} - \bar{\mathbf{y}}_{\bullet\bullet}) (\bar{\mathbf{y}}_{i\bullet} - \bar{\mathbf{y}}_{\bullet\bullet})'$ | $k - 1$                  |
| Error               | $\mathbf{E} = \sum_{i=1}^k \sum_{j=1}^{n_i} (\mathbf{y}_{ij} - \bar{\mathbf{y}}_{i\bullet}) (\mathbf{y}_{ij} - \bar{\mathbf{y}}_{i\bullet})'$                        | $\sum_{i=1}^k (n_i - 1)$ |
| Total               | $\mathbf{E}_H = \sum_{i=1}^k \sum_{j=1}^{n_i} (\mathbf{y}_{ij} - \bar{\mathbf{y}}_{\bullet\bullet}) (\mathbf{y}_{ij} - \bar{\mathbf{y}}_{\bullet\bullet})'$          | $\sum_{i=1}^k n_i - 1$   |

Observamos que esta tabla no es más que una extensión de la tabla ANOVA al caso multivariante. El sentido común nos invita a rechazar la hipótesis nula cuando la variabilidad proveniente de las diferencias entre poblaciones (que medimos mediante la matriz  $\mathbf{H}$ ) sea grande comparada con la proveniente del error (medida por  $\mathbf{E}$ ).

### 3.2.2. El estadístico $\Lambda$ de Wilks

El contraste de razón de verosimilitudes para el contraste  $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$  viene dado por

$$\Lambda = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|}.$$

Este estadístico, conocido como estadístico de Wilks, compara la matriz  $\mathbf{E}$ , que mide la variabilidad intra-grupos, con la matriz  $\mathbf{E}_H = \mathbf{E} + \mathbf{H}$ , que mide la variabilidad total<sup>1</sup>. Se puede demostrar que, bajo la hipótesis nula,

$$\begin{aligned} \mathbf{H} &\in \text{Wishart}_d(\Sigma, k - 1) \\ \mathbf{E} &\in \text{Wishart}_d(\Sigma, n - k) \end{aligned}$$

y además son independientes. Entonces tenemos que<sup>2</sup>

$$\frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} \in \Lambda(d, k - 1, n - k).$$

Por tanto, rechazaremos la hipótesis nula cuando el estadístico  $|\mathbf{E}|/|\mathbf{E} + \mathbf{H}|$  tome un valor menor que el cuantil  $\alpha$  de la distribución  $\Lambda(d, k - 1, n - k)$ , siendo  $\alpha$  el nivel de significación fijado de antemano. El estadístico se puede aproximar por una distribución  $F$  de Snédecor.

**Ejemplo.** Volvemos al ejemplo sobre manzanos. Se trata de contrastar  $H_0 : \mu_1 = \mu_2 = \dots = \mu_6$ , donde para cada  $i$  el vector  $\mu_i = (\mu_{i1}, \dots, \mu_{i4})'$  representa el vector de medias de  $\mathbf{y} = (y_1, \dots, y_4)'$  para el tipo  $i$  de portainjerto. Los datos son:

<sup>1</sup>La razón para no comparar directamente  $\mathbf{H}$  con  $\mathbf{E}$ , sino con  $\mathbf{E} + \mathbf{H}$  es que  $\mathbf{H}$  podría tener algún autovalor cero y eso haría que su determinante fuera cero.

<sup>2</sup>Ver Anexo A de distribuciones multidimensionales para la definición formal de la distribución  $\Lambda$  de Wilks

```
> x <- factor(manzanos[, 1])
> y <- as.matrix(manzanos[, 2:5])
> n <- dim(y)[1]
> d <- dim(y)[2]
> n
[1] 48
> d
[1] 4
```

Calculamos a continuación la media global de la muestra  $\bar{y}_{..}$  y las medias  $\bar{y}_{i.}$  correspondientes a cada grupo:

```
> medy <- apply(y, 2, mean)
> medy
      cir4      crec4      cir15      peso15
1.102708 2.758854 4.087292 1.083000
> medyi <- t(apply(y, 2, tapply, x, mean))
> medyi
      1      2      3      4      5      6
cir4  1.137500 1.157500 1.107500 1.09750 1.08000 1.036250
crec4  2.977125 3.109125 2.815250 2.87975 2.55725 2.214625
cir15  3.738750 4.515000 4.455000 3.90625 4.31250 3.596250
peso15 0.871125 1.280500 1.391375 1.03900 1.18100 0.735000
```

A continuación, realizamos el MANOVA:

```
> z <- lm(y ~ x)
> summary(manova(z), test = c("Wilks"))
      Df    Wilks approx F num Df den Df    Pr(>F)
x      5 0.15401   4.9369    20 130.3 7.714e-09 ***
Residuals 42
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Comprobamos que el valor del estadístico es  $\Lambda = 0,15401$ . Para ello, calculamos en primer lugar la matriz  $E$

```
> res <- z$residuals
> E <- crossprod(res) # Equivalente a (n - 1) * cov(res)
> E
      cir4      crec4      cir15      peso15
cir4  0.3199875  1.696564  0.5540875  0.217140
crec4  1.6965637 12.142790  4.3636125  2.110214
cir15  0.5540875  4.363612  4.2908125  2.481656
peso15 0.2171400  2.110214  2.4816562  1.722525
```

Calculamos ahora la matriz  $E_H = E + H$  aplicando la definición.

```
> resh <- y - matrix(medy, nrow = n, ncol = d, byrow = TRUE)
> EH <- crossprod(resh) # Equivalente a (n - 1) * cov(resh)
> EH
      cir4      crec4      cir15      peso15
cir4  0.3935479  2.233949  0.8863521  0.425610
crec4  2.2339490 16.342452  6.7190010  3.747322
cir15  0.8863521  6.719001 10.4047479  6.262700
peso15 0.4256100  3.747322  6.2627000  4.215616
```

Efectivamente, se tiene

```
> det(E)/det(EH)
[1] 0.1540077
```

En base a la aproximación a la  $F$  de Snédecor proporcionada por R y al  $p$ -valor del estadístico, se rechaza la hipótesis nula de igualdad de los vectores de medias en los 6 tipos de portainjerto.

### 3.2.3. Test de Roy

Existen otros procedimientos para contrastar  $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$  que dan lugar a estadísticos de contraste diferentes al  $\Lambda$  de Wilks. Uno de esos procedimientos alternativos es el de *unión-intersección*.

Un test de unión-intersección para contrastar una hipótesis  $H_0 = \cap_a H_{0a}$  es un test cuya región de rechazo es de la forma  $R = \cup_a R_a$ , siendo  $R_a$  la región de rechazo para  $H_{0a}$ .

Esta idea se aplica en problemas de inferencia multivariante, expresando la hipótesis multivariante como intersección de hipótesis univariantes, para las cuales ya hay tests disponibles. Siguiendo este procedimiento, el test de unión-intersección de Roy tiene como estadístico de contraste:

$$\lambda_1 = \text{máximo autovalor de } HE^{-1}$$

y rechazaremos la hipótesis nula para valores grandes de  $\lambda_1$ . De nuevo, se utilizarán aproximaciones de este estadístico a la  $F$  de Snédecor.

**Ejemplo.** Calculamos, para el ejemplo sobre manzanos, el estadístico de Roy:

```
> summary(manova(z), test = c("Roy"))
      Df      Roy approx F num Df den Df      Pr(>F)
x      5 1.8757  15.756      5    42 1.002e-08 ***
Residuals 42
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En base a este estadístico también se rechaza la hipótesis nula de igualdad de medias. Comprobamos que el valor del estadístico es  $\lambda_1 = 1,8757$ . Para ello, calculamos los autovalores de  $\mathbf{H}\mathbf{E}^{-1}$ .

```
> H <- EH - E
> lambda <- eigen(H %*% solve(E))$values
> lambda1 <- max(lambda)
> lambda1
[1] 1.875671
```

### 3.2.4. Tests de Pillai y Lawley-Hotelling

Existen otros dos tests adicionales para contrastar  $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$  basados en los autovalores de la matriz  $\mathbf{H}\mathbf{E}^{-1}$ . El estadístico de Pillai viene dado por

$$V^{(d)} = \text{traza} \left[ \mathbf{H}(\mathbf{E} + \mathbf{H})^{-1} \right] = \sum_{i=1}^d \theta_i = \sum_{i=1}^d \frac{\lambda_i}{1 + \lambda_i}$$

siendo  $\theta_1, \dots, \theta_d$  los autovalores de  $\mathbf{H}(\mathbf{E} + \mathbf{H})^{-1}$  y  $\lambda_1, \dots, \lambda_d$  los autovalores de  $\mathbf{H}\mathbf{E}^{-1}$ .

El estadístico de Lawley-Hotelling se define como

$$U^{(d)} = \text{traza} \left[ \mathbf{H}\mathbf{E}^{-1} \right] = \sum_{i=1}^d \lambda_i$$

donde  $\lambda_1, \dots, \lambda_d$  son los autovalores de  $\mathbf{H}\mathbf{E}^{-1}$ .

**Ejemplo.** Calculamos, para el ejemplo sobre manzanos, los estadísticos de Pillai y Lawley-Hotelling y comprobamos los valores obtenidos:

```
> summary(manova(z), test = c("Pillai"))
      Df Pillai approx F num Df den Df      Pr(>F)
x      5 1.3055   4.0697    20   168 1.983e-07 ***
Residuals 42
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> summary(manova(z), test = c("Hotelling-Lawley"))
      Df Hotelling-Lawley approx F num Df den Df      Pr(>F)
x      5      2.9214   5.4776    20   150 2.568e-10 ***
Residuals 42
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En base a ambos estadísticos también se rechaza la hipótesis nula de igualdad de medias. Comprobamos el valor del estadístico de Pillai y de Lawley-Hotelling

```
> sum(lambda/(1 + lambda)) # estadístico de Pillai
[1] 1.305472
> sum(lambda) # estadístico de Lawley-Hotelling
[1] 2.921368
```

### 3.3. MANOVA con dos factores de variación

En esta sección suponemos que hay dos factores: A y B. Del factor A podemos distinguir  $a$  niveles, mientras que en el factor B podemos encontrar  $b$  niveles. En cada una de las  $a \cdot b$  posibilidades realizamos  $n$  observaciones de un vector aleatorio  $\mathbf{y} = (y_1, \dots, y_d)'$ . El objetivo será estudiar la influencia de los factores A y B, o de su interacción, en la media del vector  $\mathbf{y}$ . Así, planteamos el siguiente modelo:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \gamma_{ij} + \epsilon_{ijk} \quad i = 1, \dots, a, \quad j = 1, \dots, b, \quad k = 1, \dots, n.$$

Se asume que  $\epsilon_{ijk} \in N_d(\mathbf{0}, \Sigma)$ . El parámetro  $\mu$  representa la media global, los parámetros  $\alpha_i$  representan el efecto principal del factor A, los parámetros  $\beta_j$  representan el efecto principal del factor B y los parámetros  $\gamma_{ij}$  representan la interacción de los factores A y B. Además verifican

$$\sum_{i=1}^a \alpha_i = \sum_{j=1}^b \beta_j = \sum_{i=1}^a \gamma_{ij} = \sum_{j=1}^b \gamma_{ij} = 0$$

Este modelo también se puede ver como un caso particular del modelo lineal general multivariante. Las labores de inferencia sobre el modelo se realizan en base a la siguiente descomposición de la variabilidad, mediante lo que llamaremos tabla MANOVA II:

| Fuente de variación | Matriz de covarianzas                                                                                                                                                                                                                                                                                                                                      | Grados de libertad |
|---------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------|
| Factor A            | $\mathbf{H}_A = nb \sum_{i=1}^a (\bar{\mathbf{y}}_{i\bullet\bullet} - \bar{\mathbf{y}}_{\bullet\bullet\bullet}) (\bar{\mathbf{y}}_{i\bullet\bullet} - \bar{\mathbf{y}}_{\bullet\bullet\bullet})'$                                                                                                                                                          | $a - 1$            |
| Factor B            | $\mathbf{H}_B = na \sum_{j=1}^b (\bar{\mathbf{y}}_{\bullet j\bullet} - \bar{\mathbf{y}}_{\bullet\bullet\bullet}) (\bar{\mathbf{y}}_{\bullet j\bullet} - \bar{\mathbf{y}}_{\bullet\bullet\bullet})'$                                                                                                                                                        | $b - 1$            |
| Interacción         | $\mathbf{H}_{AB} = n \sum_{i=1}^a \sum_{j=1}^b (\bar{\mathbf{y}}_{ij\bullet} - \bar{\mathbf{y}}_{i\bullet\bullet} - \bar{\mathbf{y}}_{\bullet j\bullet} + \bar{\mathbf{y}}_{\bullet\bullet\bullet}) (\bar{\mathbf{y}}_{ij\bullet} - \bar{\mathbf{y}}_{i\bullet\bullet} - \bar{\mathbf{y}}_{\bullet j\bullet} + \bar{\mathbf{y}}_{\bullet\bullet\bullet})'$ | $(a - 1)(b - 1)$   |
| Error               | $\mathbf{E} = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (\mathbf{y}_{ijk} - \bar{\mathbf{y}}_{ij\bullet}) (\mathbf{y}_{ijk} - \bar{\mathbf{y}}_{ij\bullet})'$                                                                                                                                                                                                 | $ab(n - 1)$        |
| Total               | $\sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (\mathbf{y}_{ijk} - \bar{\mathbf{y}}_{\bullet\bullet\bullet}) (\mathbf{y}_{ijk} - \bar{\mathbf{y}}_{\bullet\bullet\bullet})'$                                                                                                                                                                                      | $abn - 1$          |

La hipótesis relativa a la interacción  $H_{AB} : \gamma_{ij} = 0 \forall i, j$  se contrasta en base al estadístico

$$\frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}_{AB}|} \in \Lambda(d, (a - 1)(b - 1), ab(n - 1)).$$

Si se obtiene que la interacción no es significativa, se pasaría a un modelo sin interacción, sobre el cual se pueden cuestionar los efectos principales. Esto sería el proceder habitual dentro de un planteamiento jerárquico, cuestión que ya surgía en los modelos univariantes.

**Ejemplo.** En una especie de césped, denominada *Paspalum*, se está investigando el efecto que experimenta al ser infectada con un hongo. Al mismo tiempo se tiene en cuenta la temperatura, dentro de un diseño con cuatro valores diferentes: 14, 18, 22, 26°C. En cada realización del experimento se miden tres variables:

$y_1$  = El peso fresco de las raíces (medido en gramos)

$y_2$  = La longitud máxima de las raíces (medida en milímetros)

$y_3$  = El peso fresco de las hojas (medido en gramos)

Los datos se encuentran en el fichero `hongos.txt`. Vamos a contrastar el efecto del tratamiento con hongos, el efecto de la temperatura y la posible interacción entre ambos efectos.

```
> hongos <- read.table(file = "data/hongos.txt", header = TRUE)
> head(hongos)
  tratamiento temperatura y1 y2 y3
1           1           1 2.2 23.5 1.7
2           1           1 3.0 27.0 2.3
3           1           1 3.3 24.5 3.2
4           1           1 2.2 20.5 1.5
5           1           1 2.0 19.0 2.0
6           1           1 3.5 23.5 2.9
> y <- cbind(hongos$y1, hongos$y2, hongos$y3)
> tratamiento <- factor(hongos$tratamiento)
> temperatura <- factor(hongos$temperatura)
```

Empezando por el modelo más general, con ambos efectos principales y la interacción, si se contrasta la interacción resulta:

```
> m12i = lm(y ~ tratamiento * temperatura)
> m12 = lm(y ~ tratamiento + temperatura)
> anova(m12, m12i, test = "Wilks")
Analysis of Variance Table

Model 1: y ~ tratamiento + temperatura
Model 2: y ~ tratamiento * temperatura
  Res.Df Df Gen.var.   Wilks approx F num Df den Df Pr(>F)
1     43      12.852
2     40 -3   12.299 0.70548    1.5864      9 92.633 0.1307
> anova(m12, m12i, test = "Roy")
Analysis of Variance Table

Model 1: y ~ tratamiento + temperatura
Model 2: y ~ tratamiento * temperatura
  Res.Df Df Gen.var.   Roy approx F num Df den Df Pr(>F)
1     43      12.852
2     40 -3   12.299 0.25155    3.3541      3    40 0.02819 *
---
```

```

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> anova(m12, m12i, test = "Hotelling-Lawley")
Analysis of Variance Table

Model 1: y ~ tratamiento + temperatura
Model 2: y ~ tratamiento * temperatura
  Res.Df Df Gen.var. Hotelling-Lawley approx F num Df den Df Pr(>F)
1      43      12.852
2      40 -3    12.299      0.38126    1.5533      9    110 0.1384
> anova(m12, m12i, test = "Pillai")
Analysis of Variance Table

Model 1: y ~ tratamiento + temperatura
Model 2: y ~ tratamiento * temperatura
  Res.Df Df Gen.var. Pillai approx F num Df den Df Pr(>F)
1      43      12.852
2      40 -3    12.299 0.32058    1.5953      9    120 0.1241

```

Únicamente el test de Roy produce un nivel crítico algo pequeño, mientras que los otros tests no muestran significación. En consecuencia, se suprime la interacción del modelo. En el modelo sin interacción y con los dos efectos principales, se contrasta la significación de cada uno de los efectos, con los resultados siguientes. Para el tratamiento:

```

> m1 = lm(y ~ tratamiento)
> anova(m1, m12, test = "Wilks")
Analysis of Variance Table

Model 1: y ~ tratamiento
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Wilks approx F num Df den Df Pr(>F)
1      46      29.940
2      43 -3    12.852 0.064601    23.12      9 99.934 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> anova(m1, m12, test = "Roy")
Analysis of Variance Table

Model 1: y ~ tratamiento
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Roy approx F num Df den Df Pr(>F)
1      46      29.940
2      43 -3    12.852 5.1828    74.287      3    43 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> anova(m1, m12, test = "Hotelling-Lawley")
Analysis of Variance Table

Model 1: y ~ tratamiento
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Hotelling-Lawley approx F num Df den Df Pr(>F)
1      46      29.940
2      43 -3    12.852      6.6858    29.467      9    119 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
> anova(m1, m12, test = "Pillai")
Analysis of Variance Table

Model 1: y ~ tratamiento
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Pillai approx F num Df den Df  Pr(>F)
1      46      29.940
2      43 -3   12.852 1.4391    13.215      9   129 8.45e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Para la temperatura:

```
> m2 = lm(y ~ temperatura)
> anova(m2, m12, test = "Wilks")
Analysis of Variance Table

Model 1: y ~ temperatura
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Wilks approx F num Df den Df  Pr(>F)
1      44      13.439
2      43 -1   12.852 0.8163    3.0756      3   41 0.03807 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> anova(m2, m12, test = "Roy")
Analysis of Variance Table

Model 1: y ~ temperatura
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Roy approx F num Df den Df  Pr(>F)
1      44      13.439
2      43 -1   12.852 0.22504    3.0756      3   41 0.03807 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> anova(m2, m12, test = "Hotelling-Lawley")
Analysis of Variance Table

Model 1: y ~ temperatura
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Hotelling-Lawley approx F num Df den Df  Pr(>F)
1      44      13.439
2      43 -1   12.852      0.22504    3.0756      3   41 0.03807 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> anova(m2, m12, test = "Pillai")
Analysis of Variance Table

Model 1: y ~ temperatura
Model 2: y ~ tratamiento + temperatura
  Res.Df Df Gen.var. Pillai approx F num Df den Df  Pr(>F)
1      44      13.439
2      43 -1   12.852 0.1837    3.0756      3   41 0.03807 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Por tanto, la temperatura tiene un efecto muy significativo sobre las variables que se están midiendo. El tratamiento también resulta significativo, aunque no es tan notorio. Los niveles críticos de los cuatro test coinciden para el contraste del tratamiento. Este hecho se debe a que hay únicamente dos tratamientos, por lo que la matriz  $H$  asociada al contraste tiene rango uno.

## 4. Análisis de componentes principales

El análisis de componentes principales se concibe como una técnica de reducción de la dimensión, pues permite pasar de una gran cantidad de variables interrelacionadas a unas pocas componentes principales. El método consiste en buscar combinaciones lineales de las variables originales que representen lo mejor posible a la variabilidad presente en los datos. De este modo, con unas pocas combinaciones lineales, que serán las componentes principales, sería suficiente para entender la información contenida en los datos. Al mismo tiempo, la forma en que se construyen las componentes, y su relación con unas u otras variables originales, sirven para entender la estructura de correlación inherente a los datos. Por último, las componentes principales, que forman un vector aleatorio de dimensión menor, pueden ser empleadas en análisis estadísticos posteriores.

### 4.1. Descomposición de un vector aleatorio en sus componentes principales

En esta sección se va a definir el concepto de componentes principales, y cómo se obtienen a partir de la matriz de covarianzas de un vector aleatorio. Estas ideas y procedimientos se aplican de igual modo tanto a un vector aleatorio como a un conjunto de datos. En este último caso, se puede pensar que el análisis se está aplicando a una distribución de probabilidad discreta equiprobable sobre los vectores observados. Por este motivo, esta sección se desarrolla sobre un vector aleatorio general, con la única condición de que exista la matriz de covarianzas.

**Definición 4.1.** Sea  $\mathbf{x} = (x_1, \dots, x_d)'$  un vector aleatorio  $d$ -dimensional con vector de medias  $\boldsymbol{\mu} = E(\mathbf{x})$  y matriz de covarianzas  $\boldsymbol{\Sigma} = E((\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})')$ . Se define la primera componente principal de  $\mathbf{x}$  como una variable aleatoria  $z_1$  tal que

$$z_1 = \mathbf{v}_1' \mathbf{x} = v_{11}x_1 + \dots + v_{d1}x_d \quad \text{con} \quad \mathbf{v}_1 = (v_{11}, \dots, v_{d1})' \in \mathbb{R}^d,$$

$$\text{Var}(z_1) = \max\{\text{Var}(\mathbf{v}'\mathbf{x}) : \mathbf{v} \in \mathbb{R}^d, \mathbf{v}'\mathbf{v} = 1\}.$$

La primera componente principal es una combinación lineal normalizada de las variables de  $\mathbf{x}$ , de entre todas las combinaciones lineales normalizadas, es la que tiene mayor varianza.

**Nota.** Debe observarse que  $\text{Var}(\alpha \mathbf{v}'\mathbf{x}) = \alpha^2 \text{Var}(\mathbf{v}'\mathbf{x})$  con  $\alpha \in \mathbb{R}$ . De modo que multiplicando por una constante podemos hacer la varianza tan grande o tan pequeña como queramos. Por ello es necesario normalizar, pidiendo que  $\|\mathbf{v}\| = \sqrt{\mathbf{v}'\mathbf{v}} = 1$ .

**Teorema 4.1.** *La primera componente principal de  $\mathbf{x}$  adopta la forma*

$$z_1 = \mathbf{v}'_1 \mathbf{x},$$

*siendo  $\lambda_1$  el mayor autovalor de la matriz de covarianzas  $\Sigma$  y  $\mathbf{v}_1$  un autovector asociado a  $\lambda_1$  de norma uno ( $\mathbf{v}'_1 \mathbf{v}_1 = 1$ ). Además,*

$$\text{Var}(z_1) = \lambda_1.$$

*Demostración.* Consideremos  $z = \mathbf{v}'\mathbf{x}$ . Entonces podemos calcular su varianza

$$\text{Var}(z) = \text{Cov}(\mathbf{v}'\mathbf{x}, \mathbf{v}'\mathbf{x}) = \mathbf{v}'\text{Cov}(\mathbf{x}, \mathbf{x})\mathbf{v} = \mathbf{v}'\Sigma\mathbf{v}.$$

Nuestro problema consiste en calcular

$$\begin{aligned} &\text{máx} \quad \mathbf{v}'\Sigma\mathbf{v} \\ &\text{sueto a} \quad \mathbf{v}'\mathbf{v} = 1. \end{aligned}$$

Resolvemos este problema por el método de los multiplicadores de Lagrange.

$$L = \mathbf{v}'\Sigma\mathbf{v} - \lambda(\mathbf{v}'\mathbf{v} - 1)$$

Calculamos la matriz jacobiana de  $L$  como función de  $\mathbf{v}$  e igualamos a cero

$$\frac{\partial L}{\partial \mathbf{v}} = 2\mathbf{v}'\Sigma - 2\lambda\mathbf{v}' = 0.$$

Equivalentemente

$$\Sigma\mathbf{v} = \lambda\mathbf{v}.$$

Luego el vector  $\mathbf{v}_1$  que maximice la función sueto a la restricción ha de ser un autovector de  $\Sigma$ , y su autovalor asociado es  $\lambda_1$ . Multiplicando los dos términos de la ecuación por la izquierda por  $\mathbf{v}'_1$  resulta

$$\mathbf{v}'_1 \Sigma \mathbf{v}_1 = \mathbf{v}'_1 \lambda_1 \mathbf{v}_1 = \lambda_1 \mathbf{v}'_1 \mathbf{v}_1 = \lambda_1.$$

Luego el autovalor  $\lambda_1$  es la función objetivo en el máximo y por tanto,  $\text{Var}(z_1) = \lambda_1$ . □

**Definición 4.2.** Se define la segunda componente principal de  $\mathbf{x}$  como una variable aleatoria  $z_2$  tal que

$$z_2 = \mathbf{v}'_2 \mathbf{x} = v_{12}x_1 + \cdots + v_{d2}x_d \quad \text{con} \quad \mathbf{v}_2 = (v_{12}, \dots, v_{d2})' \in \mathbb{R}^d,$$

$$\text{Var}(z_2) = \text{máx}\{\text{Var}(\mathbf{v}'\mathbf{x}) : \mathbf{v} \in \mathbb{R}^d, \mathbf{v}'\mathbf{v} = 1, \mathbf{v}'\mathbf{v}_1 = 0\}.$$

La segunda componente principal es otra combinación lineal de las variables de  $\mathbf{x}$  y, de entre todas las combinaciones lineales formadas por vectores unitarios ortogonales a  $\mathbf{v}_1$ , es la que tiene mayor varianza.

Nótese que

$$\text{Cov}(\mathbf{v}'\mathbf{x}, z_1) = \text{Cov}(\mathbf{v}'\mathbf{x}, \mathbf{v}_1'\mathbf{x}) = \mathbf{v}'\text{Cov}(\mathbf{x}, \mathbf{x})\mathbf{v}_1 = \mathbf{v}'\mathbf{\Sigma}\mathbf{v}_1.$$

Enunciamos a continuación un resultado sencillo.

**Resultado.** Sea  $\mathbf{w} \in \mathbb{R}^d$  un autovector de  $\mathbf{\Sigma}$  asociado a un autovalor no nulo  $\lambda \neq 0$ , y sea  $\mathbf{v} \in \mathbb{R}^d$ . Entonces

$$\mathbf{v}'\mathbf{\Sigma}\mathbf{w} = 0 \Leftrightarrow \mathbf{v}'\mathbf{w} = 0.$$

*Demostración.* En primer lugar,

$$\mathbf{v}'\mathbf{\Sigma}\mathbf{w} = \mathbf{v}'\lambda\mathbf{w} = \lambda\mathbf{v}'\mathbf{w} = 0.$$

En el otro sentido,

$$\mathbf{v}'\mathbf{w} = \mathbf{v}'\frac{1}{\lambda}\mathbf{\Sigma}\mathbf{w} = \frac{1}{\lambda}\mathbf{v}'\mathbf{\Sigma}\mathbf{w} = \frac{1}{\lambda}0 = 0.$$

□

Por tanto, en aplicación de este resultado,  $\text{Cov}(\mathbf{v}'\mathbf{x}, z_1) = 0 \Leftrightarrow \mathbf{v}'\mathbf{v}_1 = 0$ . Y hemos probado que la condición de ortogonalidad entre los vectores  $\mathbf{v}_1$  y  $\mathbf{v}_2$  es equivalente a la incorrelación de las componentes  $z_1$  y  $z_2$ . En definitiva, podríamos definir la segunda componente principal como la combinación lineal de las variables de  $\mathbf{x}$  que tiene mayor varianza de entre las combinaciones lineales normalizadas e incorrelacionadas con la primera componente principal.

Respecto a la condición de que  $\lambda_1 \neq 0$ , hemos de recordar que  $\lambda_1 = \text{Var}(z_1)$ . Por tanto si  $\lambda_1 = \text{Var}(z_1) = 0$ , todos los demás autovalores serán también cero y  $z_1$  y las demás componentes serán variables degeneradas.

**Teorema 4.2.** *La segunda componente principal de  $\mathbf{x}$  adopta la forma*

$$z_2 = \mathbf{v}_2'\mathbf{x}$$

*siendo  $\lambda_2$  el segundo mayor autovalor de la matriz de covarianzas  $\mathbf{\Sigma}$  y  $\mathbf{v}_2$  un autovector asociado a  $\lambda_2$  de norma uno ( $\mathbf{v}_2'\mathbf{v}_2 = 1$ ) y ortogonal a  $\mathbf{v}_1$  ( $\mathbf{v}_1'\mathbf{v}_2 = 0$ ). Además*

$$\text{Var}(z_2) = \lambda_2.$$

*Demostración.* Procederemos de modo muy similar al caso anterior. Consideramos  $z = v'x$ , cuya varianza es  $\text{Var}(z) = v'\Sigma v$ . Nuestro problema consiste en

$$\begin{aligned} & \text{máx} && v'\Sigma v \\ \text{sujeto a} &&& v'v = 1, \\ &&& v'_1 v = 0. \end{aligned}$$

Resolvemos este problema por el método de los multiplicadores de Lagrange.

$$L = v'\Sigma v - \lambda_2(v'v - 1) - \gamma_2 v'_1 v.$$

Derivamos respecto de  $v$  e igualamos a cero (momento en el cual podemos sustituir el valor  $v_2$  para mejor comprensión):

$$\left( \frac{\partial L}{\partial v} /_{v=v_2} \right)' = 2\Sigma v_2 - 2\lambda_2 v_2 - \gamma_2 v_1 = 0. \quad (4.1)$$

Multiplicando por la izquierda por  $v'_1$  resulta

$$2v'_1 \Sigma v_2 - 2\lambda_2 v'_1 v_2 - \gamma_2 v'_1 v_1 = 0.$$

Las restricciones imponen que  $v'_1 v_2 = 0$ . Por la nota, de ello deducimos que  $v'_1 \Sigma v_2 = 0$ . Y  $v_1$  ya verificaba  $v'_1 v_1 = 1$ . Entonces la ecuación anterior se reduce a  $\gamma_2 = 0$ . Y al sustituir ese valor en la ecuación (4.1) se obtiene

$$\Sigma v_2 = \lambda_2 v_2.$$

Razonando igual que antes, el vector  $v_2$  que maximice la función sujeto a las restricciones ha de ser un autovector de  $\Sigma$ , y su autovalor asociado es  $\lambda_2$ . La restricción de ortogonalidad respecto de  $v_1$  nos obliga a tomar el segundo mayor autovalor de  $\Sigma$ . Como antes,  $\text{Var}(z_2) = v'_2 \Sigma v_2 = \lambda_2$ .  $\square$

Podríamos continuar este proceso extrayendo las componentes principales de  $x$  mediante los autovalores de la matriz de covarianzas  $\Sigma$  y la base ortonormal de autovectores asociados. De este modo, obtenemos  $p$  componentes principales.

**Definición 4.3.** Se definen las  $d$  componentes principales de  $x$  como las variables aleatorias  $(z_1, \dots, z_d)$  tales que

$$z_1 = v'_1 x, \dots, z_d = v'_d x, \quad v_1, \dots, v_d \in \mathbb{R}^d.$$

$$\begin{aligned}
\text{Var}(z_1) &= \text{máx}\{\text{Var}(\mathbf{v}'\mathbf{x}) : \mathbf{v} \in \mathbb{R}^d, \mathbf{v}'\mathbf{v} = 1\}, \\
\text{Var}(z_2) &= \text{máx}\{\text{Var}(\mathbf{v}'\mathbf{x}) : \mathbf{v} \in \mathbb{R}^d, \mathbf{v}'\mathbf{v} = 1, \mathbf{v}'_1\mathbf{v} = 0\}, \\
&\vdots \\
\text{Var}(z_j) &= \text{máx}\{\text{Var}(\mathbf{v}'\mathbf{x}) : \mathbf{v} \in \mathbb{R}^d, \mathbf{v}'\mathbf{v} = 1, \mathbf{v}'_1\mathbf{v} = 0, \dots, \mathbf{v}'_{j-1}\mathbf{v} = 0\}, \\
&\vdots \\
\text{Var}(z_d) &= \text{máx}\{\text{Var}(\mathbf{v}'\mathbf{x}) : \mathbf{v} \in \mathbb{R}^d, \mathbf{v}'\mathbf{v} = 1, \mathbf{v}'_1\mathbf{v} = 0, \dots, \mathbf{v}'_{d-1}\mathbf{v} = 0\}.
\end{aligned}$$

**Teorema 4.3.** Las  $d$  componentes principales de  $\mathbf{x}$  adoptan la forma

$$z_j = \mathbf{v}'_j \mathbf{x} \quad j \in \{1, \dots, d\}$$

siendo  $\lambda_1 \geq \dots \geq \lambda_d \geq 0$  los  $d$  autovalores ordenados de la matriz de covarianzas  $\mathbf{\Sigma}$  y  $\mathbf{v}_1, \dots, \mathbf{v}_d$  sus autovectores asociados normalizados, esto es,  $\{\mathbf{v}_1, \dots, \mathbf{v}_d\}$  es una base ortonormal de autovectores. Además  $\text{Cov}(z_j, z_k) = 0$  si  $j \neq k$  y

$$\text{Var}(z_j) = \lambda_j \quad j \in \{1, \dots, d\}.$$

Este teorema nos permite expresar

$$\mathbf{z} = \mathbf{V}'\mathbf{x}$$

siendo  $\mathbf{z} = (z_1, \dots, z_d)'$  y  $\mathbf{V} = (\mathbf{v}_1, \dots, \mathbf{v}_d)$  la matriz cuyas columnas son los autovectores de  $\mathbf{\Sigma}$ . Entonces

$$\text{Cov}(\mathbf{z}, \mathbf{z}) = \text{Cov}(\mathbf{V}'\mathbf{x}, \mathbf{V}'\mathbf{x}) = \mathbf{V}'\text{Cov}(\mathbf{x}, \mathbf{x})\mathbf{V} = \mathbf{V}'\mathbf{\Sigma}\mathbf{V}.$$

Pero la matriz de covarianzas de las componentes principales es diagonal y contiene los autovalores de  $\mathbf{\Sigma}$  en la diagonal. Luego, el proceso de extracción de las componentes principales se reduce a la diagonalización de la matriz de covarianzas del vector aleatorio  $\mathbf{x}$ .

**Ejercicio.** Sea  $\mathbf{x} = (x_1, x_2)'$  un vector aleatorio con vector de medias  $\boldsymbol{\mu} = E(\mathbf{x}) = (4, 2)'$  y matriz de covarianzas

$$\mathbf{\Sigma} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

Obtener la descomposición del vector  $\mathbf{x}$  en sus componentes principales.

**Ejemplo.** Se ha examinado a 25 alumnos, aspirantes a ingresar en la Facultad de Matemáticas, de 5 materias diferentes: Geometría Diferencial (cuyo resultado se almacena en la variable *geodif*), Análisis Complejo (*ancompl*), Álgebra (*alg*), Análisis Real (*anreal*) y Estadística (*estad*). Las puntuaciones obtenidas se encuentran en el fichero *aspirantes.txt*.

```
> dat <- read.table("data/aspirantes.txt", header = TRUE)
> dat
  geodif ancompl alg anreal estad
1      36      58 43      36      37
2      62      54 50      46      52
3      31      42 41      40      29
4      76      78 69      66      81
5      46      56 52      56      40
6      12      42 38      38      28
7      39      46 51      54      41
8      30      51 54      52      32
9      22      32 43      28      22
...
```

El objetivo de este estudio es obtener un ranking global de alumnos para la entrada en la Facultad de Matemáticas, a través de una puntuación global, extraída como cierta combinación lineal de las calificaciones en las cinco materias examinadas. El comando básico para realizar un análisis de componentes principales en R es `princomp`. También se pueden obtener resultados similares con el comando `prcomp`. La diferencia principal entre uno y otro es que `princomp` diagonaliza la matriz  $S$ , mientras que `prcomp` diagonaliza la matriz  $S_c$ . Esto modifica los autovalores en la proporción  $n/(n-1)$ , pero no supone ningún cambio en los autovectores. Hemos optado por el comando `princomp`. A continuación se muestran las instrucciones que permiten realizar un análisis de componentes principales para el ejemplo, utilizando R. Mostramos en primer lugar la salida básica del objeto, que muestra las desviaciones típicas de las componentes que son las raíces cuadradas de los autovalores.

```
> test.pca <- princomp(dat) # Análisis de componentes principales
> test.pca
Call:
princomp(x = dat)

Standard deviations:
  Comp.1   Comp.2   Comp.3   Comp.4   Comp.5
28.489680 9.035471 6.600955 6.133582 3.723358

5 variables and 25 observations.
```

Con la función `summary` obtenemos, junto a las desviaciones típicas de las componentes, la proporción de varianza explicada y sus valores acumulados.

```
> summary(test.pca)
Importance of components:
          Comp.1   Comp.2   Comp.3   Comp.4   Comp.5
Standard deviation 28.4896795 9.03547104 6.60095491 6.13358179 3.72335754
Proportion of Variance 0.8212222 0.08260135 0.04408584 0.03806395 0.01402668
Cumulative Proportion 0.8212222 0.90382353 0.94790936 0.98597332 1.00000000
> test.pca$sdev^2
  Comp.1   Comp.2   Comp.3   Comp.4   Comp.5
811.66184 81.63974 43.57261 37.62083 13.86339
```

Representamos a continuación los autovalores (gráfico de sedimentación) y el mismo gráfico con líneas, ver Figura 4.1.

```
> screeplot(test.pca)
> screeplot(test.pca, type = "lines")
```




Figura 4.1.: Gráficos de sedimentación.

La función `loadings` proporciona los coeficientes de las componentes (autovectores), ver Figura 4.2

```
> loadings(test.pca)
```

Loadings:

|         | Comp.1 | Comp.2 | Comp.3 | Comp.4 | Comp.5 |
|---------|--------|--------|--------|--------|--------|
| geodif  | 0.598  | 0.675  | 0.185  | 0.386  |        |
| ancompl | 0.361  | 0.245  | -0.249 | -0.829 | -0.247 |
| alg     | 0.302  | -0.214 | -0.211 | -0.135 | 0.894  |
| anreal  | 0.389  | -0.338 | -0.700 | 0.375  | -0.321 |
| estad   | 0.519  | -0.570 | 0.607  |        | -0.179 |

|                | Comp.1 | Comp.2 | Comp.3 | Comp.4 | Comp.5 |
|----------------|--------|--------|--------|--------|--------|
| SS loadings    | 1.0    | 1.0    | 1.0    | 1.0    | 1.0    |
| Proportion Var | 0.2    | 0.2    | 0.2    | 0.2    | 0.2    |
| Cumulative Var | 0.2    | 0.4    | 0.6    | 0.8    | 1.0    |

```
> barplot(loadings(test.pca), beside = TRUE) # Representación coeficientes
> test.pca$scores # Puntuaciones de los individuos en las componentes
```

|      | Comp.1      | Comp.2     | Comp.3     | Comp.4     | Comp.5     |
|------|-------------|------------|------------|------------|------------|
| [1,] | -7.5403215  | 10.2167650 | 2.5374713  | -8.6708997 | -4.3011164 |
| [2,] | 20.3610372  | 13.3460340 | 8.9820585  | 6.4124949  | -1.3548711 |
| [3,] | -19.5031539 | 6.5552439  | -1.6414327 | 5.0042015  | -2.2980498 |
| [4,] | 65.9652730  | 1.3136646  | 5.1988159  | -5.2093505 | -1.0457668 |
| [5,] | 9.7780565   | 6.0680143  | -9.1921582 | 2.9249303  | -2.1069944 |

```
[6,] -33.0739529 -4.3722312 -3.7345190 -2.6038323 -5.3246839
[7,]  1.4212177 -0.7833317 -5.7800406  7.8225646 -0.4967347
[8,] -6.7011638 -0.4667798 -13.3936497 -0.3040531  2.6525120
[9,] -36.1916160  5.6543609  2.9062814  5.5458471  6.5171961
...
```




Figura 4.2.: Representación de los coeficientes de las componentes principales.

El *biplot*, introducido por Gabriel (1971), es una representación gráfica simultánea de los individuos (mediante puntos) y las variables (mediante flechas), en un mismo sistema de coordenadas bidimensional construido en base a las dos primeras componentes principales. Permite interpretar el significado de las componentes (la primera en el eje horizontal y la segunda en el eje vertical) en base a las direcciones de las flechas.

A su vez, se valoran como parecidos los individuos cuyos puntos están próximos en el biplot. De igual modo tendrán correlación positiva las variables con flechas semejantes. Asimismo, los individuos que se encuentran en la dirección de cierta flecha tendrán observaciones altas en la variable representada por la flecha.

Representamos el biplot correspondiente a los datos del ejemplo, ver Figura 4.3

```
> biplot(test.pca)
```

Obtenemos los mismos resultados haciendo los cálculos de forma directa:

```
> n <- nrow(dat)
> s <- cov(dat) * (n - 1)/n
> auto <- eigen(s)
> lambda <- auto$values
> v <- auto$vectors
```




Figura 4.3.: Biplot

## 4.2. Propiedades geométricas de las componentes principales

Esta sección contiene dos propiedades geométricas interesantes, que cumplen las componentes principales, cuando se comparan con el modelo de regresión. En primer lugar veremos que las componentes principales también son aproximaciones mínimo-cuadráticas del vector aleatorio, y en segundo lugar veremos que en el caso de un vector bivalente  $x = (x_1, x_2)'$ , la primera componente principal describe una recta que pasa entre las dos rectas de regresión lineal simple, una de  $x_2$  sobre  $x_1$  y la otra de  $x_1$  sobre  $x_2$ .

### 4.2.1. Las componentes principales como mejores aproximaciones mínimo-cuadráticas

Recordemos que la componente principal es la variable aleatoria unidimensional  $z_1 = v_1'x$ . Al proyectar el vector  $x$  sobre la recta que pasa por el origen con la dirección  $v_1$ , se obtiene el vector aleatorio

$$z_1^m = v_1 z_1 = v_1 v_1' x$$

que coincide con la representación de la primera componente  $z_1$  en  $\mathbb{R}^d$  a lo largo de la dirección  $v_1$ .

Observamos que este vector aleatorio está contenido en un espacio de dimensión uno. De hecho, su matriz de covarianzas es

$$\text{Cov}(z_1^m, z_1^m) = \text{Cov}(v_1 z_1, v_1 z_1) = v_1 \text{Cov}(z_1, z_1) v_1' = \text{Var}(z_1) v_1 v_1' = \lambda_1 v_1 v_1'$$

la cual claramente es una matriz de rango uno y no es más que el primer sumando de la descomposición espectral de  $\Sigma$ .

Centramos el vector  $z_1^m$  en el vector de medias de  $x$ ,  $\mu = E(x)$ .

$$z_1^{mc} = z_1^m - E(z_1^m) + E(x) = \mu + v_1 z_1^c$$

siendo  $z_1^c = v_1'(x - \mu)$  la primera componente centrada.

Este vector aleatorio  $z_1^{mc}$  es el resultado de proyectar el vector  $x$  sobre la recta que pasa por el vector de medias  $\mu$  y tiene dirección  $v_1$ .

**Teorema 4.4.** *La recta que pasa por el vector de medias  $\mu = E(x)$  y tiene dirección  $v_1$  es la que hace mínima la distancia cuadrática del vector aleatorio  $x$  a la recta, definiendo esta distancia cuadrática como la media del cuadrado de la distancia euclídea usual (distancia ortogonal o menor distancia) del vector aleatorio  $x$  a la recta.*

**Observación.** Este resultado debe relacionarse con la recta de regresión, que hace mínima la media (suma en el caso de una muestra) de la distancia vertical a la recta. En este caso consideramos la distancia ortogonal (la menor distancia), pues no hay variable respuesta ni variable explicativa, sino que todas las variables son tratadas de igual modo.

#### 4.2.2. Posición en el plano de la 1ª componente principal respecto a las rectas de regresión

Sea  $(x, y)$  un vector aleatorio en el plano. Se puede demostrar que al representar en el plano  $XY$  la primera componente principal, junto con las dos rectas de regresión de  $y$  sobre  $x$  y de  $x$  sobre  $y$ , obtenemos tres rectas que pasan por el vector de medias, y la primera componente principal forma una recta "menos horizontal" que la recta de regresión de  $y$  sobre  $x$ , pero "más horizontal" que la recta de regresión de  $x$  sobre  $y$ .

**Ejemplo.** Se ha obtenido la muestra siguiente de un vector aleatorio  $(x, y)$ : (-3,7), (1,4), (0,6), (3,5), (1,9), (7,7), (6,9), (8,10), (7,12), (10,11). Representamos en la Figura 4.4 el diagrama de dispersión, junto con la primera componente principal y las dos rectas de regresión.




Figura 4.4.: Diagrama de dispersión, junto con la primera componente principal (verde), la recta de regresión de  $y$  sobre  $x$  (azul) y la recta de regresión  $x$  de sobre  $y$  (rojo)

### 4.3. Descomposición de la variabilidad, proporción de varianza explicada y criterios para la reducción de dimensión

Según acabamos de ver, desde un punto de vista matricial podemos contemplar el proceso de extracción de las componentes principales como la diagonalización de la matriz de covarianzas

$$\Lambda = V' \Sigma V$$

siendo  $\Sigma = \text{Cov}(x, x)$  la matriz de covarianzas del vector aleatorio original,  $\Lambda = \text{Cov}(z, z)$  la matriz de covarianzas de las componentes (que es diagonal) y  $V = (v_1 \dots, v_d)$  la matriz ortogonal cuyas columnas son los autovectores, que a su vez constituyen los coeficientes que definen las componentes.

Multiplicando por  $V$  por la izquierda y por  $V'$  por la derecha, podemos expresar

$$\Sigma = V \Lambda V' = \sum_{j=1}^d \lambda_j v_j v_j'$$

que se conoce como la descomposición espectral de la matriz  $\Sigma$ . Sabemos que

$$\text{rango}(\Sigma) = \text{rango}(\Lambda) = \text{“número de autovalores no nulos”}.$$

A su vez también recordamos que el rango de la matriz de covarianzas coincide con la dimensión del menor espacio lineal que contiene al vector aleatorio (con probabilidad uno).

Así si el rango es  $k$ , el vector aleatorio estaría contenido en un espacio lineal de dimensión  $k$ , los  $k$  primeros autovalores son no nulos y los  $(d - k)$  últimos son cero, y las  $(d - k)$  últimas componentes tienen varianza cero. Se puede por tanto reducir la dimensión hasta  $k$  sin perder variabilidad. Sólo estaríamos cambiando el sistema de coordenadas.

Consideremos como medida global de variabilidad del vector aleatorio, la traza de su matriz de covarianzas. Nótese que no es más que la suma de las varianzas de las variables del vector, pero además tiene esta justificación como medida global de variabilidad

$$\text{traza}(\Sigma) = E(\|x - E(x)\|^2).$$

Es la media de las desviaciones cuadráticas respecto a la media y por tanto es una extensión natural de la varianza de una variable aleatoria.

De la descomposición espectral se deduce

$$\text{traza}(\Sigma) = \sum_{j=1}^d \lambda_j \text{traza}(v_j v_j') = \sum_{j=1}^d \lambda_j.$$

La última igualdad es consecuencia de que los vectores  $v_j$  son de norma uno.

Si extraemos una componente principal, obtenemos la variable aleatoria unidimensional

$$z_1 = v_1' x.$$

Si en lugar de recoger todo el vector aleatorio, sólo aportamos  $z_1$  reduciendo la información a una variable unidimensional; junto con la simplificación, se produce una reducción de variabilidad, que pasa a ser

$$\text{Var}(z_1) = \lambda_1.$$

Decimos que el cociente

$$\frac{\lambda_1}{\lambda_1 + \dots + \lambda_d}$$

es la proporción de variabilidad explicada por la primera componente principal.

Si en lugar de una única componente principal extraemos  $r$  componentes resulta

$$\frac{\lambda_1 + \dots + \lambda_r}{\lambda_1 + \dots + \lambda_r + \lambda_{r+1} + \dots + \lambda_d}$$

es la proporción de variabilidad explicada por las  $r$  primeras componentes principales.

Debemos decidir entre la simplificación que supone la reducción de la dimensión y la pérdida de información resultante de la variabilidad no explicada. Como criterios para tomar esta decisión, se suelen emplear los siguientes:

- Criterio de la varianza explicada. Consiste en retener el número de componentes que conjuntamente expliquen una proporción de varianza establecida, habitualmente un 90 % o 95 % del total.
- Criterio del valor propio (Kaiser). Retener sólo las componentes cuyos autovalores sean mayores que la media, esto es, mayores que  $\text{traza}(\Sigma)/d$ . Estas componentes tendrían más varianza que la que corresponde en media a una variable, mientras que las demás componentes tienen menos.
- Gráfico de sedimentación (*screeplot*). Representar en un gráfico los valores propios  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$  en orden decreciente, y buscar un “codo” en el gráfico, entendiendo por codo un punto a partir del cual los valores propios son claramente más pequeños que los anteriores, y muy similares entre sí.
- Retener un número preestablecido de componentes principales. Por ejemplo, es costumbre retener dos componentes, pues se pueden representar fácilmente en el plano.

#### 4.4. Las componentes principales y los cambios de escala

Un problema importante del análisis de componentes principales es que sus resultados dependen de la escala de medida de las variables originales,  $\mathbf{x}$ . Así, si se cambia de escala una variable (dejando las demás fijas) las componentes principales se modifican, cambiando incluso la posible interpretación de las mismas. En concreto, si se aumenta la escala de una variable, ésta verá incrementada su varianza y su aportación proporcional a la varianza total, atrayendo de este modo a la primera componente principal, que se asemejará a esta variable.

Claro está que si se realiza el mismo cambio de escala en todas las variables, entonces los resultados del análisis de componentes principales se mantendrán idénticos.

Este problema se puede solventar de dos maneras:

- Midiendo todas las variables en la misma escala (siempre que sean de la misma naturaleza).
- Aplicando el análisis de componentes principales a las variables estandarizadas. Esto último equivale a trabajar con la matriz de correlaciones, en lugar de la matriz de covarianzas.

#### 4.5. Interpretación de las componentes principales

Para interpretar las componentes principales,  $\mathbf{z} = (z_1, \dots, z_d)'$ , es preciso relacionarlas con las variables originales,  $\mathbf{x}$ . El instrumento natural para establecer esta relación consiste en calcular la covarianza o la correlación entre las componentes y las variables originales  $\mathbf{x}$ . Lo obtenemos a continuación.

$$\text{Cov}(\mathbf{x}, z_k) = \text{Cov}(\mathbf{x}, \mathbf{v}_k' \mathbf{x}) = \text{Cov}(\mathbf{x}, \mathbf{x}) \mathbf{v}_k = \mathbf{\Sigma} \mathbf{v}_k = \lambda_k \mathbf{v}_k.$$

La notación matricial nos permite calcularlas para todas a la vez

$$\text{Cov}(\mathbf{x}, \mathbf{z}) = \text{Cov}(\mathbf{x}, \mathbf{V}' \mathbf{x}) = \text{Cov}(\mathbf{x}, \mathbf{x}) \mathbf{V} = \mathbf{\Sigma} \mathbf{V} = \mathbf{V} \mathbf{\Lambda}.$$

En particular para una variable  $x_j$  y una componente  $z_k$ :

$$\text{Cov}(x_j, z_k) = \lambda_k v_{jk}.$$

Se trata por tanto de la varianza de la componente  $z_k$  multiplicada por el coeficiente  $v_{jk}$ , que acompaña a  $x_j$  en la construcción de  $z_k$ . El coeficiente de correlación será

$$\text{Corr}(x_j, z_k) = \frac{\text{Cov}(x_j, z_k)}{\sqrt{\text{Var}(x_j) \text{Var}(z_k)}} = \frac{v_{jk}}{\sigma_j} \sqrt{\lambda_k}.$$

En notación matricial,

$$\begin{aligned}\text{Corr}(\mathbf{x}, \mathbf{z}) &= \text{diag}(1/\sigma_1, \dots, 1/\sigma_d) \mathbf{V} \mathbf{\Lambda} \text{diag}(1/\sqrt{\lambda_1}, \dots, 1/\sqrt{\lambda_d}) \\ &= \text{diag}(1/\sigma_1, \dots, 1/\sigma_d) \mathbf{V} \mathbf{\Lambda}^{1/2}.\end{aligned}$$

Se interpretará cada componente principal en función de las variables originales que estén correlacionadas con dicha componente. Asimismo, el signo de cada correlación permite valorar qué variables van en el sentido de la componente y cuáles en sentido opuesto.

## 5. Análisis de correspondencias

El Análisis de Correspondencias estudia la relación entre dos variables discretas a través de su distribución conjunta de frecuencias. Nos apoyaremos en el siguiente ejemplo.

**Ejemplo.** *Encuesta de Población Activa (EPA, 2010). Datos de actividad y ocupación.* La Encuesta de Población Activa, comúnmente conocida como EPA, es una encuesta que realiza el Instituto Nacional de Estadística (INE) y que recoge información sobre el empleo en España. Así, de esta encuesta se extraen los datos de actividad, ocupación y tasa de paro, que además se pueden relacionar con características de los individuos, como su sexo, edad o comunidad autónoma de residencia.

Vamos a estudiar la relación que puede haber entre la comunidad autónoma y una variable que indicará si el individuo es inactivo, está ocupado o está parado. Se define como inactivo a un individuo que no realiza trabajo remunerado, ni está en condiciones de realizarlo, bien por falta de capacidad (niños, ancianos o discapacitados) o por decisión propia. Ocupado es aquél que realiza trabajo remunerado, y parado es aquél que no lo realiza, aunque se encuentra en condiciones de trabajar y busca empleo. Los datos del fichero `epa2010.csv` recogen las frecuencias (en miles de personas) en cada comunidad autónoma y según su actividad (ocupado, parado o inactivo).

```
> dat <- read.csv("data/epa2010.csv", sep = ";", dec = ",", fileEncoding = "latin1")
> dat
```

|     | Comunidad.Autónoma      | Ocupados | Parados | Inactivos |
|-----|-------------------------|----------|---------|-----------|
| 1   | Andalucía               | 2849.1   | 1127.4  | 2794.2    |
| 2   | Aragón                  | 540.3    | 103.3   | 467.5     |
| 3   | Asturias, Principado de | 398.0    | 79.6    | 451.8     |
| 4   | Baleares, Illes         | 450.0    | 128.6   | 320.3     |
| 5   | Canarias                | 771.2    | 314.4   | 663.8     |
| 6   | Cantabria               | 233.8    | 41.0    | 219.6     |
| 7   | Castilla y León         | 996.8    | 186.8   | 962.4     |
| 8   | Castilla - La Mancha    | 779.2    | 211.2   | 712.9     |
| 9   | Cataluña                | 3133.5   | 686.8   | 2256.8    |
| ... |                         |          |         |           |

Mediante un análisis de correspondencias seremos capaces de describir las relaciones que pueda haber entre la comunidad autónoma y la actividad, por ejemplo, indicando que en cierta comunidad autónoma hay un mayor porcentaje de parados, que en otra abundan especialmente los inactivos, o que en una tercera predominan los ocupados.

Las tablas de frecuencias, como la vista en el ejemplo, se conocen como **tablas de contingencia**. Reflejan la distribución conjunta del par formado por las dos variables discretas, que denotaremos  $(x, y)$ . Introduciendo cierta notación, podríamos expresar la tabla de contingencia así:

| $x \backslash y$ | $y_1$           | $\dots$ | $y_j$           | $\dots$ | $y_s$           |                |
|------------------|-----------------|---------|-----------------|---------|-----------------|----------------|
| $x_1$            | $n_{11}$        | $\dots$ | $n_{1j}$        | $\dots$ | $n_{1s}$        | $n_{1\bullet}$ |
| $\vdots$         | $\vdots$        |         | $\vdots$        |         | $\vdots$        | $\vdots$       |
| $x_i$            | $n_{i1}$        | $\dots$ | $n_{ij}$        | $\dots$ | $n_{is}$        | $n_{i\bullet}$ |
| $\vdots$         | $\vdots$        |         | $\vdots$        |         | $\vdots$        | $\vdots$       |
| $x_r$            | $n_{r1}$        | $\dots$ | $n_{rj}$        | $\dots$ | $n_{rs}$        | $n_{r\bullet}$ |
|                  | $n_{\bullet 1}$ | $\dots$ | $n_{\bullet j}$ | $\dots$ | $n_{\bullet s}$ | $n$            |

siendo  $n_{ij}$  la frecuencia absoluta del par  $(x_i, y_j)$ ,  $(n_{1\bullet}, \dots, n_{i\bullet}, \dots, n_{r\bullet})$  la distribución marginal de la variable  $x$  y  $(n_{\bullet 1}, \dots, n_{\bullet j}, \dots, n_{\bullet s})$  la distribución marginal de la variable  $y$ .

Si dividimos entre el tamaño muestral,  $n$ , obtenemos una tabla similar, pero ahora en términos relativos.

| $x \backslash y$ | $y_1$           | $\dots$ | $y_j$           | $\dots$ | $y_s$           |                |
|------------------|-----------------|---------|-----------------|---------|-----------------|----------------|
| $x_1$            | $f_{11}$        | $\dots$ | $f_{1j}$        | $\dots$ | $f_{1s}$        | $f_{1\bullet}$ |
| $\vdots$         | $\vdots$        |         | $\vdots$        |         | $\vdots$        | $\vdots$       |
| $x_i$            | $f_{i1}$        | $\dots$ | $f_{ij}$        | $\dots$ | $f_{is}$        | $f_{i\bullet}$ |
| $\vdots$         | $\vdots$        |         | $\vdots$        |         | $\vdots$        | $\vdots$       |
| $x_r$            | $f_{r1}$        | $\dots$ | $f_{rj}$        | $\dots$ | $f_{rs}$        | $f_{r\bullet}$ |
|                  | $f_{\bullet 1}$ | $\dots$ | $f_{\bullet j}$ | $\dots$ | $f_{\bullet s}$ | 1              |

siendo  $f_{ij}$  la frecuencia relativa del par  $(x_i, y_j)$ ,  $(f_{1\bullet}, \dots, f_{i\bullet}, \dots, f_{r\bullet})$  la distribución marginal de la variable  $x$  y  $(f_{\bullet 1}, \dots, f_{\bullet j}, \dots, f_{\bullet s})$  la distribución marginal de la variable  $y$ .

En primer lugar recordaremos los conceptos de independencia y asociación (lo contrario a la independencia) entre dos variables discretas. Veremos que el estadístico ji-cuadrado, que se usa habitualmente para contrastar la independencia, se puede interpretar como una medida de asociación. En este sentido, veremos que refleja la variabilidad entre distribuciones condicionadas.

A continuación abordaremos la representación de la asociación mediante un procedimiento de componentes principales y la representación simultánea de las categorías de las dos variables discretas, lo cual culmina los objetivos del análisis de correspondencias, pues en este gráfico simultáneo identificaremos las asociaciones entre categorías.

## 5.1. Test ji-cuadrado de independencia y distancia ji-cuadrado entre perfiles

Si el análisis de correspondencias pretende estudiar la relación entre las dos variables, la situación extrema de no relación se producirá cuando las dos variables sean independientes. Esto es equivalente a que la distribución conjunta resulte del producto de las marginales. En términos de las frecuencias observadas, ese producto de marginales da lugar a lo que se suele conocer como frecuencias esperadas, que son:

$$n_{i\bullet}n_{\bullet j}/n.$$

A partir de aquí se construye el estadístico ji-cuadrado para contrastar la independencia comparando las frecuencias observadas con las esperadas:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n_{i\bullet}n_{\bullet j}/n)^2}{n_{i\bullet}n_{\bullet j}/n}.$$

Bajo la hipótesis nula de independencia, el estadístico ji-cuadrado tiene una distribución ji-cuadrado con  $(r-1) \times (s-1)$  grados de libertad.

Además del contraste de independencia, podemos pensar que el estadístico ji-cuadrado es una medida de discrepancia respecto de la independencia, y por tanto es una medida de asociación entre las categorías de ambas variables. Con este fin, vamos a expresar el estadístico ji-cuadrado en términos de frecuencias relativas:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{(f_{ij}n - f_{i\bullet}f_{\bullet j})^2}{f_{i\bullet}f_{\bullet j}n} = n \sum_{i=1}^r \sum_{j=1}^s \frac{(f_{ij} - f_{i\bullet}f_{\bullet j})^2}{f_{i\bullet}f_{\bullet j}}.$$

Ahora observamos que el estadístico ji-cuadrado, representado en cierta forma, admite una interpretación interesante:

$$\frac{\chi^2}{n} = \sum_{i=1}^r \sum_{j=1}^s \frac{(f_{i\bullet} \frac{f_{ij}}{f_{i\bullet}} - f_{i\bullet}f_{\bullet j})^2}{f_{i\bullet}f_{\bullet j}} = \sum_{i=1}^r f_{i\bullet} \sum_{j=1}^s \left( \frac{f_{ij}}{f_{i\bullet}} - f_{\bullet j} \right)^2 \frac{1}{f_{\bullet j}} = \sum_{i=1}^r f_{i\bullet} d^2(r_i, m_y)$$

siendo  $r_i = \left( \frac{f_{i1}}{f_{i\bullet}}, \dots, \frac{f_{is}}{f_{i\bullet}} \right)'$  la distribución de  $y$  condicionada a  $x = x_i$ , también conocida como perfil de fila  $i$ -ésimo;  $m_y = (f_{\bullet 1}, \dots, f_{\bullet s})'$  la distribución marginal de  $y$ ; y  $d^2(r_i, m_y)$  una distancia entre el perfil  $i$ -ésimo y la distribución marginal. A esta distancia se la conoce como **distancia ji-cuadrado** y a  $\chi^2/n$  como **inercia**.

La tabla siguiente contiene los perfiles de fila, junto con la distribución marginal de  $y$ :

| $x \backslash y$ | $y_1$                 | $\dots$ | $y_j$                 | $\dots$ | $y_s$                 |          |
|------------------|-----------------------|---------|-----------------------|---------|-----------------------|----------|
| $x_1$            | $f_{11}/f_{1\bullet}$ | $\dots$ | $f_{1j}/f_{1\bullet}$ | $\dots$ | $f_{1s}/f_{1\bullet}$ | 1        |
| $\vdots$         | $\dots$               | $\dots$ | $\dots$               | $\dots$ | $\dots$               | $\vdots$ |
| $x_i$            | $f_{i1}/f_{i\bullet}$ | $\dots$ | $f_{ij}/f_{i\bullet}$ | $\dots$ | $f_{is}/f_{i\bullet}$ | 1        |
| $\vdots$         | $\dots$               | $\dots$ | $\dots$               | $\dots$ | $\dots$               | $\vdots$ |
| $x_r$            | $f_{r1}/f_{r\bullet}$ | $\dots$ | $f_{rj}/f_{r\bullet}$ | $\dots$ | $f_{rs}/f_{r\bullet}$ | 1        |
|                  | $f_{\bullet 1}$       | $\dots$ | $f_{\bullet j}$       | $\dots$ | $f_{\bullet s}$       | 1        |

De este modo, el estadístico ji-cuadrado (dividido entre  $n$ ) es una media ponderada de las distancias ji-cuadrado de los perfiles de fila a la distribución marginal de  $y$ . Si observamos que la distribución marginal se puede obtener como media de los perfiles de fila, veremos el

estadístico ji-cuadrado como una medida de variabilidad de los perfiles en torno a su media,  $m_y$ . Bajo hipótesis de independencia, los perfiles han de ser muy similares entre sí y, por tanto, muy similares a la distribución marginal, dando lugar a un valor pequeño de la variabilidad, medida por el estadístico ji-cuadrado.

De igual modo se puede interpretar el estadístico ji-cuadrado en términos de distancias ji-cuadrado entre perfiles de columna:

$$\frac{\chi^2}{n} = \sum_{i=1}^r \sum_{j=1}^s \frac{\left(f_{\bullet j} \frac{f_{ij}}{f_{\bullet j}} - f_{i\bullet} f_{\bullet j}\right)^2}{f_{i\bullet} f_{\bullet j}} = \sum_{j=1}^s f_{\bullet j} \sum_{i=1}^r \left(\frac{f_{ij}}{f_{\bullet j}} - f_{i\bullet}\right)^2 \frac{1}{f_{i\bullet}} = \sum_{j=1}^s f_{\bullet j} d^2(c_j, m_x)$$

siendo  $c_j = \left(\frac{f_{1j}}{f_{\bullet j}}, \dots, \frac{f_{rj}}{f_{\bullet j}}\right)'$  la distribución de  $x$  condicionada a  $y = y_j$ , también conocida como perfil de columna  $j$ -ésimo;  $m_x = (f_{1\bullet}, \dots, f_{r\bullet})'$  la distribución marginal de  $x$ ; y  $d^2(c_j, m_x)$  la distancia ji-cuadrado entre el perfil  $j$ -ésimo y la distribución marginal.

La tabla siguiente contiene los perfiles de columna, junto con la distribución marginal de  $x$ :

| $x \backslash y$ | $y_1$                  | $\dots$  | $y_j$                  | $\dots$  | $y_s$                  |                |
|------------------|------------------------|----------|------------------------|----------|------------------------|----------------|
| $x_1$            | $f_{11}/f_{\bullet 1}$ | $\vdots$ | $f_{1j}/f_{\bullet j}$ | $\vdots$ | $f_{1s}/f_{\bullet s}$ | $f_{1\bullet}$ |
| $\vdots$         | $\vdots$               | $\vdots$ | $\vdots$               | $\vdots$ | $\vdots$               | $\vdots$       |
| $x_i$            | $f_{i1}/f_{\bullet 1}$ | $\vdots$ | $f_{ij}/f_{\bullet j}$ | $\vdots$ | $f_{is}/f_{\bullet s}$ | $f_{i\bullet}$ |
| $\vdots$         | $\vdots$               | $\vdots$ | $\vdots$               | $\vdots$ | $\vdots$               | $\vdots$       |
| $x_r$            | $f_{r1}/f_{\bullet 1}$ | $\vdots$ | $f_{rj}/f_{\bullet j}$ | $\vdots$ | $f_{rs}/f_{\bullet s}$ | $f_{r\bullet}$ |
|                  | 1                      | $\dots$  | 1                      | $\dots$  | 1                      | 1              |

El análisis de correspondencias es un procedimiento de representación e interpretación de la variabilidad resultante del estadístico ji-cuadrado. Por tanto, si aceptamos la hipótesis de independencia no procede llevar a cabo un Análisis de Correspondencias. En caso de rechazo, habremos concluido que existe asociación, y mediante el Análisis de Correspondencias se realiza un estudio de dicha asociación.

## 5.2. Representación de los perfiles de fila

### 5.2.1. Perfiles de fila estandarizados

Pensemos en la descomposición de la ji-cuadrado a través de los perfiles de fila. Los perfiles de fila se pueden concebir como vectores del espacio  $\mathbb{R}^s$  y su variabilidad se encuentra medida a través de la distancia ji-cuadrado en dicho espacio:

$$d^2(u, v) = \sum_{j=1}^s (u_j - v_j)^2 \frac{1}{f_{\bullet j}}$$

siendo  $\mathbf{u} = (u_1, \dots, u_s)'$  y  $\mathbf{v} = (v_1, \dots, v_s)'$  vectores de  $\mathbb{R}^s$ . Si dividimos las coordenadas de cada perfil de fila por  $\left(\frac{1}{\sqrt{f_{\bullet 1}}}, \dots, \frac{1}{\sqrt{f_{\bullet s}}}\right)$  entonces podemos considerar los vectores

$$\mathbf{r}_i^e = \left( \frac{f_{i1}}{f_{i\bullet} \sqrt{f_{\bullet 1}}}, \dots, \frac{f_{is}}{f_{i\bullet} \sqrt{f_{\bullet s}}} \right)' \quad i \in \{1, \dots, r\}$$

dotados ahora de la distancia euclídea ordinaria, ya que la inercia total se puede expresar como la media ponderada de las distancias euclídeas de estos vectores a su media:

$$\frac{\chi^2}{n} = \sum_{i=1}^r f_{i\bullet} \sum_{j=1}^s \left( \frac{f_{ij}}{f_{i\bullet} \sqrt{f_{\bullet j}}} - \sqrt{f_{\bullet j}} \right)^2.$$

Esto coincide con la traza de la matriz de covarianzas de los perfiles estandarizados, como medida global de variabilidad, y reduce el estudio a un análisis de componentes principales sobre los perfiles estandarizados.

### 5.2.2. Análisis de componentes principales de los perfiles estandarizados

Formemos una matriz cuyas filas sean los perfiles de fila estandarizados:

$$\mathbf{X} = \left( \frac{f_{ij}}{f_{i\bullet} \sqrt{f_{\bullet j}}} \right)_{i,j} = \begin{pmatrix} \mathbf{r}_1^{e'} \\ \vdots \\ \mathbf{r}_r^{e'} \end{pmatrix}.$$

Si esta matriz se piensa como una matriz de observaciones donde cada columna es una variable y cada fila es un individuo, ponderado por la frecuencia marginal  $f_{i\bullet}$  que le corresponda, entonces el vector de medias es:  $\mathbf{m}_y^e = (\sqrt{f_{\bullet 1}}, \dots, \sqrt{f_{\bullet s}})'$  y la matriz de covarianzas:

$$\Sigma_r = \mathbf{X}' \mathbf{D}_r \mathbf{X} - \mathbf{m}_y^e \mathbf{m}_y^{e'}$$

siendo  $\mathbf{D}_r = \text{diag}(f_{1\bullet}, \dots, f_{r\bullet})$ .

El análisis de componentes principales de los perfiles de fila estandarizados pasa por diagonalizar la matriz de covarianzas  $\Sigma_r$ . Para ello, el resultado que sigue es muy útil.

**Resultado.** La matriz  $\mathbf{X}' \mathbf{D}_r \mathbf{X}$  es una matriz simétrica y semidefinida positiva, y tiene al vector  $\mathbf{m}_y^e$  como vector propio de valor propio uno.

En base a este resultado,  $\mathbf{m}_y^e (\mathbf{m}_y^e)'$  no es más que el primer término de la descomposición espectral de  $\mathbf{X}' \mathbf{D}_r \mathbf{X}$ ,  $\mathbf{m}_y^e$  es un autovector de  $\Sigma_r$  de autovalor cero, y el resto de autovectores y autovalores de  $\Sigma_r$  y  $\mathbf{X}' \mathbf{D}_r \mathbf{X}$  coinciden.

Esta pérdida de una dimensión en el espacio de los perfiles de fila se debe a que los perfiles de fila verifican:

$$\sum_{j=1}^s \frac{f_{ij}}{f_{i\bullet}} = 1 \quad \forall i \in \{1, \dots, r\} \quad [r_i' \mathbf{1}_s = 1]$$

y, en consecuencia, los perfiles de fila estandarizados:

$$\sum_{j=1}^s \sqrt{f_{\bullet j}} \frac{f_{ij}}{\sqrt{f_{\bullet j} f_{i\bullet}}} = 1 \quad \forall i \in \{1, \dots, r\} \quad [r_i^{e'} m_y^e = 1].$$

De este modo, en ambos casos se encuentran contenidos en un hiperplano, y el vector característico de dicho hiperplano ( $m_y^e$  en el caso de los perfiles estandarizados) es un autovector cuyo autovalor asociado es cero.

Para completar la comprensión de este hecho, obtenemos una nueva expresión para la inercia:

$$\frac{\chi^2}{n} = \sum_{i=1}^r \sum_{j=1}^s \frac{(f_{ij} - f_{i\bullet} f_{\bullet j})^2}{f_{i\bullet} f_{\bullet j}} = \sum_{i=1}^r \sum_{j=1}^s \frac{f_{ij}^2}{f_{i\bullet} f_{\bullet j}} - 1 = \text{traza}(X' D_r X) - 1 = \text{traza}(\Sigma_r).$$

La segunda igualdad se obtiene desarrollando el cuadrado. Haber obtenido la traza de la matriz de covarianzas  $\Sigma_r$  no es más que lo que cabía esperar. Así, pensemos en la diagonalización

$$X' D_r X = V \Lambda V'$$

siendo  $V = (m_y^e, v_2, \dots, v_s)$  la matriz cuyas columnas son los autovectores y  $\Lambda$  la matriz diagonal que contiene los autovalores correspondientes ordenados de mayor a menor, es decir,  $\Lambda = \text{diag}(1, \lambda_2, \dots, \lambda_s)$ . Entonces las coordenadas de las filas respecto de las componentes principales vendrán dadas por las columnas segunda, tercera y sucesivas de la matriz

$$A = X V = \begin{pmatrix} r_1^{e'} \\ \vdots \\ r_r^{e'} \end{pmatrix} (m_y^e, v_2, \dots, v_s) = \begin{pmatrix} 1 & a_{12} & a_{13} & \cdots & a_{1s} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & a_{r2} & a_{r3} & \cdots & a_{rs} \end{pmatrix}.$$

Estas coordenadas verifican las siguientes propiedades:

- Las coordenadas tienen media ponderada cero. ( $\sum_{i=1}^r f_{i\bullet} a_{ij} = 0 \quad \forall j \in \{2, \dots, s\}$ ).
- Las distancias euclídeas entre los vectores de coordenadas de dos filas coincide con la distancia euclídea entre los correspondientes perfiles estandarizados, la cual a su vez coincidía con la distancia ji cuadrado entre los perfiles de fila originarios.

### 5.2.3. Contribuciones

De la segunda propiedad se deduce que la distancia al centroide, esto es, al perfil medio, de cada perfil de fila se puede expresar:

$$d^2(\mathbf{r}_i, \mathbf{m}_y) = \sum_{k=2}^s a_{ik}^2$$

y esto, multiplicado por  $f_{i\bullet}$ , lo concebimos como la contribución del perfil de fila  $i$ -ésimo a la inercia total.

El análisis de componentes principales de los perfiles estandarizados da lugar a una descomposición de la inercia como suma de los autovalores

$$\frac{\chi^2}{n} = \text{traza}(\mathbf{\Sigma}_r) = \lambda_2 + \lambda_3 + \dots + \lambda_s$$

siendo

$$\lambda_k = \mathbf{v}_k' \mathbf{X}' \mathbf{D}_r \mathbf{X} \mathbf{v}_k = \sum_{i=1}^r f_{i\bullet} a_{ik}^2.$$

Para una fácil comprensión de la segunda igualdad, debe recordarse que  $\mathbf{X} \mathbf{v}_k$  es el vector columna (columna  $k$ -ésima de la matriz  $\mathbf{A}$ ) que contiene las coordenadas de cada perfil de fila respecto de la componente  $k$ -ésima.

La tabla siguiente es una descomposición de la inercia total en perfiles de fila y componentes:

|          | Componente 2                         | ... | Componente k                         | ... | Componente s                         |                                      |
|----------|--------------------------------------|-----|--------------------------------------|-----|--------------------------------------|--------------------------------------|
| Perfil 1 | $f_{1\bullet} a_{12}^2$              | ... | $f_{1\bullet} a_{1k}^2$              | ... | $f_{1\bullet} a_{1s}^2$              | $\sum_{k=2}^s f_{1\bullet} a_{1k}^2$ |
| ...      | ...                                  |     | ...                                  |     | ...                                  | ...                                  |
| Perfil i | $f_{i\bullet} a_{i2}^2$              | ... | $f_{i\bullet} a_{ik}^2$              | ... | $f_{i\bullet} a_{is}^2$              | $\sum_{k=2}^s f_{i\bullet} a_{ik}^2$ |
| ...      | ...                                  |     | ...                                  |     | ...                                  | ...                                  |
| Perfil r | $f_{r\bullet} a_{r2}^2$              | ... | $f_{r\bullet} a_{rk}^2$              | ... | $f_{r\bullet} a_{rs}^2$              | $\sum_{k=2}^s f_{r\bullet} a_{rk}^2$ |
|          | $\sum_{i=1}^r f_{i\bullet} a_{i2}^2$ | ... | $\sum_{i=1}^r f_{i\bullet} a_{ik}^2$ | ... | $\sum_{i=1}^r f_{i\bullet} a_{is}^2$ | $\chi^2/n$                           |

La proporción de variabilidad explicada si tomamos  $(k-1)$  componentes ( $k \leq s$ ) será:

$$\frac{\lambda_2 + \dots + \lambda_k}{\lambda_2 + \dots + \lambda_s}$$

y sería como quedarnos con las  $(k-1)$  primeras columnas (de la 2 a la  $k$ ) tanto en la matriz  $\mathbf{A}$  como en la tabla anterior.

### 5.3. Representación de los perfiles de columna

#### 5.3.1. Análisis de componentes principales de los perfiles estandarizados

El análisis anterior de los perfiles de fila se puede repetir de la misma manera para los perfiles de columna. Los pasos se llevan a cabo en perfecta analogía con el caso anterior. Resumiendo, tendríamos que la inercia total se puede expresar como media ponderada de las distancias ji-cuadrado de los perfiles de columna (a su media), o equivalentemente, como las distancias euclídeas de los perfiles estandarizados (a su media correspondiente):

$$\frac{\chi^2}{n} = \sum_{j=1}^s f_{\bullet j} \sum_{i=1}^r \left( \frac{f_{ij}}{f_{\bullet j} \sqrt{f_{i\bullet}}} - \sqrt{f_{i\bullet}} \right)^2 = \sum_{j=1}^s f_{\bullet j} \|c_i^e - m_x^e\|^2.$$

Formamos la matriz  $Y$ , cuyas columnas son los perfiles de columna estandarizados:

$$Y = \left( \frac{f_{ij}}{f_{\bullet j} \sqrt{f_{i\bullet}}} \right)_{i,j} = (c_1^e, \dots, c_s^e)$$

la cual se concibe como una matriz de observaciones transpuesta, donde cada fila es una variable y cada columna es un individuo, ponderado por la frecuencia marginal  $f_{\bullet j}$  que le corresponda. Entonces el vector de medias es:  $m_x^e = (\sqrt{f_{1\bullet}}, \dots, \sqrt{f_{r\bullet}})'$  y la matriz de covarianzas:

$$\Sigma_s = Y D_s Y' - m_x^e m_x^{e'}$$

siendo  $D_s = \text{diag}(f_{\bullet 1}, \dots, f_{\bullet s})$ .

De nuevo se aplica el Análisis de Componentes Principales, mediante la diagonalización de la matriz de covarianzas  $\Sigma_s$ . Surge entonces el resultado siguiente.

**Resultado.** La matriz  $Y D_s Y'$  es una matriz simétrica y semidefinida positiva, y tiene al vector  $m_x^e$  como vector propio de valor propio uno.

En base a este resultado,  $m_x^e m_x^{e'}$  no es más que el primer término de la descomposición espectral de  $Y D_s Y'$ ,  $m_x^e$  es un autovector de  $\Sigma_s$  de autovalor cero, y el resto de autovectores y autovalores de  $\Sigma_s$  e  $Y D_s Y'$  coinciden.

De nuevo se pierde una dimensión en el espacio de los perfiles de columna, puesto que verifican una restricción lineal obvia, consecuencia de que sus componentes suman uno. Esta restricción se convierte en los perfiles de columna estandarizados, en que pertenecen al hiperplano cuyo vector característico es  $m_x^e$ . Así,

$$\frac{\chi^2}{n} = \text{traza}(Y D_s Y') - 1 = \text{traza}(\Sigma_s).$$

Entonces, la diagonalización conduce a

$$YD_sY' = W\Lambda W'$$

siendo  $W = (m_x^e, w_2, \dots, w_r)$  la matriz cuyas columnas son los autovectores y  $\Lambda$  la matriz diagonal que contiene los autovalores correspondientes ordenados de mayor a menor, es decir  $\Lambda = \text{diag}(1, \lambda_2, \dots, \lambda_r)$ . Ahora las coordenadas de las columnas respecto de las componentes principales vendrán dadas por las filas segunda, tercera y sucesivas de la matriz

$$B = W'Y = \begin{pmatrix} m_x^{e'} \\ w_2' \\ \vdots \\ w_r' \end{pmatrix} (c_1^e, \dots, c_s^e) = \begin{pmatrix} 1 & \dots & 1 \\ b_{21} & \dots & b_{2s} \\ b_{31} & \dots & b_{3s} \\ \vdots & \ddots & \vdots \\ b_{r1} & \dots & b_{rs} \end{pmatrix}.$$

Estas coordenadas verifican las siguientes propiedades:

- Las coordenadas tienen media ponderada cero.  $\left( \sum_{j=1}^s f_{\bullet j} b_{ij} = 0 \quad \forall i \in \{2, \dots, r\} \right)$ .
- Las distancias euclídeas entre los vectores de coordenadas de dos columnas coincide con la distancia euclídea entre los correspondientes perfiles estandarizados, la cual a su vez coincidía con la distancia ji cuadrado entre los perfiles de columna originarios.

### 5.3.2. Contribuciones

De la segunda propiedad se deduce que la distancia al centroide, esto es, al perfil medio, de cada perfil de columna se puede expresar:

$$d^2(c_j, m_x) = \sum_{k=2}^r b_{kj}^2$$

y esto, multiplicado por  $f_{\bullet j}$ , lo concebimos como la contribución del perfil de columna  $j$ -ésimo a la inercia total.

El análisis de componentes principales de los perfiles estandarizados da lugar a una descomposición de la inercia como suma de los autovalores

$$\frac{\chi^2}{n} = \text{traza}(\Sigma_s) = \lambda_2 + \lambda_3 + \dots + \lambda_r$$

siendo

$$\lambda_k = w_k' Y D_s Y' w_k = \sum_{j=1}^r f_{\bullet j} b_{kj}^2.$$

Para una fácil comprensión de la segunda igualdad, debe recordarse que  $w_k' Y$  es el vector fila (fila  $k$ -ésima de la matriz  $B$ ) que contiene las coordenadas de cada perfil de columna respecto de la componente  $k$ -ésima.

La tabla siguiente es una descomposición de la inercia total en perfiles de columna y componentes:

|              | Perfil 1                              | ... | Perfil j                              | ... | Perfil s                              |                                       |
|--------------|---------------------------------------|-----|---------------------------------------|-----|---------------------------------------|---------------------------------------|
| Componente 2 | $f_{\bullet 1} b_{21}^2$              | ... | $f_{\bullet j} b_{2j}^2$              | ... | $f_{\bullet s} b_{2s}^2$              | $\sum_{j=1}^s f_{\bullet j} b_{2j}^2$ |
| $\vdots$     | $\vdots$                              |     | $\vdots$                              |     | $\vdots$                              | $\vdots$                              |
| Componente k | $f_{\bullet 1} b_{k1}^2$              | ... | $f_{\bullet j} b_{kj}^2$              | ... | $f_{\bullet s} b_{ks}^2$              | $\sum_{j=1}^s f_{\bullet j} b_{kj}^2$ |
| $\vdots$     | $\vdots$                              |     | $\vdots$                              |     | $\vdots$                              | $\vdots$                              |
| Componente r | $f_{\bullet 1} b_{r1}^2$              | ... | $f_{\bullet j} b_{rj}^2$              | ... | $f_{\bullet s} b_{rs}^2$              | $\sum_{j=1}^s f_{\bullet j} b_{rj}^2$ |
|              | $\sum_{k=2}^r f_{\bullet 1} b_{k1}^2$ | ... | $\sum_{k=2}^r f_{\bullet j} b_{kj}^2$ | ... | $\sum_{k=2}^r f_{\bullet s} b_{ks}^2$ | $\chi^2/n$                            |

La proporción de variabilidad explicada si tomamos  $(k-1)$  componentes  $(k \leq r)$  será:

$$\frac{\lambda_2 + \dots + \lambda_k}{\lambda_2 + \dots + \lambda_r}$$

y sería como quedarnos con las  $(k-1)$  primeras columnas (de la 2 a la  $k$ ) tanto en la matriz  $B$  como en la tabla anterior.

## 5.4. Representación simultánea de los perfiles de fila y columna

Consideremos la matriz

$$Z = \left( \frac{f_{ij}}{\sqrt{f_{i\bullet}} \sqrt{f_{\bullet j}}} \right)_{i,j}.$$

Observemos que

$$X = D_r^{-1} F D_s^{-1/2}, \quad Y = D_r^{-1/2} F D_s^{-1}, \quad Z = D_r^{-1/2} F D_s^{-1/2}$$

siendo  $F = (f_{ij})_{i,j}$ . Entonces

- $X' D_r X = Z' Z \quad Y D_s Y' = Z Z'.$
- Si  $v$  es autovector de  $Z' Z$  con autovalor asociado  $\lambda$ , entonces  $w = Zv$  es autovector de  $Z Z'$  con autovalor asociado  $\lambda$ .

Por tanto, ambas matrices tienen los mismos autovalores, mientras que los autovectores mantienen la relación que se acaba de indicar. Como consecuencia, el número de autovalores no nulos será  $k_0 \leq \min\{r, s\}$ . En lo que sigue supondremos una matriz común de autovalores no nulos  $D_\lambda$  de orden  $k_0$ , y los autovectores y coordenadas se referirán únicamente a las  $k_0$  componentes asociadas a estos autovalores no nulos, tanto cuando se interpreten en el espacio de filas como en el de columnas.

Recordemos la diagonalización

$$Z'Z = X'D_rX = VD_\lambda V'.$$

Entonces las columnas de  $ZV$  son los autovectores de  $ZZ'$ , que una vez normalizadas darán lugar a la matriz ortogonal para la diagonalización  $ZZ' = WD_\lambda W'$ :

$$W = ZVD_\lambda^{-1/2}.$$

Finalmente, las coordenadas de los perfiles de columna eran las columnas de la matriz

$$B = W'Y.$$

Vamos a deducir la relación que existe entre estas coordenadas y las coordenadas de los perfiles de fila,  $A = XV$ .

$$\begin{aligned} B &= W'Y = (ZVD_\lambda^{-1/2})'Y = D_\lambda^{-1/2}V'Z'Y \\ &= D_\lambda^{-1/2}V'(D_r^{-1/2}FD_s^{-1/2})'D_r^{-1/2}FD_s^{-1} = D_\lambda^{-1/2}V'D_s^{-1/2}F'D_r^{-1}FD_s^{-1} \\ &= D_\lambda^{-1/2}A'FD_s^{-1}. \end{aligned}$$

En la última igualdad se ha utilizado que  $A = XV = D_r^{-1}FD_s^{-1/2}V$ . Pero el resultado obtenido se puede escribir así:

$$b_{kj} = \frac{1}{\sqrt{\lambda_k}} \left( \frac{f_{1j}}{f_{\bullet j}} a_{1k} + \dots + \frac{f_{rj}}{f_{\bullet j}} a_{rk} \right)$$

de modo que la coordenada del perfil de columna  $j$ -ésimo en la componente  $k$ -ésima es una combinación ponderada de las coordenadas de cada perfil de fila en dicha componente, siendo los pesos de tal ponderación las frecuencias relativas de cada categoría de la variable  $x$  condicionada a la categoría  $j$  de  $y$ . Así, si una categoría  $i$  presenta alta frecuencia condicionada pesará más en esta combinación, aproximando hacia sí la coordenada de la categoría  $j$  de la variable  $y$ . De igual modo, se puede ver que

$$A = D_r^{-1}FB'D_\lambda^{-1/2}.$$

**Ejemplo.** En el ejemplo sobre los datos de la EPA (2010), vamos a representar en un mismo gráfico bidimensional los perfiles de fila y columna.

```
> library(MASS) # Cargamos el paquete MASS (Venables y Ripley)
> m <- cbind(dat$Ocupados, dat$Parados, dat$Inactivos) # Frecuencias absolutas
> rownames(m) <- dat$Comunidad.Autónoma # Nombres de filas
> colnames(m) <- names(dat)[2:4] # Nombres de las columnas
> r <- nrow(m) # Número de filas
> s <- ncol(m) # Número de columnas
> n <- sum(m) # Frecuencia total (tamaño muestral)
> f <- m/n # Frecuencias relativas (conjuntas)
> mx <- apply(f, 1, sum) # Frecuencias marginales de columna
> my <- apply(f, 2, sum) # Frecuencias marginales de fila
```

Calculamos los perfiles de fila y columna.

```
> ri <- diag(1/mx) %*% f # Perfiles de fila
> rownames(ri) <- dat$Comunidad.Autónoma
> cj <- f %*% diag(1/my) # Perfiles de columna
> colnames(cj) <- names(dat)[2:4]
```

A continuación, calculamos las componentes principales de los perfiles de fila estandarizados.

```
> x <- ri %*% diag(1/sqrt(my)) # Perfiles de fila estandarizados
> mye <- sqrt(my) # Marginal de fila estandarizada
> sr <- t(x) %*% diag(mx) %*% x - mye %*% t(mye) # Matriz Sigma_r
> auto <- eigen(t(x) %*% diag(mx) %*% x) # Diagonalización
> lam <- auto$values # Autovalores
> v <- auto$vectors # Autovectores
```

Calculamos ahora las coordenadas de los perfiles de fila estandarizados en las componentes y hacemos la representación (Figura 5.1).

```
> a <- x %*% v
> plot(a[, 2], a[, 3])
> text(a[, 2], a[, 3], labels = dat$Comunidad.Autónoma)
> abline(h = 0, lty = 2)
> abline(v = 0, lty = 2)
```




Figura 5.1.: Gráficos de perfiles de fila.

A continuación, calculamos las componentes principales de los perfiles de columna estandarizados.

```

> y <- diag(1/sqrt(mx)) %*% cj # Perfiles de columna estandarizados
> mxe <- sqrt(mx) # Marginal de columna estandarizada
> sigs <- y %*% diag(my) %*% t(y) - mxe %*% t(mxe) # Matriz Sigma_s
> auto <- eigen(y %*% diag(my) %*% t(y)) # Diagonalización
> lam <- auto$values # Autovalores
> w <- auto$vectors # Autovectores

```

Calculamos ahora las coordenadas de los perfiles de columna estandarizados en las componentes y hacemos la representación (Figura 5.2).

```

> b <- t(w) %*% y
> plot(b[2, ], b[3, ])
> text(b[2, ], b[3, ], names(dat)[2:4])
> abline(h = 0, lty = 2)
> abline(v = 0, lty = 2)

```




Figura 5.2.: Gráficos de perfiles de columna.

Hacemos ahora la representación simultánea (Figura 5.3).

```

> z <- diag(1/sqrt(mx)) %*% f %*% diag(1/sqrt(my))
> k0 <- 3
> w <- z %*% v[, 1:k0] %*% diag(1/sqrt(lam[1:k0]))
> b <- t(w) %*% y
> plot(c(a[, 2], b[2, ]), c(a[, 3], b[3, ]))
> text(c(a[, 2], b[2, ]), c(a[, 3], b[3, ]),
+     labels = c(as.character(dat$Comunidad.Autónoma), names(dat)[2:4]),
+     col = c(rep("blue", r), rep("red", s)), cex = 0.7)
> abline(h = 0, lty = 2)
> abline(v = 0, lty = 2)

```

También podemos hacer la representación utilizando el comando `corresp`.




Figura 5.3.: Representación simultánea de los perfiles de fila y columna para los datos de la EPA.

```
> m <- 10 * m
> r.out <- corresp(m, nf = 2)
> biplot(corresp(m, nf = 2), cex = c(0.7, 1))
```




Figura 5.4.: Representación simultánea de los perfiles de fila y columna para los datos de la EPA (función corresp).

El resultado se muestra en la Figura 5.4. El eje horizontal corresponde a la primera componente y el eje vertical a la segunda. La proximidad entre los puntos de distintas comunidades autónomas indica que presentan perfiles similares. Asimismo, si una comunidad autónoma está próxima al punto correspondiente a los Inactivos, esto indica que en su perfil hay un porcentaje alto de población inactiva. Igualmente para las categorías de Ocupados y Parados.

## 6. Análisis discriminante

Empezamos definiendo el problema discriminante. Resumidamente se puede decir que el problema discriminante consiste en establecer reglas de diagnóstico que permitan clasificar a un individuo en alguno de dos o más grupos bien definidos. El ejemplo paradigmático sería la diagnosis entre enfermos y sanos en Medicina. Para fundamentar la decisión de diagnóstico se emplean ciertas observaciones del individuo: presencia de síntomas, análisis de sangre y otras pruebas diagnósticas. Estas pruebas son útiles para el diagnóstico en la medida en que aportan resultados diferentes para los individuos enfermos respecto de los sanos.

Esta situación da lugar a varias tareas, según el objetivo que se persiga:

1. Determinar la presencia de diferencias entre los grupos.
2. Determinar qué variables permiten discriminar mejor entre los grupos, en base a las diferencias que presentan entre ellos.
3. Construir la regla discriminante en base a una muestra de entrenamiento.
4. Asignar un individuo a cierto grupo en base a la regla discriminante, bien la regla óptima o bien estimada en base a una muestra de entrenamiento.

La primera tarea se resuelve mediante un Análisis (multivariante) de la varianza, mientras que las otras tres son específicas del Análisis discriminante.

Realmente la construcción de una regla discriminante y su aplicación constituye una cuestión de gran calado dentro de la teoría de la decisión y la inferencia estadística. Por ello, aunque el Análisis discriminante se puede considerar como una técnica de Análisis multivariante, su importancia supera ampliamente a la de otras técnicas, como las estudiadas en temas anteriores. El Análisis discriminante se puede considerar en sí mismo como una rama de la Estadística.

### 6.1. Dos grupos con distribuciones conocidas

Suponemos la existencia de dos grupos  $G_1$  y  $G_2$ , definidos de manera inequívoca. Consideramos un vector aleatorio  $x$  que presenta funciones de densidad o de probabilidad  $f_1$  si el individuo procede del grupo  $G_1$  y  $f_2$  si procede del grupo  $G_2$ . Utilizaremos el valor observado del vector aleatorio  $x$  para decidir si un individuo pertenece a uno u otro grupo. Esto supone dividir el soporte del vector  $x$  mediante una partición en dos regiones  $R_1$  y  $R_2$ :  $R = R_1 \cup R_2$  y  $R_1 \cap R_2 = \emptyset$ , de modo que clasificaremos al individuo en el grupo  $G_1$  si  $x \in R_1$  y en el grupo  $G_2$  si  $x \in R_2$ . En realidad, la regla discriminante anterior sería una regla determinista, de modo que una definición general de regla discriminante, que incluya la posibilidad de aleatorización, sería la siguiente.

**Definición 6.1.** Una regla discriminante (aleatorizada) es una aplicación

$$\begin{aligned}\varphi : R &\longrightarrow [0, 1] \\ x &\longrightarrow \varphi(x) = P(\text{Clasificar en } G_1 / x = x).\end{aligned}$$

Una regla discriminante no aleatorizada es de la forma

$$\varphi(x) = \begin{cases} 1 & \text{si } x \in R_1, \\ 0 & \text{si } x \in R_2. \end{cases}$$

En el procedimiento de clasificación podemos cometer dos tipos de errores: clasificar a un individuo que procede del grupo  $G_1$  en el grupo  $G_2$ , y clasificar a un individuo del grupo  $G_2$  en el grupo  $G_1$ . Las probabilidades condicionales de cada uno de estos errores son

$$P(2/1) = \int (1 - \varphi(x)) f_1(x) dx \quad \text{y} \quad P(1/2) = \int \varphi(x) f_2(x) dx$$

donde las integrales son sumas en el caso discreto. Si la regla discriminante es no aleatorizada, entonces las probabilidades anteriores se pueden expresar así:

$$P(2/1) = \int_{R_2} f_1(x) dx \quad \text{y} \quad P(1/2) = \int_{R_1} f_2(x) dx.$$

Nótese cómo el problema discriminante se puede encuadrar dentro de la teoría de la decisión. Un paso más en esta dirección nos conduce a la comparación de reglas discriminantes.

**Definición 6.2.** Una regla discriminante  $\varphi$  es preferible a otra  $\varphi'$  si

$$P_\varphi(2/1) \leq P_{\varphi'}(2/1)$$

y

$$P_\varphi(1/2) \leq P_{\varphi'}(1/2).$$

**Nota.** La relación “ser preferible” es una relación de orden parcial.

**Definición 6.3.** Una regla discriminante se dice admisible si no hay ninguna otra regla discriminante que sea preferible (estrictamente) a ella. Por “preferible estrictamente” entendemos que, además de ser preferible, en alguno de los dos errores de clasificación sea estrictamente mejor.

**Teorema 6.1.** Sea  $f_1$  la función de densidad o de probabilidad, según el caso, del vector aleatorio  $x$  condicionada al grupo  $G_1$  y  $f_2$  la correspondiente función de densidad o probabilidad condicionada al grupo  $G_2$ .

Las reglas discriminantes de la forma

$$\varphi(\mathbf{x}) = \begin{cases} 1 & \text{si } \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > c, \\ \gamma(\mathbf{x}) & \text{si } \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} = c, \\ 0 & \text{si } \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} < c. \end{cases}$$

son admisibles. Además, son las únicas reglas admisibles.

*Demostración.* Es la misma que para el Lema de Neyman-Pearson, en el caso del contraste de una hipótesis nula simple frente a una alternativa simple.  $\square$

En lo que sigue veremos cómo distintos criterios permiten la elección de una regla discriminante.

## 6.2. Criterios para elegir una regla discriminante

### 6.2.1. Minimizar la probabilidad total de clasificación incorrecta

Pensemos en una población que se encuentra dividida en individuos pertenecientes al grupo  $G_1$  e individuos pertenecientes al grupo  $G_2$ , con proporciones respectivas  $\pi_1$  y  $\pi_2 = 1 - \pi_1$ . Así,  $\pi_1$  y  $\pi_2$  se convierten en probabilidades originales de pertenencia a cada grupo, antes de observar el vector aleatorio  $\mathbf{x}$ . En consecuencia, la probabilidad total de clasificación incorrecta es

$$P(R, f) = \pi_1 P(2/1) + \pi_2 P(1/2)$$

denotando  $R = (R_1, R_2)'$  al vector de regiones de clasificación y  $f = (f_1, f_2)'$  al vector de densidades. Nuestro objetivo será adoptar una regla de clasificación que presente la menor probabilidad total de clasificación incorrecta. Recurrimos a un lema que nos ayudará en este propósito.

**Lema 6.1.** La integral  $\int_R g(\mathbf{x}) d\mathbf{x}$  alcanza su mínimo como función de  $R$  en

$$R^- = \{\mathbf{x} : g(\mathbf{x}) < 0\}.$$

*Demostración.* Denotemos  $R^+ = (R^-)^c = \{\mathbf{x} : g(\mathbf{x}) \geq 0\}$ . Para cualquier conjunto  $R$ , se tiene

$$\begin{aligned} \int_R g(\mathbf{x}) d\mathbf{x} &= \int_{R \cap R^-} g(\mathbf{x}) d\mathbf{x} + \int_{R \cap R^+} g(\mathbf{x}) d\mathbf{x} \geq \int_{R \cap R^-} g(\mathbf{x}) d\mathbf{x} \\ &= \int_{R^-} g(\mathbf{x}) d\mathbf{x} - \int_{R^c \cap R^-} g(\mathbf{x}) d\mathbf{x} \geq \int_{R^-} g(\mathbf{x}) d\mathbf{x}, \end{aligned}$$

lo cual concluye la demostración del presente lema.  $\square$

Desarrollando la probabilidad total de clasificación incorrecta, obtenemos

$$\begin{aligned} P(R, f) &= \pi_1 P(2/1) + \pi_2 P(1/2) \\ &= \pi_1 \left(1 - \int_{R_1} f_1(\mathbf{x}) d\mathbf{x}\right) + \pi_2 \int_{R_1} f_2(\mathbf{x}) d\mathbf{x} \\ &= \pi_1 + \int_{R_1} [\pi_2 f_2(\mathbf{x}) - \pi_1 f_1(\mathbf{x})] d\mathbf{x} \end{aligned}$$

Por el lema anterior, como función de  $R_1$  alcanza su mínimo en  $R_1 = \{\mathbf{x} : \pi_2 f_2(\mathbf{x}) - \pi_1 f_1(\mathbf{x}) < 0\}$ , que se corresponde con la regla de clasificación que asigna al grupo  $G_1$  si

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > \frac{\pi_2}{\pi_1}$$

y al grupo  $G_2$  en otro caso. La asignación en la frontera de  $R_1$  no debería ser relevante, ya que no afecta a la probabilidad total. Sin embargo, esto puede dar lugar a varias reglas con la misma probabilidad total. Pero si el vector  $\mathbf{x}$  es continuo y se cumple alguna otra condición más,  $P(f_1(\mathbf{x})/f_2(\mathbf{x}) = \pi_2/\pi_1) = 0$ , por lo que serían reglas equivalentes.

**Ejemplo.** Supongamos que  $f_i$  es la densidad de  $N_d(\mu_i, \Sigma_i)$ , con  $\Sigma_1 = \Sigma_2 = \Sigma$ . Vamos a calcular la regla de clasificación óptima con el criterio anterior y las correspondientes probabilidades de clasificación incorrecta. Las densidades adoptan la forma

$$f_i(\mathbf{x}) = (2\pi)^{-p/2} |\Sigma|^{-1/2} \exp \left[ -\frac{1}{2} (\mathbf{x} - \mu_i)' \Sigma^{-1} (\mathbf{x} - \mu_i) \right]$$

y su cociente será

$$\begin{aligned} \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= \exp \left[ -\frac{1}{2} (\mathbf{x} - \mu_1)' \Sigma^{-1} (\mathbf{x} - \mu_1) + \frac{1}{2} (\mathbf{x} - \mu_2)' \Sigma^{-1} (\mathbf{x} - \mu_2) \right] \\ &= \exp \left[ (\mu_1 - \mu_2)' \Sigma^{-1} \mathbf{x} - \frac{1}{2} (\mu_1 - \mu_2)' \Sigma^{-1} (\mu_1 + \mu_2) \right]. \end{aligned}$$

Tomando logaritmos, la regla de clasificación óptima asigna al grupo  $G_1$  si

$$D(\mathbf{x}) = \lambda' \left[ \mathbf{x} - \frac{1}{2} (\mu_1 + \mu_2) \right] > \log(\pi_2/\pi_1)$$

siendo  $\lambda = \Sigma^{-1}(\mu_1 - \mu_2)$ . La ecuación  $D(\mathbf{x}) = \log(\pi_2/\pi_1)$  define un hiperplano que separa los dos grupos.

Para calcular las probabilidades de clasificación incorrecta, observamos que, condicionado a cada grupo, la variable aleatoria  $D(\mathbf{x})$  tiene distribución normal. Su media y varianza condicionadas son

$$\begin{aligned} E[D(\mathbf{x})/G_1] &= \lambda' \left[ \mu_1 - \frac{1}{2} (\mu_1 + \mu_2) \right] = \frac{1}{2} \Delta^2, \\ \text{Var}[D(\mathbf{x})/G_1] &= \text{Var}[\lambda' \mathbf{x}/G_1] = \lambda' \Sigma \lambda = \Delta^2 \end{aligned}$$

denotando  $\Delta^2 = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \boldsymbol{\lambda}' (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$  al cuadrado de la distancia de Mahalanobis entre las medias  $\boldsymbol{\mu}_1$  y  $\boldsymbol{\mu}_2$ . Entonces

$$\begin{aligned} P(2/1) &= P[D(\mathbf{x}) \leq \log(\pi_2/\pi_1)/G_1] \\ &= P\left[\frac{D(\mathbf{x}) - \Delta^2/2}{\Delta} \leq \frac{\log(\pi_2/\pi_1) - \Delta^2/2}{\Delta}/G_1\right] \\ &= \Phi\left(\frac{\log(\pi_2/\pi_1) - \Delta^2/2}{\Delta}\right). \end{aligned}$$

De igual modo,  $E[D(\mathbf{x})/G_2] = -\frac{1}{2}\Delta^2$  y  $\text{Var}[D(\mathbf{x})/G_2] = \Delta^2$ , y así:

$$\begin{aligned} P(1/2) &= P[D(\mathbf{x}) > \log(\pi_2/\pi_1)/G_2] \\ &= P\left[\frac{D(\mathbf{x}) + \Delta^2/2}{\Delta} > \frac{\log(\pi_2/\pi_1) + \Delta^2/2}{\Delta}/G_2\right] \\ &= 1 - \Phi\left(\frac{\log(\pi_2/\pi_1) + \Delta^2/2}{\Delta}\right). \end{aligned}$$

La probabilidad total de clasificación incorrecta queda:

$$\begin{aligned} P(\text{Clasificación incorrecta}) &= \pi_1 P(2/1) + \pi_2 P(1/2) \\ &= \pi_1 \Phi\left(\frac{\log(\pi_2/\pi_1) - \Delta^2/2}{\Delta}\right) \\ &\quad + \pi_2 \left[1 - \Phi\left(\frac{\log(\pi_2/\pi_1) + \Delta^2/2}{\Delta}\right)\right]. \end{aligned}$$

Si  $\pi_1 = \pi_2 = \frac{1}{2}$ , entonces la regla discriminante consiste en clasificar en  $G_1$  si  $D(\mathbf{x}) = \boldsymbol{\lambda}'[\mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2)] > \log(\pi_2/\pi_1) = 0$ , o equivalentemente, si

$$\boldsymbol{\lambda}'\mathbf{x} > \frac{1}{2}(\boldsymbol{\lambda}'\boldsymbol{\mu}_1 + \boldsymbol{\lambda}'\boldsymbol{\mu}_2)$$

esto es, si  $\boldsymbol{\lambda}'\mathbf{x}$  está más próximo a  $\boldsymbol{\lambda}'\boldsymbol{\mu}_1$  que a  $\boldsymbol{\lambda}'\boldsymbol{\mu}_2$ . A esto se le conoce como regla discriminante lineal de Fisher (1936).

**Ejemplo.** En el ejemplo anterior, supongamos que  $\boldsymbol{\Sigma}_1 \neq \boldsymbol{\Sigma}_2$ . Entonces

$$\begin{aligned} Q(\mathbf{x}) &= \log(f_1(\mathbf{x})/f_2(\mathbf{x})) \\ &= \frac{1}{2} \log(|\boldsymbol{\Sigma}_2|/|\boldsymbol{\Sigma}_1|) - \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)' \boldsymbol{\Sigma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) + \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}_2^{-1} (\mathbf{x} - \boldsymbol{\mu}_2) \\ &= \frac{1}{2} \log(|\boldsymbol{\Sigma}_2|/|\boldsymbol{\Sigma}_1|) - \frac{1}{2} \left[ \mathbf{x}'(\boldsymbol{\Sigma}_1^{-1} - \boldsymbol{\Sigma}_2^{-1})\mathbf{x} - 2\mathbf{x}'(\boldsymbol{\Sigma}_1^{-1}\boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_2^{-1}\boldsymbol{\mu}_2) \right] \end{aligned}$$

y la regla óptima clasifica en  $G_1$  si  $Q(\mathbf{x}) > \log(\pi_2/\pi_1)$ . Pero, mientras  $D(\mathbf{x})$  es una función lineal, ahora  $Q(\mathbf{x})$  es una función cuadrática, de modo que la frontera entre las dos regiones ya no es un hiperplano.

### 6.2.2. Razón de verosimilitudes

Nos situamos en el contexto en que las probabilidades a priori,  $\pi_1$  y  $\pi_2$ , son desconocidas o sencillamente no se tienen en cuenta. Una regla de clasificación debería asignar un individuo al grupo más verosímil, que es aquel que otorga mayor probabilidad a su resultado muestral. Esto equivale a clasificar en el grupo  $G_1$  si  $f_1(\mathbf{x})/f_2(\mathbf{x}) > 1$ , lo cual coincide con el criterio anterior para  $\pi_1 = \pi_2 = 1/2$ .

### 6.2.3. Minimizar el coste total de clasificación incorrecta

Si asociamos unos costes  $C(2/1)$  y  $C(1/2)$  a cada uno de los errores de clasificación, entonces el coste total esperado es

$$C = \pi_1 P(2/1) C(2/1) + \pi_2 P(1/2) C(1/2).$$

Podemos repetir los argumentos que obtuvieron la regla que minimiza la probabilidad total de clasificación incorrecta sustituyendo  $\pi_1$  y  $\pi_2$  por  $\pi_1 C(2/1)$  y  $\pi_2 C(1/2)$ , ya que en aquellos argumentos no se usó que  $\pi_1 + \pi_2 = 1$ . Así, obtendremos que la regla que hace mínimo el coste total esperado consiste en clasificar en el grupo  $G_1$  si

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > \frac{\pi_2 C(1/2)}{\pi_1 C(2/1)}.$$

Por supuesto, si  $C(2/1) = C(1/2)$ , coincide con el criterio que minimiza la probabilidad total de clasificación incorrecta.

### 6.2.4. Maximizar la probabilidad a posteriori

Consideramos la probabilidad de que el individuo proceda del grupo  $G_1$ , conocido el valor del vector aleatorio  $\mathbf{x}$ . Dicha probabilidad se conoce como probabilidad a posteriori y se puede calcular mediante el teorema de Bayes:

$$P(G_1/\mathbf{x} = \mathbf{x}_0) = \frac{\pi_1 f_1(\mathbf{x}_0)}{\pi_1 f_1(\mathbf{x}_0) + \pi_2 f_2(\mathbf{x}_0)}.$$

La probabilidad a posteriori del grupo  $G_2$  se define y obtiene de la misma manera:

$$P(G_2/\mathbf{x} = \mathbf{x}_0) = \frac{\pi_2 f_2(\mathbf{x}_0)}{\pi_1 f_1(\mathbf{x}_0) + \pi_2 f_2(\mathbf{x}_0)}.$$

Una regla de clasificación razonable asignaría al grupo con mayor probabilidad a posteriori, esto es, clasificaría en el grupo  $G_1$  si

$$P(G_1/\mathbf{x}) > P(G_2/\mathbf{x})$$

lo cual coincide con  $f_1(\mathbf{x})/f_2(\mathbf{x}) > \pi_2/\pi_1$ .

### 6.2.5. Criterio minimax

Un procedimiento que minimice la probabilidad total de clasificación incorrecta puede no prestar suficiente atención a uno de los grupos, en especial si su probabilidad a priori es pequeña. Por ejemplo, esto ocurre en el problema de diagnóstico de una enfermedad poco frecuente, donde la probabilidad de un falso negativo puede ser alta sin afectar mucho a la probabilidad total de clasificación incorrecta.

Esto constituye una justificación para el uso de un criterio más conservador, como es el minimax. En este caso, escogemos la regla tal que el máximo de sus dos probabilidades de clasificación incorrecta sea mínima. Consideremos  $P$  una regla de clasificación cualquiera. Entonces, para todo  $\alpha \in [0, 1]$ ,

$$\begin{aligned} \max\{P(2/1), P(1/2)\} &\geq (1 - \alpha)P(2/1) + \alpha P(1/2) \\ &\geq (1 - \alpha)P_\alpha(2/1) + \alpha P_\alpha(1/2), \end{aligned}$$

siendo  $P_\alpha$  la regla de clasificación que asigna a  $G_1$  si  $f_1(X)/f_2(X) > \alpha/(1 - \alpha)$ . La primera desigualdad anterior es inmediata y la segunda se debe a que  $P_\alpha$  es la regla que hace mínima la probabilidad total de clasificación incorrecta bajo la distribución a priori:  $\pi_2 = \alpha$ ,  $\pi_1 = 1 - \alpha$ .

Tomemos  $c = \frac{\alpha_0}{1 - \alpha_0}$  (o equivalentemente,  $\alpha_0$ ) de modo que  $P_{\alpha_0}(2/1) = P_{\alpha_0}(1/2)$ . Entonces

$$\begin{aligned} \max\{P(2/1), P(1/2)\} &\geq (1 - \alpha_0)P_{\alpha_0}(2/1) + \alpha_0 P_{\alpha_0}(1/2) = (1 - \alpha_0 + \alpha_0)P_{\alpha_0}(2/1) \\ &= P_{\alpha_0}(2/1) = \max\{P_{\alpha_0}(2/1), P_{\alpha_0}(1/2)\} \end{aligned}$$

lo cual demuestra que  $P_{\alpha_0}$  es la regla minimax.

En consecuencia, la regla minimax será la que clasifica en el grupo  $G_1$  si  $f_1(x)/f_2(x) > c$ , siendo  $c$  tal que  $P_c(2/1) = P_c(1/2)$ .

**Ejemplo.** Si las dos distribuciones condicionadas a cada grupo son normales con la misma matriz de covarianzas, la regla de clasificación minimax asigna al grupo  $G_1$  si

$$D(x) > \log c$$

siendo  $c$  tal que

$$\Phi\left(\frac{\log c - \Delta^2/2}{\Delta}\right) = 1 - \Phi\left(\frac{\log c + \Delta^2/2}{\Delta}\right)$$

Esta ecuación tiene solución  $\log c = 0$ , o lo que es lo mismo,  $c = 1$ , lo cual coincide con el criterio de la razón de verosimilitudes.

**Ejemplo.** Una población se encuentra dividida en dos grupos  $G_1$  y  $G_2$ . Se realiza una observación de una variable que tiene distribución exponencial, cuyo parámetro depende del grupo. Si procede del grupo  $G_1$  el parámetro es 1, y si procede del grupo  $G_2$  el parámetro es 2.

a. Supongamos una distribución a priori equiprobable sobre los dos grupos. Calcula la regla que minimiza la probabilidad de clasificación incorrecta. Cuál es ese valor mínimo de la probabilidad de clasificación incorrecta?

b. Calcula la regla de clasificación óptima con el criterio minimax.

**Ejemplo.** Consideremos una población dividida en dos grupos. A cada individuo de la población le podemos observar una variable aleatoria discreta que toma valores 1,2,3,4 y 5, con probabilidades respectivas 0,05, 0,15, 0,5, 0,25, 0,05 para el primer grupo y 0,3, 0,1, 0,1, 0,1, 0,4 para el segundo grupo.

a. Suponiendo una distribución a priori equiprobable entre los dos grupos, determina la regla discriminante que hace mínima la probabilidad total de clasificación incorrecta.

b. Determina la regla discriminante óptima con el criterio minimax.

### 6.3. Estimación de la regla discriminante

La situación más común en la práctica consiste en que desconocemos las distribuciones de  $x$  condicionales a cada uno de los grupos. En su lugar disponemos de muestras procedentes de cada grupo,

$x_{11}, \dots, x_{1n_1}$  del grupo  $G_1$ .

$x_{21}, \dots, x_{2n_2}$  del grupo  $G_2$ .

conocidas como *muestras de entrenamiento*, que nos sirven para estimar la regla discriminante, por lo general, a través de estimaciones de las distribuciones respectivas:

$$\hat{R}_1 = \left\{ x : \frac{\hat{f}_1(x)}{\hat{f}_2(x)} > c \right\}.$$

Si se supone algún modelo paramétrico para las distribuciones, que podemos representar en la forma  $f_1(x) = f_1(x/\theta_1)$  y  $f_2(x) = f_2(x/\theta_2)$ , los estimadores serían  $\hat{f}_1(x) = f_1(x/\hat{\theta}_1)$  y  $\hat{f}_2(x) = f_2(x/\hat{\theta}_2)$ , donde  $\hat{\theta}_1$  y  $\hat{\theta}_2$  representan estimadores de los parámetros. En ausencia de modelo paramétrico,  $\hat{f}_1(x)$  y  $\hat{f}_2(x)$  serían algún tipo de estimador no paramétrico de la densidad.

La regla discriminante estimada,  $\hat{R} = (\hat{R}_1, \hat{R}_2)$ , se aplicaría más adelante para clasificar a un nuevo individuo en uno u otro grupo, en base a su resultado en el vector  $x$ .

En la sección anterior vimos que la regla discriminante óptima era  $R = (R_1, R_2)$ , donde las regiones de clasificación  $R_1$  y  $R_2$  dependían de las verdaderas funciones  $f_1$  y  $f_2$ . Como  $f_1$  y  $f_2$  son desconocidas, hemos tenido que sustituirlas por estimaciones  $\hat{f}_1$  y  $\hat{f}_2$  obteniendo una regla que ya no será óptima. Nuestra esperanza reside en que sea parecida a la regla óptima.

### 6.3.1. Tasas de error en reglas estimadas

Nos interesa conocer cómo afecta la estimación de la regla discriminante a los errores de clasificación. Debemos distinguir entre:

**Tasas de error óptimas** Son las probabilidades de error de la regla discriminante óptima. Las denotamos

$$e_{i,opt} = \int_{R_j} f_i(\mathbf{x}) d\mathbf{x} \quad i = 1, 2 \quad j \neq i.$$

$$e_{opt} = \pi_1 e_{1,opt} + \pi_2 e_{2,opt}.$$

**Tasas de error efectivas** Son las probabilidades de error de la regla discriminante estimada.

$$e_{i,efe} = \int_{\hat{R}_j} f_i(\mathbf{x}) d\mathbf{x} \quad i = 1, 2 \quad j \neq i.$$

$$e_{efe} = \pi_1 e_{1,efe} + \pi_2 e_{2,efe}.$$

Nótese que las regiones  $(\hat{R}_1, \hat{R}_2)$  se obtienen de las muestras de entrenamiento. En la medida en que estas muestras son aleatorias, las regiones de clasificación serán aleatorias, y también lo serán las tasas de error efectivas. Por tanto, tiene sentido calcular su esperanza.

**Esperanza de las tasas de error efectivas** No son más que la esperanza de las tasas de error anteriores, calculadas respecto de la distribución de probabilidad de las muestras de entrenamiento:  $E(e_{i,efe})$  y

$$E(e_{efe}) = \pi_1 E(e_{1,efe}) + \pi_2 E(e_{2,efe}).$$

Es inmediato que

$$e_{i,opt} \leq e_{i,efe} \quad \text{y} \quad e_{opt} \leq e_{efe}.$$

Las tasas de error óptimas se refieren a la situación ideal en la que las distribuciones de cada grupo son conocidas. Sin embargo, en el caso que nos ocupa, las que tienen mayor interés son las tasas de error efectivas, pues representan las probabilidades de error en las que se va a incurrir cuando se clasifique a un nuevo individuo mediante la regla estimada.

Por desgracia, las tasas de error efectivas son desconocidas ya que dependen de  $f_1$  y  $f_2$ , que representan la distribución de la nueva observación. A continuación planteamos diversos estimadores de las tasas de error efectivas.

### 6.3.2. Estimación de las tasas de error efectivas

**Estimadores plug-in** Se obtienen sustituyendo  $f_1$  y  $f_2$  por  $\hat{f}_1$  y  $\hat{f}_2$ .

$$e_{i,pl} = \int_{\hat{R}_j} \hat{f}_i(x) dx \quad i = 1, 2 \quad j \neq i.$$

**Tasas de error aparentes** Si a cada individuo de la muestra de entrenamiento le aplicamos la regla discriminante estimada tendremos algunos individuos bien clasificados y otros mal clasificados. Pues bien, las tasas de error aparentes son las frecuencias relativas de observaciones mal clasificadas.

$$e_{i,apa} = \frac{m_i}{n_i} \quad i = 1, 2$$

siendo  $m_i$  el número de individuos de la muestra de entrenamiento procedente del grupo  $G_i$  que son mal clasificados por la regla estimada. Las tasas de error aparentes tienden a infraestimar las tasas de error efectivas ya que estamos aplicando la regla estimada a los mismos datos con los que ha sido construida. El mismo fenómeno ocurre con los estimadores plug-in, ya que entre la regla estimada y  $\hat{f}_i$  hay una relación de optimalidad que no se cumple con las tasas de error efectivas. Por este motivo, se proponen correcciones de las tasas de error aparentes.

**Corrección por validación cruzada** Consiste en construir la regla discriminante con todas las observaciones menos una, y aplicar después esa regla para clasificar al individuo omitido. Las tasas de error se calcularían después como las frecuencias relativas de individuos mal clasificados.

**Corrección mediante bootstrap** Se trata de una corrección del sesgo de las tasas de error aparentes. Siguiendo las ideas del bootstrap, extraemos muestras artificiales de la forma:

$x_{11}^*, \dots, x_{1n_1}^*$  i.i.d. de la distribución equiprobable sobre  $x_{11}, \dots, x_{1n_1}$ .

$x_{21}^*, \dots, x_{2n_2}^*$  i.i.d. de la distribución equiprobable sobre  $x_{21}, \dots, x_{2n_2}$ .

Sobre las muestras artificiales aplicamos los mismos procedimientos de estimación de la regla discriminante y cálculo de las tasas de error aparentes,  $m_1^*/n_1$  y  $m_2^*/n_2$ , siendo  $m_i^*$  el número de individuos de la muestra bootstrap, del grupo  $G_i$ , que han sido mal clasificados por la regla estimada bootstrap. Denotemos  $m_i^{orig}$  al número de individuos de la muestra original que son mal clasificados por la regla bootstrap. La estimación bootstrap del sesgo sería:

$$E^* \left( \frac{m_i^*}{n_i} - \frac{m_i^{orig}}{n_i} \right)$$

donde  $E^*$  denota la esperanza respecto del muestreo bootstrap, que en la práctica se puede aproximar mediante la media obtenida tras extraer muchas muestras bootstrap.

La corrección bootstrap del sesgo daría lugar a las tasas de error siguientes:

$$\frac{m_i}{n_i} - E^* \left( \frac{m_i^*}{n_i} - \frac{m_i^{orig}}{n_i} \right)$$

A partir de cualquiera de las tasas de error anteriores, también se puede estimar la probabilidad total de clasificación incorrecta. Para ello, podemos suponer que las probabilidades a priori  $\pi_1$  y  $\pi_2$  son conocidas, o en otro caso se pueden estimar mediante las proporciones  $n_1/(n_1 + n_2)$  y  $n_2/(n_1 + n_2)$ , suponiendo que las dos muestras han sido extraídas al azar de la población formada al juntar los dos grupos.

**Ejemplo.** Supongamos dos muestras de entrenamiento

$$\mathbf{x}_{11}, \dots, \mathbf{x}_{1n_1} \in N_d(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}) \text{ del grupo } G_1.$$

$$\mathbf{x}_{21}, \dots, \mathbf{x}_{2n_2} \in N_d(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}) \text{ del grupo } G_2.$$

Estamos ante dos distribuciones normales con la misma matriz de covarianzas, por lo que, según hemos visto en la sección anterior, la regla de clasificación óptima asignaría a un nuevo individuo al grupo  $G_1$  si

$$D(\mathbf{x}) = \boldsymbol{\lambda}' \left[ \mathbf{x} - \frac{1}{2}(\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2) \right] > \log c$$

siendo  $\boldsymbol{\lambda} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ .

Como  $\boldsymbol{\mu}_1$ ,  $\boldsymbol{\mu}_2$  y  $\boldsymbol{\Sigma}$  son desconocidos, los sustituimos por sus estimaciones en base a las muestras de entrenamiento  $\bar{\mathbf{x}}_1 = n_1^{-1} \sum_{i=1}^{n_1} \mathbf{x}_{1i}$ ,  $\bar{\mathbf{x}}_2 = n_2^{-1} \sum_{i=1}^{n_2} \mathbf{x}_{2i}$  y

$$\mathbf{S}_c = \frac{(n_1 - 1)\mathbf{S}_{c1} + (n_2 - 1)\mathbf{S}_{c2}}{n_1 + n_2 - 2}$$

siendo  $\mathbf{S}_{c1} = (n_1 - 1)^{-1} \sum_{i=1}^{n_1} (\mathbf{x}_{1i} - \bar{\mathbf{x}}_1)(\mathbf{x}_{1i} - \bar{\mathbf{x}}_1)'$ , y análogamente  $\mathbf{S}_{c2}$ .

La regla estimada resulta

$$\hat{D}(\mathbf{x}) = \hat{\boldsymbol{\lambda}}' \left[ \mathbf{x} - \frac{1}{2}(\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2) \right] > \log c$$

siendo  $\hat{\boldsymbol{\lambda}} = \mathbf{S}_c^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$ .

Las tasas de error efectivas serían

$$e_{1,efe} = \Phi \left( \frac{\log c - \hat{D}(\boldsymbol{\mu}_1)}{\sqrt{\hat{\boldsymbol{\lambda}}' \boldsymbol{\Sigma} \hat{\boldsymbol{\lambda}}}} \right) \quad \text{y} \quad e_{2,efe} = \Phi \left( \frac{-\log c + \hat{D}(\boldsymbol{\mu}_2)}{\sqrt{\hat{\boldsymbol{\lambda}}' \boldsymbol{\Sigma} \hat{\boldsymbol{\lambda}}}} \right).$$

Sustituyendo en las expresiones anteriores  $\boldsymbol{\mu}_1$ ,  $\boldsymbol{\mu}_2$  y  $\boldsymbol{\Sigma}$  por sus estimaciones, obtenemos las estimaciones plug-in de las tasas de error

$$e_{1,pl} = \Phi \left( \frac{\log c - \hat{\Delta}^2/2}{\hat{\Delta}} \right) \quad \text{y} \quad e_{2,pl} = \Phi \left( \frac{-\log c - \hat{\Delta}^2/2}{\hat{\Delta}} \right)$$

donde  $\hat{\Delta}^2 = (\bar{x}_1 - \bar{x}_2)' S_c^{-1} (\bar{x}_1 - \bar{x}_2)$  es el cuadrado de la distancia de Mahalanobis en términos muestrales. Como ocurre en general, los estimadores  $e_{i,pl}$  no son buenos estimadores de  $e_{i,efe}$ . Para corregirlos se ha propuesto utilizar  $\tilde{\Delta}$  en lugar de  $\hat{\Delta}$  en la expresión de  $e_{i,pl}$ , siendo

$$\tilde{\Delta}^2 = \frac{n_1 + n_2 - d - 3}{n_1 + n_2 - 2} \hat{\Delta}^2.$$

Por supuesto, también se pueden llevar a cabo las estimaciones mediante las tasas de error aparentes, así como sus correcciones por validación cruzada o por bootstrap.

## 6.4. Varios grupos con distribuciones conocidas

Supongamos que están definidos  $I$  grupos, y queremos construir una regla discriminante que permita clasificar en alguno de los grupos en función del resultado de un vector aleatorio  $x$ . Consideramos  $\pi_1, \dots, \pi_I$  la distribución a priori sobre los  $I$  grupos, y  $f_1, \dots, f_I$  las funciones de densidad o probabilidad de  $x$  condicionadas a cada uno de los grupos. La regla discriminante óptima consistirá en

$$\text{Clasificar en el grupo } g \text{ si } \pi_g f_g(x) = \max_{i \in \{1, \dots, I\}} \pi_i f_i(x).$$

Esta regla es la que clasifica en el grupo con mayor probabilidad a posteriori, y es la regla de máxima verosimilitud si se omiten las probabilidades a priori.

### 6.4.1. Clasificación óptima de varias poblaciones normales

Pensemos que los grupos tienen las mismas probabilidades a priori, y que las distribuciones  $f_i$  son normales de medias  $\mu_1, \dots, \mu_I$ , y con la misma matriz de covarianzas  $\Sigma$ . Entonces la regla anterior se reduce a

$$\text{Clasificar en el grupo } g \text{ si } (x - \mu_g)' \Sigma^{-1} (x - \mu_g) = \min_{i \in \{1, \dots, I\}} (x - \mu_i)' \Sigma^{-1} (x - \mu_i) \quad (6.1)$$

esto es, se clasifica la observación  $x$  en el grupo cuya media está más próxima, bajo la distancia de Mahalanobis.

Cuando sólo hay dos grupos, hemos visto que esta regla es equivalente a efectuar la transformación lineal  $\lambda'x$  (siendo  $\lambda = \Sigma^{-1}(\mu_1 - \mu_2)$ ) y clasificar en el grupo 1 si  $\lambda'x$  está más próximo a  $\lambda'\mu_1$  que a  $\lambda'\mu_2$ . Cuando hay varios grupos, la regla discriminante también se convierte en un criterio lineal, aunque necesitaremos más de una transformación lineal.

Pensemos ahora que se dispone de una muestra procedente de cada grupo

$$\begin{array}{ccc} x_{11} & \cdots & x_{1,n_1} \\ \vdots & & \vdots \\ x_{I1} & \cdots & x_{I,n_I} \end{array} \begin{array}{l} \text{de una población (o grupo)} \\ \\ \text{de una población (o grupo)} \end{array} \begin{array}{l} N_d(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) \\ \\ N_d(\boldsymbol{\mu}_I, \boldsymbol{\Sigma}_I) \end{array}$$

Este tipo de observaciones son las que se obtienen en un modelo de análisis multivariante de la varianza con matrices de covarianzas desiguales.

En esta situación, suponiendo unas probabilidades a priori  $\pi_1, \dots, \pi_I$ , la regla óptima dada por la expresión (6.1), se puede reducir a

$$\text{Clasificar en el grupo } g \text{ si } d_g^Q(\mathbf{x}) = \max_{i \in \{1, \dots, I\}} d_i^Q(\mathbf{x})$$

siendo

$$d_i^Q(\mathbf{x}) = -\frac{1}{2} \log |\boldsymbol{\Sigma}_i| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)' \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) + \log \pi_i \quad \forall i \in \{1, \dots, I\}.$$

Las funciones  $d_i^Q(\mathbf{x})$  se pueden denominar **funciones de clasificación**, pues para clasificar a un individuo con observación  $\mathbf{x}$ , se calculan las funciones de clasificación que le corresponden en cada grupo,  $d_i^Q(\mathbf{x})$ , y se asigna al grupo cuya función sea más grande. El superíndice  $Q$  en  $d_i^Q(\mathbf{x})$  se debe a que estas funciones son cuadráticas, pues como ya vimos en el tema anterior, si las matrices de covarianzas son diferentes dentro de cada grupo, entonces la regla óptima es cuadrática. La muestra anterior servirá para estimar la regla discriminante, sustituyendo en las funciones de clasificación los vectores de medias y las matrices de covarianzas por sus análogos empíricos,

$$\hat{d}_i^Q(\mathbf{x}) = -\frac{1}{2} \log |\mathbf{S}_i| - \frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_i)' \mathbf{S}_i^{-1} (\mathbf{x} - \bar{\mathbf{x}}_i) + \log \pi_i \quad \forall i \in \{1, \dots, I\}.$$

Si se puede suponer que las matrices de covarianzas dentro de cada grupo son iguales, esto es,  $\boldsymbol{\Sigma}_1 = \dots = \boldsymbol{\Sigma}_I = \boldsymbol{\Sigma}$ , entonces en las funciones de clasificación se puede suprimir la parte cuadrática, pues es la misma para todos los grupos, y resultan las siguientes funciones de clasificación lineales:

$$d_i(\mathbf{x}) = \boldsymbol{\mu}_i' \boldsymbol{\Sigma}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i' \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i + \log \pi_i \quad \forall i \in \{1, \dots, I\}$$

que se estiman mediante

$$\hat{d}_i(\mathbf{x}) = \bar{\mathbf{x}}_i' \mathbf{S}^{-1} \mathbf{x} - \frac{1}{2} \bar{\mathbf{x}}_i' \mathbf{S}^{-1} \bar{\mathbf{x}}_i + \log \pi_i \quad \forall i \in \{1, \dots, I\}$$

donde  $\mathbf{S} = (n - I)^{-1} \sum_{i=1}^I (n_i - 1) \mathbf{S}_i$  es la estimación de la matriz de covarianzas común.

En estas funciones lineales los coeficientes vienen dados por los vectores  $\bar{\mathbf{x}}_i' \mathbf{S}^{-1}$  y las constantes se obtienen de  $\log \pi_i - \frac{1}{2} \bar{\mathbf{x}}_i' \mathbf{S}^{-1} \bar{\mathbf{x}}_i$ .

## 7. Técnicas de formación de grupos

En este capítulo haremos una breve introducción a los procedimientos de formación de grupos. Lo primero que destacamos es la amplitud y diversidad de estos métodos, tanto en sus objetivos como en los procedimientos que emplean. El aspecto común a todos ellos es el propósito de formar grupos que todavía no están definidos. En esto se diferencia del análisis discriminante, en el cual los grupos están perfectamente definidos y el propósito es clasificar a un individuo en alguno de los grupos. Como decimos, las técnicas de formación de grupos pretenden formar grupos, reconocer patrones o estructuras dentro de la población general, en base a cierto tipo de observaciones.

Podemos plantear una clasificación de las técnicas de formación de grupos en:

**Métodos jerárquicos** También se conocen como métodos de *taxonomía numérica*, pues tienen mucha semejanza con la taxonomía de los seres vivos en Biología. Partiendo de una matriz de distancias entre individuos, el objetivo es construir un árbol de clasificación en distintos niveles. En el nivel más bajo estarían grupos de individuos muy próximos o semejantes (por ejemplo, las especies). A niveles superiores se crean grupos como resultado de la agregación de los grupos de nivel inferior (por ejemplo, familias, tipos o reinos).

**Métodos de particionamiento** Al contrario de los métodos jerárquicos, los métodos de particionamiento sólo pretenden una división de los individuos en un conjunto de grupos, todos al mismo nivel, que constituyen una partición de la población original.

Los métodos que estudiaremos en este tema no establecen suposiciones sobre el modelo estadístico que generó los datos, y en este sentido se deben interpretar como métodos descriptivos que ayudan a la comprensión sobre las propiedades que presenta un conjunto de datos multivariantes. Además, como cualquier método descriptivo, puede servir como punto de partida que sugiere propiedades de la población, que merezcan un análisis más detallado.

Aún así, existen también métodos de formación de grupos, que están basados en un modelo estadístico, que refleja propiedades previsibles sobre cómo están constituidos los grupos, por ejemplo, la normalidad de la distribución. En este contexto, se pueden adoptar métodos de inferencia para la construcción de los grupos. No trataremos aquí estos métodos basados en el modelo, y nos restringiremos a los métodos más conocidos de formación de grupos.

### 7.1. Métodos jerárquicos.

Como ya se expresó en la introducción, los métodos jerárquicos parten de una matriz de distancia entre individuos, y en base a ella pretenden un agrupamiento de los individuos a distintos niveles. En el nivel más bajo cada grupo estaría formado por individuos, mientras

que los grupos a niveles superiores serían el resultado de agregar grupos de niveles inferiores. Los algoritmos que se emplean para crear esta jerarquía pueden ser de dos tipos:

**Aglomerativos** Partiendo de los individuos, se construyen grupos formados por individuos, para después construir grupos, mediante la agregación de los grupos ya formados en etapas anteriores.

**Divisivos** Partiendo del grupo total formado por todos los individuos, se genera una división en subgrupos (generalmente en dos), que más adelante vuelven a ser subdivididos.

Nos centraremos en los algoritmos aglomerativos, que son los más comunes. El algoritmo constaría de los siguientes pasos:

- **Paso 1 (Comienzo):** Se definen los grupos o *clusters*  $C_1, \dots, C_n$ , que están formados cada uno por un individuo.
- **Paso 2:** Se buscan los dos grupos  $C_i$  y  $C_j$  que estén más próximos, se juntan y consecuentemente se reduce el número de grupos.
- **Paso 3:** Se recalculan las distancias de todos los demás grupos al nuevo grupo, formado al juntar  $C_i$  y  $C_j$ .
- **Paso 4:** Si el número de grupos es uno, se detiene el algoritmo. En otro caso, se vuelve al paso 2.

En este algoritmo queda por determinar cómo se efectúa el paso 3. De hecho, bajo esta misma estructura del algoritmo aglomerativo, los métodos concretos se diferencian en cómo resuelven este paso. Hay variadas formas de hacerlo, pero vamos a mencionar las tres que consideramos principales.

**Método del mínimo:** Consiste en definir  $d(C_r, C_i \cup C_j) = \min\{d(C_r, C_i), d(C_r, C_j)\}$ , donde  $d(C_r, C_s)$  denota la distancia del grupo  $C_r$  al grupo  $C_s$ . Esto es equivalente a definir la distancia entre dos grupos así:

$$d(C_r, C_s) = \min_{i \in C_r, j \in C_s} d_{ij}$$

siendo  $d_{ij}$  la distancia entre los individuos  $i$  y  $j$ , que en este caso pertenecen a los grupos  $C_r$  y  $C_s$ , respectivamente.

**Método del máximo:** Consiste en definir  $d(C_r, C_i \cup C_j) = \max\{d(C_r, C_i), d(C_r, C_j)\}$ . En este caso es equivalente a definir la distancia entre dos grupos como la mayor distancia entre sus individuos:

$$d(C_r, C_s) = \max_{i \in C_r, j \in C_s} d_{ij}.$$

**Método del promedio:** Consiste en definir  $d(C_r, C_i \cup C_j) = \frac{n_i}{n_i + n_j} d(C_r, C_i) + \frac{n_j}{n_i + n_j} d(C_r, C_j)$ , siendo  $n_i$  y  $n_j$  el número de individuos en los grupos  $C_i$  y  $C_j$ , respectivamente. Es equivalente a definir la distancia entre dos grupos como el promedio de las distancias entre sus individuos:

$$d(C_r, C_s) = \frac{1}{n_r n_s} \sum_{i \in C_r, j \in C_s} d_{ij}.$$

## 7.2. Métodos de particionamiento.

Los métodos de particionamiento, según ya se dijo en la introducción, pretenden una partición de los individuos de la muestra en  $k$  grupos, en base a los valores de las variables observadas en cada individuo. Por supuesto, los grupos se formarán por proximidad en el espacio  $d$ -dimensional, siendo  $d$  el número de variables.

Un criterio natural para la formación de los grupos, consistiría en elegir la partición en grupos que haga mínima la variabilidad dentro de cada grupo, medida por la suma de cuadrados intra-grupo. El criterio parece sencillo pero el problema será la imposibilidad de recorrer todas las particiones posibles de  $n$  individuos en  $k$  grupos. Sólo  $n = 15$  datos y  $k = 3$  grupos son suficientes para generar más de dos millones de posibles particiones. Con valores de  $n$  y  $k$  algo más grandes, el número de particiones crece de manera desorbitada.

Ante esta situación, es preciso adoptar un algoritmo que partiendo de una solución inicial razonable, llegue a una solución mejor de acuerdo con el criterio, mediante pasos que aporten mejoras sucesivas. Nótese que, a pesar de existir muchas particiones, la inmensa mayoría son absurdas como solución del problema, pues carecen de sentido todos los grupos que se formen tomando observaciones "salteadas" en el espacio.

Vamos a considerar únicamente el algoritmo de las  $k$ -medias, del que hay múltiples versiones, aunque su forma más sencilla podría constar de los pasos siguientes.

- **Paso 1:** Crear una partición inicial en  $k$  grupos.
- **Paso 2:** Asignar cada individuo al grupo cuyo centro, que denominaremos **centroide**, le quede más próximo. Recalcular los centroides en base a los grupos modificados.
- **Paso 3:** Repetir el paso 2 hasta que no haya más reasignaciones.

El primer paso se puede obtener proporcionando  $k$  centroides iniciales escogidos adecuadamente a la vista de la muestra. De hecho, pueden ser individuos de la muestra. También es posible conformar la partición inicial, aplicando una técnica de agrupamiento jerárquico, y escogiendo el nivel de agrupamiento en el cual se generan  $k$  grupos.

El paso 2 admite muchas variantes dependiendo del algoritmo concreto. Planteado en términos generales, la idea es considerar posibles cambios de algunos individuos de un grupo a otro. Serían candidatos a cambiar de grupo los individuos que ocupan posiciones fronterizas. Para cada posible cambio, se evalúan las consecuencias que tendría sobre el criterio (por ejemplo, suma de cuadrados intra-grupo), y se efectúa el cambio que más contribuye a mejorar el criterio. Se detiene el algoritmo cuando no hay cambios que redunden en mejoras apreciables del criterio.

Los algoritmos de las  $k$ -medias presentan ciertas limitaciones, como puede ser la dependencia de la partición inicial que se escoja, así como la tendencia a formar grupos esféricos, ya que la distancia que se considera es la distancia euclídea usual. Existen muchas propuestas de otros

métodos que permiten superar estas limitaciones y que se adaptan a propósitos diversos. En cualquier caso, el algoritmo de las  $k$ -medias es un punto de referencia inicial, que se debe tener presente dentro de los métodos de particionamiento.

La función *kmeans* de *R* permite escoger entre varios métodos de las  $k$ -medias. Si no se indica el método, por defecto aplica el algoritmo de Hartigan and Wong (1979).

## A. Distribuciones notables multidimensionales

Al igual que en el caso univariante, en el que el análisis del comportamiento muestral de determinados estadísticos da lugar a la aparición de distribuciones como la  $t$  de Student, la ji-cuadrado o la  $F$  de Snédecor, también en el contexto multidimensional surgen nuevas distribuciones como consecuencia del estudio de estadísticos importantes. En este tema estudiaremos distribuciones que surgen al hacer operaciones naturales de cara a la inferencia sobre vectores normales multivariantes.

### A.1. Distribución normal multivariante

Un vector aleatorio  $d$ -dimensional  $\mathbf{x}$  tiene distribución normal multivariante con vector de medias  $\boldsymbol{\mu}$  y matriz de covarianzas  $\boldsymbol{\Sigma}$  si su función de densidad viene dada por

$$f(\mathbf{x}) = \frac{1}{(\sqrt{2\pi})^d |\boldsymbol{\Sigma}|^{1/2}} e^{-\frac{(\mathbf{x}-\boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}{2}}.$$

Decimos en este caso que  $\mathbf{x}$  tiene distribución  $N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ .

#### A.1.1. Propiedades de la distribución normal multivariante

Presentamos a continuación algunas propiedades conocidas de la distribución normal multivariante.

- Sean  $a_1, \dots, a_d$  constantes y consideremos la combinación lineal  $z = a_1 x_1 + \dots + a_d x_d = \mathbf{a}' \mathbf{x}$ . Si  $\mathbf{x}$  es  $N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , entonces  $z$  es  $N(a' \boldsymbol{\mu}, \mathbf{a}' \boldsymbol{\Sigma} \mathbf{a})$ .
- Si  $\mathbf{A}$  es una matriz  $k \times d$  de rango  $k$  (siendo  $k \leq d$ ), entonces las  $k$  combinaciones lineales en  $\mathbf{A} \mathbf{x}$  tienen distribución normal multivariante, es decir, si  $\mathbf{x}$  es  $N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , entonces  $\mathbf{A} \mathbf{x}$  es  $N_k(\mathbf{A} \boldsymbol{\mu}, \mathbf{A} \boldsymbol{\Sigma} \mathbf{A}')$ .
- Recordamos que si  $\mathbf{x}$  es  $N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , entonces  $\mathbf{z} = \boldsymbol{\Sigma}^{-1/2} (\mathbf{x} - \boldsymbol{\mu})$  tiene distribución  $N_d(\mathbf{0}, \mathbf{I}_d)$ . Además,

$$\mathbf{z}' \mathbf{z} = \sum_{i=1}^d z_i^2$$

es la suma de los cuadrados de  $d$  variables normales estándar e independientes y, por lo tanto, tiene distribución  $\chi_d^2$ . Es decir

$$(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \text{ tiene distribución } \chi_d^2.$$

- Cualquier subconjunto de variables de un vector  $x$  con distribución normal  $N_d(\mu, \Sigma)$ , tiene a su vez distribución normal (con vector de medias y matriz de covarianzas correspondiente a la partición de  $x$ ). Por ejemplo, si  $x_1 = (x_1, \dots, x_p)'$  denota el subvector de las primeras  $p$  componentes de  $x$  y  $x_2 = (x_{p+1}, \dots, x_d)'$  denota el subvector con las restantes  $d - p$  componentes, podemos escribir:

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}.$$

Además

$$x_1 \text{ tiene distribución } N_p(\mu_1, \Sigma_{11}),$$

$$x_2 \text{ tiene distribución } N_{d-p}(\mu_2, \Sigma_{22}).$$

En particular cada componente  $x_i$  del vector  $x$  ( $i = 1, \dots, d$ ) tiene distribución  $N(\mu_i, \sigma_i^2)$ . Es importante notar que el recíproco no es cierto, es decir, si la densidad de cada  $x_i$  es normal no se sigue necesariamente que  $x$  sea normal multivariante.

- Consideremos ahora un vector particionado en dos subvectores  $x$  de dimensión  $p \times 1$  e  $y$  de dimensión  $q \times 1$ , de forma que:

$$\begin{pmatrix} x \\ y \end{pmatrix} \text{ tiene distribución } N_{p+q} \left( \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix} \right).$$

- Los subvectores  $x$  e  $y$  son independientes si y sólo si  $\Sigma_{xy} = 0$ .
- Si  $x$  e  $y$  no son independientes, entonces  $\Sigma_{xy} \neq 0$  y la distribución condicional del vector  $x$  dados los valores del vector  $y$  también es normal ( $p$ -dimensional) con vector de medias

$$E(x/y) = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$$

y con matriz de covarianzas

$$\Sigma_{x/y} = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}.$$

- Si  $x$  e  $y$  son vectores con distribución normal, tienen la misma dimensión  $p \times 1$  y son independientes, entonces

$$x + y \text{ tiene distribución } N_p(\mu_x + \mu_y, \Sigma_{xx} + \Sigma_{yy}).$$

$$x - y \text{ tiene distribución } N_p(\mu_x - \mu_y, \Sigma_{xx} + \Sigma_{yy}).$$

## A.2. Distribución de Wishart

### A.2.1. Definición y propiedades

La distribución de Wishart surge como una extensión al caso multivariante de la distribución ji-cuadrado. Recuerda que si  $x_1, \dots, x_m$  son variables aleatorias independientes con distribución  $N(0, 1)$ , entonces la variable  $\sum_{i=1}^m x_i^2$  tiene distribución ji-cuadrado con  $m$  grados de libertad.

Cuando  $x_1, \dots, x_m$  son vectores aleatorios en lugar de variables aleatorias, por ejemplo  $x_i \in \mathbb{R}^d$  con  $x_i \in N_d(\mathbf{0}, \mathbf{I}_d)$ , una posible forma de generalizar la suma de cuadrados anterior sería construir la matriz  $d \times d$  semidefinida positiva  $M = \sum_{i=1}^m x_i x_i'$ . Mientras la distribución ji-cuadrado se atribuye a estimadores de la varianza, como la varianza muestral, la distribución de Wishart corresponde a matrices de covarianza muestrales.

La representación de  $M$  da lugar, en esencia, a la definición de la distribución de Wishart. Como se trata de una matriz aleatoria, no nos vamos a preocupar por una supuesta función de densidad para la distribución de Wishart, ni vamos a considerar tablas de cuantiles. Simplemente vamos a estudiar las propiedades que presenta una matriz de covarianzas aleatoria, que serán de utilidad más adelante para las regiones de confianza multivariantes.

**Definición A.1.** Sean  $x_1, \dots, x_m \in N_d(\mathbf{0}, \Sigma)$  independientes. Diremos que la matriz aleatoria

$$M = \sum_{i=1}^m x_i x_i'$$

tiene una distribución Wishart con matriz  $\Sigma$  y  $m$  grados de libertad. Denotamos  $M \in W_d(\Sigma, m)$ .

#### Observaciones

1. Si construimos la matriz de observaciones

$$X = \begin{pmatrix} x_1' \\ \vdots \\ x_m' \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} \end{pmatrix}$$

de orden  $m \times d$ , entonces podemos escribir

$$M = \sum_{i=1}^m x_i x_i' = (x_1, \dots, x_m) \begin{pmatrix} x_1' \\ \vdots \\ x_m' \end{pmatrix} = X' X = \left( \sum_{i=1}^m x_{ij} x_{ik} \right)_{j,k \in \{1, \dots, d\}}.$$

2. Si  $\Sigma = \mathbf{I}_d$  diremos que la distribución tiene forma estándar.

3. Si  $d = 1$ , entonces  $\Sigma = \sigma^2$  y la distribución de Wishart es una ji-cuadrado con  $m$  grados de libertad y parámetro de escala  $\sigma^2$ . Es decir,  $x_1, \dots, x_m \in N(0, \sigma^2)$  independientes y

$$M = \sum_{i=1}^m x_i x_i' = \sum_{i=1}^m x_i^2 = \sigma^2 \sum_{i=1}^m \left(\frac{x_i}{\sigma}\right)^2 \in \sigma^2 \chi_m^2.$$

**Teorema A.1.** Si  $M \in W_d(\Sigma, m)$  y  $A$  es una matriz  $q \times d$  de rango  $q$  ( $q \leq d$ ), entonces

$$A M A' \in W_q(A \Sigma A', m).$$

*Demostración.* Si  $M \in W_d(\Sigma, m)$ , entonces lo podemos expresar así

$$M = \sum_{i=1}^m x_i x_i'$$

siendo  $x_1, \dots, x_m \in N_d(0, \Sigma)$  independientes. En tal caso, resulta que

$$A M A' = \sum_{i=1}^m A x_i x_i' A' = \sum_{i=1}^m (A x_i) (A x_i)'$$

y además  $A x_1, \dots, A x_m \in N_q(0, A \Sigma A')$  independientes. Entonces, atendiendo a la definición de la distribución de Wishart, se tiene que  $A M A' \in W_q(A \Sigma A', m)$ .  $\square$

**Corolario A.1.** Si  $M \in W_d(\Sigma, m)$ , entonces las submatrices diagonales de  $M$  también tienen distribuciones de Wishart, con parámetros la submatriz correspondiente y  $m$  grados de libertad.

**Corolario A.2.** Si  $M \in W_d(\Sigma, m)$  y  $a$  es un vector  $d$ -dimensional tal que  $a' \Sigma a > 0$ , entonces

$$a' M a \in (a' \Sigma a) \chi_m^2.$$

En particular, por el Corolario A.2 se tiene que dado  $e_j = (0, \dots, 0, 1, 0, \dots, 0)'$ ,

$$e_j' M e_j \equiv m_{jj} \in \sigma_{jj}^2 \chi_m^2.$$

Es decir, la distribución marginal de  $m_{jj}$  es ji-cuadrado para  $j = 1, \dots, d$ . Sin embargo, la distribución marginal de  $m_{jk}$  ( $j \neq k$ ) no es ji-cuadrado.

Otra consecuencia del Teorema A.1 es que, fijado  $d$  y  $m$ , la familia de distribuciones  $W_d(\Sigma, m)$  con  $\Sigma$  semidefinida positiva puede ser generada a partir de la distribución  $W_d(I_d, m)$  y de matrices  $d \times d$ . Observa que si  $M \in W_d(I_d, m)$  y  $\Sigma = A A'$ , entonces

$$A M A' \in W_d(A I_d A', m) = W_d(\Sigma, m).$$

Veremos a continuación algunas propiedades de la distribución Wishart.

### Propiedades

1. Si  $M \in W_d(\Sigma, m)$ , entonces  $E(M) = m \cdot \Sigma$ .
2.  $M = x_1 x_1' + \cdots + x_m x_m'$  es una matriz simétrica, semidefinida positiva y de rango la dimensión del espacio lineal generado por  $x_1, \dots, x_m$ . Si  $x_1, \dots, x_m$  son vectores aleatorios independientes, con la misma distribución y su matriz de covarianzas tiene rango  $k$ , entonces

$$P(\text{rango}(M) = \min\{m, k\}) = 1.$$

3. Como consecuencia de la propiedad anterior, si  $M \in W_d(\Sigma, m)$ ,  $\Sigma$  es definida positiva y  $m \geq d$ , entonces

$$P(M \text{ sea definida positiva}) = 1.$$

4. La familia de distribuciones  $W_d(\Sigma, m)$  es reproductiva respecto del parámetro  $m$ , esto es, si  $M_1 \in W_d(\Sigma, m_1)$ ,  $M_2 \in W_d(\Sigma, m_2)$  y además son independientes, entonces

$$M_1 + M_2 \in W_d(\Sigma, m_1 + m_2).$$

### A.2.2. Formas cuadráticas en una muestra de observaciones normales multivariantes

En esta sección veremos las extensiones al caso multivariante de los resultados sobre la distribución de formas cuadráticas de variables normales. Estos resultados, al igual que en el caso unidimensional, serán útiles para las tareas de inferencia en base a una muestra de una distribución normal o en problemas de regresión.

**Teorema A.2.** Sean  $x_1, \dots, x_m \in N_d(\mathbf{0}, \Sigma)$  independientes y la matriz de observaciones

$$X = \begin{pmatrix} x_1' \\ \vdots \\ x_m' \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1d} \\ \cdots & \cdots & \cdots \\ x_{m1} & \cdots & x_{md} \end{pmatrix}.$$

Entonces:

- Si  $a$  es un vector de dimensión  $m$  no nulo, entonces

$$X'a \in N_d(\mathbf{0}, \|a\|^2 \Sigma).$$

- Si  $a$  y  $b$  son dos vectores no nulos y ortogonales,  $a'b = 0$ , entonces  $X'a$  y  $X'b$  son independientes.

*Demostración.* Probamos a continuación cada uno de los puntos del enunciado.

i. Observamos que

$$\mathbf{X}'\mathbf{a} = (\mathbf{x}_1, \dots, \mathbf{x}_m) \mathbf{a} = \sum_{i=1}^m \mathbf{x}_i a_i.$$

Entonces, como  $\mathbf{x}_1, \dots, \mathbf{x}_m \in N_d(\mathbf{0}, \Sigma)$  independientes y

$$\text{Cov}(\mathbf{X}'\mathbf{a}, \mathbf{X}'\mathbf{a}) = \text{Cov}\left(\sum_{i=1}^m \mathbf{x}_i a_i, \sum_{i=1}^m \mathbf{x}_i a_i\right) = \sum_{i=1}^m \sum_{j=1}^m a_i a_j \text{Cov}(\mathbf{x}_i, \mathbf{x}_j) \stackrel{(a)}{=} \sum_{i=1}^m a_i^2 \Sigma = \|\mathbf{a}\|^2 \Sigma,$$

se concluye que  $\mathbf{X}'\mathbf{a}$  tiene distribución normal de media cero y con la matriz de covarianzas que se acaba de obtener. La igualdad (a) es consecuencia de que los vectores  $\mathbf{x}_1, \dots, \mathbf{x}_m$  son independientes y la matriz de covarianzas de cada uno de ellos es  $\Sigma$ .

ii. De manera muy similar al apartado anterior, se tiene que

$$\begin{aligned} \text{Cov}(\mathbf{X}'\mathbf{a}, \mathbf{X}'\mathbf{b}) &= \text{Cov}\left(\sum_{i=1}^m \mathbf{x}_i a_i, \sum_{i=1}^m \mathbf{x}_i b_i\right) \\ &= \sum_{i=1}^m \sum_{j=1}^m a_i b_j \text{Cov}(\mathbf{x}_i, \mathbf{x}_j) \\ &= \sum_{i=1}^m a_i b_i \Sigma \\ &= (\mathbf{a}'\mathbf{b}) \Sigma \\ &= \mathbf{0}. \end{aligned}$$

De modo que  $\mathbf{X}'\mathbf{a}$  y  $\mathbf{X}'\mathbf{b}$  están incorrelacionados. Como por el apartado anterior, tienen distribución normal, entonces son independientes.  $\square$

**Teorema A.3.** Sean  $\mathbf{x}_1, \dots, \mathbf{x}_m \in N_d(\mathbf{0}, \Sigma)$  independientes y  $\mathbf{X}$  la correspondiente matriz de observaciones.

- Si  $\mathbf{A}$  es una matriz simétrica de orden  $m \times m$ , idempotente ( $\mathbf{A}^2 = \mathbf{A}$ ) y de rango  $r \leq m$ , entonces

$$\mathbf{X}'\mathbf{A}\mathbf{X} \in W_d(\Sigma, r).$$

- Si  $\mathbf{A}$  es una matriz en las condiciones anteriores y  $\mathbf{b}$  es un vector de dimensión  $m$ , tal que  $\mathbf{A}\mathbf{b} = \mathbf{0}$ , entonces

$\mathbf{X}'\mathbf{A}\mathbf{X}$  y  $\mathbf{X}'\mathbf{b}$  son independientes.

- Si  $A$  y  $B$  son dos matrices en las condiciones anteriores y  $AB = 0$ , entonces

$X'AX$  y  $X'BX$  son independientes.

*Demostración.* i. Por ser  $A$  simétrica, idempotente y de rango  $r \leq m$ , tendrá  $r$  autovalores iguales a uno y  $(m - r)$  autovalores iguales a cero. En tal caso, se podrá expresar

$$A = \sum_{i=1}^r v_i v_i'$$

siendo  $v_1, \dots, v_r$  los autovectores asociados a los autovalores unitarios. Entonces

$$X'AX = \sum_{i=1}^r X'v_i v_i'X = \sum_{i=1}^r (X'v_i) (X'v_i)' \quad (A.1)$$

El apartado (i) del Teorema A.2 nos lleva a que  $X'v_1, \dots, X'v_r \in N_d(0, \Sigma)$  y el apartado (ii) del mismo teorema a que son independientes. En consecuencia, de la expresión (A.1) y la definición de la distribución de Wishart, se deduce que

$$X'AX \in W_d(\Sigma, r).$$

ii. La hipótesis  $Ab = 0$  implica que  $v_j'b = 0$  para todo  $j \in \{1, \dots, r\}$ . El apartado (ii) del Teorema A.2 conduce a que  $X'v_1, \dots, X'v_r$  sean independientes de  $X'b$ . Recordando la expresión (A.1), se llega a que  $X'AX$  y  $X'b$  son independientes.

iii. Siendo  $A = \sum_{i=1}^r v_i v_i'$  y  $B = \sum_{j=1}^s \omega_j \omega_j'$ , con  $AB = 0$ , se tiene que  $v_k'\omega_l = 0$  para todo  $k \in \{1, \dots, r\}$  y todo  $l \in \{1, \dots, s\}$ .

Ahora, como  $v_k'\omega_l = 0$ , aplicando el apartado (ii) del Teorema A.2, tenemos que  $X'v_1, \dots, X'v_r$  son independientes de  $X'\omega_1, \dots, X'\omega_s$ , y en base a la expresión (A.1) y su análogo para  $X'BX$ , se concluye que  $X'AX$  y  $X'BX$  son independientes.  $\square$

El teorema siguiente es la versión multivariante del Teorema de Fisher.

**Teorema A.4.** Sean  $x_1, \dots, x_n \in N_d(\mu, \Sigma)$  independientes. Entonces el vector de medias y la matriz de covarianzas muestrales verifican

1.  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \in N_d\left(\mu, \frac{1}{n}\Sigma\right)$ .
2.  $nS = \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})' \in W_d(\Sigma, n - 1)$ .
3.  $\bar{x}$  y  $S$  son independientes.

*Demostración.* La demostración es idéntica a la correspondiente al Teorema de Fisher en el caso unidimensional. Así, se empieza observando que basta hacer la demostración suponiendo que  $\mu = \mathbf{0}$ . En el caso general, bastaría considerar  $\mathbf{y} = \mathbf{x} - \mu$ , que serían observaciones con media cero, y tener en cuenta que  $\bar{\mathbf{y}} = \bar{\mathbf{x}} - \mu$  y que la matriz de covarianzas muestral no se ve afectada por la resta de  $\mu$ .

i. Tomamos el vector  $\mathbf{b} = (1/n, \dots, 1/n)'$  y aplicamos el Teorema A.2, apartado (i), teniendo en cuenta que en este caso  $\|\mathbf{b}\|^2 = 1/n$ .

ii. Consideramos la matriz

$$\mathbf{A} = \mathbf{M} = \begin{pmatrix} 1 - 1/n & -1/n & \cdots & -1/n \\ -1/n & 1 - 1/n & \ddots & \vdots \\ \vdots & \ddots & \ddots & -1/n \\ -1/n & \cdots & -1/n & 1 - 1/n \end{pmatrix} = \mathbf{I}_n - (1/n)\mathbf{1}_n\mathbf{1}_n'$$

que tiene el valor  $(1 - 1/n)$  en la diagonal y el valor  $(-1/n)$  fuera de la diagonal. La notación  $\mathbf{1}_n$  significa  $\mathbf{1}_n = (1, \dots, 1)'$ , esto es, un vector compuesto por unos en todas sus componentes.

La matriz  $\mathbf{M}$  es muy importante en la Estadística. Su efecto sobre el conjunto de observaciones es el siguiente:

$$\mathbf{M}\mathbf{X} = \begin{pmatrix} (\mathbf{x}_1 - \bar{\mathbf{x}})' \\ \vdots \\ (\mathbf{x}_n - \bar{\mathbf{x}})' \end{pmatrix}.$$

De modo que  $\mathbf{M}$  es una matriz centralizadora, pues aplicada a un conjunto de datos, los centra, al restar a cada dato la media. Además, si se emplea como forma cuadrática, se tiene que

$$\begin{aligned} \mathbf{X}'\mathbf{M}\mathbf{X} &\stackrel{(a)}{=} \mathbf{X}'\mathbf{M}\mathbf{M}\mathbf{X} \\ &\stackrel{(b)}{=} (\mathbf{M}\mathbf{X})'(\mathbf{M}\mathbf{X}) \\ &= (\mathbf{x}_1 - \bar{\mathbf{x}}, \dots, \mathbf{x}_n - \bar{\mathbf{x}}) \cdot \begin{pmatrix} (\mathbf{x}_1 - \bar{\mathbf{x}})' \\ \vdots \\ (\mathbf{x}_n - \bar{\mathbf{x}})' \end{pmatrix} \\ &= \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'. \end{aligned}$$

En la igualdad (a) se ha empleado que  $\mathbf{M}$  es una matriz idempotente y en la igualdad (b) que es simétrica. Es fácil comprobar que  $\mathbf{M}$  es una matriz simétrica, idempotente y de rango  $(n - 1)$ . Pero entonces el Teorema A.3, apartado (i), permite concluir la demostración de que la matriz de covarianzas muestral tiene distribución Wishart con matriz  $\Sigma$  y  $(n - 1)$  grados de libertad.

iii. La independencia se deduce del Teorema A.3, apartado (ii), al observar que  $\mathbf{M}\mathbf{b} = \mathbf{0}$ .  $\square$

### A.3. Distribución $\Gamma^2$ de Hotelling

#### A.3.1. Definición y propiedades

La distribución  $\Gamma^2$  de Hotelling juega un papel semejante a la distribución  $t$  de Student en el caso multivariante. En concreto, la distribución  $t$  de Student surge cuando se estandariza la media muestral mediante la varianza muestral. En el caso de poblaciones normales multivariantes, se calcula la distancia de la media muestral a la media teórica usando la distancia de Mahalanobis, que la distancia asociada a la matriz de covarianzas muestral.

Empezamos con la definición de la distribución  $\Gamma^2$  de Hotelling, que, igual que ocurría con la  $t$  de Student, es una definición formal, preparada para adaptarse al problema de inferencia.

**Definición A.2.** Sean  $\mathbf{Z} \in N_d(\mathbf{0}, \mathbf{I}_d)$  y  $\mathbf{R} \in W_d(\mathbf{I}_d, m)$  independientes, con  $m \geq d$ . Diremos que la variable aleatoria unidimensional

$$m\mathbf{Z}'\mathbf{R}^{-1}\mathbf{Z} \in \Gamma^2(d, m)$$

tiene una distribución  $\Gamma^2$  de Hotelling de parámetros  $d$  y  $m$ .

En el caso particular  $d = 1$ , resulta  $\Gamma^2(1, m) \stackrel{d}{=} t_m^2$ , por lo cual decimos que la  $\Gamma^2$  de Hotelling generaliza la distribución  $t$  de Student. Nótese que en la definición anterior, tanto  $\mathbf{Z}$  como  $\mathbf{R}$  están estandarizados. Así,  $\mathbf{Z}$  tiene media cero y como matriz de covarianzas la identidad.  $\mathbf{R}$  tiene forma estándar, pues su matriz de covarianzas asociada es también la identidad.

En el teorema siguiente vemos cómo se obtiene una distribución  $\Gamma^2$  de Hotelling a partir de variables no estandarizadas. El único requisito es que el vector aleatorio y la matriz aleatoria tengan la misma matriz de covarianzas de referencia.

**Teorema A.5.** Si  $\mathbf{x} \in N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  y  $\mathbf{M} \in W_d(\boldsymbol{\Sigma}, m)$  son independientes, entonces

$$m(\mathbf{x} - \boldsymbol{\mu})' \mathbf{M}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \in \Gamma^2(d, m).$$

*Demostración.* Para demostrar este teorema vamos a estandarizar el vector aleatorio  $\mathbf{x}$  y la matriz aleatoria  $\mathbf{M}$ . Así, definiendo como  $\mathbf{Z}$  y  $\mathbf{R}$  a sus estandarizaciones, se tiene que

$$\mathbf{Z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{x} - \boldsymbol{\mu}) \in N_d(\mathbf{0}, \mathbf{I}_d).$$

$$\mathbf{R} = \boldsymbol{\Sigma}^{-1/2}\mathbf{M}\boldsymbol{\Sigma}^{-1/2} \in W_d(\mathbf{I}_d, m).$$

Para la distribución de  $\mathbf{R}$  se aplicó el Teorema A.1. □

El siguiente teorema es muy útil, pues permite convertir una variable con distribución  $\Gamma^2$  de Hotelling en otra con distribución  $F$  de Snédecor. De este modo se evita la necesidad de considerar nuevas tablas de cuantiles, o en general cualquier tipo de cálculos relacionados con la  $\Gamma^2$  de Hotelling. Simplemente se efectuaría la transformación y se apelaría a las tablas y operaciones conocidas para la  $F$  de Snédecor.

**Teorema A.6.**

$$\Gamma^2(d, m) \stackrel{d}{=} \frac{md}{m-d+1} F_{d, m-d+1}$$

*Demostración.* Se omite aquí la demostración de este teorema. Se puede encontrar en Mardia et al. (1979).  $\square$

**A.3.2. El estadístico  $\Gamma^2$  de Hotelling para inferencia sobre el vector de medias**

El siguiente corolario establece que la distancia de la media muestral a la media poblacional, medida a partir de la matriz de covarianzas muestral, tiene distribución de Hotelling. De hecho, este estadístico es la razón principal por la que se ha definido la distribución de Hotelling, hasta el punto de que recibe el nombre de estadístico de Hotelling.

**Corolario A.3.** Sean  $\mathbf{x}_1, \dots, \mathbf{x}_n \in N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  independientes, y  $\bar{\mathbf{x}}$  el vector de medias y  $\mathbf{S}$  la matriz de covarianzas muestrales obtenidos sobre la muestra anterior. Entonces

$$(n-1) (\bar{\mathbf{x}} - \boldsymbol{\mu})' \mathbf{S}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}) = n (\bar{\mathbf{x}} - \boldsymbol{\mu})' \mathbf{S}_c^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}) \in \Gamma^2(d, n-1)$$

siendo  $\mathbf{S}_c = \frac{n}{n-1} \mathbf{S}$ .

*Demostración.* Por el Teorema de Fisher multivariante, se tiene que

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \in N_d\left(\boldsymbol{\mu}, \frac{1}{n} \boldsymbol{\Sigma}\right), \quad n\mathbf{S} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})' \in W_d(\boldsymbol{\Sigma}, n-1)$$

y además son independientes. Se puede deducir que

$$\sqrt{n} (\bar{\mathbf{x}} - \boldsymbol{\mu}) \in N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

lo cual sigue siendo independiente de  $n\mathbf{S}$ . Entonces, aplicando el Teorema 5, se llega a que

$$(n-1) (\sqrt{n} (\bar{\mathbf{x}} - \boldsymbol{\mu}))' (n\mathbf{S})^{-1} \sqrt{n} (\bar{\mathbf{x}} - \boldsymbol{\mu}) \in \Gamma^2(d, n-1).$$

Efectuando operaciones se obtiene

$$(n-1) (\sqrt{n} (\bar{\mathbf{x}} - \boldsymbol{\mu}))' (n\mathbf{S})^{-1} \sqrt{n} (\bar{\mathbf{x}} - \boldsymbol{\mu}) = (n-1) (\bar{\mathbf{x}} - \boldsymbol{\mu})' \mathbf{S}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu})$$

con lo cual se concluye la demostración.  $\square$

Juntando el resultado anterior con el Teorema A.6, se puede transformar el estadístico de Hotelling para que tenga distribución  $F$  de Snédecor, lo cual es más útil a efectos prácticos.

Así, el siguiente corolario contiene el resultado práctico que se suele emplear para obtener regiones de confianza o realizar contrastes de hipótesis sobre el vector de medias.

**Corolario A.4.** Sean  $\mathbf{x}_1, \dots, \mathbf{x}_n \in N_d(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  independientes, y  $\bar{\mathbf{x}}$  el vector de medias y  $\mathbf{S}$  la matriz de covarianzas muestrales obtenidos sobre la muestra anterior. Entonces

$$\frac{n-d}{d} (\bar{\mathbf{x}} - \boldsymbol{\mu})' \mathbf{S}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}) \in F_{d, n-d}$$

*Demostración.* Es consecuencia directa del Corolario A.4 y el Teorema A.6. Así, se tiene que

$$(n-1) (\bar{\mathbf{x}} - \boldsymbol{\mu})' \mathbf{S}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}) \in \Gamma^2(d, n-1) = \frac{(n-1)d}{n-1-d+1} F_{d, n-1-d+1}.$$

Simplificando se llega a la expresión que figura en este corolario.  $\square$

## A.4. Distribución $\Lambda$ de Wilks

### A.4.1. Introducción

La distribución  $\Lambda$  de Wilks sirve para extender al caso multivariante la distribución  $F$  de Snédecor. Así, si la  $F$  de Snédecor se obtiene mediante el cociente de dos variables de tipo ji-cuadrado, la  $\Lambda$  de Wilks surge como el cociente de los determinantes de dos matrices de covarianzas. Iremos viendo cómo se llega a ese cociente.

El uso más destacable de la distribución  $F$  de Snédecor es para realizar el test  $F$  de comparación de modelos lineales. En el test  $F$  se contrastaba una hipótesis nula que constituía una restricción sobre un modelo más general. El modelo general era la hipótesis alternativa.

Así, si  $RSS$  representaba la suma residual de cuadrados bajo la hipótesis alternativa y  $RSS_0$  la misma suma residual bajo la hipótesis nula, entonces necesariamente  $RSS_0 > RSS$  y el estadístico de contraste se calculaba así:

$$\frac{(RSS_0 - RSS)/q}{RSS/(n-p)} \in F_{q, n-p}$$

donde  $q$  y  $n-p$  eran los grados de libertad de numerador y denominador ( $q$  era el número de restricciones,  $n$  el número de individuos y  $p$  el número de parámetros bajo el modelo general).

En el caso multivariante, esto es, en modelos lineales con respuesta multivariante, los residuos de la regresión serán vectores, y en lugar de sumas de cuadrados, generan matrices de covarianzas.

La idea será comparar la matriz de covarianzas residual, que vamos a denotar por  $\mathbf{E}$ , con la matriz de covarianzas asociada a la restricción, que denotamos por  $\mathbf{H}$ , y juega el papel de  $(RSS_0 - RSS)$ . Si  $\mathbf{H}$  es muy grande, en comparación con  $\mathbf{E}$ , entonces se rechaza la hipótesis nula. La forma de medir si una matriz de covarianzas es grande o pequeña será a través de su determinante.

### A.4.2. Definición y propiedades

Vamos a definir la distribución  $\Lambda$  de Wilks como el cociente entre el determinante de  $\mathbf{E}$  y el determinante de  $\mathbf{E} + \mathbf{H}$ . Recordemos que  $\mathbf{E}$  estaba asociado a la matriz de covarianzas residual, y  $\mathbf{H}$  a la matriz de covarianzas adicional, debida a las restricciones.

La razón para no comparar directamente  $\mathbf{H}$  con  $\mathbf{E}$ , sino  $\mathbf{E} + \mathbf{H}$  con  $\mathbf{E}$  es que  $\mathbf{H}$  podría tener algún autovalor igual a cero, y eso haría que su determinante fuera cero. Ese problema desaparece al sumarlo a  $\mathbf{E}$ , pues  $\mathbf{E}$  siempre tiene todos sus autovalores distintos de cero, ya que sus grados de libertad son  $(n - p)$ , en los problemas de regresión, donde  $n$  es el número de individuos y  $p$  los parámetros del modelo.

Lo anterior es la justificación práctica. A continuación se ofrece la definición formal y genérica de la distribución de Wilks.

**Definición A.3.** Sean  $\mathbf{E} \in W_d(\mathbf{I}_d, m_E)$  y  $\mathbf{H} \in W_d(\mathbf{I}_d, m_H)$  independientes, y  $m_E \geq d$ . Diremos que la variable aleatoria unidimensional

$$\frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} = \left| \mathbf{I}_d + \mathbf{E}^{-1} \mathbf{H} \right|^{-1} \in \Lambda(d, m_H, m_E)$$

tiene una distribución  $\Lambda$  de Wilks de parámetros  $d$ ,  $m_H$  y  $m_E$ .

El siguiente resultado, que presentamos sin demostración, permite simplificar la construcción de tablas para la distribución  $\Lambda$  de Wilks, pues los dos primeros parámetros se pueden intercambiar en cierta manera.

**Teorema A.7.** Si denotamos mediante  $\psi(d, m_H, m_E)$  la distribución conjunta de los autovalores no nulos de  $\mathbf{E}^{-1} \mathbf{H}$ , con  $m_E \geq d$ ,  $m_H \geq 1$ ,  $d \geq 1$ , entonces

$$\psi(d, m_H, m_E) = \psi(m_H, d, m_E - d + m_H).$$

En consecuencia,

$$\Lambda(d, m_H, m_E) \stackrel{d}{=} \Lambda(m_H, d, m_E - d + m_H).$$

A continuación se presenta un compendio de propiedades de las distribuciones de Hotelling y de Wilks que facilitan la obtención de cuantiles u otros elementos necesarios para la inferencia.

## Propiedades de la distribución de Hotelling y de Wilks

### Distribución de Hotelling

$$\Gamma^2(d, m) \stackrel{d}{=} \frac{md}{m - d + 1} F_{d, m-d+1}.$$

**Distribución de Wilks. Casos especiales**

$$\Lambda(d, m_H, m_E) \stackrel{d}{=} \Lambda(m_H, d, m_E - d + m_H).$$

Si  $d = 1$ ,

$$\frac{1 - \Lambda(1, m_H, m_E)}{\Lambda(1, m_H, m_E)} \stackrel{d}{=} \frac{m_H}{m_E} F_{m_H, m_E}.$$

Si  $m_H = 1$ ,

$$\frac{1 - \Lambda(d, 1, m_E)}{\Lambda(d, 1, m_E)} \stackrel{d}{=} \frac{d}{m_E - d + 1} F_{d, m_E - d + 1}.$$

Si  $d = 2$  ( $m_H \geq 2$ ),

$$\frac{1 - \sqrt{\Lambda(2, m_H, m_E)}}{\sqrt{\Lambda(2, m_H, m_E)}} \stackrel{d}{=} \frac{m_H}{m_E - 1} F_{2m_H, 2(m_E - 1)}.$$

Si  $m_H = 2$  ( $d \geq 2$ ),

$$\frac{1 - \sqrt{\Lambda(d, 2, m_E)}}{\sqrt{\Lambda(d, 2, m_E)}} \stackrel{d}{=} \frac{d}{m_E - d + 1} F_{2d, 2(m_E - d + 1)}.$$

Aproximación de Bartlett: Para  $m_E$  grande,

$$-f \ln \Lambda(d, m_H, m_E) \text{ se aproxima a } \chi_{dm_H}^2$$

donde

$$f = m_E - \frac{1}{2}(d - m_H + 1).$$

Aproximación de Rao:

$$\frac{1 - \Lambda(d, m_H, m_E)^{1/t}}{\Lambda(d, m_H, m_E)^{1/t}} \frac{ft - g}{dm_H} \text{ es aproximadamente } F_{dm_H, ft-g}$$

siendo

$$f = m_E - \frac{1}{2}(d - m_H + 1),$$

$$t = \left( \frac{d^2 m_H^2 - 4}{d^2 + m_H^2 - 5} \right)^{1/2},$$

$$g = \frac{dm_H - 2}{2}.$$

## B. Conceptos básicos de álgebra matricial

Este Anexo introduce conceptos básicos de álgebra matricial y hace una revisión breve de resultados que serán útiles a lo largo del curso.

### B.1. Autovalores

Dada una matriz  $A$  de tamaño  $n \times n$  con autovalores  $\lambda_1, \dots, \lambda_n$ , se tiene:

1.  $\text{tr}(A) = \sum_{i=1}^n \lambda_i$ .
2.  $|A| = \prod_{i=1}^n \lambda_i$ .
3. Descomposición espectral. Sea  $A$  una matriz de tamaño  $n \times n$  simétrica. Entonces existe una matriz ortogonal  $T$  tal que

$$T'AT = \text{diag}(\lambda_1, \dots, \lambda_n)$$

donde  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$  son los autovalores de  $A$ .

### B.2. Matrices semidefinidas positivas

Una matriz simétrica  $A$  se dice **semidefinida positiva** si y solo si  $x'Ax \geq 0$  para todo  $x$ .

1. Una matriz simétrica  $A$  es semidefinida positiva si y solo si todos sus autovalores son no negativos.
2. Si  $A$  es semidefinida positiva entonces  $\text{tr}(A) \geq 0$ .
3. Si  $A$  es semidefinida positiva entonces  $C'AC$  es semidefinida positiva.
4. Si  $A$  es semidefinida positiva entonces existe una matriz semidefinida positiva  $A^{1/2}$ , tal que  $A = (A^{1/2})^2$ .

### B.3. Matrices definidas positivas

Una matriz simétrica  $A$  se dice **definida positiva** si y solo si  $x'Ax > 0$  para todo  $x$ , con  $x \neq 0$ . Observamos que toda matriz definida positiva es también semidefinida positiva.

1. Una matriz simétrica  $A$  es definida positiva si y solo si todos sus autovalores son positivos.
2. Si  $A$  es semidefinida positiva y  $|A| \neq 0$ , entonces  $A$  es definida positiva.
3.  $A$  es definida positiva si y solo si existe una matriz no singular  $R$  tal que  $A = R'R$ .
4. Si  $A$  es definida positiva entonces existe una matriz definida positiva  $A^{1/2}$ , tal que  $A = (A^{1/2})^2$ .
5. Si  $A$  es definida positiva también lo es  $A^{-1}$ .
6. Si  $A$  es una matriz definida positiva de tamaño  $n \times n$  y  $C$  es una matriz  $p \times n$  de rango  $p$ , entonces  $CAC'$  es definida positiva.
7. Descomposición de Choleski. Si  $A$  es definida positiva existe una única matriz triangular superior  $U$  con elementos positivos en la diagonal tal que  $A = U'U$ . También existe una única matriz triangular inferior  $L$  con elementos positivos en la diagonal tal que  $A = L'L$ .

# Bibliografía

- Andrews, D. F. and Herzberg, A. M. (1985). *Data : a collection of problems from many fields for the student and research worker*. Springer-Verlag, New York.
- Cuadras, C. (1996). *Nuevos métodos de análisis multivariante*. CMC Edicions.
- Everitt, B. (2006). *An R and S-Plus® Companion to Multivariate Analysis*. Springer Texts in Statistics. Springer London.
- Everitt, B., Everitt, D., and Dunn, G. (2001). *Applied Multivariate Data Analysis*. A Hodder Arnold Publication. Wiley.
- Gabriel, K. R. (1971). The biplot graphic display of matrices with application to principal component analysis 1. *Biometrika*, 58(3):453–467.
- Härdle, W. and Simar, L. (2007). *Applied Multivariate Statistical Analysis*. Springer Berlin Heidelberg.
- Hartigan, J. A. and Wong, M. A. (1979). A k-means clustering algorithm. *Applied Statistics*, 28(1):100–108.
- Hastie, T., Tibshirani, R., and Friedman, J. (2001). *The Elements of Statistical Learning*. Springer Series in Statistics. Springer New York Inc., New York, NY, USA.
- Hotelling, H. (1936). Relations between two sets of variates. *Biometrika*, 28(3/4):321–377.
- Johnson, R. and Wichern, D. (2002). *Applied multivariate statistical analysis*. Prentice Hall, 5. ed edition.
- Koch, I. (2013). *Analysis of Multivariate and High-Dimensional Data*. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press.
- Mardia, K., Kent, J., and Bibby, J. (1979). *Multivariate analysis*. Probability and mathematical statistics. Acad. Press, London [u.a.].
- Mardia, K. V. (1970). Measures of multivariate skewness and kurtosis with applications. *Biometrika*, 57(3):519–530.
- Muirhead, R. J. (2005). *Aspects of Multivariate Statistical Theory*. Wiley-Interscience.
- Peña, D. (2002). *Análisis multivariante de datos*. McGraw-Hill Interamericana de España S.L.
- R Core Team (2020). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Rencher, A. and Christensen, W. (2012). *Methods of Multivariate Analysis*. Wiley Series in Probability and Statistics. Wiley.

- Sarkar, D. (2008). *Lattice: Multivariate Data Visualization with R*. Use R! Springer New York.
- Seber, G. (2009). *Multivariate Observations*. Wiley Series in Probability and Statistics. Wiley.
- Yau, N. (2011). *Visualize This: The FlowingData Guide to Design, Visualization, and Statistics*. Wiley Publishing, 1st edition.