

Estatística

Intelixencia Artificial

Beatriz Pateiro López

Táboa de contidos

Prefacio	5
Introdución	7
Poboación e mostra	8
Principais disciplinas da Estatística	8
1 Estatística descritiva	9
1.1 Tipos de variables	10
1.2 Distribución de frecuencias dunha variable	11
1.3 Representacións gráficas para unha variable	13
1.4 Medidas características dunha variable: posición, de dispersión e de forma	14
1.4.1 Medidas de posición	14
1.4.2 Medidas de dispersión	17
1.4.3 Medidas de forma	19
1.5 O diagrama de caixas (boxplot)	20
1.6 Transformacións nos datos	21
1.6.1 Tipificación	21
1.6.2 Transformación de Box-Cox	21
1.7 Estatística descritiva bidimensional	22
1.7.1 Análise de dúas variables cualitativas	22
1.7.2 Análise de dúas variables cuantitativas	24
2 Fundamentos de probabilidade	27
2.1 Conceptos básicos	27
2.1.1 Experimento aleatorio	27
2.1.2 Espazo mostral e sucesos	28
2.2 Definición de probabilidade.	29
2.2.1 Definición clásica ou de Laplace	29
2.2.2 Definición frecuentista	29
2.2.3 Definición axiomática (Kolmogorov 1933)	30
2.3 Probabilidade condicionada	31
2.4 Independencia de sucesos	31
2.5 Resultados notables	32
2.5.1 Regra do produto	32
2.5.2 Lei das probabilidades totais	32
2.5.3 Teorema de Bayes	33

3	Variables aleatorias	34
3.1	Variable aleatoria	34
3.1.1	Función de distribución dunha variable aleatoria	35
3.1.2	Variables aleatorias discretas	35
3.1.3	Variables aleatorias continuas	36
3.1.4	Variables aleatorias multidimensionais	37
3.2	Medidas características dunha variable aleatoria	38
3.2.1	Media ou esperanza	38
3.2.2	Varianza	38
3.3	Principais modelos de variables aleatorias discretas	39
3.3.1	Distribución de Bernoulli	39
3.3.2	Distribución binomial	40
3.3.3	Distribución xeométrica	40
3.3.4	Distribución binomial negativa	41
3.3.5	Distribución de Poisson	41
3.3.6	Distribución hiperxeométrica	42
3.3.7	Distribución uniforme discreta	43
3.4	Principais modelos de variables aleatorias continuas	43
3.4.1	Distribución uniforme	43
3.4.2	Distribución normal	44
3.4.3	Distribución exponencial	45
3.4.4	Distribución gamma	46
3.4.5	Distribución beta	46
3.5	Teorema Central do Límite	47
3.5.1	Aproximacións entre variables aleatorias	47
4	Introdución á inferencia estatística e á estimación de parámetros	49
4.1	Conceptos básicos	49
4.2	Plantexamento xeral do problema de inferencia paramétrica	50
4.3	Estimación puntual	52
4.3.1	Estimación puntual da media e a varianza	53
4.3.2	Estimación puntual dunha proporción	54
4.4	Intervalos de confianza	55
4.4.1	Intervalo de confianza para a media dunha poboación normal	55
4.4.2	Intervalo de confianza para a diferenza de medias de poboacións normais	58
4.4.3	Intervalo de confianza para a varianza dunha poboación normal	61
4.4.4	Intervalo de confianza para o cociente de varianzas de poboacións normais	61
4.4.5	Intervalo de confianza para unha proporción	62
4.4.6	Intervalo de confianza para a diferenza de proporcións	63
	Anexo: Distribucións asociadas coa normal	64
4.4.7	Distribución chi cadrado	64
4.4.8	Distribución t de Student	64
4.4.9	Distribución F de Snedecor	65

5	Contraste de hipóteses	66
5.1	Conceptos básicos	66
5.1.1	Erro de tipo I e erro de tipo II	67
5.1.2	Nivel de significación e potencia dun test	68
5.1.3	Rexión crítica dun test	68
5.1.4	O p-valor dun contraste	69
5.1.5	Resumo das etapas na resolución dun contraste de hipóteses	69
5.1.6	Relación cos intervalos de confianza	70
5.2	Contrastes sobre a media dunha poboación normal	70
5.2.1	Contrastes sobre a media con varianza coñecida	70
5.2.2	Contrastes sobre a media con varianza descoñecida	72
5.3	Contrastes sobre as medias de dúas poboacións normais	73
5.3.1	Mostras independentes, varianzas coñecidas	73
5.3.2	Mostras independentes, varianzas descoñecidas e iguais	74
5.3.3	Mostras emparelladas	76
5.4	Contrastes sobre unha varianza	77
5.5	Contrastes sobre dúas varianzas	78
5.6	Contrastes sobre unha proporción	79
5.7	Contrastes sobre dúas proporcións	80
6	Introdución á regresión lineal	82
6.1	Regresión lineal simple	82
6.2	Método dos mínimos cadrados	84
6.3	Descomposición da variabilidade	85
6.4	Coeficiente de determinación	86
	Bibliografía	87

Prefacio

Este material foi deseñado para o estudantado da materia Estatística do [Grao en Intelixencia Artificial](#). O obxectivo deste curso é que o estudantado aprenda conceptos básicos de estatística descritiva, probabilidade e inferencia estatística, que lle servirán de base para construír modelos estatísticos avanzados para a análise de datos.

Neste curso empregamos [R](#) como linguaxe de referencia para a análise de datos. R é unha ferramenta de código aberto amplamente utilizada nos ámbitos da estatística, a aprendizaxe automática e a ciencia de datos, tanto na investigación como noutros ámbitos profesionais. A súa potencia, flexibilidade e a extensa comunidade internacional que a mantén fan del unha elección ideal para a análise estatística. Co fin de facilitar a aprendizaxe práctica, podes consultar o [material de laboratorio](#), onde se introducen de maneira guiada as principais funcións de R que empregaremos ao longo da materia, acompañado de exemplos e exercicios. Este material servirá como apoio para as sesións prácticas e como referencia para o traballo autónomo do estudantado.

Referencias principais

Este texto está inspirado en diversas obras e materiais docentes do ámbito da estatística, que se recomenda consultar como apoio. Algunhas das máis consultadas para a elaboración destes apuntes foron:

- Alexander (2023)
- Berrendero (2025)
- Çetinkaya-Rundel and Hardin (2024)
- Speegle and Clair (2024)

Emprego de ferramentas asistidas por IA

Este libro foi redactado combinando experiencia docente e recursos tecnolóxicos actuais. Puntualmente, empregouse ChatGPT —unha ferramenta de intelixencia artificial desenvolvida por OpenAI— para apoiar a redacción ou facilitar algunhas traducións automáticas, sempre baixo supervisión e revisión dos resultados. A responsabilidade final sobre os contidos, interpretacións e adaptacións é exclusivamente da autora.

Agradecementos e suxestións

Agradezo calquera suxestión que axude a mellorar este documento. Se atopas erratas, erros, ou consideras que algunha sección se podería explicar mellor, non dubides en escribirme a

beatriz.pateiro@usc.es.



Esta obra está baixo una [Licencia Creative Commons Atribución-NonComercial-Compartir igual 4.0 Internacional](#)

Introdución

Poderíamos definir a Estatística como a ciencia que estuda como **obter información a partir de datos**, utilizando ferramentas matemáticas para analizar e modelar esa información, e tratando de **cuantificar a incerteza** asociada ás conclusións que extraemos. Esta incerteza pode xurdir da natureza aleatoria dos procesos observados, da presenza de ruído nas medicións, da variabilidade entre individuos ou sistemas, ou da complexidade dos modelos empregados. Contar con ferramentas que permitan **medir, describir e modelar esa incerteza** é esencial para tomar decisións ben fundamentadas.

Neste contexto, a Estatística converteuse nunha **peza clave da IA**, xa que moitos dos algoritmos empregados en aprendizaxe automática (machine learning) e ciencia de datos teñen unha base estatística. Desde a análise exploratoria ata a construción de modelos predictivos, a Estatística permite entender mellor os datos, identificar patróns relevantes e avaliar a calidade das decisións automatizadas.

O termo “Estatística” procede do latín *status*, que significa “Estado”. Antigamente, a Estatística se utilizaba principalmente para describir e analizar datos relacionados cos asuntos do Estado: censos de poboación, recadación de impostos, produción agrícola, etc.

Ademais de medir a incerteza, a Estatística preocúpase tamén de **controlar o seu impacto** nas decisións que se toman. Por exemplo, cando un modelo de IA realiza unha predición, é importante saber **con que confianza** fai esa predición, e se existen situacións nas que o modelo poida fallar. A capacidade para interpretar resultados, validar modelos e evitar conclusións erróneas é esencial en calquera aplicación seria da IA.

En definitiva, a Estatística é unha ferramenta transversal, que intervéen en todo o proceso de análise de datos: desde a **recompilación**, pasando pola **organización e visualización**, ata a **análise cuantitativa e a toma de decisións**.

Nesgos en sistemas de IA

Os sistemas baseados en IA empréganse hoxe en día de forma xeneralizada para tomar decisións que teñen un impacto profundo nas persoas e na sociedade. As súas decisións poden afectar a todo o mundo, o que xera preocupacións sobre posibles cuestións relacionadas cos dereitos humanos. Por iso, é necesario ir máis aló dos algoritmos tradicionais de IA optimizados só para o rendemento predictivo e incorporar principios éticos e legais no seu deseño, adestramento e implementación para garantir o ben social, ao tempo que se aproveita o enorme potencial da IA. Neste sentido, a estatística xoga un papel fundamental, non só proporcionando ferramentas para garantir que os datos sexan representativos e libres de nesgos, senón tamén proporcionando métodos para validar, interpretar e explicar

as decisións dos modelos, garantido así que sexan xustas.
Este texto parte das ideas expostas en Ntoutsis et al. (2020). Para máis información sobre os negos en sistemas de IA, consulta esa referencia.

Poboación e mostra

En Estatística, adoita interesarnos extraer información sobre un conxunto completo de elementos, ao que denominamos **poboación**. Porén, en moitas ocasións a poboación é tan grande que resulta inviable analizar todos os seus membros de forma individual.

Por exemplo, a poboación podería estar formada por todos os usuarios dunha aplicación móbil, por todos os dispositivos fabricados por unha empresa durante o último ano, ou por todos os fogares dunha determinada rexión.

Nestes casos, o habitual é seleccionar un subconxunto representativo da poboación, ao que chamamos **mostra**, e realizar o estudo sobre ese subgrupo para extraer conclusións sobre o conxunto completo (poboación).

Destacamos así, os seguintes conceptos fundamentais, que estarán presentes ao longo de todos os contidos deste texto:

- **Poboación:** Conxunto de individuos aos que se refire o estudo que se pretende realizar.
- **Mostra:** Subconxunto da poboación do que se coñecen os valores da variable ou variables que se queren analizar.
- **Variable:** Característica dos elementos da poboación que se pretende estudar.

Principais disciplinas da Estatística

A Estatística inclúe tres grandes áreas ou tarefas fundamentais:

- **Estatística Descritiva:** Ocúpase de recoller, clasificar e resumir a información contida na mostra.
- **Cálculo de Probabilidades:** Parte da matemática teórica que estuda os mecanismos aleatorios.
- **Inferencia Estatística:** Pretende extraer conclusións sobre a poboación a partir dos resultados observados na mostra.

A **Inferencia Estatística** persegue un obxectivo máis ambicioso que a mera descrición da mostra: **obter conclusións sobre a poboación**. Dado que a mostra se obtén mediante procedementos aleatorios, o **Cálculo de Probabilidades** é unha ferramenta esencial da Inferencia Estatística.

1 Estatística descritiva

Como mencionamos anteriormente, unha análise estatística comeza xeralmente cun conxunto de datos cos que traballamos e que son só unha mostra representativa dunha poboación maior. O obxectivo da **estatística descritiva** é extraer e presentar a información que contén esa mostra, resumindo e describindo os datos dunha forma clara e útil mediante representacións gráficas e medidas numéricas fundamentalmente. A estatística descritiva non ten como propósito sacar conclusións sobre a poboación ou facer inferencias, senón describir os datos dispoñibles.

A estatística descritiva está estreitamente relacionada co que se coñece como **análise exploratoria de datos** (EDA, polas súas siglas en inglés), que abrangue tamén o preprocesado dos datos como parte fundamental. Esta etapa inclúe tarefas como a eliminación ou imputación de valores ausentes, a corrección de formatos erróneos e a detección e tratamento de valores atípicos.

“Algunhas persoas teñen suxerido que a análise exploratoria de datos non é máis ca estatística descritiva actualizada. Nos últimos anos dedicouse moito esforzo, intelixencia e comprensión a convencernos de que “o mapa non é o territorio”. Quizais sexa necesario un esforzo similar —polo menos entre as persoas dedicadas á estatística— para convencernos dunha verdade igual de certa: “o conxunto habitual de técnicas non é un campo de actividade intelectual”. Se precisamos unha definición breve do que é a análise exploratoria de datos, eu suxeriría que é unha actitude, e unha flexibilidade, e algo de papel milimetrado (ou transparencias, ou ambos). Ningún catálogo de técnicas pode transmitir a disposición a observar o que se pode ver, tanto se se esperaba como se non. E, con todo, iso está no corazón da análise exploratoria de datos.” Tukey (1980)

John Tukey (1915–2000) foi unha figura destacada no ámbito da estatística, que defendeu, antes incluso da chegada dos computadores potentes, a importancia de coñecer a estrutura e as características dos datos previo á aplicación de técnicas estatísticas formais.

Antes de nada, será interesante deternos a analizar a estrutura da mostra e o tipo de información que contén. Habitualmente, os datos organízanse nunha matriz de dimensións $n \times p$, onde n é o número de observacións ou individuos (o que se coñece como **tamaño de mostra**) e p é o número de variables medidas para cada unha delas.

Equidade en IA

A estatística descritiva é o primeiro paso fundamental para entender os datos e descubrir posibles nesgos ou desigualdades que poden afectar a equidade (*fairness*) dun modelo de IA. Ao realizar análises de estatística descritiva, é fundamental lembrar que os datos deben ser representativos da poboación ou do fenómeno que se quere estudar. Sen embargo, na práctica, a recollida de datos pode estar afectada por diversos nesgos que levan á

sobre- ou sub-representación de certos grupos. Isto pode provocar que, se os grupos mal representados coinciden con grupos sociais afectados por prexuízos ou discriminación, os modelos resultantes perpetúen ou amplifiquen estas desigualdades, aínda que os algoritmos sexan neutrais. Por iso, antes de realizar calquera análise ou modelado, é clave explorar e entender a composición e posibles nesgos da mostra, para interpretar correctamente os resultados e tomar medidas que mitiguen estes problemas.

Para máis información sobre equidade en IA, podes consultar Mehrabi et al. (2021).

É importante tamén identificar o tipo de variables que temos, xa que iso condicionará os métodos que empreguemos para resumir e analizar os datos. Podemos atopar variables cualitativas (que describen categorías ou atributos) e variables cuantitativas (que representan cantidades numéricas).

1.1. Tipos de variables

Variables cualitativas: Non aparecen en forma numérica, senón como categorías ou atributos. Por exemplo, o grupo sanguíneo (A, B, AB, O), o navegador de Internet (Chrome, Firefox, Safari, Edge, ...), ou o nivel educativo (sen estudos, primaria, secundaria, universitaria, ...). As variables cualitativas clasifícanse a súa vez en:

- **Cualitativas nominais:** Miden características que non toman valores numéricos e non presentan entre os seus posibles valores unha relación de orde. Por exemplo, a variable navegador de Internet (Chrome, Firefox, Safari, Edge, ...).
- **Cualitativas ordinais:** Miden características que non toman valores numéricos pero si presentan entre os seus posibles valores unha relación de orde. Por exemplo, o nivel de estudos pode tomar os valores: sen estudos, primaria, secundaria, etc.

Variables cuantitativas: Toman valores numéricos porque son frecuentemente o resultado dunha medición. Por exemplo, o peso (kg) dunha persoa, a estatura (m), o número de parámetros dun modelo, o tempo de adestramento dun algoritmo, etc. As variables cuantitativas clasifícanse a súa vez en:

- **Cuantitativas discretas:** Toman un número discreto de valores (no conxunto dos números naturais). Por exemplo, o número de parámetros dun modelo, o número de usuarios dunha aplicación, etc.
- **Cuantitativas continuas:** Toman valores numéricos dentro dun intervalo real. Por exemplo, a altura, o peso, o tempo de adestramento dun algoritmo, etc.

É importante clasificar correctamente as variables de interese xa que os procedementos que veremos a continuación dependerán do tipo de variable co que traballemos. En primeiro lugar, centrarémonos na análise descritiva **unidimensional**, é dicir, no estudo dunha única variable

estatística. Esta análise permítenos describir e resumir a información dunha variable dunha mostra sen ter en conta outras variables. Na última sección deste capítulo abordaremos tamén a análise descritiva **bidimensional**, onde se estuda conxuntamente o comportamento de dúas variables. Aínda que non o abordaremos neste curso, de forma xeral, o termo **análise multi-variante ou multidimensional** refírese ao estudo conxunto de varias variables estatísticas, permitindo analizar patróns e relacións complexas que non se poden detectar ao considerar cada variable de forma illada.

1.2. Distribución de frecuencias dunha variable

A primeira forma de recoller e resumir a información contida nunha mostra $\{x_1, x_2, \dots, x_n\}$ de tamaño n dunha variable é realizar un recuento do número de veces que se observou cada un dos distintos valores que pode tomar a variable. A isto chamámoslle frecuencia. Supoñamos entón que os valores diferentes que aparecen nos datos son $c_1, c_2, \dots, c_k$. Para cada $i = 1, \dots, k$, podemos calcular:

- **Frecuencia absoluta:** denótase por n_i e representa o número de veces que ocorre o resultado c_i .
- **Frecuencia relativa:** denótase por f_i e representa a proporción de datos en cada unha das clases c_i :

$$f_i = \frac{n_i}{n}$$

A frecuencia relativa é igual á frecuencia absoluta dividida polo tamaño de mostra.

- **Frecuencia absoluta acumulada:** denótase por N_i e representa o número total de observacións correspondentes a valores menores ou iguais que c_i :

$$N_i = \sum_{c_j \leq c_i} n_j$$

- **Frecuencia relativa acumulada:** denótase por F_i e representa a frecuencia absoluta acumulada N_i dividida polo tamaño de mostra:

$$F_i = \frac{N_i}{n} = \sum_{c_j \leq c_i} f_j$$

Debemos observar que as frecuencias acumuladas só teñen sentido cando é posible establecer unha orde entre os valores da variable. Cando consultamos a frecuencia acumulada dun valor c_i , o que estamos a obter é a proporción (ou número) de datos menores ou iguais que c_i . É dicir, a frecuencia acumulada inclúe todas as observacións que toman valores inferiores ou iguais ao valor de referencia.

As frecuencias pódense escribir ordenadamente mediante unha táboa de frecuencias, que adopta esta forma:

c_i	n_i	f_i	N_i	F_i
c_1	n_1	f_1	N_1	F_1
c_2	n_2	f_2	N_2	F_2
...	...	...	...	...
c_k	n_k	f_k	N_k	F_k

A continuación, recóllense as principais propiedades que cumpren as distintas formas de expresar a frecuencia: absoluta, relativa, acumulada e relativa acumulada.

Propiedade		
Frecuencias absolutas	$0 \leq n_i \leq n$	$\sum_{i=1}^k n_i = n$
Frecuencias relativas	$0 \leq f_i \leq 1$	$\sum_{i=1}^k f_i = 1$
Frecuencias absolutas acumuladas	$0 \leq N_i \leq n$	$N_k = n$
Frecuencias relativas acumuladas	$0 \leq F_i \leq 1$	$F_k = 1$

En particular, observamos que a suma das frecuencias absolutas é o número total de datos n e a suma das frecuencias relativas é igual a 1. O último valor da distribución de frecuencias absolutas acumuladas coincide co número total de observacións, e de forma análoga, o último valor da distribución de frecuencias relativas acumuladas é 1.

! Descrición de variables cuantitativas continuas

Para construír táboas de frecuencias de variables cuantitativas continuas é habitual agrupar os valores que pode tomar a variable en intervalos. Deste xeito contamos o número de veces que a variable cae en cada intervalo. A cada un destes intervalos chamámoslle **intervalo de clase** e ao seu punto medio **marca de clase**. Por tanto, para a definición das frecuencias e a construción da táboa de frecuencias substituiremos os valores c_i polos intervalos de clase e as marcas de clase. Algunhas consideracións a ter en conta:

- **Número de intervalos a considerar:** Para adoptar esta decisión teremos en conta:
 1. Se usamos poucos intervalos, a información queda moi xeneralizada e perdemos detalles importantes sobre a distribución dos datos.
 2. Se usamos moitos intervalos, a táboa de frecuencias pode facerse moi complexa e difícil de interpretar, xa que haberá moitas categorías con poucas observacións cada unha.

Aínda que non hai unanimidade ao respecto, un criterio bastante estendido consiste

en tomar como número de intervalos o enteiro máis próximo a $\sqrt{n}$.

- **Amplitude de cada intervalo:** O máis común é que todos os intervalos teñan igual lonxitude, pois facilita a interpretación e comparación das frecuencias. Non obstante, en ocasións pode ser conveniente utilizar intervalos de lonxitudes diferentes para captar mellor a distribución dos datos, especialmente cando hai concentracións maiores ou menores de valores en determinadas zonas.
- **Posición dos intervalos:** Os intervalos deben situarse alí onde se atopen as observacións e de forma contigua.

1.3. Representacións gráficas para unha variable

As representacións gráficas son unha parte fundamental da estatística descritiva porque permiten resumir datos complexos dunha forma visual accesible e intuitiva. A través das representacións gráficas que comentaremos, podemos identificar patróns xerais, tendencias, distribucións e posibles valores atípicos. Isto resulta especialmente útil para explorar os datos e obter unha visión global antes de aplicar técnicas estatísticas máis avanzadas. Existen multitude de gráficos adecuados para cada situación. Algúns empréganse con variables cualitativas e outros con variables cuantitativas.

Diagrama de barras

Empréganse para representar as frecuencias absolutas ou relativas de variables cualitativas ou cuantitativas discretas. Para iso, situamos as modalidades da variable no eixe das abscisas, respectando a súa orde se a houbese, e debuxamos barras verticais sobre elas. As alturas das barras representan frecuencias absolutas, relativas ou porcentaxes.

Diagrama de sectores

Obtense dividindo un círculo en tantos sectores como modalidades teña a variable. A amplitude (ou ángulo) de cada sector debe ser proporcional á frecuencia do valor correspondente, de maneira que a área de cada segmento represente visualmente o peso relativo de cada categoría sobre o total. Este tipo de gráfica resulta especialmente útil para representar variables cualitativas ou discretas con poucas categorías, xa que permite comparar proporcións de forma clara e intuitiva.

Histograma

As frecuencias dunha variable cuantitativa continua tamén se poden representar graficamente. Porén, o diagrama de barras non resulta axeitado neste caso, xa que o que se debe representar son frecuencias asociadas a intervalos contiguos. O histograma é un gráfico utilizado para a distribución dunha variable cuantitativa continua, no que se representan as frecuencias mediante áreas. O histograma constrúese situando os intervalos de clase no eixo das abscisas, como segmentos contiguos da recta real, e erguendo sobre eles rectángulos cuxa **área sexa proporcional á frecuencia** correspondente.

- A diferenza do diagrama de barras, no histograma os rectángulos débúxanse contiguos.
- O aspecto do histograma cambia ao variar o número de intervalos e a amplitude dos mesmos.
- Nun histograma, a altura das barras representa o que se coñece como **densidade de frecuencia**, é dicir, a frecuencia relativa dividida polo tamaño do intervalo que representan (canto maior é a área dunha clase, maior é a súa frecuencia). Deste xeito, cando calculamos a área total que ocupan todas as barras xuntas, esta suma debería ser igual a 1, o que permite interpretar o histograma como unha aproximación da distribución dos datos en termos relativos.
- O histograma axuda a describir como é a distribución da variable: se é simétrica (cun eixe de simetría), se ten unha ou varias modas (máximos relativos), etc.

1.4. Medidas características dunha variable: posición, de dispersión e de forma

O obxectivo fundamental da estatística é extraer conclusións sobre unha poboación baseándonos na información obtida a partir dunha mostra. Ata o de agora vimos como resumir esa información mediante táboas de frecuencias e representacións gráficas que nos axudan a visualizar a distribución dos datos. A continuación estudaremos como calcular medidas que nos dean unha descrición moi resumida dalgunha propiedade concreta do conxunto de datos. Por **medida** entendemos, polo tanto, un número que se calcula a partir da mostra e que reflicte algunha característica desta.

O cálculo destas medidas require realizar operacións cos valores que toma a variable. Por este motivo, a partir de agora traballaremos só con variables cuantitativas.

1.4.1. Medidas de posición

Nesta sección estudamos medidas que nos indican a posición que ocupa a mostra. A posición central é o obxectivo da media, da mediana e da moda. O estudo de posicións non centrais realizarase mediante os cuantís.

Media aritmética

Sexan $x_1, x_2, \dots, x_n$ un conxunto de n observacións da variable que estamos a analizar. Definimos a media aritmética (ou simplemente media) destes valores como:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

Propiedades:

- A media aritmética sempre se atopa entre o valor mínimo e o valor máximo dos datos, é dicir, $\min(x_i) \leq \bar{x} \leq \max(x_i)$, e exprésase na mesma unidade que os valores da variable.
- A media aritmética é o centro de gravidade dos datos, é dicir, $\sum_{i=1}^n (x_i - \bar{x}) = 0$.
- A media aritmética minimiza a suma das desviacións cadradas, é dicir, $\sum_{i=1}^n (x_i - \bar{x})^2 = \min_{a \in \mathbb{R}} \sum_{i=1}^n (x_i - a)^2$.
- Se transformamos todos os valores $x_1, \dots, x_n$ aplicándolles unha función lineal da forma $y_i = a + bx_i$, entón a media dos novos valores $y_1, \dots, y_n$ obtense aplicando esa mesma transformación á media orixinal, é dicir, $\bar{y} = a + b\bar{x}$.

A media é unha das medidas de posición central máis empregadas e é especialmente útil cando a distribución dos datos é simétrica e non contén valores extremos. Porén, a media é moi sensible a valores atípicos ou extremos, que poden modificar notablemente o seu valor e dar unha imaxe distorsionada da posición central real dos datos.

i Media ponderada

A media ponderada é unha extensión da media aritmética que se usa cando non todos os datos teñen a mesma importancia. En lugar de dar o mesmo “peso” a cada valor, asignámoslle a cada un un peso proporcional á súa relevancia. Así, dado un conxunto de valores $x_1, x_2, \dots, x_n$ e os seus pesos correspondentes $w_1, w_2, \dots, w_n$ (non negativos), a media ponderada calcúlase como

$$\bar{x} = \frac{w_1 x_1 + w_2 x_2 + \dots + w_n x_n}{w_1 + w_2 + \dots + w_n} = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

Observa que a media aritmética é un caso particular de media ponderada onde todos os pesos son $w_i = 1/n$, $i = 1, \dots, n$.

Nos modelos estatísticos e de IA, os pesos teñen un papel importante para controlar a influencia que cada observación ou variable exerce sobre a estimación ou predición final. Moitos modelos dispoñen de mecanismos para asignar pesos, o que permite axustar o impacto dos datos.

Media truncada e media recortada

Un inconveniente da media aritmética é que un dato anómalo pode facer que varíe moito (pensa que a contribución de cada dato á media é x_i/n).

Para evitar este efecto, utilízase a **media truncada**, que consiste en calcular a media aritmética dunha porcentaxe central dos datos (é dicir, eliminando un porcentaxe dos valores máis baixos e outro dos máis altos). Así, por exemplo, unha media truncada ao 10 % calcularía a media aritmética do 90 % dos valores centrais, desprezando o 5 % máis baixo e o 5 % máis alto.

A media recortada é un concepto semellante ao anterior, pero en lugar de eliminar eses valores extremos, o que se fai é modificalos: substitúense os valores máis baixos polo valor máis baixo do grupo central, e os máis altos polo valor máis alto dese grupo central.

Mediana

Unha vez ordenados os datos de menor a maior, defínese a mediana como o valor da variable que deixa á súa esquerda o mesmo número de valores que á dereita. Se hai un número impar de datos, a mediana é o valor central. Se hai un número par de datos, a mediana é a media dos dous valores centrais.

A mediana é menos sensible a valores atípicos porque non se ve afectada polas magnitudes extremas, senón só pola posición relativa dos datos. Por iso, dicimos que a mediana é unha medida **robusta** de posición central. En situacións nas que os datos teñen unha distribución moi asimétrica ou conteñen valores atípicos, a mediana ofrece unha representación máis fiable e estable do valor central do conxunto de datos que a media.

Moda

É o valor da mostra que aparece con maior frecuencia. Ao contrario das outras medidas, a moda tamén se pode calcular para variables cualitativas. Porén, ao estar estreitamente ligada á frecuencia, non se pode calcular para variables continuas sen agrupación por intervalos de clase. Ao intervalo con maior densidade de frecuencia chamámoslle **clase modal**. Pode suceder que exista unha única moda, neste caso falamos de distribución de frecuencias unimodal. Se hai máis dunha moda, dicimos que a distribución é multimodal.

Cuantís

Vimos que a mediana divide os datos en dúas partes iguais. Pero tamén é interesante estudar outras medidas de posición, chamadas cuantís, que dividen os datos da distribución en partes iguais, é dicir, en intervalos que comprenden o mesmo número de valores. En xeral, para un valor $p \in (0, 1)$, defínese o cuantil como o valor que deixa á súa esquerda unha frecuencia

relativa p . Observa que con esta definición, a mediana é o cuantil 0,5. Existen diferentes métodos para calcular os cuantís. Unha forma posible de calcular o cuantil p consistiría en ordenar a mostra de menor a maior e tomar como cuantil o menor dato da mostra (o primeiro da mostra ordenada) cuxa frecuencia relativa acumulada sexa maior que p .

Algúns ordes dos cuantís teñen nomes específicos. Así:

- Os **cuartís** son os cuantís de orde 0.25, 0.5, 0.75 (dividen a distribución en catro partes) e denótanse Q_1 , Q_2 e Q_3 , respectivamente.
- Os **decís** son os cuantís de orde 0.1, 0.2, ..., 0.9.
- Os **percentís** son os cuantís de orde $j/100$, $j = 1, \dots, 99$.

1.4.2. Medidas de dispersión

As medidas de dispersión empréganse para describir a variabilidade dos datos dunha mostra respecto á súa posición central. En primeiro lugar, presentaremos as principais **medidas de dispersión absoluta** —que dependen das unidades da variable orixinal— e finalizaremos cunha **medida de dispersión relativa**, o coeficiente de variación, que expresa a variabilidade de forma adimensional, é dicir, sen depender das unidades da variable.

Recorrido ou rango

O recorrido (ou rango) é unha medida moi sinxela de dispersión que indica a diferenza entre o valor máis grande e o máis pequeno dun conxunto de datos. É dicir, móstranos o intervalo total no que se espallan os valores da mostra. Formalmente,

$$R = \max(x_i) - \min(x_i)$$

Recorrido ou rango intercuartílico

Defínese como a diferenza entre o terceiro cuartil e o primeiro cuartil, é dicir,

$$RI = Q_3 - Q_1$$

Así, rango intercuartílico representa a amplitude do intervalo central onde se atopa o 50 % dos datos. É unha medida máis robusta que o rango porque non se ve afectada polos valores extremos ou atípicos, xa que se basea en cuartís, que son posicións relativas dentro dos datos ordenados.

Varianza

Se utilizamos a media como medida de posición, parece razoable tomar como medida de dispersión algún criterio que indique a discrepancia dos valores respecto á media. Como vimos, a diferenza simple entre os valores e a media, ao ponderala, dá cero. Por iso, elevamos esas diferenzas ao cadrado para que os sumandos positivos e negativos non se cancelen. O resultado é a varianza, cuxa definición se dá a continuación. Sean $x_1, x_2, \dots, x_n$ un conxunto de n observacións. Defínese a varianza da mostra como:

$$s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Propiedades:

- A varianza toma sempre valores non negativos.
- Se transformamos todos os valores $x_1, \dots, x_n$ aplicándolles unha función lineal da forma $y_i = a + bx_i$, entón a varianza dos novos valores $y_1, \dots, y_n$ verifica $s_y^2 = b^2 s_x^2$. É dicir, engadir unha constante a a todos os datos (traslación) non afecta á varianza. Isto é porque a varianza mide a dispersión dos datos respecto á súa media, e ao sumar o mesmo número a todos os valores, a dispersión mantense igual. Multiplicar todos os datos por unha constante b (escalado) modifica a varianza multiplicándoa polo cadrado de b .

! Cuasivarianza

Na práctica, cando calculamos a varianza dunha mostra, é común usar unha fórmula lixeiramente diferente á presentada anteriormente. Defínese **cuasivarianza** da mostra como:

$$s_c^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Observa que a diferenza entre a fórmula da varianza e da cuasivarianza está no denominador. Na varianza s^2 faise un promedio e na cuasivarianza s_c^2 , divídese por $n - 1$. Neste caso non facemos unha media exacta, senón un axuste (cando coñecemos a media, con $n - 1$ valores xa poderíamos calcular o dato que falta)

Desviación típica

Calculase como a raíz cadrada positiva da varianza, polo que se expresa nas mesmas unidades que os datos orixinais, facilitando así a súa interpretación. Denótase por s .

Outras medidas de dispersión absoluta

Ademais das medidas máis habituais como a varianza ou a desviación típica, tamén existen outras medidas de dispersión que poden ser útiles nalgúns contextos.

- **Desviación absoluta con respecto á media:** Consiste no promedio das distancias absolutas entre cada valor da mostra e a media aritmética, e defínese como:

$$D_{\bar{x}} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

- **Desviación absoluta con respecto á mediana:** Consiste no promedio das distancias absolutas entre cada valor da mostra e a mediana, e defínese como:

$$D_{Q_2} = \frac{1}{n} \sum_{i=1}^n |x_i - Q_2|$$

- **Mediana das desviacións absolutas (MEDA):** Defínese como a mediana das desviacións absolutas dos datos respecto á mediana da mostra. É dicir:

$$\text{MEDA} = \text{Mediana}(|x_1 - Q_2|, |x_2 - Q_2|, \dots, |x_n - Q_2|)$$

Coefficiente de variación

Se queremos unha medida de dispersión que non dependa da escala das unidades, e que permita comparar a variabilidade relativa entre distintas mostras, podemos usar o coeficiente de variación, que se define como:

$$CV = \frac{s}{\bar{x}}$$

Para que esta medida teña sentido, é necesario que a media non sexa cero. Ademais, o coeficiente de variación só é adecuado para variables que tomen valores positivos e que non estean afectadas por cambios de localización (é dicir, que non se desprazan simplemente por sumar ou restar unha constante).

1.4.3. Medidas de forma

As medidas de forma son ferramentas estatísticas que nos permiten describir características máis detalladas da distribución dos datos, máis alá da posición e a dispersión. En particular, estas medidas avalían dous aspectos fundamentais da forma da distribución: o grao de **simetría**, que indica se os datos están distribuídos de maneira equilibrada arredor dun punto central (normalmente a media) e o **apuntamento** (tamén chamado curtose), que mide o grao de concentración ou dispersión dos datos arredor da media.

Coeficiente de asimetría de Fisher

Defínese como

$$As_F = \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{ns^3}$$

A interpretación deste coeficiente é a seguinte: se o seu valor é case cero, díse que os datos son simétricos. Se toma valores significativamente maiores que cero, diremos que os datos teñen asimetría cara á dereita, e se toma valores significativamente menores que cero, diremos que teñen asimetría cara á esquerda.

Coeficiente de apuntamento de Fisher

Mide o grao de concentración dunha variable respecto da súa medida habitual de centralización (a media). Defínese como:

$$K_F = \frac{\sum_{i=1}^n (x_i - \bar{x})^4}{ns^4}$$

En Estatística, o modelo de distribución de referencia habitual é o gaussiano ou normal, que presenta teoricamente un coeficiente de apuntamento igual a 3, polo que este valor se toma como referencia. Así, se este coeficiente é menor que 3, diremos que os datos teñen forma platicúrtica; se é maior que 3, dirase que son leptocúrticos; e se é aproximadamente 3, que son mesocúrticos. Unha distribución con alto apuntamento ten unha maior concentración de datos próximos á media e colas máis pesadas.

1.5. O diagrama de caixas (boxplot)

O boxplot é unha representación gráfica que resume visualmente as características principais dunha distribución de datos. Baseándose nalgúnhas das medidas de posición e dispersión que vimos (mediana, cuartís, rango intercuartílico), este gráfico amosa:

- Unha caixa central, que vai do primeiro ao terceiro cuartil, representando o 50 % dos datos centrais.
- Unha liña á altura da mediana (Q_2), que mostra o valor central da mostra.
- Os bigotes, que se estenden ata os límites definidos para detectar valores normais, considerando unha marxe de 1.5 veces o rango intercuartílico (RI). Así, o bigote superior chega ata o maior dato observado no conxunto de datos que sexa menor ou igual a $Q_3 + 15RI$ e o bigote inferior chega ata o menor dato observado que sexa maior ou igual a $Q_1 - 15RI$.
- Valores atípicos, que se representan como puntos ou símbolos fóra dos bigotes (se corresponden cos puntos observados que quedan fóra dos límites dos bigotes).

1.6. Transformacións nos datos

Ás veces, antes de aplicar técnicas estatísticas ou modelos de aprendizaxe automática, convén transformar os datos para mellorar o seu comportamento, cumprir os supostos do modelo que se quere aplicar ou facilitar a interpretación. Dúas das transformacións máis habituais son a **tipificación** e a **transformación de Box-Cox**.

1.6.1. Tipificación

Cando se queren realizar comparacións entre valores particulares de variables medidas en distintas escalas, convén empregar unha referencia común que faga efectiva a comparación. Isto conséguese mediante a **tipificación**.

A mostra tipificada obtense transformando cada observación x_i da mostra orixinal restándolle a media muestral $\bar{x}$ e dividíndoa pola desviación típica muestral s . É dicir, calculamos

$$z_i = \frac{x_i - \bar{x}}{s}$$

Esta transformación xera unha nova mostra $\{z_1, z_2, \dots, z_n\}$, que terá media $\bar{z}$ igual a 0 e desviación típica s_z igual a 1, o que permite comparar directamente os valores desta mostra cos doutras mostras tamén tipificadas, sen que a diferenza de escalas afecte á análise.

A tipificación non modifica as medidas adimensionais, como o coeficiente de asimetría ou a curtose, pero si altera as medidas con unidades, como a media ou a desviación típica. En xeral, as transformacións lineais, como a tipificación, preservan as propiedades de forma da distribución relativa aos datos da mostra.

1.6.2. Transformación de Box-Cox

A transformación de **Box-Cox** emprégase para converter datos que non seguen unha distribución normal nunha forma máis próxima á normalidade, o que é útil en moitos modelos estatísticos e de aprendizaxe automática.

Para datos positivos, a transformación defínese como:

$$x^{(\lambda)} = \begin{cases} \frac{x^\lambda - 1}{\lambda}, & \text{se } \lambda \neq 0 \\ \log(x), & \text{se } \lambda = 0 \end{cases}$$

A elección do parámetro λ faise habitualmente por métodos automáticos (como *máxima verosimilitude*), escollendo o valor que mellor axuste os datos a unha distribución normal.

Esta transformación axuda a **reducir a asimetría** ou a **variabilidade desigual** e é especialmente útil cando se traballa con **datos de resposta positiva**.

1.7. Estatística descritiva bidimensional

En moitas ocasións, mídense simultaneamente en cada individuo dunha poboación dúas ou máis variables co propósito de determinar se existen relacións entre elas ou non. As situacións que se poden presentar neste tipo de estudos son moi variadas, dependendo da natureza das variables analizadas. Consideraremos unicamente o caso de dúas variables (bidimensional).

1.7.1. Análise de dúas variables cualitativas

Considérense dúas variables cualitativas X e Y observadas nunha mostra de tamaño n , representada polos pares ordenados $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$. Supoñamos que a variable X pode tomar valores nun conxunto finito de categorías $c_1, c_2, \dots, c_k$, e a variable Y pode tomar valores $d_1, d_2, \dots, d_l$. Estas categorías representan distintas cualidades ou atributos dos individuos da mostra.

Distribución conxunta

O obxectivo é analizar a distribución conxunta das dúas variables cualitativas, estudando a frecuencia con que aparecen cada unha das combinacións posibles (c_i, d_j) para $i = 1, \dots, k$ e $j = 1, \dots, l$. Esta análise permite investigar posibles relacións ou asociacións entre X e Y . As frecuencias poden recollerse ordenadamente mediante unha **táboa de frecuencias absolutas**, que adopta esta forma:

$X \backslash Y$	d_1	...	d_j	...	d_l
c_1	n_{11}	...	n_{1j}	...	n_{1l}
$\vdots$	$\vdots$		$\vdots$		$\vdots$
c_i	n_{i1}	...	n_{ij}	...	n_{il}
$\vdots$	$\vdots$		$\vdots$		$\vdots$
c_k	n_{k1}	...	n_{kj}	...	n_{kl}

Táboa de continxencia

A táboa de frecuencias absolutas tamén se coñece como **táboa de continxencia** ou **táboa de dobre entrada**. Unha táboa de continxencia é un cadro que cruza as categorías dunha variable coas categorías da outra. Cada celda da táboa indica cantas veces se observa esa combinación específica de categorías. As táboas de continxencia permiten analizar a independencia entre dúas variables cualitativas. Se as variables son independentes, as frecuencias observadas nas celdas deberían achegarse ás frecuencias esperadas baixo independencia. A partir desta comparación, introdúcese o coñecido test de chi cadrado, que cuantifica se existe evidencia suficiente para concluír que as dúas variables non son

independentes.

As frecuencias tamén se poden escribir ordenadamente mediante unha **táboa de frecuencias relativas**, que adopta esta forma:

$X \backslash Y$	d_1	...	d_j	...	d_l
c_1	f_{11}	...	f_{1j}	...	f_{1l}
$\vdots$	$\vdots$		$\vdots$		$\vdots$
c_i	f_{i1}	...	f_{ij}	...	f_{il}
$\vdots$	$\vdots$		$\vdots$		$\vdots$
c_k	f_{k1}	...	f_{kj}	...	f_{kl}

A continuación, recóllense as principais propiedades que cumpren as frecuencias absolutas e relativas.

Propiedades		
Frecuencias absolutas	$0 \leq n_{ij} \leq n$	$\sum_{i=1}^k \sum_{j=1}^l n_{ij} = n$
Frecuencias relativas	$0 \leq f_{ij} \leq 1$	$\sum_{i=1}^k \sum_{j=1}^l f_{ij} = 1$

Distribución marxinal

Nunha táboa de frecuencias bidimensional, as **frecuencias marxinais** son as sumas das frecuencias ao longo das filas ou das columnas. Estas distribucións marxinais permiten coñecer a distribución dunha variable por separado dentro da táboa conxunta.

- As frecuencias marxinais de X , denotadas por $n_{i\bullet}$ para $i = 1, \dots, k$, son as sumas das frecuencias absolutas de cada fila. De xeito análogo, as frecuencias relativas marxinais de X , denotadas por $f_{i\bullet}$, son as sumas das frecuencias relativas de cada fila.
- As frecuencias marxinais de Y , denotadas por $n_{\bullet j}$ para $j = 1, \dots, l$, son as sumas das frecuencias absolutas de cada columna. De igual forma, as frecuencias relativas marxinais de Y , denotadas por $f_{\bullet j}$, son as sumas das frecuencias relativas de cada columna.

Podemos organizar as frecuencias conxuntas e as frecuencias marxinais nunha táboa, como se amosa a continuación (poderíamos facer igual coas frecuencias relativas):

$X \backslash Y$	d_1	...	d_j	...	d_l	Marxinal X
c_1	n_{11}	...	n_{1j}	...	n_{1l}	$n_{1\bullet}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
c_i	n_{i1}	...	n_{ij}	...	n_{il}	$n_{i\bullet}$

$X \backslash Y$	d_1	...	d_j	...	d_l	Marxinal X
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
c_k	n_{k1}	...	n_{kj}	...	n_{kl}	$n_{k\bullet}$
Marxinal Y	$n_{\bullet 1}$	...	$n_{\bullet j}$	...	$n_{\bullet l}$	n

Distribución condicionada

A **distribución de X condicionada a $Y = d_j$** é a distribución unidimensional de X sabendo que a variable Y tomou a modalidade d_j . É dicir, describe como se distribúen os valores da variable X cando se sabe que a variable Y tomou a modalidade d_j . Esta distribución permítenos estudar o comportamento de X dentro do subconxunto da poboación ou mostra no que Y presenta un valor fixo. Trátase dunha ferramenta fundamental para analizar dependencias entre variables cualitativas ou para estudar asociacións entre categorías.

A frecuencia absoluta de X condicionada a $Y = d_j$ é:

$$n_{X=c_i|Y=d_j} = n_{ij}, \quad i = 1, \dots, k$$

A frecuencia relativa de X condicionada a $Y = d_j$ é:

$$f_{X=c_i|Y=d_j} = \frac{n_{ij}}{n_{\bullet j}} = \frac{f_{ij}}{f_{\bullet j}}, \quad i = 1, \dots, k$$

Do mesmo xeito, poderíamos definir a **distribución de Y condicionada a $X = c_i$** , analizando a distribución das modalidades de Y dentro do grupo con $X = c_i$.

Como consecuencia directa das definicións, obtemos a seguinte relación:

$$f_{ij} = f_{\bullet j} \cdot f_{X=c_i|Y=d_j} = f_{Y=d_j} \cdot f_{X=c_i|Y=d_j}$$

Esta identidade amosa como a frecuencia conxunta pode obterse a partir das distribucións marxinais e condicionais.

1.7.2. Análise de dúas variables cuantitativas

Considérense agora dúas variables cuantitativas X e Y observadas nunha mostra de tamaño n , representada polos pares ordenados $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$.

O diagrama de dispersión

A representación gráfica máis útil de dúas variables continuas é o **diagrama de dispersión**. Este consiste en representar nunha cuadrícula os pares de observacións (x_i, y_i) de cada individuo da mostra. A nube de puntos que se forma, tamén chamada **nube de puntos** ou *scatter plot*, permite:

- Visualizar a posible relación entre as dúas variables e detectar patróns lineais ou non lineais.
 - Se non hai relación, a nube aparecerá dispersa sen patrón definido.
 - Se hai relación lineal os puntos tenden a agruparse arredor dunha liña ascendente pou descendente.
 - Se hai relación non lineal a tendencia dos puntos segue unha curva, por exemplo, unha parábola ou un patrón sen liña recta clara.
- Identificar posibles valores atípicos.

Covarianza

A maioría das medidas características estudadas no caso unidimensional (como, por exemplo, a media) pódense estender ao caso bidimensional. Ademais, no contexto de dúas variables surxen novas medidas que nos permiten **cuantificar a dispersión conxunta de dúas variables**. Consideremos unha mostra de n observacións dunha variable bidimensional cuantitativa (X, Y)

A **covarianza** entre X e Y (denotada por s_{xy}) defínese como:

$$\text{Cov}(X, Y) = s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

A covarianza pódese interpretar como unha medida de relación lineal entre as variables X e Y :

- Valores positivos indican que cando X aumenta, Y tende a aumentar.
- Valores negativos indican que cando X aumenta, Y tende a diminuír.
- Valores próximos a cero indican que non hai unha relación lineal clara.

Propiedades da covarianza

- A covarianza de (X, Y) é igual á de (Y, X) , é dicir, $s_{xy} = s_{yx}$
- A covarianza de (X, Y) é igual á varianza de X , é dicir, $s_{xx} = s_x^2$

Coeficiente de correlación lineal

A covarianza varía se modificamos as unidades de medida das variables. Isto pode ser un inconveniente, porque non permite comparar a relación entre distintos pares de variables medidos en unidades diferentes.

A solución consiste en utilizar o **coeficiente de correlación lineal**, que se obtén tipificando a covarianza, é dicir, dividíndoa polas desviacións típicas das dúas variables:

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$

O coeficiente de correlación lineal toma valores entre -1 e 1 e serve para investigar a relación lineal entre as variables.

- Se r_{xy} é próximo a -1 , temos unha relación inversa entre X e Y , é dicir, cando unha variable toma valores altos, a outra tende a ser baixa.
- Se r_{xy} é próximo a $+1$, temos unha relación directa, de modo que valores altos dunha variable están asociados con valores altos da outra.
- Se r_{xy} é próximo a cero, non existe relación lineal significativa entre as variables.

Cando $r_{xy} = 1$ ou $r_{xy} = -1$, existe dependencia lineal exacta. Se $r_{xy} = 0$, decimos que as variables son incorreladas.

2 Fundamentos de probabilidade

O obxectivo da Estatística é empregar os datos para inferir sobre as características dunha poboación á que non podemos acceder de maneira completa. No tema anterior vimos como realizar unha análise descritiva dunha mostra de datos. A **Probabilidade** é a disciplina científica que proporciona e estuda modelos para fenómenos aleatorios nos que intervén o azar, e serve como soporte teórico para a Estatística.

Os primeiros traballos con certo grao de formalización na Teoría da Probabilidade atribúense a Cardano e Galilei (século XVI), aínda que as bases desta teoría foron desenvolvidas por Pascal e Fermat no século XVII. A partir de aí, grandes científicos contribuíron ao desenvolvemento da Probabilidade, como Bernoulli, Bayes, Euler ou Gauss, durante os séculos XVIII e XIX. Será a finais do século XIX e comezos do XX cando a Probabilidade acade unha maior formalización matemática, en boa parte grazas á chamada Escola de San Petersburgo, onde destacan os estudos de Tchebychev, Markov e Liapunov.

2.1. Conceptos básicos

2.1.1. Experimento aleatorio

Cando dun experimento podemos saber dalgunha maneira cal vai ser o seu resultado antes de realizalo, dicimos que o experimento é determinista. Así, podemos considerar que as horas de saída do Sol, ou as mareas (pleamar e baixamar), son deterministas, pois podemos consultalas no xornal antes de que ocorran. Pola contra, non podemos atopar en ningún medio o número premiado na Lotería de Nadal antes do sorteo.

Nós queremos estudar experimentos que non son deterministas, mais non estamos interesados en todos eles. Por exemplo, non estudaremos un experimento do que, por descoñecemento, nin sequera sabemos de antemán cales son os seus posibles resultados. Non imos facer tarefas de adiviñación. Por iso definiremos un experimento aleatorio como aquel que cumpra certas condicións que nos permitan un estudo rigoroso do mesmo.

Chámase experimento aleatorio a aquel que cumpre os seguintes requisitos:

- Todos os seus posibles resultados son coñecidos de antemán.
- O resultado particular de cada realización do experimento é imprevisible.
- O experimento pódese repetir indefinidamente en condicións idénticas.

2.1.2. Espazo mostral e sucesos

Chamamos **espazo mostral** ao conxunto formado por todos os resultados posibles dun experimento aleatorio. Denotámolo por Ω .

Un **suceso** é calquera subconxunto do espazo mostral.

Chamamos **suceso elemental** a un suceso formado por un único resultado do experimento aleatorio.

Decimos que ocorreu un suceso cando se obtivo algún dos resultados que o forman. O obxectivo da Teoría da Probabilidade é estudar con rigor os sucesos, asignarlles probabilidades e realizar cálculos sobre estas. Observamos que os sucesos non son outra cousa que conxuntos e, por tanto, serán tratados desde a **Teoría de Conxuntos**. Lembramos as operacións básicas e engadímoslles interpretación no contexto dos sucesos:

- **Suceso seguro:** é o que sempre ocorre e, polo tanto, coincide co espazo mostral, Ω .
- **Suceso imposible:** é o que nunca ocorre e, polo tanto, é o baleiro, $\emptyset$.
- **Unión:** ocorre $A \cup B$ se ocorre polo menos un dos sucesos A ou B .
- **Intersección:** ocorre $A \cap B$ se ocorren simultaneamente os dous sucesos A e B .
- **Complementario:** ocorre A^c se, e só se, non ocorre A .
- **Diferenza de sucesos:** ocorre $A \setminus B$ se ocorre A pero non ocorre B . É dicir, $A \setminus B = A \cap B^c$.
- **Sucesos incompatibles:** dous sucesos A e B son incompatibles se non poden ocorrer ao mesmo tempo. É dicir, $A \cap B = \emptyset$.
- **Suceso contido noutro:** dicimos que A está contido en B , e escribímolo $A \subset B$, se sempre que ocorre A , tamén ocorre B .

As operacións con sucesos obedecen unha serie de propiedades fundamentais que derivan das regras da álgebra de conxuntos. A seguinte táboa resume as principais propiedades, aplicadas tanto á unión como á intersección de sucesos:

Propiedade	Unión	Intersección
Asociativa	$A \cup (B \cup C) = (A \cup B) \cup C$	$A \cap (B \cap C) = (A \cap B) \cap C$
Conmutativa	$A \cup B = B \cup A$	$A \cap B = B \cap A$
Distributiva	$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$	$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
Elemento neutro	$\emptyset$ é o neutro da unión: $A \cup \emptyset = A$	Ω é o neutro da intersección: $A \cap \Omega = A$
Complementario	$A \cup A^c = \Omega$	$A \cap A^c = \emptyset$
Leis de De Morgan	$(A \cup B)^c = A^c \cap B^c$	$(A \cap B)^c = A^c \cup B^c$

2.2. Definición de probabilidade.

O principal obxectivo dun experimento aleatorio adoita ser determinar con que probabilidade ocorre cada un dos sucesos elementais. Mais, **como lle asignamos probabilidades aos sucesos?**

2.2.1. Definición clásica ou de Laplace

Estamos ante un experimento, cunha colección de sucesos, e preguntámonos como debemos actuar para asignarlle a cada suceso un número entre 0 e 1 que represente a probabilidade de que dito suceso ocorra.

Cando o espazo mostral é finito, o problema redúcese a asignar probabilidades aos sucesos elementais. As probabilidades dos demais sucesos obteranse sumando as dos sucesos elementais que os compoñen (suma finita).

Sen dúbida, o caso máis sinxelo é aquel no que non temos razóns para supoñer que uns sucesos son máis probables ca outros.

Se o espazo mostral Ω é finito e todos os sucesos elementais teñen a mesma probabilidade, diremos que son **equiprobables**, e poderemos utilizar a coñecida **regra de Laplace**:

$$P(A) = \frac{\text{casos favorables a } A}{\text{casos posibles}}$$

2.2.2. Definición frecuentista

Cando se emprega **coloquialmente** o termo probabilidade, adoita querer expresarse o grao de certeza ou incerteza sobre o resultado dun experimento **antes** da súa realización. Para cuantificar esa probabilidade, apoiámonos na experiencia empírica que poidamos ter do experimento. Así, se xa foi observado con anterioridade, podemos ter calculado as frecuencias relativas dos distintos resultados:

$$f_n(A) = \frac{\text{nº de veces que ocorreu } A \text{ en } n \text{ repeticións}}{n}$$

A partir desas frecuencias formamos a nosa idea de certeza sobre o resultado dunha futura realización do experimento. Cómpre destacar que as frecuencias calcúlanse despois da realización do experimento, mentres que as probabilidades exprésanse antes de levalo a cabo. Como apoio a este enfoque contamos coa **Lei da Estabilidade das Frecuencias**, que nos di que cando se repite moitas veces un mesmo experimento, as frecuencias relativas dos seus posibles resultados tendan a estabilizarse arredor de certos valores. Para que isto sexa posible, suponse que o

experimento pode repetirse, sempre nas mesmas condicións, tantas veces como sexa necesario. Así, no século XIX definiuse a probabilidade dun suceso como **o límite das súas frecuencias relativas cando realizamos o experimento moitas veces**.

$$P(A) = \lim_{n \rightarrow \infty} f_n(A)$$

Esta definición presenta certos inconvenientes. Ademais de dificultades formais importantes, na práctica pode que poidamos realizar o experimento moitas veces, pero será imposible repetilo indefinidamente.

2.2.3. Definición axiomática (Kolmogorov 1933)

As dificultades que presenta a definición de probabilidade resolvéronse a principios do século XX mediante a utilización dunha definición axiomática da probabilidade.

Sexa Ω o espazo mostral, e $P(\Omega)$ o conxunto formado por todos os sucesos. Defínese a probabilidade como unha aplicación

$$P : P(\Omega) \longrightarrow [0, 1]$$

que cumpre as seguintes condicións:

- $P(\Omega) = 1$ (A probabilidade do suceso seguro é 1).
- Se $A \cap B = \emptyset$ entón $P(A \cup B) = P(A) + P(B)$ (Se A e B son sucesos incompatibles, entón a probabilidade da súa unión é a suma das súas probabilidades).

A partir da definición anterior pódese deducir que:

- $P(\emptyset) = 0$
- Se $A_1, A_2, \dots, A_n$ son sucesos incompatibles dous a dous, entón

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = P(A_1) + P(A_2) + \dots + P(A_n)$$

- $P(A^c) = 1 - P(A)$
- Se $A \subset B$, entón $P(A) \leq P(B)$
- Se A e B son dous sucesos calquera (non necesariamente incompatibles), entón

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Esta definición foi a base de todo o cálculo de probabilidades no século XX.

2.3. Probabilidade condicionada

O concepto de probabilidade condicionada é un dos máis importantes en Teoría da Probabilidade. A probabilidade condicionada pon de manifesto o feito de que as probabilidades cambian cando a información dispoñible cambia. Por exemplo, cal é a probabilidade de sacar un 1 ao lanzar un dado? E cal é a probabilidade de sacar un 1 ao lanzar un dado se sabemos que o resultado foi un número impar?

Supoñamos entón que no estudo dun experimento aleatorio nos interesa coñecer a probabilidade de que ocorra un certo suceso A , pero dispoñemos de información previa sobre o experimento: sabemos que o suceso B ocorreu. Está claro que agora a probabilidade de A xa non é a mesma que cando non sabiamos nada sobre B .

A **probabilidade do suceso A condicionada ao suceso B** defínese como:

$$P(A | B) = \frac{P(A \cap B)}{P(B)} \quad \text{coa condición de que } P(B) \neq 0$$

Tamén se deduce de maneira inmediata que $P(A \cap B) = P(A) \cdot P(B/A) = P(B) \cdot P(A/B)$.

2.4. Independencia de sucesos

Dous sucesos A e B son **independentes** se

$$P(A \cap B) = P(A) \cdot P(B)$$

Comentarios:

- Se $P(B) > 0$, A e B son independentes se e só se $P(A | B) = P(A)$, isto é, o coñecemento da ocorrencia de B non modifica a probabilidade de ocorrencia de A .
- Se $P(A) > 0$, A e B son independentes se e só se $P(B | A) = P(B)$, isto é, o coñecemento da ocorrencia de A non modifica a probabilidade de ocorrencia de B .
- Non debemos confundir sucesos **independentes** con sucesos **incompatibles**: os sucesos incompatibles son os máis dependentes que pode haber. Por exemplo, no lanzamento dunha moeda consideramos os sucesos incompatibles “saír cara” e “saír cruz”, o coñecemento de que saíu cara dá o máximo de información sobre o outro suceso: xa que saíu cara é imposible que saíse cruz.

2.5. Resultados notables

Nesta sección veremos tres teoremas moi importantes, tanto a nivel teórico como para a resolución de exercicios. Trátase da regra do produto (Teorema 2.1), a lei das probabilidades totais (Teorema 2.2) e o teorema de Bayes (Teorema 2.3). Enunciaremos a súa forma máis xeral, aínda que despois mostraremos con exemplos que a súa aplicación non é complicada.

2.5.1. Regra do produto

A regra do produto utilízase en experimentos aleatorios formados por etapas consecutivas (da 1 á n) e permite calcular a probabilidade de que ocorra unha concatenación (intersección) de sucesos ao longo das etapas (A_1 na primeira etapa, A_2 na segunda etapa, ..., e A_n na etapa n). Esta probabilidade exprésase como o produto da probabilidade inicial $P(A_1)$ e das probabilidades en cada etapa condicionadas ás etapas anteriores, coñecidas como probabilidades de transición.

Teorema 2.1 (Regra do produto). *Se temos os sucesos $A_1, A_2, \dots, A_n$ tales que $P(A_1 \cap A_2 \cap \dots \cap A_n) \neq 0$, entón se cumpre*

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2 \mid A_1) \cdot P(A_3 \mid A_1 \cap A_2) \cdots P(A_n \mid A_1 \cap A_2 \cap \dots \cap A_{n-1})$$

2.5.2. Lei das probabilidades totais

O segundo teorema é a chamada lei das probabilidades totais. Esta descompón a probabilidade dun suceso na segunda etapa en función do que ocorreu na etapa anterior. Antes do enunciado deste teorema facemos unha definición.

Definición 2.1. Un **sistema completo de sucesos** é unha partición do espazo mostral, isto é, é unha colección de sucesos $A_1, A_2, \dots, A_n$ (subconxuntos do espazo mostral) que verifican $A_1 \cup A_2 \cup \dots \cup A_n = \Omega$ (son exhaustivos, cubren todo o espazo mostral) e ademais son incompatibles dous a dous (se se verifica un deles, non pode ocorrer simultaneamente ningún dos outros).

Teorema 2.2 (Lei das probabilidades totais). *Sexan $A_1, A_2, \dots, A_n$ un sistema completo de sucesos. Entón:*

$$P(B) = P(A_1) \cdot P(B \mid A_1) + P(A_2) \cdot P(B \mid A_2) + \cdots + P(A_n) \cdot P(B \mid A_n)$$

2.5.3. Teorema de Bayes

Por último, tratamos o teorema de Bayes. Consideremos un experimento que se realiza en dúas etapas: na primeira, temos un sistema completo de sucesos $A_1, A_2, \dots, A_n$ con probabilidades $P(A_i)$ que denominamos *probabilidades a priori*. Nunha segunda etapa, ocorreu o suceso B e cóñécense as probabilidades condicionadas $P(B | A_i)$ de obter na segunda etapa o suceso B cando na primeira etapa se obtivo o suceso A_i , para $i = 1, \dots, n$.

Nestas condicións, o teorema de Bayes permite calcular as probabilidades $P(A_i | B)$, que son probabilidades condicionadas en sentido inverso. Reciben o nome de *probabilidades a posteriori*, pois calcúlanse despois de observarse o suceso B .

Teorema 2.3 (Teorema de Bayes). *Nas condicións anteriores,*

$$P(A_i | B) = \frac{P(A_i) \cdot P(B | A_i)}{P(B)}$$

Ademais, aplicando no denominador a lei das probabilidades totais:

$$P(A_i | B) = \frac{P(A_i) \cdot P(B | A_i)}{P(A_1) \cdot P(B | A_1) + P(A_2) \cdot P(B | A_2) + \dots + P(A_n) \cdot P(B | A_n)}$$

3 Variables aleatorias

No capítulo de estatística descritiva estudamos as variables, entendéndoas como medicións que se realizan sobre os individuos dunha mostra. Así, a estatística descritiva permitíanos analizar os distintos valores que tomaban as variables sobre unha mostra xa observada. Tratábase, pois, dun estudo posterior á realización do experimento aleatorio.

Neste capítulo trataremos as variables situándonos antes da realización do experimento aleatorio. Polo tanto, faremos uso dos conceptos do capítulo anterior (Probabilidade), mentres que algúns desenvolvementos serán análogos aos do capítulo de estatística descritiva.

3.1. Variable aleatoria

De maneira informal, unha **variable aleatoria** é un valor numérico que corresponde ao resultado dun experimento aleatorio. Por exemplo, unha variable X como resultado de lanzar unha moeda ao aire pode tomar o valor 1 se o resultado é cara e 0 se é cruz. Deste xeito, escribiremos, por exemplo, $P(X = 1) = 05$. Outro exemplo de variable aleatoria, Y , pode ser o resultado de medir en $^{\circ}\text{C}$ a temperatura corporal de homes adultos sans. Cando se teñen tomado moitísimas observacións (infinitas), pódese chegar á conclusión, por exemplo, de que a probabilidade de que a temperatura corporal sexa inferior a 368°C é igual a 08, o que escribimos como $P(Y < 368) = 08$.

Definición 3.1. Variable aleatoria. Chamamos *variable aleatoria* a unha aplicación do espazo mostral asociado a un experimento aleatorio en $\mathbb{R}$, que a cada resultado dese experimento lle asigna un número real, obtido pola medición dunha certa característica.

$$\begin{array}{rcl} X: \Omega & \longrightarrow & \mathbb{R} \\ \omega & \longrightarrow & X(\omega) \end{array}$$

Denotamos a variable aleatoria cunha letra maiúscula. O conxunto imaxe desa aplicación é o conxunto de valores que pode tomar a variable aleatoria, que serán denotados por letras minúsculas.

As variables aleatorias son equivalentes ás variables que analizabamos no tema de Estatística Descritiva. A diferenza é que no tema de Estatística Descritiva traballabamos cunha mostra de datos, mentres que agora imos considerar que dispoñemos de toda a poboación (o que case sempre é imposible na práctica). Agora supoñeremos que podemos calcular as probabilidades de todos os sucesos resultantes dun experimento aleatorio.

3.1.1. Función de distribución dunha variable aleatoria

A función de distribución F dunha variable aleatoria X é unha función definida na recta real que toma valores no intervalo $[0, 1]$.

$$F(x) = P(X \leq x) = P(\{\omega \in \Omega : X(\omega) \leq x\}) = P(X^{-1}((-\infty, x]))$$

Para cada valor $x \in \mathbb{R}$, a función F devolve a probabilidade de que a variable tome un valor menor ou igual que x .

Propiedades da función de distribución:

1. $0 \leq F(x) \leq 1$
2. F é non decrecente
3. $\lim_{x \rightarrow +\infty} F(x) = 1$
4. $\lim_{x \rightarrow -\infty} F(x) = 0$
5. F é continua pola dereita

Ao igual que no tema de Estatística Descritiva, as variables aleatorias poden clasificarse en **discretas** e **continuas**, en función do conxunto de valores que poden tomar.

3.1.2. Variables aleatorias discretas

Unha variable aleatoria é **discreta** cando toma unha cantidade numerable (que se pode contar) de valores. Por exemplo, o número de caras ao lanzar dúas veces unha moeda ou o número de correos electrónicos clasificados como SPAM por un filtro.

Función de masa

Se X é unha variable discreta, a súa distribución vén dada polos valores que pode tomar e polas probabilidades de que aparezan.

A función $p(x) = P(X = x)$ denomínase **función de probabilidade** ou **función de masa**, sendo x donde calquera valor que poida tomar a variable. Observa que $p(x) \geq 0$ para todo x e $\sum_x p(x) = 1$.

No caso das variables discretas cúmprese que:

$$F(x) = \sum_{y \leq x} P(X = y)$$

É dicir, a función de distribución obtense **acumulando os valores** que vai tomando a función de masa de probabilidade. As variables aleatorias discretas caracterízanse por ter funcións de

distribución acumulada escalonadas, que se van incrementando mediante saltos. As posicións destes saltos corresponden aos valores que pode tomar a variable aleatoria. Pola súa banda, a magnitude de cada salto é igual á probabilidade de observar o valor correspondente ao punto de salto. Entre salto e salto, a función de distribución permanece constante.

3.1.3. Variables aleatorias continuas

Unha variable aleatoria é **continua** se pode tomar todos os valores dentro dun ou varios intervalos da recta real, é dicir, unha cantidade infinita non numerable de valores. Por exemplo, se realizamos un experimento aleatorio no que obtemos un número ao azar entre 0 e 1 (no intervalo $[0,1]$), todos os valores posibles teñen probabilidade 0, mais a probabilidade total segue sendo 1. Así, a probabilidade de obter un número menor ou igual que 05 é $F(05) = 05$.

Función de densidade

A **función de densidade dunha variable continua** mide como medra a función de distribución en cada punto, aínda que non representa a probabilidade exacta nun punto. Denótase por f , e calcúlase como:

$$f(x) = F'(x) = \frac{dF(x)}{dx} = \lim_{h \rightarrow 0} \frac{P(x-h \leq X \leq x+h)}{2h}$$

A función de distribución obtense acumulando os valores da función de densidade:

$$F(x_0) = \int_{-\infty}^{x_0} f(x) dx$$

A densidade non indica probabilidade directamente; a área baixo a curva entre dous valores é a que representa a probabilidade.

Propiedades da función de densidade:

1. $f(x) \geq 0$, para todo $x \in \mathbb{R}$.
2. $\int_{-\infty}^{+\infty} f(x) dx = F(+\infty) = 1$.
3. $P(a \leq X \leq b) = \int_a^b f(x) dx = F(b) - F(a)$.
4. A probabilidade de calquera valor concreto é 0: $P(X = x_0) = \int_{x_0}^{x_0} f(x) dx = 0$.

A función de masa de probabilidade e a función de densidade son conceptos análogos; o uso dunha ou doutra depende da natureza da variable aleatoria que se estea estudando.

Aínda que non se estudarán neste texto, tamén existen variables aleatorias que toman certos valores puntuais cunha probabilidade positiva e, ao mesmo tempo, distribúen o resto dos valores dentro dun ou varios intervalos segundo unha función de densidade. Nestes casos fálase de **variables aleatorias mixtas**.

3.1.4. Variables aleatorias multidimensionais

Aínda que neste curso traballaremos con variables aleatorias de forma individual, en moitas ocasións é necesario considerar conxuntamente dúas ou máis variables aleatorias definidas sobre o mesmo experimento aleatorio. Nestes casos fálase de **variables aleatorias multidimensionais** (ou **vectores aleatorios**), que permiten modelar situacións nas que varias características dun mesmo fenómeno se observan ao mesmo tempo e poden estar relacionadas entre si. Por exemplo, pode interesar estudar simultaneamente as variables (X, Y) , onde X é altura e Y o peso dun individuo. O estudo conxunto destas variables require xeneralizar os conceptos de función de distribución, función de masa ou función de densidade e introducir outros como o de independencia de variables aleatorias. Por simplicidade, consideraremos unicamente o caso bidimensional, onde temos un vector aleatorio formado por dúas variables (X, Y) .

- A función $F(x, y) = P(X \leq x \cap Y \leq y)$ recibe o nome de **función de distribución conxunta** do vector (X, Y) .
- Se X e Y son discretas, a función $p(x, y) = P(X = x \cap Y = y)$ recibe o nome de **función de masa conxunta** do vector (X, Y) .
- Se X e Y son continuas, a **función de densidade conxunta** do vector (X, Y) é a función $f(x, y) : \mathbb{R}^2 \rightarrow \mathbb{R}$ integrable e non negativa tal que

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) dt ds$$

Independencia de variables aleatorias

No tema anterior falamos sobre independencia de eventos ou sucesos. Recordamos que dous sucesos A e B son independentes se $P(A \cap B) = P(A)P(B)$. O seguinte paso sería falar sobre independencia de variables aleatorias, entendendo de forma similar que dúas variables aleatorias son independentes cando un evento que involucra a X non afecta ás probabilidades de Y ou viceversa. Dúas variables aleatorias X e Y son independentes se para todos x e y , os eventos $\{X \leq x\}$ e $\{Y \leq y\}$ son independentes, é dicir

$$P(X \leq x \cap Y \leq y) = P(X \leq x)P(Y \leq y)$$

3.2. Medidas características dunha variable aleatoria

Os conceptos que permiten resumir unha distribución de frecuencias utilizando valores numéricos poden utilizarse tamén para describir a distribución de probabilidade dunha variable aleatoria. As definicións son análogas ás introducidas no Tema 1. A **media ou esperanza** μ representa o valor esperado ao realizar o experimento coa variable aleatoria. Ademais, a media pode verse tamén como o valor central da distribución de probabilidade. A interpretación da **varianza** σ^2 é a mesma que para un conxunto de datos: é un valor non negativo que expresa a dispersión da distribución arredor da media. Pódese calcular a **desviación típica** poboacional σ como a raíz cadrada da varianza. Valores pequenos de σ indican concentración da distribución arredor da esperanza, e valores grandes corresponden a distribucións máis dispersas. Aínda que non se definen a continuación, pódense calcular outros momentos, como **asimetría** ou **curtose**, así como **cuantís** da distribución, que serían valores por debaixo dos cales se acumula unha determinada probabilidade.

3.2.1. Media ou esperanza

Defínese a **media poboacional** ou **esperanza** dunha variable aleatoria como a media dos seus posibles valores ponderados polas súas probabilidades.

- **Variable aleatoria discreta:** se X é discreta e toma valores x con probabilidades $P(X = x)$, entón

$$\mu = \mathbb{E}(X) = \sum_x x P(X = x)$$

- **Variable aleatoria continua:** se X é unha continua, con función de densidade $f(x)$,

$$\mu = \mathbb{E}(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

Propiedades

- $\mathbb{E}(aX + b) = a \mathbb{E}(X) + b$
- $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$
- Se X e Y son independentes, $\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y)$.

3.2.2. Varianza

Defínese a **varianza poboacional** dunha variable aleatoria discreta como a media das desviacións á media ao cadrado,

- **Variable aleatoria discreta:** se X é discreta e toma valores x con probabilidades $P(X = x)$, entón

$$\sigma^2 = \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}(X))^2] = \sum_x (x - \mu)^2 P(X = x)$$

- **Variable aleatoria continua:** se X é unha continua, con función de densidade $f(x)$,

$$\sigma^2 = \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}(X))^2] = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

Propiedades

- Pódese calcular de forma equivalente como $\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$.
- $\text{Var}(aX + b) = a^2 \text{Var}(X)$
- Se X e Y son independentes, $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

3.3. Principais modelos de variables aleatorias discretas

Estudaremos agora distribucións de variables aleatorias que adquiriron unha especial relevancia por ser axeitadas para modelar unha gran cantidade de situacións. Presentaremos modelos de variables discretas e caracterizaremos estas distribucións mediante a distribución de probabilidade. Calcularemos tamén os momentos (media e varianza) e destacaremos as propiedades de maior utilidade.

3.3.1. Distribución de Bernoulli

En moitas ocasións atopámonos ante experimentos aleatorios con só dous posibles resultados: Éxito e fracaso (cara ou cruz no lanzamento dunha moeda, gañar ou perder un partido, aprobar ou suspender un exame, unha proba diagnóstica que dá positivo ou negativo...). Poden modelarse estas situacións mediante a variable aleatoria

$$X = \begin{cases} 1 & \text{se Éxito} \\ 0 & \text{se Fracaso} \end{cases}$$

O único que hai que coñecer é a probabilidade de éxito, p , xa que os valores de X son sempre os mesmos e a probabilidade de fracaso é $q = 1 - p$.

Se denotamos por p a probabilidade de éxito, entón diremos que a variable X ten **distribución de Bernoulli de parámetro p** , e o denotamos $X \sim \text{Bernoulli}(p)$.

Función de probabilidade:

X	0	1
$P(X = x_i)$	$1 - p$	p

Polo tanto, a probabilidade de éxito p determina plenamente a distribución de Bernoulli.

Características:

- Esperanza: $\mathbb{E}(X) = p$
- Varianza: $\text{Var}(X) = p(1 - p)$

3.3.2. Distribución binomial

Sexa X o **número de éxitos** e n **experimentos independentes de Bernoulli de parámetro p** . Así definida, X ten **distribución binomial de parámetros n e p** , e o denotamos $X \sim \text{Binom}(n, p)$.

Función de probabilidade:

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, \quad x = 0, 1, \dots, n$$

Características:

- Esperanza: $\mathbb{E}(X) = np$
- Varianza: $\text{Var}(X) = np(1 - p)$

Esta distribución emprégase frecuentemente en procesos de control de calidade e en mostraxe con reposición.

Observa que $\text{Bernoulli}(p) = \text{Binom}(1, p)$.

Se $X \sim \text{Binom}(n, p)$ e $Y \sim \text{Binom}(m, p)$ son independentes, entón $X + Y \sim \text{Binom}(n + m, p)$.

3.3.3. Distribución xeométrica

Consideramos novamente o experimento que consiste en repetir un experimento de Bernoulli ata obter o primeiro éxito, e definimos a variable aleatoria X como o **número de fracasos antes de obter o primeiro éxito**. A probabilidade de éxito en cada intento está dada polo parámetro p . Diremos que a variable X ten **distribución xeométrica de parámetro p** , e o denotamos $X \sim \text{Xe}(p)$.

Función de probabilidade:

$$P(X = x) = (1 - p)^x p, \quad x = 0, 1, 2, \dots$$

Características:

- Esperanza: $\mathbb{E}(X) = \frac{1-p}{p}$
- Varianza: $\text{Var}(X) = \frac{1-p}{p^2}$

3.3.4. Distribución binomial negativa

Trátase dunha xeneralización do caso anterior. Estudamos a variable aleatoria X que representa o **número de fracasos antes de acadar o k -ésimo éxito**. Diremos que a variable X ten **distribución binomial negativa de parámetros k e p** , e o denotamos $X \sim \text{BN}(k, p)$ (a distribución xeométrica é un caso particular con $k = 1$).

Función de probabilidade:

$$P(X = x) = \binom{k+x-1}{x} p^k (1-p)^x, \quad x = 0, 1, 2, \dots$$

Características:

- Esperanza: $\mathbb{E}(X) = \frac{k(1-p)}{p}$
- Varianza: $\text{Var}(X) = \frac{k(1-p)}{p^2}$

Esta distribución emprégase, por exemplo, en estudos de fiabilidade de sistemas.

3.3.5. Distribución de Poisson

Un proceso de Poisson xeneraliza en certa medida o proceso de Bernoulli. Consiste en observar o **número de veces que se presenta un suceso (número de éxitos) nun determinado intervalo (xeralmente de tempo, aínda que tamén pode ser de espazo, volume ou outra magnitude continua)**. Nestes procesos supónse que hai estabilidade, no sentido de que os sucesos ocorren de maneira aleatoria pero cunha taxa media constante. Baixo estas hipóteses, o número de éxitos por intervalo segue unha **distribución de Poisson de parámetro λ** , que se denota por $X \sim \text{Pois}(\lambda)$, onde $\lambda > 0$ representa o número medio de sucesos no intervalo.

Función de probabilidade:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

Características:

- Esperanza: $\mathbb{E}(X) = \lambda$
- Varianza: $\text{Var}(X) = \lambda$

Dadas dúas variables $X \sim \text{Pois}(\lambda_1)$ e $Y \sim \text{Pois}(\lambda_2)$ independentes, a variable $X + Y$ distribúese segundo unha $\text{Pois}(\lambda_1 + \lambda_2)$.

A distribución de Poisson obtense como límite da binomial cando $n \rightarrow \infty$ e $p \rightarrow 0$. É dicir, se repetimos moitas veces un proceso con probabilidade moi pequena de éxito, pódese utilizar a distribución de Poisson para obter unha boa aproximación do resultado (notar que a distribución de Poisson é, en xeral, máis fácil de calcular que a binomial debido ao problema computacional dos números combinatorios).

3.3.6. Distribución hiperxeométrica

Consideremos unha poboación finita de N elementos, dos cales k pertencen á clase D e $N - k$ ao resto. Tomamos unha mostra **sen reposición** e estudamos a variable aleatoria X que representa o **número de elementos da clase D na mostra de tamaño n** . Así definida, X segue unha **distribución hiperxeométrica de parámetros N , n e k** e denótase $X \sim H(N, n, k)$. Sexa $p = \frac{k}{N}$ a probabilidade de obter un elemento da clase D na primeira extracción.

Función de probabilidade:

$$P(X = x) = \frac{\binom{k}{x} \binom{N-k}{n-x}}{\binom{N}{n}}, \quad \max\{0, n - (N - k)\} \leq x \leq \min\{k, n\}$$

Características:

- Esperanza: $\mathbb{E}(X) = np$
- Varianza: $\text{Var}(X) = \frac{np(1-p)(N-n)}{N-1}$

A distribución hiperxeométrica utilízase no mostreo dunha poboación finita sen reposición, en contraste coa binomial que se emprega cando hai reposición. No caso de que o tamaño da poboación sexa moi grande, a hiperxeométrica pódese aproximar pola normal (a probabilidade de éxito apenas varía entre cada repetición do experimento).

3.3.7. Distribución uniforme discreta

Unha variable aleatoria X que toma os valores $\{x_1, \dots, x_n\}$ dise **uniforme discreta** se todos eles son equiprobables.

Función de probabilidade:

$$P(X = x) = \frac{1}{n}, \quad x = x_1, \dots, x_n$$

Características:

- Esperanza: $\mathbb{E}(X) = \frac{1}{n} \sum_{i=1}^n x_i$
- Varianza: $\text{Var}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \mathbb{E}(X))^2$

3.4. Principais modelos de variables aleatorias continuas

3.4.1. Distribución uniforme

Como indica o seu propio nome, unha variable aleatoria continua segue unha distribución uniforme continua cando todos os valores do intervalo no que está definida teñen a mesma probabilidade de ocorrer.

Dicimos que unha variable aleatoria X segue unha distribución **uniforme no intervalo** $[a, b]$, e escribimos $X \sim \text{Unif}(a, b)$ se a súa función de densidade f é constante nese intervalo e vén dada por:

Función de densidade:

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{se } x \in (a, b), \\ 0, & \text{en caso contrario} \end{cases}$$

Función de distribución:

$$F(x) = \begin{cases} 0, & \text{se } x < a, \\ \frac{x-a}{b-a}, & \text{se } a \leq x \leq b, \\ 1, & \text{se } x > b \end{cases}$$

Características:

- Esperanza: $\mathbb{E}(X) = \frac{a+b}{2}$
- Varianza: $\text{Var}(X) = \frac{(b-a)^2}{12}$. \$\$

3.4.2. Distribución normal

A distribución normal é a máis utilizada de todas as distribucións de probabilidade. Son moitas as magnitudes que poden modelarse habitualmente mediante distribucións normais. Por exemplo, medidas biométricas como altura ou peso adoitan ser case normais. Tamén algúns indicadores económicos ou os erros de medida en experimentos científicos. Ademais, a importancia da distribución normal deriva do Teorema Central do Límite que veremos mais adiante, e que establece que as variables aleatorias que resultan da suma dun gran número de factores pequenos e independentes teñen, aproximadamente, unha distribución normal. Unha variable X **normal de media μ e varianza σ^2** denótase $X \sim N(\mu, \sigma)$.

Función de densidade:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

A pesar da súa expresión complicada, pode obterse como límite da distribución binomial cando n tende a infinito. Destaca que é unha función simétrica, cun máximo en $x = \mu$ e puntos de inflexión en $x = \mu - \sigma$ e $x = \mu + \sigma$.

Características:

- Esperanza: $\mathbb{E}(X) = \mu$
- Varianza: $\text{Var}(X) = \sigma^2$

Para traballar con variables normais, moitas veces convén reducir ou estandarizar a variable. Isto significa transformar calquera variable normal $X \sim N(\mu, \sigma)$ nunha variable normal estandar (de media 0 e varianza 1). Cúmprese:

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

É dicir, se transformamos unha variable aleatoria normal X de media μ e varianza σ^2 restando a media e dividindo pola desviación típica, obtemos unha variable aleatoria Z que segue sendo normal, pero de media 0 e varianza 1. Isto é útil porque bastaría coñecer a distribución normal estándar para calcular probabilidades de calquera normal.

Cando definimos a curtose, comentamos que normalmente se fala de “apuntamiento” respecto dunha variable normal, sen dicir nada da media ou varianza da mesma. Isto débese a que todas as distribucións normais teñen a mesma curtose.

Se $X \sim N(\mu_1, \sigma_1)$ e $Y \sim N(\mu_2, \sigma_2)$ son independentes, entón a variable $X + Y$ seguirá unha distribución do tipo $N(\mu_1 + \mu_2, \sqrt{\sigma_1^2 + \sigma_2^2})$. Deste modo, concluímos que a combinación lineal de variables aleatorias normais e independentes tamén é unha variable aleatoria normal.

3.4.3. Distribución exponencial

Un proceso de Poisson utilizábase para medir o número de sucesos dun determinado tipo que tiñan lugar nun determinado intervalo. Consideremos agora a variable aleatoria X que estuda o **tempo entre dous sucesos consecutivos**. Esta seguirá unha distribución **exponencial de parámetro λ** e denótase $X \in \text{Exp}(\lambda)$. Podemos dicir entón que unha distribución de Poisson mide o número de sucesos por unidade de tempo e unha exponencial o tempo que tarda en producirse un suceso.

Función de densidade:

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x > 0, \\ 0 & \text{noutro caso} \end{cases}$$

Función de distribución:

$$F(x) = 1 - e^{-\lambda x}$$

Características:

- Esperanza: $\mathbb{E}(X) = \frac{1}{\lambda}$
- Varianza: $\text{Var}(X) = \frac{1}{\lambda^2}$

Cómpre notar que este valor para a media encaixa coa motivación que demos para a distribución exponencial a través da Poisson: se nun proceso de Poisson de parámetro λ se producen, de media, λ sucesos por unidade de tempo, cabe esperar que, de media, a separación entre sucesos sexa $\frac{1}{\lambda}$.

A distribución exponencial é a xeneralización ao caso continuo da distribución xeométrica e, ao igual que esta, ten unha importante propiedade que é a ausencia de memoria. Vexámola cun exemplo: supoñamos que estamos a medir a probabilidade de que un proceso en cadea teña algún fallo debido ao azar (non ao desgaste). Se sabemos que na primeira hora non se produciu ningún erro e queremos saber a probabilidade de que na segunda hora tampouco se produza ningún (isto é, $P(X > 2 \mid X > 1)$), calcúlase directamente como a probabilidade de que durante unha hora non haxa ningún fallo (non importa que xa leve unha hora funcionando sen erro, non ten memoria). Escribindo con máis rigor esta propiedade:

$$P(X > t_0 + t_1 \mid X > t_0) = P(X > t_1)$$

É un bo modelo para describir a aparición de fallos ao azar, pero non para estudar sistemas que se deterioran co tempo.

3.4.4. Distribución gamma

A distribución gamma é unha xeneralización da distribución exponencial. En primeiro lugar, chamaremos función gamma a:

$$\Gamma(p) = \int_0^{\infty} x^{p-1} e^{-x} dx,$$

e ten as seguintes propiedades:

1. $\Gamma(p) = (p-1)!$ se p é un número natural distinto de 0.
2. $\Gamma(p) = (p-1)\Gamma(p-1)$
3. $\Gamma(1/2) = \sqrt{\pi}$

Unha variable aleatoria X que mide o **tempo de espera ata o suceso número k nun proceso de Poisson** segue unha distribución **gamma de parámetros λ e k** . Denótase por $X \sim \text{Gamma}(\lambda, k)$, onde o primeiro parámetro representa o número medio de sucesos por unidade de tempo e k é o número de sucesos que queremos que ocorran. Deste xeito, unha exponencial non será máis que unha $\text{Gamma}(\lambda, 1)$.

Función de densidade:

$$f(x) = \begin{cases} \frac{\lambda^k}{\Gamma(k)} e^{-\lambda x} x^{k-1} & \text{se } x > 0, \\ 0 & \text{noutro caso} \end{cases}$$

Características:

- Esperanza: $\mathbb{E}(X) = \frac{k}{\lambda}$
- Varianza: $\text{Var}(X) = \frac{k}{\lambda^2}$

Unha propiedade importante da distribución gamma é que, se $X \sim \Gamma(\lambda, k_1)$ e $Y \sim \Gamma(\lambda, k_2)$ son idenpendentes, entón $X + Y \sim \Gamma(\lambda, k_1 + k_2)$

3.4.5. Distribución beta

Chamaremos función beta á aplicación:

$$\beta(p, q) = \int_0^1 x^{p-1} (1-x)^{q-1} dx = \frac{\Gamma(p) \cdot \Gamma(q)}{\Gamma(p+q)}$$

Diremos que unha variable aleatoria X segue unha distribución **beta de parámetros p e q** , e denotamos $X \sim \text{Beta}(p, q)$ con p e q positivos se a súa función de densidade vén dada por:

Función de densidade:

$$f(x) = \begin{cases} \frac{x^{p-1}(1-x)^{q-1}}{\beta(p,q)} & \text{se } 0 < x < 1, \\ 0 & \text{noutro caso} \end{cases}$$

Características:

- Esperanza: $\mathbb{E}(X) = \frac{p}{p+q}$
- Varianza: $\text{Var}(X) = \frac{pq}{(p+q)^2(p+q+1)}$

Utilízase principalmente cando se traballa con estatística bayesiana.

3.5. Teorema Central do Límite

O Teorema Central do Límite establece que, se temos unha sucesión de variables aleatorias independentes e idénticamente distribuídas (i.i.d.), cunha media finita μ e unha varianza finita σ^2 , entón a distribución da súa suma (ou, de maneira equivalente, da súa media) tende a unha distribución normal cando o número de variables é suficientemente grande.

Teorema 3.1 (Teorema Central do Límite). *Se $X_1, X_2, \dots, X_n$ son variables aleatorias i.i.d. con $\mathbb{E}(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2$, entón*

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \rightarrow N(0, 1)$$

cando $n \rightarrow \infty$.

De forma equivalente, a media muestral $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ ten aproximadamente unha distribución normal de media μ e varianza σ^2/n para valores grandes de n , independentemente da distribución orixinal das variables.

Este resultado xustifica as seguintes aproximacións da distribución binomial e Poisson a unha normal.

3.5.1. Aproximacións entre variables aleatorias

- Se n é grande ($n > 30$) e $np > 5$ e $n(1-p) > 5$, entón a binomial pódese aproximar por unha normal con media $\mu = np$ e varianza $\sigma^2 = np(1-p)$.
- Se n é grande ($n > 50$) e $np < 5$, entón a binomial pódese aproximar por unha Poisson con media $\lambda = np$.
- Se $\lambda \geq 5$, entón a Poisson pódese aproximar por unha normal con media $\mu = \lambda$ e varianza $\sigma^2 = \lambda$.

Corrección por continuidad. Para aproximar unha das variables discretas pola normal utilizamos a corrección:

$$P(X_d = x) \approx P(x - 0.5 \leq X_c \leq x + 0.5)$$

4 Introducción á inferencia estatística e á estimación de parámetros

Como xa comentamos noutras ocasións, o noso obxectivo principal é o estudo dunha poboación e das súas características. Chamaremos **parámetro** a unha característica numérica que nos interese coñecer da poboación. Por exemplo, poderían ser parámetros de interese a proporción real de acertos dun modelo de clasificación de imaxes que distingue entre gatos e cans ou o tempo medio de resposta dun sistema de recomendación, por exemplo, o número medio de milisegundos que tarda unha plataforma de comercio electrónico en xerar recomendacións personalizadas para un usuario. Xeralmente é difícil obter información de toda a poboación (todas as imaxes posibles que o modelo pode recibir ou todas as interaccións futuras dos usuarios) e por iso, na práctica, contaremos cunha mostra representativa da devandita poboación, é dicir, cun conxunto limitado de imaxes de proba nas que se avalía o modelo de clasificación ou cun rexistro de tempos de resposta, que nos permitan estimar esas cantidades descoñecidas.

No tema 1 estudamos conceptos básicos de estatística descritiva, que nos proporcionaban ferramentas para resumir, ordenar e extraer os aspectos máis relevantes da información da mostra. No tema 2 establecemos as bases para traballar con incertezas ou probabilidades. Agora, tras estudar os principais modelos de variables aleatorias no tema 3, poderemos comezar a facer inferencia sobre a poboación de interese baseándonos no que observamos nunha mostra. Non nos conformaremos con describir uns datos contidos nunha mostra, senón que pretendemos extraer conclusións para a poboación da que foron extraídos. A esta última tarefa chamámoslle **Inferencia Estatística**.

Segundo os obxectivos, poderemos clasificar as tarefas de inferencia en dúas grandes categorías: a primeira, na que o interese se centra en **estimar** ou aproximar o valor dun parámetro (por exemplo, a proporción de acertos do modelo de clasificación ou o tempo medio de resposta do sistema de recomendación) e a segunda, na que o interese se centra en **contrastar** posibles valores dun parámetro (por exemplo, determinar se o tempo medio de resposta do sistema de recomendación é superior a 5 milisegundos).

4.1. Conceptos básicos

Vexamos algunhas definicións básicas en Inferencia Estatística. Algunhas delas xa foron introducidas nos temas anteriores.

- **Poboación.** É o conxunto homoxéneo de individuos sobre os que se estudan unha ou varias características observables. Por exemplo, todos os usuarios dunha plataforma de comercio electrónico, sobre os que nos interesa coñecer o tempo medio de resposta do sistema de recomendación.

- **Mostra.** É un subconxunto extraído da poboación ao que podemos observar. Múltiples razóns impídenos observar toda a poboación. Por ese motivo, extraemos unha mostra e con ela obtemos información sobre o conxunto da poboación.
- **Tamaño da poboación ou da mostra.** É o número de individuos que as forman, en cada caso.

Debemos facer unha primeira distinción, ao falar de Inferencia, segundo a natureza do problema que se formule:

- **Inferencia paramétrica:** cando se coñece a forma da distribución de probabilidade e interesa determinar o parámetro ou parámetros dos que depende. Por exemplo, se o tempo de resposta do sistema de recomendación segue unha distribución Normal e interesa coñecer a media μ e a desviación típica σ . Dentro da inferencia paramétrica distinguimos:
 - **Estimación puntual.** Consiste en propoñer un valor, calculado a partir da mostra, que estea o máis próximo posible ao verdadeiro parámetro. Por exemplo, a media mostral pode ser un estimador razoable da media poboacional e a proporción mostral da proporción poboacional.
 - **Intervalos de confianza.** Dado que a estimación puntual leva asociado un certo erro, construímos un intervalo que, con alta probabilidade, conteña o parámetro. A amplitude do intervalo dános unha idea da marxe de erro da nosa estimación.
 - **Contrastes de hipóteses.** Trátase de responder a preguntas moi concretas sobre a poboación, reducindo o problema a unha decisión sobre a veracidade de determinadas hipóteses. Por exemplo, podemos preguntarnos se o tempo medio de resposta do sistema de recomendación é superior a 5 milisegundos.
- **Inferencia non paramétrica:** cando non se coñece a forma da distribución poboacional. Tamén se poden formular tarefas de estimación, intervalos de confianza e contrastes de hipóteses, aínda que as técnicas estatísticas empregadas son diferentes.

4.2. Plantexamento xeral do problema de inferencia paramétrica

Como xa comentamos no tema 3, unha variable aleatoria é unha función que asigna un valor numérico ao resultado dun experimento aleatorio. É dicir, representa numericamente unha característica observable cuxo valor pode variar segundo o caso considerado. Por exemplo, unha variable aleatoria pode ser o tempo de resposta dun sistema de recomendación. O seu valor cambia dun usuario a outro ou dunha interacción a outra. Outros exemplos serían o número de recomendacións aceptadas por un usuario ou o acerto ou erro dun modelo de clasificación de imaxes (variable binaria).

Xeralmente asúmese que a distribución da variable de interese X pertence a unha determinada familia de distribucións, como por exemplo a normal ou a binomial. Esta familia depende dun ou varios parámetros, como a media μ e a varianza σ^2 no caso da normal, e a probabilidade de éxito p no caso da binomial.

Normalmente é imposible ou moi custoso obter os valores da variable de interese para todos os individuos da poboación e así determinar o parámetro que define a distribución. Na práctica só contamos cunha mostra representativa e teremos que estimar os parámetros poboacionais a partir dos valores observados na mostra.

- Unha **mostra aleatoria simple (m.a.s)** de tamaño n está formada por n variables $X_1, X_2, \dots, X_n$ independentes e coa mesma distribución que X .
- Chamamos **realización mostral** aos valores concretos $x_1, x_2, \dots, x_n$ que toman as n variables aleatorias despois de obter a mostra.
- Un **estatístico** é unha función da mostra aleatoria $T(X_1, X_2, \dots, X_n)$ e, polo tanto, xorde como resultado de calquera operación realizada sobre a mostra. Tamén é unha variable aleatoria e, por iso, terá unha determinada distribución, denominada **distribución do estatístico no mostreo**.
- Para resolver o problema da **estimación puntual**, é dicir, para propoñer un valor do parámetro poboacional descoñecido θ , escollemos o valor que tomou un estatístico calculado sobre a nosa realización mostral. Ao estatístico escollido para este fin chamámoslle **estimador** do parámetro. Ao valor concreto obtido cunha realización mostral determinada chamámoslle **estimación**.

O problema consiste, polo tanto, en elixir un bo estimador, é dicir, unha función da mostra que teña boas propiedades. En xeral, para estimar un parámetro poboacional (como a media ou unha proporción), adoita empregarse o correspondente estatístico mostral. Así, a media mostral utilízase como estimador da media poboacional e a proporción mostral como estimador da proporción poboacional. Estes estimadores resultan naturais e intuitivos, e baixo condicións habituais presentan boas propiedades teóricas.

Notación

O longo do tema empregaremos a notación x_α para indicar o cuantil de orde $1 - \alpha$ dunha distribución. É dicir, x_α é o valor que verifica

$$P(X \leq x_\alpha) = 1 - \alpha,$$

ou, de forma equivalente, o valor que deixa unha probabilidade α á súa dereita.

4.3. Estimación puntual

Sexa $X_1, X_2, \dots, X_n$ unha m.a.s dunha poboación. Sexa θ un parámetro de interese desa poboación. Un **estimador puntual (estimador)** de θ é un estatístico $\hat{\theta} \equiv T(X_1, X_2, \dots, X_n)$ cuxa función é aproximar o valor de θ . Lembramos que un estatístico é unha variable aleatoria e, por iso, terá unha certa distribución.

i Propiedades dos estimadores

Sexa θ un parámetro de interese e $\hat{\theta} \equiv T(X_1, X_2, \dots, X_n)$ un estimador de θ . O **nesgo** de $\hat{\theta}$ é a diferenza entre a súa esperanza e o verdadeiro valor θ , é dicir,

$$\text{Nesgo}_\theta(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$$

Diremos que $\hat{\theta}$ é **sen nesgo** para θ se ten nesgo cero ou, equivalentemente, se

$$\mathbb{E}(\hat{\theta}) = \theta$$

Diremos que $\hat{\theta}$ é **asintoticamente sen nesgo** para θ se

$$\lim_{n \rightarrow \infty} \mathbb{E}(\hat{\theta}) = \theta$$

Defínese o **Erro Cuadrático Medio (ECM)** dun estimador $\hat{\theta}$ como

$$\text{ECM}(\hat{\theta}) = \mathbb{E}((\hat{\theta} - \theta)^2)$$

Pódese demostrar que

$$\text{ECM}(\hat{\theta}) = \mathbb{E}((\hat{\theta} - \theta)^2) = \text{Var}(\hat{\theta}) + \text{Nesgo}_\theta(\hat{\theta})^2$$

Diremos que $\hat{\theta}$ é **consistente en media cuadrática** se

$$\lim_{n \rightarrow \infty} \text{ECM}(\hat{\theta}) = 0$$

Que un estimador sexa sen nesgo é unha boa propiedade. Tamén nos interesará que a dispersión do estimador sexa pequena e que diminúa ao aumentar o tamaño da mostra. Canto máis preto estea a esperanza dun estimador do parámetro, e canto máis pequena sexa a súa varianza, menor será o seu ECM.

4.3.1. Estimación puntual da media e a varianza

Consideremos unha mostra aleatoria simple $X_1, \dots, X_n$ de tamaño n dunha poboación con media μ e desviación típica σ . O problema consiste en estimar os parámetros μ (media poboacional) e σ (desviación típica poboacional).

Estimación puntual da media

Como estimador natural para a media poboacional, μ , propoñemos a media muestral:

$$\bar{X} = \frac{X_1 + \dots + X_n}{n}$$

Observamos que $\mathbb{E}(\bar{X}) = \mu$, polo que $\bar{X}$ é sen nesgo para μ , e a súa varianza é:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

Polo tanto, a desviación típica da media muestral é $\sigma/\sqrt{n}$. Este valor denomínase **erro estándar** de $\bar{X}$. Canto maior sexa n , menor será o erro estándar e máis precisa será a estimación.

Distribución do estatístico: Se $X_1, \dots, X_n$ son variables aleatorias independentes e distribuídas segundo $N(\mu, \sigma)$, entón a media muestral é exactamente normal:

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

e podemos facer inferencias exactas mesmo con mostras pequenas.

Se $X_1, \dots, X_n$ non son necesariamente normais, polo Teorema Central do Límite, para n grande, a media muestral aproxímase a unha normal:

$$\bar{X} \xrightarrow[n \rightarrow \infty]{} N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Estimación puntual da varianza

Como estimador para a varianza poblacional σ^2 empregaremos:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

tamén chamada **cuasivarianza muestral**. Definida desta maneira, S^2 cumpre que $\mathbb{E}(S^2) = \sigma^2$, polo que é un estimador sen nesgo para σ^2 .

Distribución do estatístico: Se $X_1, \dots, X_n$ son variables aleatorias independentes e distribuídas segundo $N(\mu, \sigma)$, entón $(n-1)S^2/\sigma^2$ segue unha distribución chi cadrado con $n-1$ graos de liberdade (ver [Anexo](#)):

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Se a poboación non é normal, a distribución non ten unha forma simple. Polo tanto, a partir de agora faremos inferencias sobre a varianza só en poboacións normais, onde a distribución do estimador está ben definida.

4.3.2. Estimación puntual dunha proporción

Consideremos agora o problema de estimar a proporción de individuos dunha poboación que presentan unha certa característica, a partir dunha mostra aleatoria simple. Para iso, definimos a variable aleatoria

$$X = \begin{cases} 1, & \text{se o individuo presenta a característica de interese} \\ 0, & \text{se o individuo non presenta a característica de interese.} \end{cases}$$

Observa que así definida, X ten distribución Bernoulli(p), onde o parámetro p é precisamente a proporción (descoñecida) de individuos coa característica na poboación.

A mostra está formada por n variables $X_1, \dots, X_n$ independentes e coa mesma distribución que X . O estimador razoable para p é a proporción muestral:

$$\hat{p} = \frac{\text{número de individuos coa característica na mostra}}{n} = \frac{X_1 + \dots + X_n}{n}$$

Observamos que $\mathbb{E}(\hat{p}) = p$, polo que $\hat{p}$ é un estimador sen nesgo para p . A súa varianza é

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$$

Como consecuencia, o erro estándar de $\hat{p}$ é $\sqrt{p(1-p)/n}$. Canto maior sexa o tamaño da mostra n , menor será o erro estándar e máis precisa será a estimación de p

Distribución do estatístico: Polo Teorema Central do Límite, para n grande, $\hat{p}$ é aproximadamente normal con media p e varianza $p(1-p)/n$. É dicir,

$$\hat{p} \xrightarrow[n \rightarrow \infty]{} N\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$$

4.4. Intervalos de confianza

En moitos casos, unha estimación puntual non é suficiente, xa que non nos proporciona o erro que se comete na estimación. Para obter máis información, veremos a continuación como calcular un intervalo numérico que, cunha certa *seguridade*, conteña o valor do parámetro na poboación.

Un **intervalo de confianza** é un intervalo construído a partir da mostra e, por tanto, **aleatorio**, que contén ao parámetro cunha certa probabilidade, chamada **nivel de confianza**.

Definición 4.1. Un intervalo de confianza para un parámetro descoñecido θ con nivel de confianza $1 - \alpha$, $\alpha \in [0, 1]$ é un intervalo de extremos aleatorios $L_1 \equiv L_1(X_1, \dots, X_n)$ e $L_2 \equiv L_2(X_1, \dots, X_n)$ que, con probabilidade $1 - \alpha$ contén ao parámetro, é dicir,

$$P(L_1 \leq \theta \leq L_2) = 1 - \alpha$$

O nivel de confianza adoita expresarse en porcentaxe. Por exemplo, un intervalo de confianza do 95 % contén ao parámetro descoñecido cunha probabilidade de 0.95.

O método que usaremos para construír intervalos de confianza denomínase **método pivotal**.

4.4.1. Intervalo de confianza para a media dunha poboación normal

Consideremos unha mostra aleatoria simple $X_1, \dots, X_n$ de tamaño n procedente dunha poboación normal $N(\mu, \sigma)$. O obxectivo é construír un intervalo de confianza para o parámetro μ , é dicir, para a media da poboación.

Intervalo de confianza para a media con varianza coñecida

Se coñecemos a varianza poboacional σ^2 , podemos usar como pivote a distribución da media muestral:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Se $z_{\alpha/2}$ é o número tal que $P(Z \leq z_{\alpha/2}) = 1 - \alpha/2$ con $Z \sim N(0, 1)$, entón:

$$P\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

Equivalentemente:

$$P\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

O intervalo de confianza con nivel $1 - \alpha$ é:

$$\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$$

Ao radio do intervalo de confianza anterior chámasele **marxe de erro**. Observa que a marxe de erro depende da desviación típica da poboación, do tamaño da mostra e do nivel de confianza fixado:

- **Desviación típica da poboación.** Canto maior sexa a dispersión dos datos na poboación, máis difícil é estimar con precisión a media poboacional. Por iso, a medida que σ aumenta, tamén aumenta a marxe de erro dun intervalo de confianza.
- **Tamaño da mostra.** Para un nivel de confianza fixo, canto maior sexa o tamaño da mostra, menor será o marxe de erro.
- **Nivel de confianza.** Se aumentamos o nivel de confianza (por exemplo, de 90 % a 95 %), quere dicir que queremos estar máis seguros de non equivocarnos. Para conseguir esa seguridade, o intervalo debe ser máis amplo, polo que o marxe de erro aumenta.

Unha cuestión interesante é determinar o **tamaño da mostra necesario** para obter un intervalo de confianza cunha lonxitude determinada. Neste caso, a lonxitude do intervalo é:

$$L = 2 z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Despexando n da fórmula anterior, obtemos o tamaño da mostra necesario:

$$n = \left(\frac{2 z_{\alpha/2} \sigma}{L} \right)^2$$

Isto permite calcular directamente o número de observacións necesarias para que o intervalo de confianza teña a lonxitude desexada e un nivel de confianza determinado.

Intervalo de confianza para a media con varianza descoñecida

Na práctica, normalmente non se coñece σ^2 . Neste caso, usamos como pivote:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}},$$

onde S é a cuasidesviación típica muestral

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

Este pivote segue unha distribución t de Student con $n - 1$ graos de liberdade (ver [Anexo](#)):

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Se $t_{n-1, \alpha/2}$ é tal que $P(T \leq t_{n-1, \alpha/2}) = 1 - \alpha/2$ con $T \sim t_{n-1}$, entón:

$$P\left(-t_{n-1, \alpha/2} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{n-1, \alpha/2}\right) = 1 - \alpha$$

Equivalentemente:

$$P\left(\bar{X} - t_{n-1, \alpha/2} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}\right) = 1 - \alpha$$

O intervalo de confianza con nivel $1 - \alpha$ é:

$$\left(\bar{X} - t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, \alpha/2} \frac{S}{\sqrt{n}} \right)$$

4.4.2. Intervalo de confianza para a diferenza de medias de poboacións normais

O obxectivo deste apartado é construír intervalos de confianza non só para a media dunha característica dunha poboación, como fixemos anteriormente, senón tamén para **comparar dúas medias**, xa sexa de dúas poboacións diferentes ou de dúas medicións sobre os mesmos individuos dunha poboación. Segundo o tipo de datos dispoñibles, a comparación realízase con **mostras independentes** ou **mostras emparelladas**, nas que se obteñen dúas observacións relacionadas para cada individuo.

Mostras independentes, varianzas coñecidas

Supoñamos dúas poboacións nas que se estudan dúas características distribuídas normalmente con medias descoñecidas μ_1 e μ_2 , respectivamente. Estamos interesados en construír un intervalo de confianza para a diferenza de medias $\mu_1 - \mu_2$ a partir de dúas mostras:

- Unha mostra formada por n_1 variables independentes e coa mesma distribución $N(\mu_1, \sigma_1)$.
- Unha mostra formada por n_2 variables independentes e coa mesma distribución $N(\mu_2, \sigma_2)$.

As mostras considéranse **independentes**, é dicir, os individuos da poboación 1 son distintos dos individuos da poboación 2. Supoñemos ademais que as **varianzas σ_1^2 e σ_2^2 son coñecidas**.

O estatístico a utilizar é:

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

O intervalo de confianza de nivel $1 - \alpha$ para a diferenza de medias $\mu_1 - \mu_2$ será:

$$\left((\bar{X}_1 - \bar{X}_2) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X}_1 - \bar{X}_2) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right)$$

Mostras independentes, varianzas descoñecidas e iguais

En moitas aplicacións, os valores de σ_1^2 e σ_2^2 son descoñecidos, pero podemos supoñer que son iguais. Consideremos dúas poboacións con características distribuídas normalmente con medias descoñecidas μ_1 e μ_2 . Queremos construír un intervalo de confianza para $\mu_1 - \mu_2$ a partir de dúas mostras:

- Unha mostra formada por n_1 variables independentes e coa mesma distribución $N(\mu_1, \sigma_1)$.
- Unha mostra formada por n_2 variables independentes e coa mesma distribución $N(\mu_2, \sigma_2)$.

As mostras considéranse **independentes** e supoñemos que as **varianzas son descoñecidas pero iguais**. O estatístico é:

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_p^2}{n_1} + \frac{S_p^2}{n_2}}} \sim t_{n_1+n_2-2},$$

onde S_p^2 é o estimador combinado de varianza das dúas poboacións

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

O intervalo de confianza de nivel $1 - \alpha$ para $\mu_1 - \mu_2$ será:

$$\left((\bar{X}_1 - \bar{X}_2) - t_{n_1+n_2-2, \alpha/2} \sqrt{\frac{S_p^2}{n_1} + \frac{S_p^2}{n_2}}, (\bar{X}_1 - \bar{X}_2) + t_{n_1+n_2-2, \alpha/2} \sqrt{\frac{S_p^2}{n_1} + \frac{S_p^2}{n_2}} \right)$$

Mostras independentes, varianzas descoñecidas e distintas

Consideremos agora dúas poboacións con características distribuídas normalmente con medias descoñecidas μ_1 e μ_2 . Queremos construír un intervalo de confianza para $\mu_1 - \mu_2$ a partir de dúas mostras:

- Unha mostra formada por n_1 variables independentes e coa mesma distribución $N(\mu_1, \sigma_1)$.
- Unha mostra formada por n_2 variables independentes e coa mesma distribución $N(\mu_2, \sigma_2)$.

As mostras considéranse **independentes** e supoñemos que as **varianzas son descoñecidas e diferentes**. Agora non podemos ter unha estimación global da varianza como no caso anterior, polo que o estatístico pivote que debemos utilizar é:

$$W = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}},$$

que asintoticamente segue unha distribución $N(0, 1)$. Por tanto, para tamaños de mostra grandes podemos construír un intervalo de confianza aproximado de nivel $1 - \alpha$ para a diferenza de medias $\mu_1 - \mu_2$ da forma:

$$\left((\bar{X}_1 - \bar{X}_2) - z_{\alpha/2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}, (\bar{X}_1 - \bar{X}_2) + z_{\alpha/2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right)$$

Con todo, a converxencia do estatístico é lenta, polo que o resultado pode ser pouco preciso para tamaños de mostra pequenos. Para este caso, cando n_1 ou $n_2 < 30$, convén tomar precaucións ou empregar aproximacións alternativas (aproximación de Welch, que substitúe $z_{\alpha/2}$ polo valor $t_{\alpha/2}$ dunha distribución t de Student adecuada para o caso).

Mostras emparelladas

Consideremos agora unha poboación na que medimos dúas características relacionadas X_1 e X_2 sobre os mesmos individuos. Supoñemos que $X_1 \sim N(\mu_1, \sigma_1)$ e $X_2 \sim N(\mu_2, \sigma_2)$, pero tendo en conta que agora X_1 e X_2 **non son independentes**. Definimos a variable das diferenzas $D = X_1 - X_2$, que segue unha distribución normal con media

$$\mu_D = \mathbb{E}(X_1 - X_2) = \mu_1 - \mu_2$$

e varianza

$$\sigma_D^2 = \text{Var}(X_1 - X_2)$$

Queremos construír un intervalo de confianza para a diferenza de medias $\mu_1 - \mu_2$. Na práctica, dispoñemos de dúas **mostras emparelladas** de tamaño n observadas **nos mesmos individuos**:

- $X_{11}, \dots, X_{1n}$ coa mesma distribución $N(\mu_1, \sigma_1)$.
- $X_{21}, \dots, X_{2n}$ coa mesma distribución $N(\mu_2, \sigma_2)$.

Tendo en conta que os valores están emparellados, construímos a mostra das diferenzas:

$$D_i = X_{1i} - X_{2i}, \quad i = 1, \dots, n$$

e estimamos:

- $\mu_D = \mu_1 - \mu_2$ mediante a media das diferenzas $\bar{D}$.
- σ_D^2 mediante a varianza muestral das diferenzas S_D^2 .

Como estatístico pivote utilizamos:

$$\frac{\bar{D} - (\mu_1 - \mu_2)}{S_D/\sqrt{n}} \sim t_{n-1}$$

O intervalo de confianza de nivel $1 - \alpha$ para a diferenza de medias $\mu_1 - \mu_2$ é:

$$\left(\bar{D} - t_{n-1, \alpha/2} \frac{S_D}{\sqrt{n}}, \bar{D} + t_{n-1, \alpha/2} \frac{S_D}{\sqrt{n}} \right)$$

4.4.3. Intervalo de confianza para a varianza dunha poboación normal

Consideremos de novo unha mostra aleatoria simple $X_1, \dots, X_n$ de tamaño n procedente dunha poboación normal $N(\mu, \sigma)$. Agora o obxectivo é construír un intervalo de confianza para o parámetro σ^2 , é dicir, para a varianza da poboación. Nese caso, podemos considerar como estatístico pivote:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

Procedendo de forma análoga ao caso da media, temos:

$$P\left(\chi_{n-1, 1-\alpha/2}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{n-1, \alpha/2}^2\right) = 1 - \alpha,$$

onde $\chi_{n-1, 1-\alpha/2}^2$ e $\chi_{n-1, \alpha/2}^2$ denotan, respectivamente, os cuantís $\alpha/2$ e $1 - \alpha/2$ da distribución χ^2 con $n - 1$ graos de liberdade. Despexando σ^2 , obtense o intervalo de confianza de nivel $1 - \alpha$ para a varianza:

$$\left(\frac{(n-1)S^2}{\chi_{n-1, \alpha/2}^2}, \frac{(n-1)S^2}{\chi_{n-1, 1-\alpha/2}^2} \right)$$

4.4.4. Intervalo de confianza para o cociente de varianzas de poboacións normais

Supoñamos dúas poboacións nas que se estudan dúas características distribuídas normalmente con varianzas descoñecidas σ_1^2 e σ_2^2 , respectivamente. O obxectivo deste apartado é construír un intervalo de confianza para **comparar as dúas varianzas**. Estamos interesados en construír un intervalo de confianza para o cociente de varianzas σ_1^2/σ_2^2 a partir de dúas mostras:

- Unha mostra formada por n_1 variables independentes e coa mesma distribución $N(\mu_1, \sigma_1)$.
- Unha mostra formada por n_2 variables independentes e coa mesma distribución $N(\mu_2, \sigma_2)$.

Sabemos que

$$\frac{(n_1 - 1)S_1^2}{\sigma_1^2} \sim \chi_{n_1-1}^2, \quad \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \sim \chi_{n_2-1}^2,$$

e que estas variables son independentes. Polo tanto,

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1},$$

onde F_{n_1-1, n_2-1} é unha distribución F de Snedecor (ver [Anexo](#)). Procedendo como nos casos anteriores, obtense

$$P\left(F_{n_1-1, n_2-1, 1-\alpha/2} \leq \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \leq F_{n_1-1, n_2-1, \alpha/2}\right) = 1 - \alpha,$$

onde $F_{n_1-1, n_2-1, 1-\alpha/2}$ e $F_{n_1-1, n_2-1, \alpha/2}$ denotan, respectivamente, os cuantís $\alpha/2$ e $1 - \alpha/2$ da distribución F de Snedecor con $n_1 - 1$ e $n_2 - 1$ graos de liberdade. Despexando σ_1^2/σ_2^2 , o intervalo de confianza de nivel $1 - \alpha$ para o cociente de varianzas é

$$\left(\frac{S_1^2/S_2^2}{F_{n_1-1, n_2-1, \alpha/2}}, \frac{S_1^2/S_2^2}{F_{n_1-1, n_2-1, 1-\alpha/2}}\right) = \left(\frac{S_1^2}{S_2^2} F_{n_2-1, n_1-1, 1-\alpha/2}, \frac{S_1^2}{S_2^2} F_{n_2-1, n_1-1, \alpha/2}\right)$$

4.4.5. Intervalo de confianza para unha proporción

Consideremos unha mostra aleatoria simple de tamaño n dunha poboación na que queremos estimar a proporción p dunha característica de interese. A proporción muestral é:

$$\hat{p} = \frac{X_1 + \dots + X_n}{n},$$

onde $X_i = 1$ se o individuo presenta a característica e $X_i = 0$ en caso contrario. Para n grande, polo Teorema Central do Límite, podemos aproximar a distribución da proporción muestral por unha normal:

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \xrightarrow[n \rightarrow \infty]{d} N(0, 1)$$

Entón:

$$P\left(-z_{\alpha/2} \leq \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

Equivalentemente:

$$P\left(\hat{p} - z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \leq p \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}}\right) = 1 - \alpha$$

O intervalo de confianza aproximado para p con nivel $1 - \alpha$ é:

$$\left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right)$$

4.4.6. Intervalo de confianza para a diferenza de proporcións

Nalgúns casos estamos interesados en estimar a diferenza de proporcións $p_1 - p_2$ de dúas poboacións. Para iso dispoñemos de dúas mostras:

- Unha mostra formada por n_1 variables independentes procedentes da poboación 1.
- Unha mostra formada por n_2 variables independentes procedentes da poboación 2.

Supoñemos que as mostras son independentes, é dicir, os individuos nos que se realizan as medicións da poboación 1 son distintos dos individuos da poboación 2.

Para tamaños mostrais grandes, o estatístico

$$\frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}} \sim N(0, 1)$$

A partir deste resultado, o intervalo de confianza de nivel $1 - \alpha$ para a diferenza de proporcións $p_1 - p_2$ é

$$\left((\hat{p}_1 - \hat{p}_2) - z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}, (\hat{p}_1 - \hat{p}_2) + z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}\right)$$

Anexo: Distribucións asociadas coa normal

Ademais do modelo normal, existen outros modelos probabilísticos que desempeñan un papel fundamental na inferencia estatística. Entre eles destacan as distribucións χ^2 (chi cadrado) e t de Student, que aparecen de maneira natural ao estudar estimadores baseados en mostras dunha poboación normal.

4.4.7. Distribución chi cadrado

A distribución chi cadrado con $n \in \mathbb{N}$ graos de liberdade é a distribución da suma dos cadrados de n variables aleatorias independentes que seguen unha distribución normal estándar. É dicir, se $Z_1, \dots, Z_n$ son variables aleatorias independentes e distribuídas como $N(0, 1)$, entón a variable

$$X = Z_1^2 + Z_2^2 + \dots + Z_n^2$$

segue unha distribución chi cadrado con n graos de liberdade. Denótase por $X \sim \chi_n^2$.

Propiedades

1. A variable χ_n^2 só toma valores en $[0, +\infty)$.
2. A distribución é asimétrica, especialmente para poucos graos de liberdade.
3. A distribución chi cadrado con n graos de liberdade é un caso particular da distribución gamma. Concretamente, $\chi_n^2 \sim \text{Gamma}(\frac{1}{2}, \frac{n}{2})$.
4. A media e varianza da distribución chi cadrado con n graos de liberdade son:

$$\mathbb{E}(\chi_n^2) = n, \quad \text{Var}(\chi_n^2) = 2n$$

4.4.8. Distribución t de Student

A distribución t de Student é unha distribución de variable aleatoria continua que describe a relación entre unha normal estándar e unha chi cadrado. Se $Z \sim N(0, 1)$ é unha variable normal estándar e $Y \sim \chi_n^2$ é independente de Z , entón a variable aleatoria:

$$T = \frac{Z}{\sqrt{Y/n}}$$

segue unha distribución t de Student con n graos de liberdade. Denótase por $T \sim t_n$.

Propiedades

1. A variable t_n toma valores en toda a recta real: $(-\infty, +\infty)$.
2. A distribución é simétrica respecto de 0.
3. Para $n > 1$, a media existe e é $\mathbb{E}(t_n) = 0$.
4. Para $n > 2$, a varianza existe e é $\text{Var}(t_n) = \frac{n}{n-2}$.
5. Canto maior sexa n , máis se asemella á normal estándar $N(0, 1)$.

4.4.9. Distribución F de Snedecor

A distribución F de Snedecor é unha distribución de variable aleatoria continua que describe a relación entre dúas chi cadrado independentes. Sexan $X \sim \chi_n^2$ e $Y \sim \chi_m^2$ independentes. Entón, a variable aleatoria

$$F = \frac{X/n}{Y/m}$$

segue unha distribución F de Snedecor con n e m graos de liberdade. Denótase por $F \sim F_{n,m}$.

Propiedades

1. A variable F_{n_1, n_2} só toma valores en $[0, +\infty)$.
2. A distribución é asimétrica, con cola cara a dereita, especialmente cando n ou m son pequenos.

5 Contraste de hipóteses

Os procedementos de inferencia que levamos realizado ata agora resúmense en dous: a estimación puntual e os intervalos de confianza. Coa estimación puntual obtemos valores concretos que serven como estimacións dos parámetros poboacionais de interese; por exemplo, estimamos a media poboacional, μ , coa media mostral, $\bar{X}$. Cos intervalos de confianza obtemos rexións aleatorias que conteñen os parámetros de interese con certa probabilidade.

A outra grande tarefa da Inferencia Estatística consiste en responder a preguntas moi concretas sobre a poboación. Por exemplo, ¿podemos asumir que o tempo medio de resposta do sistema de recomendación dunha plataforma de comercio electrónico é 5 ms? ou ¿o tempo medio de resposta do sistema de recomendación dunha plataforma de comercio electrónico é o mesmo que o do sistema de recomendación doutra plataforma? ou ¿a probabilidade de acerto dun sistema de clasificación é 0.9? Como veremos, estas cuestións fórmulanse en termos de hipóteses que debemos aceptar ou rexeitar. E esta decisión tomarémola en base a unha realización mostral. Cando os datos mostrais discrepen moito da hipótese, rexeitaremos a hipótese.

5.1. Conceptos básicos

Comezamos cunha hipótese de traballo sobre un parámetro de interese θ e dispoñemos dunha mostra de observacións. O obxectivo é determinar se a hipótese formulada é compatible co que podemos inferir a partir dos datos da mostra; é dicir, decidir se a información empírica apoia ou contradí a hipótese inicial.

- Chamaremos **hipótese nula**, denotada por H_0 , á que asumimos certa antes de observar os datos. Goza de *presunción de inocencia*, de modo que só se rexeitará se hai evidencia suficiente en contra dela.
- Chamaremos **hipótese alternativa**, denotada por H_1 , á situación na que a hipótese nula non é certa, e é nela onde recae a carga da proba.

Na práctica, analizamos se os datos da mostra proporcionan evidencia estatística suficiente en contra de H_0 . Rexeitamos H_0 en favor de H_1 se os datos mostran probas significativas que apoian H_1 . Se non, consideramos que os datos son consistentes con H_0 .

De forma xeral, un contraste de hipóteses para un parámetro θ pódese expresar como:

$$\begin{cases} H_0 : \theta \in \Theta_0 \\ H_1 : \theta \in \Theta_1 \end{cases}$$

onde Θ_0 e Θ_1 son subconxuntos do espazo de parámetros.

- Unha **hipótese simple** é aquela en que Θ_0 contén un único valor de θ .
- Unha **hipótese composta** é aquela en que Θ_0 contén varios valores posibles de θ .

Por exemplo, se queremos comprobar se θ toma un valor específico θ_0 , o contraste sería:

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta \neq \theta_0 \end{cases}$$

Neste caso H_0 é simple, e rexeitaríase só se os datos mostrasen evidencia suficiente para suxerir que $\theta \neq \theta_0$.

Se, en cambio, queremos determinar se θ supera un certo limiar θ_0 , o contraste sería:

$$\begin{cases} H_0 : \theta \leq \theta_0 \\ H_1 : \theta > \theta_0 \end{cases}$$

Agora a hipótese nula H_0 é composta, xa que admite calquera valor de θ menor ou igual a θ_0 .

5.1.1. Erro de tipo I e erro de tipo II

Volvemos ao problema de decisión que supón o contraste de hipóteses. A seguinte táboa reflicte os posibles acertos ou erros nun contraste:

		Decisión: non se rexeita H_0	Decisión: rexeítase H_0
Realidade	H_0 verdadeira	Decisión correcta	Erro tipo I
	H_0 falsa	Erro tipo II	Decisión correcta

Observamos que se pode tomar unha decisión correcta ou errónea:

- Chamamos **erro de tipo I** ao que cometemos cando rexeitamos a hipótese nula sendo certa.
- O **erro de tipo II** é o que cometemos cando non rexeitamos (aceptamos) a hipótese nula sendo falsa.

5.1.2. Nivel de significación e potencia dun test

Dado que calquera decisión tomada ao facer un contraste está baseada en información parcial dunha poboación, debemos ter en conta a probabilidade de tomar unha decisión incorrecta.

- Probabilidade do erro de tipo I: denótase por α e denomínase **nivel de significación**.

$$\alpha = P(\text{rexeitar } H_0 \mid H_0 \text{ é certa})$$

- Probabilidade do erro de tipo II: denótase por β .

$$\beta = P(\text{non rexeitar } H_0 \mid H_0 \text{ é falsa})$$

- A probabilidade de detectar que unha hipótese é falsa denomínase **potencia**:

$$\text{Potencia} = P(\text{rexeitar } H_0 \mid H_0 \text{ é falsa}) = 1 - \beta$$

Así, o nivel de significación é a probabilidade de rexeitar H_0 cando é certa. A potencia é a probabilidade de rexeitar H_0 cando é falsa. Debemos adoptar un criterio que, en base á mostra, nos permita decidir se rexeitamos ou non a hipótese nula. Sería desexable facelo de maneira que as probabilidades de ambos tipos de erro fosen o máis pequenas posible. Porén, cun tamaño de mostra fixo, diminuír a probabilidade do erro de tipo I implica aumentar a probabilidade do erro de tipo II. É dicir, se reducimos o nivel de significación, tamén reducimos a potencia do test. Unha forma habitual de proceder é fixar o nivel de significación α (son comúns valores como 005, 001 e 01) e escoller o criterio que proporcione a maior potencia posible.

5.1.3. Rexión crítica dun test

Ao fixar un nivel de significación α , obtense implícitamente unha división en dúas rexións do conxunto de posibles valores do estatístico de contraste:

- A **rexión de rexeitamento** ou rexión crítica, que ten probabilidade α (baixo H_0).
- A **rexión de aceptación**, que ten probabilidade $1 - \alpha$ (baixo H_0).

Se o valor do estatístico cae na rexión de aceptación, non existen razóns suficientes para rexeitar a hipótese nula cun nivel de significación α , e o contraste considérase **estatisticamente non significativo**, é dicir, non existe evidencia a favor de H_1 .

Se o valor do estatístico cae na rexión de rexeitamento, os datos non son compatibles con H_0 e rexeitamos a hipótese. Entón dicimos que o contraste é **estatisticamente significativo**, é dicir, existe evidencia estatisticamente significativa a favor de H_1 .

5.1.4. O p-valor dun contraste

A medida que o nivel de significación α diminúe, é máis difícil rexeitar a hipótese nula (mantendo os mesmos datos). Dado un estatístico de contraste, existe un valor de α a partir do cal xa non podemos rexeitar H_0 . A este valor chámase o **p-valor** do contraste e denótase por p . Se o nivel de significación é menor que p , xa non se rexeita H_0 .

- Se $\alpha < p$, non podemos rexeitar H_0 a nivel α .
- Se $\alpha > p$, podemos rexeitar H_0 a nivel α .

5.1.5. Resumo das etapas na resolución dun contraste de hipóteses

Resumindo, as etapas na resolución dun contraste de hipóteses son:

1. Especificar as hipóteses nula H_0 e alternativa H_1 .
2. Escoller un estatístico de contraste apropiado, para medir a discrepancia entre a hipótese e a mostra.
3. Fixar o nivel de significación α en función de canto de importante se considere rexeitar H_0 cando realmente é certa.
4. Ao fixar un nivel de significación α , obtéñase implícitamente unha división en dúas rexións do conxunto de posibles valores do estatístico de contraste:
 - A **rexión de rexeitamento** ou rexión crítica, que ten probabilidade α (baixo H_0).
 - A **rexión de non rexeitamento**, que ten probabilidade $1 - \alpha$ (baixo H_0).
5. Se o valor do estatístico cae na rexión de rexeitamento, os datos non son compatibles con H_0 e rexeitamos a hipótese. Entón dicimos que o contraste é **estatisticamente significativo**, é dicir, existe evidencia estatisticamente significativa a favor de H_1 .
6. Se o valor do estatístico cae na rexión de aceptación, non existen razóns suficientes para rexeitar a hipótese nula cun nivel de significación α , e o contraste considérase **estatisticamente non significativo**, é dicir, non existe evidencia a favor de H_1 .
7. Alternativamente, en lugar de fixar un nivel de significación, podemos calcular o **p-valor** asociado ao estatístico observado. O p-valor indica o nivel de significación máis pequeno para o cal se rexeitaría H_0 . Se $p \leq \alpha$, rexeitamos H_0 ; se $p > \alpha$, non rexeitamos H_0 .

5.1.6. Relación cos intervalos de confianza

Os intervalos de confianza e os contrastes de hipóteses están intimamente relacionados. En xeral, un contraste bilateral pode expresarse como:

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta \neq \theta_0 \end{cases}$$

onde θ é o parámetro de interese (media, proporción, etc.).

Unha vez dispoñemos dunha mostra, o contraste consiste en determinar se o valor observado do estatístico é suficientemente “lonxe” do valor baixo H_0 . Neste contexto, podemos interpretar os resultados do contraste utilizando un intervalo de confianza para θ de nivel $1 - \alpha$:

- Se θ_0 **non pertence** ao intervalo de confianza, existe evidencia suficiente para rexeitar H_0 ao nivel de significación α .
- Se θ_0 **pertence** ao intervalo de confianza, non existe evidencia suficiente para rexeitar H_0 ao nivel α .

Esta relación é válida de forma xeral para calquera parámetro sobre o que poidamos construír un intervalo de confianza. En termos intuitivos, o intervalo de confianza indica todos os valores de θ que serían compatibles cos datos segundo o nivel de significación seleccionado; os valores fóra dese intervalo son os que o contraste consideraría “incompatibles” coas observacións.

Veremos agora como levar a cabo os contrastes de hipóteses na práctica. Estudaremos cales son os estatísticos de contraste axeitados dependendo do parámetro ao que faga referencia o test e veremos como construír a rexión crítica en cada caso.

5.2. Contrastes sobre a media dunha poboación normal

Queremos contrastar hipóteses relativas á media dunha poboación con distribución normal $N(\mu, \sigma)$. Para iso, tomamos $X_1, \dots, X_n$ unha mostra aleatoria simple dunha $N(\mu, \sigma)$.

5.2.1. Contrastes sobre a media con varianza coñecida

Supoñamos que a varianza σ^2 é coñecida. Deséxase contrastar unha hipótese relativa á media μ .

Contraste bilateral. Se queremos determinar se a media é significativamente distinta dun certo valor dado μ_0 , entón o contraste formulado sería un contraste bilateral

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu \neq \mu_0 \end{cases}$$

Se a hipótese nula $H_0 : \mu = \mu_0$ é certa, entón

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$$

O sentido común aconséllanos rexeitar a hipótese nula de que a media poboacional é μ_0 cando a media mostral sexa moi distinta de μ_0 . Para respectar ademais un nivel de significación α prefixado, rexeitamos a hipótese nula $H_0 : \mu = \mu_0$ fronte a $H_1 : \mu \neq \mu_0$ se

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \leq -z_{\alpha/2} \quad \text{ou} \quad \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq z_{\alpha/2}$$

Lembra que $z_{\alpha/2}$ denota o punto tal que $P(Z > z_{\alpha/2}) = \alpha/2$ sendo $Z \sim N(0, 1)$.

Contraste unilateral pola dereita. Supoñamos agora que queremos determinar se a media μ é significativamente maior que un valor dado μ_0 . Entón, o contraste formulado sería

$$\begin{cases} H_0 : \mu \leq \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$$

Dados os valores dunha mostra, parece claro que deberíamos rexeitar H_0 se $\bar{X}$ é considerablemente maior que μ_0 . , Fixado un nivel de significación α , rexeitamos a hipótese nula $H_0 : \mu \leq \mu_0$ fronte a $H_1 : \mu > \mu_0$ se

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq z_\alpha$$

Contraste unilateral pola esquerda. Supoñamos agora que queremos determinar se a media μ é significativamente menor que un valor dado μ_0 . Entón, o contraste formulado sería

$$\begin{cases} H_0 : \mu \geq \mu_0 \\ H_1 : \mu < \mu_0 \end{cases}$$

Dados os valores dunha mostra, parece claro que deberíamos rexeitar H_0 se $\bar{X}$ é considerablemente menor que μ_0 . Fixado un nivel de significación α , rexeitamos a hipótese nula $H_0 : \mu \geq \mu_0$ fronte a $H_1 : \mu < \mu_0$ se

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \leq -z_\alpha$$

5.2.2. Contrastes sobre a media con varianza descoñecida

Supoñamos agora que queremos contrastar hipóteses relativas á media μ pero descoñecemos a varianza σ^2 . Podemos repetir toda a argumentación anterior coa salvidade de que cando a varianza é descoñecida non podemos usar σ^2 e no seu lugar debemos empregar un estimador axeitado como a varianza mostral S^2 .

Contraste bilateral. Se queremos determinar se a media é significativamente distinta dun certo valor dado μ_0 , entón o contraste formulado sería un contraste bilateral

$$\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu \neq \mu_0 \end{cases}$$

Se a hipótese nula $H_0 : \mu = \mu_0$ é certa, entón

$$\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$$

O sentido común aconséllanos rexeitar a hipótese nula de que a media poboacional é μ_0 cando a media mostral sexa moi distinta de μ_0 . Para respectar ademais un nivel de significación α prefixado, rexeitamos a hipótese nula $H_0 : \mu = \mu_0$ fronte a $H_1 : \mu \neq \mu_0$ se

$$\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \leq -t_{n-1, \alpha/2} \quad \text{ou} \quad \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \geq t_{n-1, \alpha/2}$$

Lembra que $t_{n-1, \alpha/2}$ denota o punto tal que $P(T > t_{n-1, \alpha/2}) = \alpha/2$ sendo T unha variable t de Student con $n - 1$ graos de liberdade.

Contraste unilateral pola dereita. Supoñamos agora que queremos determinar se a media μ é significativamente maior que un valor dado μ_0 . Entón, o contraste formulado sería

$$\begin{cases} H_0 : \mu \leq \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$$

Dados os valores dunha mostra, parece claro que deberíamos rexeitar H_0 se $\bar{X}$ é considerablemente maior que μ_0 . Fixado un nivel de significación α , rexeitamos a hipótese nula $H_0 : \mu \leq \mu_0$ fronte a $H_1 : \mu > \mu_0$ se

$$\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \geq t_{n-1, \alpha}$$

Contraste unilateral pola esquerda. Supoñamos agora que queremos determinar se a media μ é significativamente menor que un valor dado μ_0 . Entón, o contraste formulado sería

$$\begin{cases} H_0 : \mu \geq \mu_0 \\ H_1 : \mu < \mu_0 \end{cases}$$

Dados os valores dunha mostra, parece claro que deberíamos rexeitar H_0 se $\bar{X}$ é considerablemente menor que μ_0 . Fixado un nivel de significación α , rexeitamos a hipótese nula $H_0 : \mu \geq \mu_0$ fronte a $H_1 : \mu < \mu_0$ se

$$\frac{\bar{X} - \mu_0}{S/\sqrt{n}} \leq -t_{n-1, \alpha}$$

5.3. Contrastes sobre as medias de dúas poboacións normais

5.3.1. Mostras independentes, varianzas coñecidas

Consideremos agora o seguinte modelo xeral. Temos dúas poboacións normais, coas súas respectivas medias e varianzas: $N(\mu_1, \sigma_1^2)$ e $N(\mu_2, \sigma_2^2)$ e queremos contrastar hipóteses que comparen as súas medias, μ_1 e μ_2 . Extraemos:

- Unha mostra formada por n_1 variables independentes e coa mesma distribución $N(\mu_1, \sigma_1^2)$.
- Unha mostra formada por n_2 variables independentes e coa mesma distribución $N(\mu_2, \sigma_2^2)$.

Supoñemos que as mostras son independentes, é dicir, os individuos onde se obtiveron as medicións da poboación 1 son distintos dos da poboación 2. Supoñemos ademais que as varianzas σ_1^2 e σ_2^2 son coñecidas.

Contraste bilateral. Se queremos saber se podemos asumir que a media é a mesma en ambas poboacións, o contraste sería

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{cases} \quad \text{ou equivalentemente} \quad \begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_1 : \mu_1 - \mu_2 \neq 0 \end{cases}$$

Se H_0 é certa, entón

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

Fixado un nivel de significación α , rexeitamos H_0 fronte a H_1 se

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq -z_{\alpha/2} \quad \text{ou} \quad \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \geq z_{\alpha/2}$$

Aquí $z_{\alpha/2}$ verifica $P(Z > z_{\alpha/2}) = \alpha/2$ con $Z \sim N(0, 1)$.

Contraste unilateral pola dereita. Se queremos comprobar se $\mu_1 > \mu_2$, o contraste é

$$\begin{cases} H_0 : \mu_1 \leq \mu_2 \\ H_1 : \mu_1 > \mu_2 \end{cases} \quad \text{ou equivalentemente} \quad \begin{cases} H_0 : \mu_1 - \mu_2 \leq 0 \\ H_1 : \mu_1 - \mu_2 > 0 \end{cases}$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \geq z_\alpha$$

Contraste unilateral pola esquerda. Se queremos comprobar se $\mu_1 < \mu_2$, o contraste é

$$\begin{cases} H_0 : \mu_1 \geq \mu_2 \\ H_1 : \mu_1 < \mu_2 \end{cases} \quad \text{ou equivalentemente} \quad \begin{cases} H_0 : \mu_1 - \mu_2 \geq 0 \\ H_1 : \mu_1 - \mu_2 < 0 \end{cases}$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq -z_\alpha$$

5.3.2. Mostras independentes, varianzas descoñecidas e iguais

Na práctica, σ_1^2 e σ_2^2 adoitan ser descoñecidas, pero ás veces pódese asumir que son iguais. Consideramos dúas mostras independentes como antes e supoñemos $\sigma_1^2 = \sigma_2^2$.

O estimador combinado da varianza é

$$S_P^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2},$$

onde S_1^2 e S_2^2 son as varianzas mostrais.

Contraste bilateral.

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{cases} \quad \text{ou} \quad \begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_1 : \mu_1 - \mu_2 \neq 0 \end{cases}$$

Se H_0 é certa,

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_P^2}{n_1} + \frac{S_P^2}{n_2}}} \sim t_{n_1+n_2-2}$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_P^2}{n_1} + \frac{S_P^2}{n_2}}} \leq -t_{n_1+n_2-2, \alpha/2} \quad \text{ou} \quad \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_P^2}{n_1} + \frac{S_P^2}{n_2}}} \geq t_{n_1+n_2-2, \alpha/2}$$

Aquí $t_{\alpha/2}$ cumpre $P(T > t_{n_1+n_2-2, \alpha/2}) = \alpha/2$ con T t de Student con $n_1 + n_2 - 2$ graos de liberdade.

Contraste unilateral pola dereita.

$$\begin{cases} H_0 : \mu_1 \leq \mu_2 \\ H_1 : \mu_1 > \mu_2 \end{cases}$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_P^2}{n_1} + \frac{S_P^2}{n_2}}} \geq t_{n_1+n_2-2, \alpha}$$

Contraste unilateral pola esquerda.

$$\begin{cases} H_0 : \mu_1 \geq \mu_2 \\ H_1 : \mu_1 < \mu_2 \end{cases}$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_P^2}{n_1} + \frac{S_P^2}{n_2}}} \leq -t_{n_1+n_2-2, \alpha}$$

5.3.3. Mostras emparelladas

En moitas ocasións compáranse dous tratamentos aplicados aos mesmos individuos. Neste caso considéranse mostras emparelladas. Definimos $D = X_1 - X_2$.

Contraste bilateral.

$$\left\{ \begin{array}{l} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{array} \right. \quad \text{ou} \quad \left\{ \begin{array}{l} H_0 : \mu_1 - \mu_2 = 0 \\ H_1 : \mu_1 - \mu_2 \neq 0 \end{array} \right.$$

Se H_0 é certa,

$$\frac{\bar{D}}{S_D/\sqrt{n}} \sim t_{n-1}$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{D}}{S_D/\sqrt{n}} \leq -t_{n-1, \alpha/2} \quad \text{ou} \quad \frac{\bar{D}}{S_D/\sqrt{n}} \geq t_{n-1, \alpha/2}$$

Contraste unilateral pola dereita.

$$\left\{ \begin{array}{l} H_0 : \mu_1 \leq \mu_2 \\ H_1 : \mu_1 > \mu_2 \end{array} \right.$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{D}}{S_D/\sqrt{n}} \geq t_{n-1, \alpha}$$

Contraste unilateral pola esquerda.

$$\left\{ \begin{array}{l} H_0 : \mu_1 \geq \mu_2 \\ H_1 : \mu_1 < \mu_2 \end{array} \right.$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\bar{D}}{S_D/\sqrt{n}} \leq -t_{n-1, \alpha}$$

5.4. Contrastes sobre unha varianza

Se queremos contrastar hipóteses sobre a varianza dunha poboación normal σ^2 , utilizaremos como estatístico de referencia a varianza mostrada S^2 .

Contraste bilateral. Se queremos comprobar se a varianza σ^2 é significativamente distinta dun valor dado σ_0^2 , o contraste sería

$$\begin{cases} H_0 : \sigma^2 = \sigma_0^2 \\ H_1 : \sigma^2 \neq \sigma_0^2 \end{cases}$$

O estatístico de contraste é

$$\frac{(n-1)S^2}{\sigma_0^2}$$

que segue unha distribución χ^2 con $n-1$ graos de liberdade baixo H_0 . Fixado un nivel de significación α , rexeitamos H_0 se

$$\frac{(n-1)S^2}{\sigma_0^2} \leq \chi_{n-1, 1-\alpha/2}^2 \quad \text{ou} \quad \frac{(n-1)S^2}{\sigma_0^2} \geq \chi_{n-1, \alpha/2}^2$$

onde $\chi_{n-1, 1-\alpha/2}^2$ e $\chi_{n-1, \alpha/2}^2$ denotan, respectivamente, os cuantís $\alpha/2$ e $1-\alpha/2$ da distribución χ^2 con $n-1$ graos de liberdade.

Contraste unilateral pola dereita.

$$\begin{cases} H_0 : \sigma^2 \leq \sigma_0^2 \\ H_1 : \sigma^2 > \sigma_0^2 \end{cases}$$

Fixado un nivel de significación α , rexeitamos H_0 se

$$\frac{(n-1)S^2}{\sigma_0^2} \geq \chi_{n-1, \alpha}^2$$

Contraste unilateral pola esquerda.

$$\begin{cases} H_0 : \sigma^2 \geq \sigma_0^2 \\ H_1 : \sigma^2 < \sigma_0^2 \end{cases}$$

Fixado un nivel de significación α , rexeitamos H_0 se

$$\frac{(n-1)S^2}{\sigma_0^2} \leq \chi_{n-1, 1-\alpha}^2$$

5.5. Contrastes sobre dúas varianzas

Queremos comparar as varianzas de dúas poboacións normais σ_1^2 e σ_2^2 a partir de dúas mostran independentes:

- Mostra 1: tamaño n_1 e varianza mostral S_1^2
- Mostra 2: tamaño n_2 e varianza mostral S_2^2

Contraste bilateral.

$$\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_1 : \sigma_1^2 \neq \sigma_2^2 \end{cases}$$

O estatístico de contraste é

$$F = \frac{S_1^2}{S_2^2}$$

que segue unha distribución F_{n_1-1, n_2-1} baixo H_0 . Fixado un nivel de significación α , rexeitamos H_0 se

$$F \leq F_{n_1-1, n_2-1, 1-\alpha/2} \quad \text{ou} \quad F \geq F_{n_1-1, n_2-1, \alpha/2}$$

onde $F_{n_1-1, n_2-1, 1-\alpha/2}$ e $F_{n_1-1, n_2-1, \alpha/2}$ denotan, respectivamente, os cuantís $\alpha/2$ e $1 - \alpha/2$ da distribución F de Snedecor con $n_1 - 1$ e $n_2 - 1$ graos de liberdade.

Contraste unilateral pola dereita.

$$\begin{cases} H_0 : \sigma_1^2 \leq \sigma_2^2 \\ H_1 : \sigma_1^2 > \sigma_2^2 \end{cases}$$

Fixado un nivel de significación α , rexeitamos H_0 se

$$F \geq F_{n_1-1, n_2-1, \alpha}$$

Contraste unilateral pola esquerda.

$$\begin{cases} H_0 : \sigma_1^2 \geq \sigma_2^2 \\ H_1 : \sigma_1^2 < \sigma_2^2 \end{cases}$$

Fixado un nivel de significación α , rexeitamos H_0 se

$$F \leq F_{n_1-1, n_2-1, 1-\alpha}$$

5.6. Contrastes sobre unha proporción

Queremos contrastar hipóteses como as propostas na sección anterior pero sobre unha proporción p . Para iso utilizaremos como estatístico de referencia a proporción mostral $\hat{p}$.

Contraste bilateral. Se queremos determinar se a proporción p é significativamente distinta dun certo valor dado p_0 , o contraste sería

$$\begin{cases} H_0 : p = p_0 \\ H_1 : p \neq p_0 \end{cases}$$

O sentido común aconséllanos rexeitar a hipótese nula de que a proporción é p_0 cando a proporción mostral $\hat{p}$ sexa moi distinta de p_0 . Para respectar ademais un nivel de significación α prefixado, rexeitamos H_0 fronte a H_1 se

$$\frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \leq -z_{\alpha/2} \quad \text{ou} \quad \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \geq z_{\alpha/2}$$

Aquí $z_{\alpha/2}$ denota o punto tal que $P(Z > z_{\alpha/2}) = \alpha/2$ sendo $Z \sim N(0, 1)$.

Contraste unilateral pola dereita. Se queremos determinar se a proporción p é significativamente maior que un valor dado p_0 , o contraste sería

$$\begin{cases} H_0 : p \leq p_0 \\ H_1 : p > p_0 \end{cases}$$

Dados os valores dunha mostra, parece claro que deberíamos rexeitar H_0 se $\hat{p}$ é considerablemente maior que p_0 . Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 fronte a H_1 se

$$\frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \geq z_{\alpha}$$

Contraste unilateral pola esquerda. Se queremos determinar se a proporción p é significativamente menor que un valor dado p_0 , o contraste sería

$$\begin{cases} H_0 : p \geq p_0 \\ H_1 : p < p_0 \end{cases}$$

Dados os valores dunha mostra, parece claro que deberíamos rexeitar H_0 se $\hat{p}$ é considerablemente menor que p_0 . Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 fronte a H_1 se

$$\frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \leq -z_\alpha$$

5.7. Contrastes sobre dúas proporcións

En ocasións estamos interesados en contrastar as proporcións p_1 e p_2 de dúas poboacións. Temos entón dúas mostras:

- Unha mostra formada por n_1 variables independentes da poboación 1.
- Unha mostra formada por n_2 variables independentes da poboación 2.

Supoñemos que as mostras son independentes. Denotamos por x_1 e x_2 o número de éxitos observados en cada mostra, respectivamente. As proporcións mostrais son

$$\hat{p}_1 = \frac{x_1}{n_1}, \quad \hat{p}_2 = \frac{x_2}{n_2}$$

Contraste bilateral. Se queremos saber se podemos asumir que a proporción é a mesma en ambas poboacións, o contraste sería

$$\begin{cases} H_0 : p_1 = p_2 \\ H_1 : p_1 \neq p_2 \end{cases} \quad \text{ou equivalentemente} \quad \begin{cases} H_0 : p_1 - p_2 = 0 \\ H_1 : p_1 - p_2 \neq 0 \end{cases}$$

Fixado un nivel de significación α , rexeitamos H_0 fronte a H_1 se

$$\frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \leq -z_{\alpha/2} \quad \text{ou} \quad \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \geq z_{\alpha/2}$$

onde $\hat{p} = \frac{x_1+x_2}{n_1+n_2}$ é o estimador da proporción común baixo a hipótese nula ($H_0: p_1=p_2$), e $z_{\alpha/2}$ verifica $P(Z > z_{\alpha/2}) = \alpha/2$ con $Z \sim N(0, 1)$.

Contraste unilateral pola dereita. Se queremos determinar se p_1 é maior que p_2 , o contraste sería

$$\left\{ \begin{array}{l} H_0 : p_1 \leq p_2 \\ H_1 : p_1 > p_2 \end{array} \right. \quad \text{ou equivalentemente} \quad \left\{ \begin{array}{l} H_0 : p_1 - p_2 \leq 0 \\ H_1 : p_1 - p_2 > 0 \end{array} \right.$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \geq z_\alpha$$

Contraste unilateral pola esquerda. Se queremos determinar se p_1 é menor que p_2 , o contraste sería

$$\left\{ \begin{array}{l} H_0 : p_1 \geq p_2 \\ H_1 : p_1 < p_2 \end{array} \right. \quad \text{ou equivalentemente} \quad \left\{ \begin{array}{l} H_0 : p_1 - p_2 \geq 0 \\ H_1 : p_1 - p_2 < 0 \end{array} \right.$$

Fixado un nivel de significación α , rexeitamos a hipótese nula H_0 se

$$\frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \leq -z_\alpha$$

6 Introducción á regresión lineal

A regresión é unha das ferramentas fundamentais da estatística para analizar a relación entre variables cuantitativas. En moitas situacións prácticas non só interesa describir unha variable, senón comprender como cambia en función doutras. Por exemplo, poderíamos analizar como inflúe o tamaño dun conxunto de datos de adestramento na precisión dun modelo de aprendizaxe automática, estudar como cambia o tempo de adestramento dun modelo en función do número de parámetros e o número de características empregadas, ou modelar a relación entre o número de interaccións dun usuario nunha plataforma e o tempo que permanece na aplicación.

Os **modelos de regresión** teñen como obxectivo describir e predicir o valor dunha variable numérica (chamada **variable resposta** ou **variable dependente**) a partir dunha ou máis **variables explicativas** (ou **variables independentes**). Estes modelos permiten non só analizar a relación entre as variables, senón tamén realizar predicións para novos datos.

6.1. Regresión lineal simple

Un dos modelos de regresión máis sinxelos e utilizados é a **regresión lineal simple**. Neste caso considérase que a variable resposta Y depende dunha única variable explicativa X , e supóñese que a relación entre ambas pode aproximarse mediante unha recta.

O modelo escríbese como

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

onde β_0 é o **intercepto** da recta, β_1 é a **pendente** que describe como cambia Y cando cambia X , e ε representa o **termo de erro**, que recolle a variabilidade que o modelo non pode explicar.

Na práctica, os parámetros β_0 e β_1 son descoñecidos e deben estimarse a partir dunha mostra, formada por pares de observacións da forma $(x_1, y_1), \dots, (x_n, y_n)$. Para facer a estimación dos parámetros do modelo utilizaremos o método dos mínimos cadrados. As estimacións resultantes adoitan denotarse por $\hat{\beta}_0$ e $\hat{\beta}_1$, e a recta estimada escríbese como

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$$

Esta recta coñécese como **recta de regresión**, e permítenos estimar o valor medio da variable resposta para distintos valores da variable explicativa.

Moitos dos conceptos que veremos neste tema xa foron introducidos no Tema 1 de Estatística Descritiva ao estudar variables bidimensionais. En particular, considerabamos unha poboación na que cada individuo está descrito por un par de características (X, Y) . Na práctica,

non observamos toda a poboación, senón unha mostra de tamaño n , formada por pares de observacións da forma

$$(x_1, y_1), \dots, (x_n, y_n)$$

A partir destes datos podemos analizar a posible relación entre ambas variables mediante ferramentas como o **diagrama de dispersión**, a **covarianza** ou o **coeficiente de correlación lineal**. O diagrama de dispersión permitíanos visualizar a relación entre X e Y , mentres que a covarianza e a correlación proporcionaban medidas numéricas da intensidade e do sentido da relación lineal entre as dúas variables. Recordamos que a covarianza (denotada por s_{xy}) calculábase como:

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

O coeficiente de correlación lineal

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$

toma valores entre -1 e 1 e servía para investigar a relación lineal entre as variables.

- Se r_{xy} é próximo a -1 , temos unha relación inversa entre X e Y , é dicir, cando unha variable toma valores altos, a outra tende a ser baixa.
- Se r_{xy} é próximo a $+1$, temos unha relación directa, de modo que valores altos dunha variable están asociados con valores altos da outra.
- Se r_{xy} é próximo a cero, non existe relación lineal significativa entre as variables.

Cando $r_{xy} = 1$ ou $r_{xy} = -1$, existe dependencia lineal exacta. Se $r_{xy} = 0$, decimos que as variables son incorreladas.

Neste tema imos dar un paso máis: ademais de estudar se existe relación entre as variables, trataremos de **modelar esa relación** mediante modelos de regresión, que permiten describir como cambia unha variable en función doutra e realizar predicións.

6.2. Método dos mínimos cadrados

Dada unha mostra $(x_1, y_1), \dots, (x_n, y_n)$, o obxectivo é determinar os valores dos parámetros descoñecidos β_0 e β_1 (mediante os estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$) de maneira que a recta axuste o mellor posible aos datos observados. Uns bos estimadores deben ser aqueles para os que os **erros de predición** sexan pequenos. Estes erros defínense como a diferenza entre o valor observado e o valor predito polo modelo:

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

O obxectivo da regresión é precisamente atopar os valores de $\hat{\beta}_0$ e $\hat{\beta}_1$ que fagan que estes erros sexan o máis pequenos posible, no sentido de minimizar a súa magnitude global. Aínda que existen moitos métodos de estimación, o máis clásico é o coñecido como **método dos mínimos cadrados**, que consiste en atopar os valores dos parámetros que minimizan a suma dos erros ao cadrado, dados os datos da mostra. É dicir, o criterio consiste en minimizar

$$M(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=1}^n e_i^2 = \frac{1}{n} \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

Os valores dos parámetros obtéñense derivando a función obxectivo e igualando a cero. Desta forma, tense:

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2}$$

e

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Estes valores reciben o nome de **coeficientes de regresión** e presentan boas propiedades estatísticas como estimadores de β_0 e β_1 baixo as hipóteses habituais do modelo, o que xustifica o seu uso na práctica. Obtemos así a ecuación da recta de regresión:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x = \bar{y} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 x = \bar{y} + \hat{\beta}_1 (x - \bar{x}) = \bar{y} + \frac{s_{xy}}{s_x^2} (x - \bar{x})$$

Esta expresión coñécese como **recta de regresión de Y sobre X**, para salientar que se obtén supoñendo que Y é a variable resposta e X a variable explicativa.

Se intercambiamos os papeis de X e Y , obtemos a recta de regresión de X sobre Y , que representada no mesmo sistema de coordenadas será, en xeral, distinta da anterior.

Unha vez estimado o modelo, podemos interpretar o valor da pendente $\hat{\beta}_1$. Se $\hat{\beta}_1 > 0$, a relación entre as variables é positiva: ao aumentar X , tamén tende a aumentar Y . Se $\hat{\beta}_1 < 0$, a relación é negativa: valores maiores de X asóciáanse con valores menores de Y . Ademais da interpretación, o modelo de regresión lineal utilízase con frecuencia para realizar predicións. Dado un valor concreto de X , podemos substituílo na ecuación da recta estimada para obter unha estimación do valor esperado de Y . Non obstante, estas predicións deben interpretarse con cautela, xa que dependen da validez do modelo e da variabilidade inherente aos datos.

Ademais da estimación dos parámetros, a regresión lineal permite realizar contrastes de hipóteses para avaliar a importancia das variables no modelo. En particular, é habitual analizar se existe relación lineal significativa entre as variables ou se, pola contra, a variable explicativa non achega información relevante para explicar a variable resposta.

6.3. Descomposición da variabilidade

Os modelos de regresión pretenden explicar como a variable resposta Y varía en función da variable explicativa X . Deste xeito, parte da variabilidade de Y pode ser explicada pola relación coas variables do modelo, mentres que outra parte se debe a factores non observados ou ao erro aleatorio.

A variabilidade total dos datos mídese mediante a **suma total de cadrados**, que se define como:

$$VT = \sum_{i=1}^n (y_i - \bar{y})^2$$

Esta variabilidade total pode descompoñerse en dúas partes:

- **Variabilidade explicada (VE):** é a parte da variabilidade de Y que o modelo de regresión é capaz de explicar. Mide canto se separan as predicións do modelo $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ da media global $\bar{y}$:

$$VE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- **Variabilidade non explicada (VNE):** representa a parte da variabilidade que o modelo non é capaz de explicar e que se atribúe aos erros de predición. Calcúlase a partir dos residuos:

$$VNE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Deste xeito, a variabilidade total pode expresarse como a suma destas dúas compoñentes:

$$VT = VE + VNE$$

Esta descomposición é fundamental na regresión, xa que permite avaliar ata que punto o modelo é capaz de explicar a variabilidade dos datos.

6.4. Coeficiente de determinación

Unha vez estimados os parámetros do modelo de regresión, xorde a pregunta de se a recta obtida é ou non representativa dos datos. Para responder a isto utilízase o **coeficiente de determinación** (R^2), que mide a proporción da variabilidade da variable resposta que é explicada polo modelo.

Defínese como:

$$R^2 = \frac{VE}{VT} = 1 - \frac{VNE}{VT},$$

onde VT é a variabilidade total, VE a variabilidade explicada polo modelo e VNE a variabilidade non explicada (residual).

O coeficiente R^2 toma valores entre 0 e 1. Canto máis próximo a 1 sexa o seu valor, maior será a capacidade do modelo para explicar a variabilidade dos datos; pola contra, valores próximos a 0 indican que o modelo explica pouca variabilidade.

No caso da regresión lineal simple, o coeficiente de determinación coincide co cadrado do coeficiente de correlación entre a variable explicativa e a variable resposta:

$$R^2 = r_{xy}^2$$

Bibliografía

- Alexander, R. 2023. *Telling Stories with Data: With Applications in R*. Chapman & Hall/CRC Data Science Series. CRC Press. https://rohanalexander.github.io/telling_stories-published/.
- Berrendero, J. R. 2025. *Fundamentos de Estadística*. <https://verso.mat.uam.es/~joser.berrendero/libro-est/>.
- Çetinkaya-Rundel, Mine, and Johanna Hardin. 2024. *Introduction to Modern Statistics (2e)*. OpenIntro. <https://openintrostat.github.io/ims/>.
- Mehrabi, Ninareh, Fred Morstatter, Nripsuta Saxena, Kristina Lerman, and Aram Galstyan. 2021. “A Survey on Bias and Fairness in Machine Learning.” *ACM Comput. Surv.* (New York, NY, USA) 54 (6). <https://doi.org/10.1145/3457607>.
- Ntoutsis, Eirini, Pavlos Fafalios, Ujwal Gadiraju, et al. 2020. “Bias in Data-Driven Artificial Intelligence Systems—An Introductory Survey.” *WIREs Data Mining and Knowledge Discovery* 10 (3): e1356. <https://doi.org/10.1002/widm.1356>.
- Speegle, Darrin, and Bryan Clair. 2024. *Probability, Statistics, and Data: A Fresh Approach Using R*. CRC Press. <https://probstatsdata.com/>.
- Tukey, John W. 1980. “We Need Both Exploratory and Confirmatory.” *The American Statistician* 34 (1): 23–25. <http://www.jstor.org/stable/2682991>.