

Exercicios. Estatística descritiva

1. O ficheiro `spotify.csv` recompila información diversa sobre un subconxunto de cancións dispoñíbles na plataforma, incluíndo para cada tema datos como o artista, a popularidade, o xénero e características musicais específicas. Entre estas características atópanse a enerxía (representa a intensidade da canción), a sonoridade (mide o volume xeral da canción), o modo (1 indica un son máis positivo, e 0 un máis triste), a instrumentalidade (grao no que unha canción está composta principalmente por instrumentos, en lugar de voces), a vivacidade e a duración en minutos. Importa o conxunto de datos en R e gárdao nun obxecto de nome `spotify`.
 1. Cantas cancións aparecen recollidas? De cantos artistas? Cal é o artista con máis cancións no conxunto de datos?
 2. Fai unha análise descritiva do variable xénero musical (`genero`).
 - Que xéneros musicais rexistráronse?
 - Calcula as frecuencias relativas e absolutas correspondentes.
 - Cal é a moda?
 - Fai algunha representación gráfica ilustrativa dos datos.
 3. Fai unha análise descritiva da variable duración da canción (`duracion`).
 - Cal é a duración media das cancións rexistradas? E a duración mediana?
 - Que porcentaxe das cancións rexistradas duran menos de 3 minutos?
 - Fai algunha representación gráfica ilustrativa dos datos.
 - Fai unha gráfica que resuma a duración das cancións dependendo do xénero musical.
 4. Fai unha análise descritiva da variable popularidade da canción (`popularidad`)
 - Cal é a popularidade media das cancións? E por xénero musical?
 - Que xénero presenta máis variabilidade na popularidade das cancións?
 5. Fai unha táboa de continxencia para as variables `artista` e `genero`.
 6. Selecciona as cancións do grupo musical Queen.
 - Cantas cancións aparecen rexistradas? De que xénero musical son? Cal é a popularidade media das cancións de Queen?
 - Fai un boxplot da duración das cancións de Queen e analiza os resultados.
 - Fai unha análise descritiva das características musicais das cancións de Queen?
 - Representa un gráfico de dispersión (nube de puntos) cos datos de sonoridade e enerxía dos temas de Queen. Que observas? Cal é a correlación entre ambas as variables?

2. O nivel de recepción de spam nun servidor pode clasificarse en catro estados: baixo, medio, alto e crítico. Durante o mes de setembro ($n=30$ días), rexistráronse devanditos niveis. Completa a táboa de frecuencias e representa o diagrama de barras correspondente.

Nivel	n_i	f_i	N_i	F_i
Baixo	18			
Medio			25	
Alto				
Crítico	2			

3. Do seguinte conxunto de datos $\{2, 3, 4, 4, 5, 6\}$:
1. Podería ser a media menor que 2?
 2. Calcula a media aritmética, a moda e a mediana.
 3. Calcula a varianza, a desviación típica e o rango muestrais.
 4. Calcula a media dos valores transformados $y_i = 3x_i - 2$.
4. Sexa X a idade nun grupo de traballadores dunha empresa informática. Cales destas afirmacións son posibles?
1. O primeiro cuartil é $Q_1 = 20$ e a mediana é $Me = 18$.
 2. O decil $d_7 = 33$ e o terceiro cuartil $Q_3 = 32$.
 3. O decil $d_8 = 45$ e o percentil $p_{81} = 47$.
 4. O rango é 25 e o rango intercuartílico é 10.
5. Un profesor está a facer aos seus alumnos un exame que ten unha cualificación máxima de 20 puntos. O seu sistema de puntuación é tal que as notas deben ser necesariamente múltiplos de 5. Ao final, unha vez corrixidos os exames, obtén a seguinte distribución de notas:

Nota	f_i
5	0.1
10	0.2
15	0.3
20	0.4

1. Supón que hai 10 alumnos na clase. Podes calcular a media das notas?
2. Supón que hai 20 alumnos na clase. Podes calcular a media das notas?
3. Supón que non sabes cantos alumnos hai na clase. Podes calcular a media das notas?

6. Panasonic e KTS fabrican un tipo de pilas que se utilizan nos BIOS dos computadores. A primeira das marcas garante unha duración media de 1600 días, cunha desviación típica de 200 días, mentres que KTS dános unha media de 1800 días, con desviación típica de 300 días. Se temos dúas pilas de ambas as marcas que duraron 1500 días, cal delas presenta un mellor rendemento relativo? E se tivéssemos dúas pilas que durasen 2000 e 2100 días, respectivamente? (*Aplicación de tipificación de datos*). Que marca ofrece unha menor variación? (*Aplicación do coeficiente de variación*).
7. Podemos empregar modelos estatísticos para construír filtros de correo electrónico spam. Observando certas características dun correo, é posible clasificar algúns correos como spam ou non spam cunha precisión elevada. Unha destas características é o formato do correo, que indica se un correo contén elementos HTML (como texto en negrita) ou é texto plano. A seguinte táboa resume para unha mostra de correos o formato e o seu estado de spam. Calcula a táboa de frecuencias relativas e as distribucións marxinais. Que sería máis útil para alguén que queira clasificar un correo como spam ou regular: as proporcións por fila ou por columna?

	HTML	texto plano
non spam	2568	986
spam	158	209