

Exercicios. Introducción á inferencia estatística e á estimación de parámetros

1. Un servizo de recoñecemento facial sabe que o tempo medio de procesamento dunha imaxe de usuario é de 3100 ms cunha desviación típica de 370 ms.
 1. Calcular a probabilidade de que, nunha mostra de 25 imaxes, o tempo medio estea entre 2950 e 3120 ms.
 2. E se a mostra é de 50 imaxes?
2. M&M's determina a distribución de cores das súas bolitas de chocolate baseándose en preferencias de consumidores. A proporción de bolitas azuis é do 24%, naranxas 20%, verdes 16%, vermellas 13% e marróns 13%.
 1. Nunha mostra aleatoria de 100 M&M's, cal é a proporción esperada de azuis? Cal é a probabilidade de que haxa entre 20% e 25% de bolitas azuis? E máis do 25%?
 2. Recalcula o anterior para mostra de 1000 M&M's.
3. Nunha plataforma de recomendación por IA, a proporción de usuarios que interactúan coas recomendacións é coñecida e igual a 0.4. Se queremos estimar esta proporción a partir dunha mostra de tamaño $n = 100$, cal é a probabilidade aproximada (empregando a aproximación normal) de que a proporción estimada sexa correcta cun erro máximo de $\pm 3\%$? E se a mostra fose de tamaño 200? Poderías calcular estas probabilidades de forma exacta?
4. Un laboratorio desenvolve un sensor de concentración de glicosa no sangue para dispositivos wearables. O erro de medición ten desviación típica de 2.4 mg/l. A continuación amósase unha mostra de erros de medición (mg/l). Estima a partir dos datos o erro medio e constrúe un intervalo de confianza ao 99% supoñendo normalidade.

0.51	-2.75	1.83	2.97	-0.82	2.32	-0.69	-2.19
1.47	-1.54	0.30	-1.25	0.18	-0.21	-1.95	-3.67

5. Unha empresa fabrica sensores de distancia para robots domésticos. Queremos estimar o diámetro medio dun sensor. O proceso de produción é normal cunha desviación típica de 0.1 cm. Nunha mostra de 25 sensores, o diámetro medio foi de 3.5 cm. Calcula un intervalo de confianza ao 95% para o diámetro medio.
6. Un estudo avalía a calidade das respostas xeradas por dúas LLMs (LLM1 e LLM2) nun conxunto de preguntas de comprensión de texto. De 307 preguntas feitas á LLM1, 132 foron consideradas respondidas de forma incorrecta. De 75 preguntas feitas á LLM2, 30 foron consideradas respondidas de forma incorrecta.
 1. Estima a proporción de respostas incorrectas para cada LLM. Calcula o intervalo de confianza do 95% para a proporción de erros de LLM1. Calcula tamén o intervalo de confianza ao 90%.

2. Constrúe un intervalo de confianza ao 90% para a diferenza de proporcións de respostas incorrectas entre LLM1 e LLM2. Interpreta os resultados.
7. Unha empresa quere estimar o tempo medio de resposta do seu sistema. Sábese que o tempo de resposta é normal e que a desviación típica da poboación é $\sigma = 0.4$ ms.
 1. Calcula a marxe de erro dun IC do 95% para μ cun tamaño de mostra $n = 25$.
 2. Calcula o tamaño da mostra necesario para que a lonxitude do IC sexa como máximo $L = 0.2$.
 3. Estuda como cambia a marxe de erro ao duplicar o tamaño da mostra. Estuda como cambia a marxe de erro ao aumentar o nivel de confianza ao 99%
8. O ficheiro StudentPerformanceFactors.csv recolle datos dun estudo sobre estudantes que inclúe factores académicos, de estilo de vida e socioeconómicos, así como rendemento en exames. Entre as variables recollidas atópanse: horas de estudo, asistencia ás clases, horas de sono, motivación, participación en sesións de titoría, implicación dos pais, tipo de escola e outras características ambientais. Considera os datos da variable Hours_Studied para os estudantes que desenvolven actividades extracurriculares (Extracurricular_Activities=="Yes"). Representa un histograma dos datos para analizar se é razoable supoñer que dita variable segue unha distribución normal. En caso afirmativo, calcula un intervalo de confianza para a media da variable Hours_Studied e un intervalo de confianza para a varianza da variable Hours_Studied. Compara a media de Hours_Studied entre estudantes que participan en actividades extracurriculares e os que non (Extracurricular_Activities=="No"). Calcula un intervalo de confianza para a diferenza de medias e un intervalo de confianza para o cociente de varianzas e interpreta os resultados.
9. O ficheiro heart_rate_data.csv contén datos simulados de 500 persoas, incluíndo a súa frecuencia cardíaca, xunto con variables adicionais como idade, horas de sono por noite e frecuencia de exercicio. As columnas Resting_Heart_Rate_Before e Resting_Heart_Rate_After conteñen os datos de frecuencia cardíaca en repouso antes e despois dun programa de exercicio de 6 semanas.
 1. Representa un histograma da variable Resting_Heart_Rate_Before e outro da variable Resting_Heart_Rate_After para analizar a súa distribución.
 2. Representa un boxplot que compare a frecuencia cardíaca en repouso antes e despois do programa de exercicio.
 3. Calcula un intervalo de confianza do 95% para a diferenza media da frecuencia cardíaca en repouso antes do programa respecto a despois do programa. Interpreta os resultados e comenta se o programa de exercicio tivo un efecto significativo sobre a frecuencia cardíaca en repouso.